

Publicado en su forma final editada como:

Neurociencia Nacional 2020 01 de septiembre; 23(9): 1138-1149. doi:10.1038/s41593-020-0671-1.

Dinámica de tipo cortical en circuitos recurrentes optimizados para la inferencia probabilística basada en muestreo

Rodrigo Echeveste^{1,2,@}, Laurence Aitchison¹, Guillaume Hennequin^{#1}, Máté Lengyel^{#1,3}

¹Laboratorio de Aprendizaje Computacional y Biológico, Departamento de Ingeniería, Universidad de Cambridge, Cambridge, Reino Unido

²Instituto de Investigación en Señales, Sistemas e Inteligencia Computacional sinc(i) (FICH-UNL/ CONICET), Santa Fe, Argentina

³Centro de Computación Cognitiva, Departamento de Ciencias Cognitivas, Centroeuropa Universidad de Budapest, Hungría

Estos autores contribuyeron igualmente a este trabajo.

Abstracto

Las cortezas sensoriales presentan un conjunto de características dinámicas omnipresentes, como la variabilidad continua del ruido, los sobreimpulsos transitorios y las oscilaciones, que hasta ahora han escapado a una explicación teórica común y fundamentada. Desarrollamos un modelo unificador para estos fenómenos mediante el entrenamiento de un modelo recurrente de circuito neuronal excitatorio-inhibitorio de una hipercolumna cortical visual para realizar inferencia probabilística basada en muestreo. La red optimizada mostró varias propiedades biológicas clave, como la normalización divisiva, así como la variabilidad del ruido modulada por el estímulo, transitorios dominados por la inhibición al inicio del estímulo y fuertes oscilaciones gamma. Estas características dinámicas desempeñaron un papel funcional distintivo en la aceleración de las inferencias y permitieron realizar predicciones que confirmamos en nuevos análisis de grabaciones de monos despiertos. Nuestros resultados sugieren que los motivos básicos de la dinámica cortical surgen como consecuencia de la implementación eficiente de la misma función computacional (inferencia rápida basada en muestreo) y predicen otras propiedades de estos motivos que podrán evaluarse en futuros experimentos.

Los usuarios pueden ver, imprimir, copiar y descargar texto y extraer datos del contenido de dichos documentos, con fines de investigación académica, siempre sujetos a las Condiciones de uso completas: http://www.nature.com/authors/editorial_policies/license.html#terms

@autor correspondiente: recheveste@sinc.unl.edu.ar.

Contribuciones de los

autores: RE, GH y ML diseñaron el estudio. RE y GH desarrollaron el enfoque de optimización, RE realizó todas las simulaciones numéricas, RE y GH analizaron los datos experimentales, todos los autores realizaron derivaciones analíticas, REGH y ML interpretaron los resultados y redactaron el artículo, con comentarios de LA.

Declaración de conflictos de intereses

Los autores declaran no tener conflictos de intereses.

Resumen del informe. Para más información sobre el diseño de la investigación, consulte el Resumen del informe sobre ciencias biológicas, enlazado a este artículo.

Aleatorización. No se recopilaron nuevos datos experimentales para este trabajo.

Cegamiento. Dado que otros laboratorios habían recopilado datos mucho antes de nuestro estudio, estos no conocieron los objetivos del mismo. El análisis de datos no se realizó sin conocer las condiciones de los experimentos.

Exclusión de datos. En la Fig. 7e, solo se seleccionaron las celdas con un índice de ajuste superior a 0,75. No se excluyó ningún otro dato del texto principal. En la Fig. 9 de Datos Extendidos, se repitió el mismo análisis de la Fig. 7e, excluyendo los valores atípicos para comprobar la robustez.

La dinámica de las cortezas sensoriales exhibe un conjunto de características ubicuas en todas las especies y condiciones experimentales. Las respuestas varían con el tiempo y entre ensayos, incluso ante el mismo estímulo estático¹, y estas variaciones intrínsecas presentan componentes tanto sistemáticos como aparentemente aleatorios (la denominada variabilidad del ruido). Los patrones sistemáticos más prominentes de actividad neuronal son los transitorios intensos, dominados por la inhibición, al inicio del estímulo² (o, equivalentemente, una fuerte adaptación tras el inicio del estímulo) y las oscilaciones poblacionales dependientes del estímulo en la banda gamma (20-80 Hz)^{3,4}. El grado y el patrón de la variabilidad del ruido también dependen del estímulo: la variabilidad se atenúa al inicio del estímulo¹ disminuyendo gradualmente con el contraste del estímulo en la corteza visual primaria (V1)⁵ y se modula además por el contenido del estímulo, por ejemplo, la orientación o dirección de las rejillas móviles de las células en V1 o en el área visual temporal media (MT)⁶.

Si bien los mecanismos que dan lugar a estos fenómenos dinámicos se comprenden cada vez mejor^{6,7}, su importancia funcional sigue siendo en gran medida desconocida y controvertida.

Por ejemplo, se ha sugerido que las oscilaciones gamma corticales son un sustrato para la unión de diferentes fuentes de información sobre una característica (conocido como unión por sincronía⁸), para mediar en el enrutamiento de la información (comunicación por sincronía⁹) o para habilitar un código temporal de picos relativos a la fase de oscilación¹⁰. Se ha propuesto que los sobreimpulsos transitorios transporten señales de novedad o error de predicción¹¹. Se ha argumentado que la variabilidad del ruido, cuando se considera útil en absoluto, lleva firmas de cálculos probabilísticos^{5,12,13}. Sin embargo, no está claro si estas explicaciones pueden reconciliarse, ya que cada una de ellas solo da cuenta de aspectos selectos de los datos y ha sido cuestionada por explicaciones alternativas^{3,14–16}.

Aquí, presentamos un modelo unificador en el que todos estos fenómenos dinámicos emergen como consecuencia de la implementación eficiente de la misma función computacional: inferencia probabilística. La inferencia probabilística proporciona una solución basada en principios para formar perceptos fusionando información parcial y ruidosa de múltiples fuentes (incluyendo múltiples señales sensoriales, modalidades y formas de memoria)¹⁷. Formalmente, esta fusión resulta en una distribución posterior que expresa la probabilidad de que las características relevantes en el entorno que no son directamente accesibles al cerebro (por ejemplo, las formas tridimensionales de los objetos) puedan tomar cualquier configuración particular dada la información que está directamente disponible para nuestros sentidos (por ejemplo, fotones absorbidos en la retina). La evidencia conductual en varios dominios, incluyendo el desempeño casi óptimo en integración multisensorial, toma de decisiones, control motor y aprendizaje sugiere que el cerebro representa distribuciones posteriores al menos aproximadamente¹⁸.

También se han propuesto varias maneras de implementar estas representaciones probabilísticas en las respuestas neuronales de las poblaciones corticales sensoriales^{5,12,19}. Si bien estos modelos explicaron con éxito aspectos importantes de las distribuciones de las respuestas (p. ej., curvas de ajuste, factores de Fano, correlaciones de ruido), hasta el momento no han logrado explicar la riqueza intrínseca de las áreas corticales sensoriales.

Para reunir la dinámica (patrones de actividad de tipo cortical) y la función (que representa distribuciones posteriores) de una manera basada en principios, optimizamos una red neuronal recurrente restringida biológicamente para realizar inferencia probabilística basada en muestreo^{5,13,20,21}.

Específicamente, el objetivo de la red era producir dinámicamente respuestas cuya distribución coincidiera con la distribución posterior del observador ideal bayesiano para cada estímulo.

El circuito neuronal optimizado exhibió una serie de características dinámicas y computacionales atractivas.

Características. Computacionalmente, tras el entrenamiento con un conjunto reducido de estímulos, la red exhibió fuertes formas de generalización al producir distribuciones de respuesta casi óptimas a nuevas entradas que requerían respuestas cualitativamente diferentes. Además, la red descubrió dinámicas de desequilibrio, una estrategia empleada actualmente por algoritmos modernos de aprendizaje automático para producir muestras que se vuelven estadísticamente independientes en escalas de tiempo cortas²².

Biológicamente, el circuito optimizado logró una normalización divisiva de sus salidas y mostró transitorios marcados al inicio del estímulo, así como fuertes oscilaciones gamma. Tanto la magnitud de los transitorios como la frecuencia de las oscilaciones gamma escalaban con el contraste del estímulo. Fundamentalmente, estos fenómenos dinámicos no surgieron en redes de control optimizadas para objetivos relacionados que no requerían muestreo. Análisis posteriores de transitorios y oscilaciones en la red optimizada revelaron roles funcionales distintos para ellos. Estos análisis predijeron nuevas propiedades de la dinámica cortical: los transitorios de inicio deberían estar sintonizados con los estímulos, lo cual confirmamos mediante nuevos análisis de grabaciones V1 publicadas en el mono despierto²³. Además, nuestro modelo también realizó predicciones específicas sobre el ajuste del estímulo de los retardos excitatorios-inhibitorios y la distribución de la potencia gamma en los diferentes modos de la dinámica de la red. Ambos pueden probarse fácilmente en futuros experimentos.

En resumen, construimos la primera red neuronal recurrente con restricciones biológicas que realiza inferencia probabilística basada en muestreo, la cual explica una gran cantidad de observaciones electrofisiológicas en las cortezas sensoriales. Nuestro modelo proporciona, por lo tanto, una explicación teórica unificadora de los motivos básicos de la dinámica cortical sensorial.

Resultados

Optimización de un circuito neuronal recurrente para inferencia probabilística

Para estudiar la dinámica de circuitos neuronales implementando inferencia probabilística, utilizamos una novedosa combinación de dos enfoques computacionales bien establecidos, aunque hasta ahora no relacionados: observadores ideales bayesianos y el entrenamiento de redes neuronales recurrentes (Métodos). Primero, utilizamos un modelo de observador ideal bayesiano para especificar el objetivo computacional de la inferencia perceptual en una tarea visual simplificada. Realizar inferencia requiere un modelo interno que encapsule las suposiciones sobre cómo las entradas a procesar han sido generadas por el entorno. Para esto, adoptamos el modelo de mezcla de escala gaussiana (GSM) (Fig. 1a), un modelo generativo que ha demostrado capturar las estadísticas de parches de imagen naturales²⁴.

Por el contrario, se ha demostrado que la inferencia bajo el modelo GSM da cuenta de datos conductuales y neuronales (para respuestas estacionarias) en la percepción visual^{5,25,26}. El modelo GSM asume que un parche de imagen se genera como una combinación lineal de características visuales orientadas similares a filtros de Gabor ("campos proyectivos"), cada una presente con una intensidad diferente (las variables latentes del modelo). El parche de imagen se escala adicionalmente mediante una única variable global de "contraste". Aquí, nos centramos en modelar una única hipercolumna, eligiendo que los campos proyectivos de las variables latentes GSM solo difieran en su orientación, de modo que formaran una topología de anillo (Fig. 1a, Datos Extendidos Fig. 1a-b). El observador ideal se obtuvo mediante una inversión bayesiana de este modelo. Por lo tanto, para cada parche de imagen tomado como entrada sensorial, el observador ideal produjo una distribución posterior de alta dimensión que cuantifica la probabilidad de que cualquier combinación conjunta particular de intensidades de características pudiera haber generado la entrada (Fig. 1b).

En segundo lugar, para modelar la dinámica de los circuitos corticales, utilizamos un modelo canónico de red neuronal recurrente estocástica basado en la tasa, la variante estocástica de la red supralineal estabilizada (SSN)^{6,27}. La red se limitó a exhibir algunas características biológicas básicas previamente demostradas como fundamentales para la dinámica cortical: poblaciones de neuronas excitatorias (E) e inhibitorias (I) separadas pero interconectadas (Fig. 1c), funciones de entrada/salida supralineales (expansivas)^{27,28}, y ruido de proceso finito e independiente del estímulo^{6,29} que incorpora formas intrínsecas y extrínsecas de variabilidad neuronal.

Entrenamos esta red para realizar inferencia basada en muestreo bajo el GSM. Para ello, asumimos una correlación biunívoca entre variables latentes y células excitadoras, de modo que la respuesta (potencial de membrana) de cada célula E representara la intensidad de una característica diferente en el modelo GSM. Las neuronas inhibitorias se trataron como unidades auxiliares, no restringidas explícitamente por el objetivo computacional. La red se optimizó para producir distribuciones de actividades neuronales excitadoras que coincidieran con las posteriores calculadas por el observador ideal basado en GSM hasta estadísticas de segundo orden. Para cada estímulo en un pequeño conjunto de entrenamiento, la red debía utilizar su dinámica estocástica para visitar diferentes partes del espacio de estados a lo largo del tiempo con una frecuencia proporcional a la distribución posterior correspondiente al mismo estímulo (Fig. 1d). Fundamentalmente, dado que el ruido de proceso en la red era independiente del estímulo, la red tuvo que utilizar su dinámica recurrente para moldear esta variabilidad adecuadamente y así coincidir con las posteriores objetivo para cada entrada. El objetivo de entrenamiento también incluyó términos que fomentaban la dinámica de circuitos rápidos. En resumen, la red tenía que generar fluctuaciones rápidas con los patrones correctos dependientes del estímulo de la media y la covarianza entre ensayos.

Optimizar nuestra red fue un desafío porque modular la variabilidad de la respuesta (para que coincidiera con las covarianzas posteriores dependientes del estímulo del modelo de observador ideal) requiere interacciones recurrentes fuertes y no lineales, pero las redes de neuronas excitatorias fuertemente conectadas, especialmente con funciones de entrada/salida supralineales, son propensas a volverse inestables^{6,30}. En tales redes, no es trivial encontrar regímenes de parámetros en los que se preserve la estabilidad y, por lo tanto, la optimización pueda proceder⁶. Por lo tanto, recurrimos a una parametrización de "anillo" reducida (hipercolumna) en la que la fuerza de conexión recurrente entre dos células cualesquiera (y la covariabilidad de su ruido de proceso) solo dependía de la distancia angular entre sus estímulos preferidos y sus respectivos tipos de células (E o I; Datos extendidos Fig. 1d). Los campos receptivos de alimentación directa de las células fueron fijos e idénticos a los campos proyectivos de las variables latentes correspondientes del GSM estructurado en anillo (Datos extendidos Fig. 1a).

Inferencia y generalización en la red optimizada

De acuerdo con los registros neuronales, la actividad en la red optimizada fue muy variable a lo largo del tiempo y de los ensayos, tanto para estímulos de bajo contraste (Fig. 2a, arriba) como de alto contraste (Fig. 2a, abajo). Fundamentalmente, las distribuciones de las respuestas neuronales en los cinco estímulos de entrenamiento (el mismo parche de imagen con cinco niveles de contraste diferentes; Fig. 2b, izquierda) coincidieron estrechamente con las posteriores GSM correspondientes (Fig. 2b-d, comparar rojo con verde). Específicamente, la actividad media de las neuronas aumentó, mientras que la variabilidad de sus respuestas disminuyó con el contraste, así como con la coincidencia entre la orientación del estímulo y su orientación preferida. Esto fue consistente con

El comportamiento de los momentos del GSM posterior (Fig. 2c y círculos en la Fig. 3a). Por lo tanto, la red se había entrenado correctamente para realizar inferencia basada en muestreo sobre estos estímulos.

También evaluamos la capacidad de la red para representar las distribuciones posteriores adecuadas para estímulos novedosos. En primer lugar, confirmamos que la media y la variabilidad de las respuestas de la red se interpolaban uniformemente entre los momentos objetivo correspondientes para niveles de contraste intermedios, siguiendo de cerca el comportamiento de la distribución posterior del GSM (Fig. 3a, curvas sólidas entre círculos). A continuación, presentamos a la red 500 parches de imagen completamente nuevos, generados aleatoriamente a partir del GSM (Datos Extendidos, Fig. 1c). En general, tanto las medias (Fig. 3b, arriba) como las covarianzas de las respuestas de la red (Fig. 3b, abajo) coincidieron con las de las distribuciones posteriores objetivo. Esta correspondencia fue igualmente buena para los estímulos de prueba (Fig. 3b, naranja) y para los estímulos de entrenamiento (Fig. 3b, lavanda). Fundamentalmente, mientras que las entradas del conjunto de entrenamiento incluyeron una sola orientación dominante, muchos estímulos de prueba tuvieron una estructura más compleja, con más de una orientación dominante (Fig. 3c, primera columna). En consecuencia, los posteriores GSM correspondientes que la red debía emparejar se volvieron cualitativamente diferentes. Específicamente, tanto los perfiles de actividad media en la población (Fig. 3c, segunda columna) como los componentes principales (CP) de las covarianzas de ruido (Fig. 3c, columnas restantes) se volvieron multimodales y altamente dependientes del estímulo (Fig. 3c, verde; comparar entre filas). La red fue capaz de emparejar los posteriores GSM requeridos con alta precisión incluso en estos casos desafiantes (Fig. 3c, rojo). De este modo, la red optimizada realizó una inferencia bayesiana aproximada sobre una amplia gama de estímulos tomando siempre como muestra (aproximadamente) la distribución posterior de alta dimensión apropiada y dependiente del estímulo del observador ideal.

La red optimizada realiza un muestreo rápido

Bajo la inferencia basada en muestreo, el tiempo que toma representar con precisión una distribución posterior mediante la recolección de muestras sucesivas es directamente proporcional a la escala de tiempo en la que estas muestras están correlacionadas³¹. En nuestra red optimizada, la variabilidad del ruido generó nuevas muestras independientes cada pocas decenas de milisegundos en todos los niveles de contraste. Esto fue evidente en la rápida caída de las autocorrelaciones de respuesta (Fig. 4a, curvas coloreadas), similar a la observada en las cortezas sensoriales^{13,32}. De hecho, nuestra red fue incluso más rápida que una red desconectada con las mismas constantes de tiempo de membrana y entrada (Fig. 4a, curva discontinua), y cerca del límite teórico de una red de neuronas infinitamente rápidas en la que la velocidad de muestreo está limitada únicamente por la constante de tiempo de entrada (Fig. 4a, curva punteada).

Para comprender cómo la red optimizada logró un muestreo rápido, comparamos su dinámica con un algoritmo conocido como muestreo de Langevin, una forma de recorrido aleatorio dirigido (Métodos). El muestreo mediante dinámica de Langevin resultó ser una comparación relevante para nuestra red por dos razones. En primer lugar, el muestreo de Langevin es un algoritmo popular y de propósito general en aprendizaje automático, útil para evaluar el rendimiento de nuestra red. En segundo lugar, trabajos previos sugirieron que el muestreo en redes neuronales recurrentes estocásticas (sin respetar el principio de Dale) podría implementarse mediante dinámicas similares a las de Langevin^{33–35}.

Descubrimos que, para cada entrada, la dinámica de Langevin era consistentemente un orden de magnitud más lenta que nuestra red (Fig. 4a, curvas grises). Se sabe que la lentitud de la dinámica de Langevin se debe a una de sus características críticas: la dinámica reversible en el tiempo, es decir, que cualquier serie temporal de respuestas es tan probable como su contraparte invertida en el tiempo³⁶. Esto fue, de hecho.

Esto se refleja en correlogramas cruzados con simetría temporal (Fig. 4b, arriba). Por el contrario, nuestra red optimizada mostró una marcada desviación de la reversibilidad temporal, como lo evidencian los fuertes componentes asimétricos en sus correlogramas cruzados (Fig. 4b, abajo). Esta irreversibilidad dinámica implicó secuencialidad en la activación de pares específicos de neuronas. En particular, observamos que las células I típicamente presentaban un retraso con respecto a las células E. Además, para cualquier célula, su entrada inhibitoria total tendía a presentar un retraso con respecto a su entrada excitatoria total (Fig. 4c), en consonancia con la electrofisiología conocida³⁷. Curiosamente, este retraso fue menor para las células más fuertemente impulsadas por el estímulo, y esta modulación se intensificó al aumentar el contraste. Estos resultados constituyen predicciones comprobables de nuestro modelo.

Dinámica de tipo cortical en el circuito optimizado

Tras establecer que nuestra red representaba distribuciones posteriores mediante muestreo, comparamos sus respuestas con las propiedades fisiológicas conocidas de V1. En primer lugar, las tasas de activación del modelo presentaron un rango dinámico fisiológicamente realista y se ajustaron a la orientación del estímulo, de forma similar a las neuronas en V1 de macaco (Fig. 5a, izquierda-centro; Ref. 6, análisis de los datos registrados por la Ref. 23). También calculamos las estadísticas del recuento de picos en la red a partir de las tasas de activación, asumiendo un proceso de generación de picos doblemente estocástico (Métodos). La atenuación de la variabilidad del potencial de membrana al aumentar el contraste (Fig. 2d, abajo) dio lugar a una atenuación de la variabilidad del recuento de picos (cuantificada por el factor Fano), más intensa en la orientación preferida de la célula (Fig. 5b, centro). Estos efectos coincidieron cualitativamente con los datos de V1, pero fueron algo más débiles (Fig. 5b, izquierda). Además, las respuestas estacionarias en la red mostraron claras señales de normalización divisiva (Datos Extendidos, Fig. 2a-b)³⁸. Todos estos resultados eran esperados para una red cuyas distribuciones de respuesta del potencial de membrana estacionario representan posteriores GSM5.

Aunque nuestro procedimiento de optimización solo restringió las distribuciones de respuesta estacionarias de la red, sin prescribir ninguna dinámica específica, observamos que la red optimizada exhibió una dinámica realista, similar a la cortical. Específicamente, surgieron fuertes oscilaciones gamma, con una frecuencia pico que aumentaba con el contraste, en consonancia con los registros V1 en el mono despierto^{3,4} (Fig. 5c, izquierda-centro). Además, la fijación selectiva de la población E o I eliminó las oscilaciones gamma (o la estabilidad por completo) (Datos Extendidos, Fig. 2c-d), lo que sugiere que las oscilaciones gamma surgieron de interacciones dinámicas entre las células E e I (mecanismo «PING»¹⁶). La red también mostró fuertes respuestas transitorias, de modo que las tasas promedio de la población presentaron sobreimpulsos marcados dependientes del contraste al inicio del estímulo, en consonancia con los registros en V1³

(Fig. 5d, centro-izquierda). Finalmente, utilizando una aproximación basada en la conductancia de nuestro modelo basado en la corriente (Métodos), observamos que la inhibición predominó transitoriamente sobre la excitación durante la presentación del estímulo, como en V1 del ratón despierto² (Fig. 5e, centro-izquierda).

Las redes de control no muestran una dinámica similar a la cortical

A continuación, buscamos determinar si estas propiedades dinámicas surgieron simplemente debido a las restricciones biológicas y arquitectónicas impuestas a nuestra red, o específicamente debido a la optimización para la inferencia basada en muestreo. Para ello, utilizamos una serie de redes de control en las que se analizaron parámetros celulares individuales (constantes de tiempo y no linealidades de la tasa de disparo), la red general

La arquitectura y los campos receptivos eran idénticos a los utilizados en la red original. Así pues, estas redes sólo se diferenciaban en el objetivo para el que estaban optimizadas.

En primer lugar, confirmamos que la dinámica característica de la red originalmente optimizada no emergió en redes parametrizadas aleatoriamente sin optimización, sino que emergió robustamente tras la optimización a partir de diferentes condiciones iniciales aleatorias (Figs. 3 y 4 de Datos Extendidos). A continuación, optimizamos una red de control que difería de la red original en un único aspecto crítico: solo se requería que coincidiera con las medias de las distribuciones posteriores, pero no con las varianzas ni las covarianzas. A pesar de las claras modulaciones dependientes del estímulo en las respuestas medias (como se requiere en el entrenamiento; Fig. 5a, derecha), esta red exhibió modulaciones mínimas tanto de la variabilidad del potencial de membrana (Figs. 5a-g de Datos Extendidos) como de los factores de Fano (Fig. 5b, derecha; Fig. 6 de Datos Extendidos). Por lo tanto, las modulaciones de la variabilidad de la respuesta observadas en la red original, que son un sello distintivo de la inferencia basada en muestreo⁵, no estaban simplemente un subproducto de la dinámica no lineal E-I. Además, ni oscilaciones gamma ni transitorios marcados dominados por inhibición emergieron en la red de control (Fig. 5c-e, derecha). De hecho, igualar tanto medias como varianzas, pero no covarianzas (necesario para una inferencia completa), aún eliminó estas características dinámicas (Datos Extendidos Fig. 5h-n y 6). Finalmente, las oscilaciones también estuvieron ausentes en otra red de control específicamente optimizada para modular sus tasas de disparo promedio como antes, mientras mantenía sus factores Fano constantes (Datos Extendidos Figs. 6 y 7), como sería requerido por otras representaciones probabilísticas no basadas en muestreo¹².

Estos resultados sugieren que las características dinámicas observadas en la red original surgieron como consecuencia del cálculo específico para el cual fue optimizada. Por el contrario, entrenar la red con la función de costo original, pero sin aplicar el principio de Dale, resultó en un rendimiento considerablemente inferior y en la ausencia de oscilaciones y transitorios (Figuras 4, 6 y 8 de Datos Extendidos). Por lo tanto, lograr un rendimiento de muestreo competente y exhibir una dinámica realista parecían estar nuevamente acoplados.

Las oscilaciones mejoran el tiempo de mezcla.

Para estudiar los posibles beneficios funcionales de las oscilaciones, lo ideal sería "eliminarlas" de la red dejando intactas todas las demás características de la dinámica.

La dinámica compleja y de alta dimensión de nuestra red hizo que esto fuera inviable.

Por lo tanto, primero estudiamos la respuesta de una sola neurona para comprender analíticamente el papel general de las oscilaciones en el muestreo (Fig. 6a-b). Posteriormente, generalizamos este análisis a las oscilaciones en los patrones de actividad de toda la red, en lugar de a neuronas individuales, lo que nos permitió comprender mejor la dinámica de alta dimensión de toda la red (Fig. 6c-d).

Suponiendo que la respuesta de una neurona es estadísticamente estacionaria y se distribuye aproximadamente de forma normal, esta se caracteriza completamente por su media, varianza y autocorrelograma. Mientras esta neurona forme parte de una red optimizada para muestreo, la media y la varianza de su respuesta deberán coincidir con las prescritas por la distribución objetivo muestreada por la red (Fig. 2b-d). Aunque el autocorrelograma no está limitado por los momentos objetivo, contribuye de forma crucial al rendimiento de la red. Específicamente, se puede demostrar matemáticamente que el área total bajo el autocorrelograma escala directamente el «tiempo de mezcla»: el tiempo que tarda la dinámica en representar la distribución objetivo con una precisión dada.

(Nota de Matemáticas Suplementaria). Por lo tanto, para comprender el papel específico de las oscilaciones, comparamos respuestas neuronales idealizadas (estacionarias y con distribución normal), construidas para tener la misma media y varianza que las respuestas de nuestra red, pero con diferentes funciones de autocorrelación (Métodos).

Comparamos autocorrelogramas de respuesta con diferentes grados de oscilación (Fig. 6a, azul, naranja, rojo), pero con la misma envolvente que la de la red completa (Fig. 6a, recuadro, línea punteada negra; véase también la Fig. 4). Estas oscilaciones redujeron sustancialmente el área bajo el autocorrelograma (Fig. 6a, recuadro) y, por lo tanto, aceleraron la convergencia de la distribución empírica de respuestas a la distribución objetivo (Fig. 6b; Nota Matemática Suplementaria).

Es importante destacar que las oscilaciones solo reducirán el área bajo el autocorrelograma si al menos un ciclo de oscilación se encuentra bajo la envolvente, es decir, si el período de oscilación es suficientemente corto que la anchura de la envolvente (aproximadamente 35 ms). Esto implica frecuencias de oscilación superiores a 30 Hz, tal como se observa en la red optimizada (Fig. 5c, centro).

A continuación, estudiamos la organización de las oscilaciones gamma en las respuestas multidimensionales de la red completa. Pudimos demostrar que la velocidad de muestreo máxima se alcanza específicamente cuando una menor varianza de respuesta se asocia con una mayor frecuencia de oscilación (Nota Matemática Suplementaria). A su vez, como se mostró anteriormente, la variabilidad se atenúa al aumentar el contraste, tanto en nuestra red como en la corteza (Fig. 2b-c, Fig. 3a, Fig. 5b). Esto explica por qué la frecuencia de las oscilaciones gamma aumentó con el contraste en nuestra red tras la optimización. Estos resultados sugieren que las oscilaciones gamma moduladas por contraste observadas en la corteza ^{3,4} podrían reflejar una estrategia de muestreo optimizada para la velocidad (Fig. 5c).

Nuestros análisis matemáticos también predijeron que las oscilaciones en una red de muestreo eficiente deberían expresarse predominantemente donde más importan: en los patrones de actividad de toda la red (dependientes del estímulo), que capturan la mayor parte de la variabilidad general de la respuesta. Es decir, para cada estímulo, esperábamos las oscilaciones más intensas a lo largo de los CP superiores de la covarianza estacionaria correspondiente (Nota Matemática Suplementaria). Esto fue evidente en los espectros de potencia de nuestra red asociados con los 10 CP superiores (Fig. 6c) y en los autocorrelogramas correspondientes, que incluso mostraron lóbulos negativos (Fig. 6c, recuadro).

Específicamente, se observó una relación positiva entre la oscilación a lo largo de PC sucesivos y la fracción de varianza explicada. Esto significó que la red osciló más en las direcciones donde sus respuestas presentaron la mayor varianza (Fig. 6d). (Cabe destacar que nuestra medida de oscilación se basó en autocorrelogramas y, por lo tanto, no dependió de la varianza de la respuesta; Métodos). En resumen, la red utilizó ^a a priori dinámicas temporales no triviales, en forma de oscilaciones gamma dependientes del contraste y selectivas de patrones, para garantizar que incluso segmentos cortos de su actividad fueran suficientemente representativos de la distribución posterior que representaba para cada estímulo.

Los transitorios admiten la inferencia continua

Los resultados anteriores mostraron que las oscilaciones aumentan la velocidad de mezcla en el régimen estacionario, es decir, una vez que las respuestas de la red se han vuelto representativas de la distribución objetivo. Como complemento a esto, descubrimos que los transitorios en nuestra red mitigan la otra restricción temporal principal del muestreo: el tiempo de "acondicionamiento" que tardan las respuestas en volverse representativas en primer lugar³¹. Observamos que, de acuerdo con los datos experimentales, durante

Tras el inicio del estímulo, las respuestas neuronales tendían a sobrepasar los niveles de respuesta estacionarios correspondientes (Fig. 5d, Fig. 7a). Se podría esperar, ingenuamente, que estos transitorios fueran perjudiciales para la representación de una distribución, ya que se desvían claramente del objetivo (representado por las respuestas de estado estacionario). Sin embargo, en un entorno realista con un entorno cambiante, las distribuciones deben representarse continuamente, sin esperar a que el sistema alcance el estado estacionario.

Para comprender el papel de los transitorios en la inferencia continua, consideramos cómo un decodificador móvil de respuestas neuronales durante una ventana de tiempo de seguimiento finita se aproximaba al objetivo. Al igual que con las oscilaciones, realizamos este análisis en dos pasos. Primero, para aislar los posibles beneficios funcionales de los transitorios, consideramos una vez más la respuesta de una sola neurona idealizada que forma parte de una red optimizada para muestreo (Métodos). Para esta neurona idealizada, fijamos el autocorrelograma (controlando así las oscilaciones), así como las medias y varianzas del estado estacionario antes y después del inicio del estímulo, a las de una neurona real representativa en nuestra red (Datos extendidos, Fig. 9a). Luego comparamos tres formas en que esta neurona podría transitar entre estos dos estados estacionarios (Fig. 7a): 1. como un límite superior del rendimiento, cambiando instantáneamente entre los dos estados estacionarios (Fig. 7a, línea discontinua gris); 2. acercándose exponencialmente al nuevo estado estable con la constante de tiempo característica de las celdas en la red, por lo que carecen de sobreimpulsos (Fig. 7a, línea discontinua negra); y 3. sufriendo sobreimpulsos como se ve en nuestra red optimizada (Fig. 7a, roja).

Descubrimos que los sobreimpulsos se comportaron cerca del límite superior, proporcionado por la conmutación instantánea. En particular, generaron muestras que permitieron una estimación sustancialmente más precisa de la media objetivo que la proporcionada al acercarse al nuevo estado estacionario exponencialmente sin sobreimpulsos (Fig. 7a-b). (Estos resultados se extendieron cualitativamente al caso en que se consideró la coincidencia en las distribuciones completas, Datos Extendidos Fig. 9b). Esto se debió a que sin sobreimpulsos al inicio del estímulo, las respuestas aún se muestreaban de la distribución correspondiente a la entrada de referencia. Por lo tanto, incluirlas en la estimación de la nueva media relacionada con el estímulo inevitablemente sesgó la estimación a la baja. El sobreimpulso compensó en gran medida este sesgo. De hecho, pudimos demostrar analíticamente que la compensación óptima requiere sobreimpulsos transitorios al inicio del estímulo (Nota Matemática Suplementaria).

Esto se debe a que el promediado continuo de respuestas corresponde formalmente a una convolución temporal, por lo que la respuesta óptima es la deconvolución del objetivo con el núcleo de promediación. Bajo restricciones básicas de suavidad, la deconvolución de una función escalonada con dicho núcleo de promediación produce transitorios como los observados en la red (Figura 9c de Datos Extendidos).

La hipótesis de una mayor precisión de muestreo mediante la compensación transitoria generó una predicción clara (Nota Matemática Suplementaria): los sobreimpulsos transitorios deberían escalar con el cambio en las respuestas en estado estacionario. De hecho, nuestra red exhibió este efecto tanto en los potenciales de membrana como en las tasas de disparo (Fig. 7c-d, arriba). Cabe destacar que los sobreimpulsos transitorios heredaron el ajuste de orientación de las respuestas estacionarias (Fig. 7c-d, abajo). Si bien los transitorios de inicio del estímulo se han observado ~~complementariamente~~ ^{complementariamente} a su ajuste al estímulo. Por lo tanto, analizamos un conjunto de datos previamente publicado sobre las respuestas V1 en el mono despierto²³. De acuerdo con las predicciones del modelo, los tamaños de sobreimpulso se ajustaron según la orientación (Fig. 7e, abajo) y, en general, se ajustaron con el cambio en las respuestas estacionarias.

(Fig. 7e, arriba; estos resultados fueron robustos al excluir los valores atípicos con altas tasas de disparo, por ejemplo, por encima de 60 Hz, Datos extendidos Fig. 9d-e).

Discusión

Hemos demostrado que un modelo de red neuronal canónica^{6,27} produce dinámicas similares a las corticales cuando se optimiza para la inferencia basada en muestreo, pero no cuando se optimiza para objetivos no probabilísticos o para objetivos probabilísticos no basados en muestreo. Controles posteriores demostraron que estas dinámicas no eran meros subproductos de las restricciones biológicas particulares ni del enfoque de optimización que adoptamos. En cambio, desempeñaban funciones bien definidas en la realización de la inferencia.

El modelo de mezcla de escala gaussiana y la red supralineal estabilizada estocástica

Utilizamos un modelo canónico de dinámica de redes neuronales (el modelo estocástico SSN) para incorporar un conjunto de restricciones biológicamente relevantes para los circuitos corticales. No era trivial que este modelo pudiera modular sus respuestas según fuera necesario para una inferencia exitosa basada en muestreo bajo un modelo generativo canónico de parches de imagen visual (el GSM). Un indicio de que esto podría ser posible provino de estudios previos que mostraban que tanto en el SSN^{6,27} como en el GSM^{5,39}, existe un rango de parámetros para los cuales la respuesta promedio o media posterior aumenta monótonamente, mientras que la varianza disminuye al aumentar la intensidad del estímulo. Empíricamente, encontramos una buena coincidencia cuantitativa que iba más allá de esta tendencia cualitativa burda, ya que el SSN también capturaba gran parte de la estructura detallada de las posteriores del GSM. Sin embargo, esta coincidencia no fue perfecta: por ejemplo, las posteriores del GSM mostraron sistemáticamente correlaciones negativas de mayor magnitud que la que la red pudo expresar (Fig. 2d y Fig. 3b-c). Podría ser posible lograr una correspondencia más precisa permitiendo correlaciones de entrada negativas y, en general, una parametrización más flexible del SSN. De hecho, una vez que sea factible la optimización de SSN a mayor escala y con parametrización más flexible, también esperamos que puedan muestrear modelos generativos más ricos y profundos.

Redes neuronales optimizadas para funciones

Nuestro enfoque es complementario a los enfoques clásicos para el entrenamiento de modelos de redes neuronales. Trabajos previos mostraron cómo varias propiedades de estado estacionario de las respuestas corticales (como campos receptivos o actividades promediadas por ensayo) emergen de la optimización de redes neuronales para algún objetivo computacionalmente bien definido^{30,40–44}. En particular, nuestro objetivo computacional basado en muestreo requirió que nuestra red modulara no solo la media sino también la variabilidad de sus respuestas de manera dependiente del estímulo. Esto hizo que el entrenamiento de redes fuera significativamente más desafiante que los enfoques convencionales de entrenamiento de redes para objetivos deterministas sin requerir explícitamente que modulen su variabilidad^{40,43,45}. A cambio, la dinámica de nuestra red exhibió ricos patrones de variabilidad modulados por estímulo. Estas respuestas capturaron una variedad de características ubicuas del comportamiento ensayo por ensayo de las respuestas corticales (variabilidad del ruido, transitorios y oscilaciones) más allá de las propiedades de estado estacionario o promedio de ensayo que podrían abordarse mediante trabajos previos.

Típicamente, los enfoques previos de optimización de redes apuntaban a determinar los tipos de dinámicas que surgen cuando una tarea se ejecuta bajo restricciones mecanicistas mínimas, utilizando una red neuronal como un aproximador de función universal. Como resultado, produjeron conocimientos fundamentales sobre la organización macroscópica de la dinámica de la red (p. ej., la presencia de atractores de línea⁴⁵), pero no intentaron incorporar algunas de las restricciones más salientes en la organización detallada de los circuitos corticales. Específicamente, utilizaron redes que eran puramente de alimentación hacia adelante⁴⁰, utilizaron funciones de transferencia neuronal que carecían de las no linealidades expansivas características de las neuronas corticales^{40,42,44,45}, no tenían separación de células E e I^{40,44,45}, o tenían dinámicas sin ruido⁴³.

En contraste, nuestro objetivo era estudiar la emergencia de computaciones (probabilísticas) a través de dinámicas y conectar estas dinámicas a datos experimentales en (o cerca de) la resolución de una sola célula (por ejemplo, la reducción de variabilidad específica de la neurona y del estímulo, o el desfase entre las entradas inhibitorias y excitatorias totales en células individuales). Esto requirió respetar todas las restricciones biológicas mencionadas anteriormente. Sin embargo, este realismo adicional vino a costa de tener que limitar el número de parámetros optimizados para que fuera mucho menor que los enfoques estándar con redes de propagación hacia adelante o redes recurrentes para las cuales la estabilidad dinámica se logra más fácilmente. Si bien esta parametrización reducida facilitó encontrar soluciones estables, todavía era suficientemente expresiva. En particular, encontramos que nuestros resultados no podrían haberse obtenido sin la optimización (Figs. 3 y 4 de Datos Extendidos), o con la optimización de otras funciones objetivo (Fig. 5 y Figs. 5-7 de Datos Extendidos). De hecho, esta parametrización aún incluía redes que eran inestables, o mostraban una disminución en las respuestas medias y/o un aumento en la variabilidad con el aumento de la fuerza del estímulo (es decir, lo opuesto a lo que se requería para igualar el GSM), o estaban moduladas de manera no monótona o solo mínimamente en conjunto (Figura 3 de Datos Extendidos).

Representaciones neuronales de la incertidumbre

Nuestro enfoque difería notablemente de trabajos previos sobre las bases neuronales de la inferencia probabilística. Los modelos previos se derivaban típicamente mediante un enfoque (véase la referencia 43), empleando dinámicas de red diseñadas manualmente que imitaban explícitamente algoritmos específicos de inferencia aproximada existentes de aprendizaje automático basados en el muestreo de u otro representaciones 33–36,46,12,19,33,47. Como resultado, estos modelos ofrecían sólidas garantías teóricas para su rendimiento, pero a menudo ofrecían solo una coincidencia mayormente fenomenológica con la dinámica de los circuitos neuronales. En particular, no respetaban algunas restricciones biológicas básicas (p. ej. Principio de Dale^{33,35,47}), o tuvo que asumir una influencia irrealmente rápida y directa de los parámetros de la red de estimulación (por ejemplo, los pesos sinápticos^{35,46}). Por el contrario, utilizamos un método más de abajo hacia arriba enfoque, a partir de las limitaciones conocidas de la organización del circuito cortical, y Luego, se optimizaron los parámetros de las redes bajo dichas restricciones para lograr una inferencia probabilística eficiente basada en muestreo, sin preespecificar los detalles de la dinámica necesaria para implementarse. Si bien este enfoque no puede ofrecer garantías formales de rendimiento, nuestra red optimizada descubrió nuevos motivos algorítmicos (oscilaciones y transitorios) para acelerar la inferencia probabilística. Si bien algunos de estos motivos se habían observado en trabajos previos⁴⁶, su función seguía siendo incierta, ya que estaban integrados por diseño en lugar de obtenerse como resultado de la optimización, o parecían puramente epifenoménicos. En contraste, estos motivos cumplieron funciones computacionalmente bien definidas en nuestra red.

La dinámica de nuestra red también puede proporcionar pistas útiles para construir nuevos algoritmos de aprendizaje automático. En general, el tipo de dinámica irreversible en el tiempo y fuera de equilibrio que demostramos para nuestra red solo se ha apreciado recientemente en el aprendizaje automático^{22,36}. Al mismo tiempo, se sabe desde hace tiempo que los algoritmos de inferencia basados en muestreo que utilizan dinámicas de segundo orden con las llamadas variables de "momentum", como el Hamiltoniano Monte Carlo, mejoran la velocidad de muestreo³¹. De hecho, podría ser interesante explorar en qué medida la dinámica de nuestra red puede interpretarse como una implementación neuronal del Hamiltoniano Monte Carlo⁴⁶. Sin embargo, a pesar de que estos sistemas dinámicos de segundo orden a menudo exhiben oscilaciones y sobreimpulsos transitorios, su eficiencia de muestreo generalmente se ha analizado solo en los términos más genéricos de la supresión del comportamiento aleatorio similar a un paseo. En contraste, nuestros análisis revelaron roles específicos para las oscilaciones y los transitorios. De hecho, el entorno de inferencia continua que utilizamos para demostrar los beneficios de los transitorios no se ha considerado en aplicaciones de aprendizaje automático hasta ahora, aunque esperamos que sea muy relevante tanto para la cognición biológica como para la artificial.

Variabilidad cortical, transitorios y oscilaciones

Nuestro trabajo sugiere una novedosa función unificadora para tres propiedades ubicuas de las respuestas corticales sensoriales: variabilidad modulada por estímulos, sobreimpulsos transitorios y oscilaciones gamma. En trabajos previos, estos fenómenos se han estudiado tradicionalmente de forma aislada y se les han atribuido roles funcionales separados que han sido difíciles de reconciliar. En particular, no se han derivado normativamente, es decir, partiendo de algún objetivo funcional y luego optimizándolo de manera basada en principios (pero véase, por ejemplo, la Ref. 47). Por ejemplo, la variabilidad cortical se ha considerado con mayor frecuencia una molestia, que disminuye la precisión de los códigos neuronales²³. Las teorías que postulan un rol funcional de la variabilidad en los cálculos probabilísticos solo han considerado la distribución de estado estacionario de las respuestas sin hacer predicciones específicas sobre sus características dinámicas^{5,12}. Por el contrario, las respuestas transitorias figuran prominentemente como ingredientes centrales de los modelos de codificación predictiva, donde señalan novedad o desviaciones entre los estados predichos y observados⁴⁷. Sin embargo, estas teorías no abordaron la variabilidad de la respuesta.

Nuestro trabajo considera tanto los transitorios como la variabilidad a partir de un principio único, utilizando únicamente el equivalente de las "neuronas de representación interna"⁴⁸ de la codificación predictiva, pero sin invocar neuronas específicas de codificación de errores de predicción. En particular, nuestro modelo predijo correctamente una relación de escala específica entre los transitorios y las respuestas en estado estacionario, que probamos mediante nuevos análisis de datos experimentales (Fig. 7). Además, nuestro análisis matemático sugirió que las señales similares a errores de predicción (más formalmente, respuestas que escalan con la magnitud del cambio en la distribución objetivo; Datos Extendidos Fig. 9c) son una firma genérica de inferencia continua utilizando dinámicas basadas en muestreo y, por lo tanto, no solo aparecerán en los inicios del estímulo, sino en cualquier situación en la que las predicciones cambien temporalmente. Una prueba concluyente de si las respuestas similares a errores de predicción en la corteza se deben a este mecanismo o a mecanismos clásicos de codificación predictiva requerirá manipulaciones más específicas de las expectativas previas.

Las oscilaciones gamma también se han propuesto como sustrato para una serie de funciones en el pasado, relacionadas con la forma en que se codifica, combina o enruta la información en el cerebro^{8–10,49}.

Estas funciones putativas no necesitan ser mutuamente excluyentes con las que se desempeñan en nuestra red. Sin embargo, algunas de estas funciones parecen difíciles de conciliar con hallazgos experimentales específicos^{3,14,15,50}. En términos más generales, las teorías de las oscilaciones gamma no suelen abordar transitorios.

Los modelos de codificación predictiva consideran de forma natural los transitorios y también pueden explicar las oscilaciones gamma¹¹. Sin embargo, no está claro si estas teorías también explicarían propiedades más allá de la mera existencia de oscilaciones gamma. Estas incluirían la modulación de frecuencia por contraste^{3,4} que nuestro modelo reprodujo (Fig. 5), o, de hecho, cualquier aspecto de la variabilidad ubicua de las respuestas corticales y su modulación por estímulos, que nuestro modelo también reprodujo como una característica central (Figs. 2, 3 y 5). En contraste, nuestros resultados muestran que la variabilidad, los transitorios y las oscilaciones gamma pueden surgir del mismo objetivo funcional: que los circuitos neuronales utilicen una representación eficiente de la incertidumbre basada en muestreo bajo restricciones temporales.

El mecanismo por el cual se generan las oscilaciones gamma en el cerebro, en particular si implica interacciones entre células E e I (mecanismo «PING») o solo entre células I (mecanismo «ING»), es un tema de debate actual¹⁶. En nuestro modelo, la fijación de voltaje de las células E eliminó las oscilaciones gamma (Datos Extendidos, Fig. 2c-d), lo que apunta al mecanismo «PING». Sin embargo, nuestra red solo incluía un tipo de célula inhibitoria y una conectividad muy restringida; por lo tanto, queda pendiente de investigación futura cómo el mecanismo preciso de generación gamma depende de dichas restricciones arquitectónicas. El estudio de versiones más jerárquicas o espacialmente extendidas de nuestro modelo también podría permitirnos estudiar a más largo plazo.

Aspectos de rango de las oscilaciones gamma, como la sincronización gamma

Métodos

Modelo de observador ideal

Siguiendo las referencias 5 y 25, adoptamos el modelo de mezcla de escalas gaussianas (GSM)²⁴ como modelo generativo de parches de imagen naturales bajo los cuales la corteza visual primaria (V1) realiza inferencias. Por lo tanto, se asumió que un parche de imagen x se construía mediante la combinación lineal de un conjunto de características locales, las columnas de x , ponderado por un conjunto de coeficientes de características específicas del parche de imagen A , y , y y , y escalado por una única variable de contraste global (a la escala del parche de imagen), z , más ruido gaussiano blanco aditivo, lo que resulta en la siguiente verosimilitud para los coeficientes de características y :

$$p(x|y, z) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi} \sigma_i} \exp\left(-\frac{(x_i - \sum_j A_{ij} y_j)^2}{2\sigma_i^2}\right) \quad (1)$$

donde se asumió que los coeficientes de las características se extrajeron de una distribución previa gaussiana multivariada:

$$y \sim N(0, C) \quad (2)$$

Se asumió que se extrajo de un Gamma anterior: $z \sim \Gamma(K, \rho)$ (Tabla S1, ver también Ref. 39).

Para modelar las inferencias en una hipercolumna V1, elegimos las columnas de A (los llamados campos proyectivos de las variables latentes) como filtros de Gabor orientados que solo diferían en su orientación (espaciados uniformemente entre -90° y 90° ; se muestran cuatro ejemplos en la Fig. 1a; véase también la Fig. 1a de Datos Extendidos). La matriz de covarianza a priori C era una matriz circulante cuyos elementos variaban suavemente en función de la distancia angular entre las orientaciones de los campos proyectivos de las variables latentes correspondientes, desde positivo (para campos proyectivos con orientación similar) hasta negativo (para campos proyectivos con orientación ortogonal) (Fig. 1b de Datos Extendidos).

Los coeficientes de característica latente posterior del observador ideal y bajo el GSM para un parche de imagen dado, x , y un contraste conocido z , se pueden escribir como:

$$PGSM(y|x, z) = N(y; \mu_{GSM}, \Sigma_{GSM}) \quad (3)$$

$$\text{con } \mu_{GSM} = \frac{z}{\sigma_x^2} \Sigma_{GSM} A \quad (4)$$

$$\text{y } \Sigma_{GSM} = C \left(-1 + \frac{z^2}{\sigma_x^2} A^T A \right)^{-1} \quad (5)$$

En general, también sería necesario inferir z . Sin embargo, z es solo un único escalar del cual como la inferencia agrupa información de todos los píxeles de la entrada, aproximamos la posterior encima z con una distribución delta en z^* , el verdadero valor z que se utilizó para generar la entrada. Por lo tanto, la posterior final sobre y , después de marginalizar la incógnita z , se aproximó mediante sustituyendo z^* en la ecuación 3:

$$PGSM(y|x) = PGSM(y|x, z^*) \quad (6)$$

Siguiendo la referencia 5, los potenciales de membrana, u_i , se tomaron como representantes de una función débilmente no lineal de las activaciones de las características visuales y_i (Nota matemática complementaria):

$$u_i = \left(y_i - \beta \right)^{n_l} + \beta \quad (7)$$

donde $\cdot^{n_l}$ es la función lineal de umbral, y n_l son respectivamente la escala, la línea de base y la potencia de la transformación (Tabla S1, Fig. S1a).

Dinámica y arquitectura de redes

Nuestra red E/I estocástica y no lineal consistió en E excitatorio y I neuronas inhibitorias.

Siguiendo la referencia 6, modelamos la dinámica de cada neurona como:

$$\tau_i \frac{du_i}{dt} = -u_i(t) + i_i(t) + \sum_j W_{ij} r_j(t) + \eta_i(t) \quad (8)$$

dónde τ representaba el potencial de membrana de la neurona, τ_m su constante de tiempo de membrana, σ su entrada de avance, σ_r el ruido del proceso (incorporando formas intrínsecas y extrínsecas de variabilidad neuronal) y σ_s el peso de la sinapsis que conectaba la neurona i a la neurona j . Las tasas de disparo se dieron mediante una transformación supralineal de los potenciales de membrana:

$$r_i(t) = k u_i(t)^{\gamma} \quad (9)$$

dónde k y γ fueron respectivamente la escala y el exponente de la no linealidad de la tasa de disparo (Tabla S1).

Razonamos que cualquier red que realice una inferencia precisa basada en muestreo bajo nuestro GSM con estructura en anillo debería exhibir la misma simetría circular. Por lo tanto, parametrizamos la conectividad recurrente de la red para que fuera rotacionalmente simétrica, de modo que las neuronas se dispusieran en pares de células E e I alrededor de un "anillo" según sus orientaciones preferidas (Fig. 1c) y la conectividad de la red (así como la covarianza del ruido de proceso, véase más adelante) fuera una función de decrecimiento suave (gaussiana circular) de la diferencia de ajuste entre dos células. Específicamente, cada cuadrante de la matriz de ponderaciones ($E \rightarrow E$, $E \rightarrow I$, $I \rightarrow E$ e $I \rightarrow I$) se definió como:

$$W_{XY}(\theta_i, \theta_j) = a_{XY} \exp\left(\frac{\cos[2(\theta_i - \theta_j - \lambda)]}{d_{XY}^2}\right) \quad (10)$$

dónde θ_i (θ_j) y, por lo tanto, $\theta_i = \pi i / n_{E/I}$ era la orientación representada por el índice i la neurona E/I.

tanto, no optimizamos todos los elementos de la matriz de ponderaciones, sino solo los ocho libres a_{XY} . También restringimos las

Los a_{XY} a este amplitud de XY para que fueran positivas para $XY = E$, de modo que la red obedeciera el principio de Dale. $\lambda = E$ parámetros y la λ circulante

negatividad para la parametrización implicaban que entrenar la red con un par estímulo-posterior específico la entrenaba en todas las rotaciones posibles de este par. Esto redujo el tamaño del conjunto de entrenamiento necesario para lograr una buena generalización y, por lo tanto, aceleró el entrenamiento.

El ruido del proceso independiente del estímulo (último término en la ecuación 8) estaba correlacionado espacial y temporalmente con una gaussiana de media cero (por ejemplo, modelando entradas de otras áreas del cerebro o variabilidad intrínseca en la red):

$$\langle \eta(t) \eta(t+s) \rangle = \sum \eta \exp\left(-\frac{s}{\tau_\eta}\right) \quad (11)$$

dónde τ_η fue la escala de tiempo del ruido del proceso (Tabla S1) y Σ^η era el estacionario Matriz de covarianza (zerolag) parametrizada por bloques como:

$$\Sigma_{EE}^\eta \parallel (\theta_i, \theta_j) = \sigma_E^2 \exp\left(\frac{\cos[2(\theta_i - \theta_j - \lambda)]}{d_\sigma^2}\right) \quad (12)$$

$$\Sigma_{EI}^\eta (\theta_i, \theta_j) = \rho \sigma_E \sigma_I \exp\left(\frac{\cos[2(\theta_i - \theta_j - \lambda)]}{d_\sigma^2}\right) \quad (13)$$

que introdujo cuatro parámetros libres adicionales: $\sigma_{mi} > 0$, $\sigma_{\sigma} > 0$, ρ , d_σ .

Al igual que en los modelos estándar de células simples V151, la entrada dependiente del estímulo a cada neurona se obtuvo aplicando un filtro lineal W al estímulo seguido de una no linealidad estática:

$$i(t) = \alpha h \left[\beta \left(\sum_j W_{ij} x_j(t) \right) \right] \quad (14)$$

donde $x(t)$ fue el estímulo (parche de imagen de entrada) recibido en el tiempo t y α , β y h eran respectivamente la escala, línea base y exponente de la no linealidad de entrada (Tabla S1, Datos Extendidos Fig. 1e). Dada la correspondencia uno a uno entre las variables latentes del GSM y pares de neuronas excitatorias-inhedoras del modelo de red (Fig. 1a y c), determinamos la entrada externa a cada neurona a través de un campo receptivo de entrada que era idéntico (hasta un factor constante) al campo proyectivo de la variable latente GSM correspondiente, ya que se sugirió que esto era óptimo para el muestreo por trabajo previo³⁰: W la misma matriz que en el modelo generativo (Ec. 1), y $[A A]^{adj} = [A A]^T / 15$, donde A era denota concatenar A consigo misma columna por columna.

En resumen, optimizamos un total de 15 parámetros: 8 que describen la matriz de peso W (Ec. 10), 4 que describen Σ^{-1} (Ecs. 12 y 13), y 3 que especifica el mapeo de los estímulos a las entradas de la red (Ec. 14).

Cálculo de los momentos de las respuestas neuronales

Por cada t en relación con el inicio del estímulo, denotamos los momentos de respuesta neuronal entre ensayos. respuesta de tiempo

$$\mu(t) = \langle u(t) \rangle \quad (15)$$

$$\Sigma(t, \Delta t) = \langle (u(t) - \mu(t))(u(t + \Delta t) - \mu(t + \Delta t)) \rangle \quad (16)$$

Donde $\langle \cdot \rangle$ denota el promedio de los ensayos. Para calcular estos momentos, empleamos dos métodos diferentes. El primer enfoque, denominado «método estocástico», consistió en aproximar los promedios mediante muestreo, es decir, simular la dinámica de la red estocástica en un conjunto de ensayos utilizando el mismo estímulo (Ecs. 8, 9 y 14) y calcular la media y la covarianza muestral entre ensayos en cada paso de tiempo. Utilizamos este enfoque en la primera fase del entrenamiento de la red y para obtener los resultados de la red una vez entrenada (véase más adelante).

El segundo enfoque, denominado «filtrado de densidad supuesta» (ADF), utilizó ecuaciones deterministas de movimiento para calcular los momentos entre ensayos. Este enfoque solo se empleó en la última fase del entrenamiento de la red (véase más adelante). Con base en la referencia 52, se utilizaron las siguientes ecuaciones diferenciales exactas para describir la evolución de $\mu(t)$ y $\Sigma(t, \cdot)$:

$$\frac{d\mu(t)}{dt} = T^{-1} [-\mu(t) + h(t) + W v(t)] \quad (17)$$

$$\frac{d\Sigma(t, 0)}{dt} = [T^{-1}\Sigma^*(t)] + T^{-1}\left[\Sigma^*(t) + J(t)\Sigma(t, 0) + \Sigma(t, 0)J(t)\right] \quad (18)$$

$$\frac{d\Sigma^*(t)}{dt} = -\frac{1}{\tau\eta}\Sigma^*(t) + \Sigma^*T^{-1} + \Sigma^*(t)J(t) \quad (19)$$

$$\frac{d\Sigma(t, \Delta t)}{d\Delta t} = e^{-\Delta t/\tau\eta} \left[-\Sigma^*(t) \right] + \Sigma(t, \Delta t)J(t + \Delta t) \quad \Delta t > 0 \quad (20)$$

donde T es la matriz diagonal de las constantes de tiempo de membrana (Tabla S1), η es el T (tasa de disparo promedio de las neuronas), Σ es la covarianza cruzada con retardo temporal de los potenciales de membrana en la red, $\Sigma^* = (u - \mu)T\eta$ es la covarianza cruzada instantánea entre los potenciales de membrana y el ruido de proceso correlacionado temporalmente con covarianza instantánea Σ (Ec. 11), y

$$J = T^{-1} \left[-I + W \text{diagonal} \left(\frac{\partial v}{\partial \mu} \right) \right] \quad (21)$$

es el jacobiano de la ecuación 17 con respecto a μ . La integración de las ecuaciones 17-20 requirió, a su vez, la evaluación de algunos momentos no lineales de u , concretamente las covarianzas entre los potenciales de membrana, u , y las tasas de activación, r . Para la SSN, estos momentos pueden obtenerse en forma cerrada, asumiendo que la distribución conjunta (espacio-tiempo) completa de los potenciales de membrana es gaussiana⁵². Por lo tanto, a diferencia del primer método (estocástico), que produce una estimación insesgada, pero potencialmente de alta varianza, de los momentos, el método ADF produce estimaciones de varianza cero, pero potencialmente sesgadas. Para entrenar la red, como se describe a continuación, combinamos las ventajas de estos dos enfoques.

Estímulos de entrenamiento y prueba y momentos objetivo

El conjunto de entrenamiento (Fig. 2b) constaba de cinco parches de imagen:

$$x_\alpha = z_\alpha A y \quad (22)$$

con $\alpha = 1, \dots, 5$ y $z_\alpha \in \{0, 0.125, 0.25, 0.5, 1.0\}$. Por lo tanto, estos estímulos tenían la misma contenido una función gaussiana de 27° de ancho centrada en 0° (es decir, una única orientación dominante) —, y diferían únicamente en su contraste (Fig. 2b). Dado que la parametrización de nuestra red era rotacionalmente invariante (véase arriba), dicho estímulo era, de hecho, representativo de todos los parches de imagen que se podían obtener al rotar este parche alrededor del centro. Para cada estímulo de entrenamiento α calculamos las distribuciones posteriores correspondientes sobre u bajo el GSM (Ecs. 6 y 7). Llamamos a estas distribuciones "distribuciones objetivo" y sus medias correspondientes μ_{tgt} α y covarianzas Σ_{tgt} α , los "momentos objetivo" (Fig. 2c,d):

$$\mu_{tgt}^\alpha = \int u(y) P_{GSM}(y | x^\alpha) dy \quad (23)$$

$$\Sigma_{tgt}^{afa} = \int u(y)u(y)PGSM(y-x)dy - \mu_{tgt}^{afa} \alpha \mu_{tgt}^{afa} \quad (24)$$

Para probar la generalización en la red, generamos un conjunto de 500 nuevos parches de imagen con el GSM, que, por lo tanto, no estaban restringidos a una única orientación dominante (ya que la distribución a priori permitía que múltiples elementos de y con diferentes campos proyectivos fueran distintos de cero, Ec. 2). Para ser consistentes con el conjunto de entrenamiento, no incluimos ruido aditivo en x y añadimos una línea base dependiente del contraste a y , de modo que su media se modulara por el contraste de la misma manera que en el conjunto de entrenamiento. Para cada parche de imagen del conjunto de prueba, también calculamos los momentos posteriores correspondientes (Ecs. 23 y 24) para evaluar el rendimiento de la red en las pruebas.

Capacitación en red

La función de costo que minimizamos durante el entrenamiento de la red consistió en cuatro términos para cada estímulo de entrada en el conjunto de entrenamiento:

$$= \sum_{afa} \left(\text{media}_{afa}^2 + \text{var}_{afa}^2 + \text{cov}_{afa}^2 + \text{lento}_{afa}^2 \right) \quad (25)$$

Los primeros tres términos de la ecuación 25 penalizaron las diferencias entre los momentos (a lo largo de la prueba) de la distribución de respuesta de la red (ecuaciones 15 y 16) promediados en una ventana de tiempo finita que termina en $T_{\text{máx}} = 500$ ms después del inicio del estímulo, y los respectivos momentos objetivo de las distribuciones posteriores correspondientes del observador ideal (ecuaciones 23 y 24):

$$\text{media}_{afa} = \int_{T_{\text{mín}}}^{T_{\text{máx}}} \left\| \mu_{afa}(t) - \mu_{tgt}^{afa} \right\|_F^2 dt \quad (26)$$

$$\text{var}_{afa} = \int_{T_{\text{mín}}}^{T_{\text{máx}}} \left\| \sigma_{afa}(t) - \sigma_{tgt}^{afa} \right\|_F^2 dt \quad (27)$$

$$\text{cov}_{afa} = \int_{T_{\text{mín}}}^{T_{\text{máx}}} \left\| \Sigma_{afa}(t, 0) - \Sigma_{tgt}^{afa} \right\|_F^2 dt \quad (28)$$

donde $\sigma_{afa}(t) = \text{diag}(\Sigma_{afa}(t, 0))$ y $\Sigma_{afa}(t, 0)$ y Σ_{tgt} son la respuesta y el objetivo σ_{tgt} varianzas, respectivamente. El último término de la ecuación 25 fue un coste de lentitud adicional, que penalizó la autocorrelación total de la respuesta neuronal rezagada, dada por la diagonal de $C(\tau) = \text{corr}(u(t), u(t + \tau))$, dentro de un $T_{\text{máximo}} =$ ventana de tiempo de 100 ms:

$$\text{lento}_{afa} = \int_0^{T_{\text{máx}}} \left\| \text{diagonal } C_{afa}(\tau) \right\|_F^2 d\tau \quad (29)$$

Los coeficientes Se controló la importancia relativa de estos términos (Tabla S1). En la primera red de control (Fig. 5, columna derecha; Datos Extendidos Fig. 5a-g y 6), establecimos $\text{variedad} = \text{cubierta} = \text{lento} = 0$, pero se mantuvieron iguales todos los demás metaparámetros y las medias objetivo. En la segunda red de control (Figs. 5h-n y 6 de Datos Extendidos), se $\text{cubierta} = \text{lento} = 0$, pero queda variedad mantuvieron iguales solo los metaparámetros y otros metaparámetros de la red original. En la tercera red de control (Figs. 6 y 7 de Datos Extendidos, derecha), todos los parámetros e fueron iguales a los de la optimización de la red original, pero las covarianzas objetivo se modificaron para inducir factores de Fano independientes del contraste (véase más adelante).

La optimización implicó retropropagación a través del tiempo⁵³, para lo cual utilizamos diferenciación automática. Entrenamos la red en dos etapas. Durante la primera etapa, empleamos un método de gradiente estocástico utilizando 50 ensayos para cada estímulo de entrenamiento para estimar los momentos correspondientes de las respuestas de la red (véase más arriba), y realizamos 250 iteraciones del optimizador ADAM⁵⁴. Tanto las condiciones iniciales de la red como el ruido del proceso se remuestrearon para cada ensayo e iteración. Las condiciones iniciales se extrajeron de una distribución gaussiana $N(\mu_0, \Sigma_0)$ (Tabla S1). Además, a lo largo de las iteraciones, el inicio de la ventana de tiempo de promediación, T_{min} en las ecuaciones 26-28, se modificó sistemáticamente («recocado») $T_{\text{min. de}} = 0$ ms (inicio del estímulo) a $T_{50\text{ms}}$. La longitud finita de la ventana de promediación, En particular, la inclusión de muestras inmediatamente o poco después del inicio del estímulo fomentó un muestreo rápido. Por lo tanto, la definición explícita del coste de lentitud $= 0$ no ralentizó afectó cualitativamente nuestros resultados (Figuras 6 y 10 de Datos Extendidos).

En la segunda etapa, continuamos la optimización con el optimizador L-BFGS-B⁵⁵, ahora empleando el método ADF para calcular (determinísticamente) los momentos de la distribución de respuesta de la red (véase más arriba). Mantuvimos la ventana de tiempo de integración de costes al mínimo $T_{\text{mín.}} = 50$ ms, alcanzado al final de la primera fase). El coste de penalización por lentitud en la ecuación 29 sólo se aplicó durante la optimización basada en ADF y, para simplificar, se aproximó utilizando correlaciones rezagadas estacionarias predichas por el método ADF (Ec. 20) en el límite del ruido de proceso temporalmente blanco⁵².

Como la función de costo que utilizamos (Ecuación 25) no era convexa, verificamos la solidez de nuestros hallazgos realizando 10 intentos de optimización más a partir de condiciones iniciales aleatorias. Ninguna solución logró costos sustancialmente menores, y aquellas cuyo costo final fue al menos aproximadamente tan bajo como el de la red presentada en el texto principal se comportaron cualitativamente de manera similar (en particular, mostraron oscilaciones y transitorios dependientes del contraste; Datos Extendidos, Fig. 4). Sin embargo, nuestros resultados no deben interpretarse como un óptimo global de nuestra función de costos.

Muestreo de Langevin

A modo de comparación (Fig. 4), también implementamos la dinámica de Langevin³¹ para muestrear los mismos posteriores objetivo utilizados para entrenar la red optimizada. Dado que los posteriores objetivo GSM eran gaussianos (Ecs. 3 y 6), la dinámica de Langevin resultante fue isomorfa a la de una red neuronal recurrente lineal estocástica genérica:

$$= WLu + h + \eta \tau Eu \quad (30)$$

Donde, para una comparación T_{mi} y η eran respectivamente la misma constante de tiempo y proceso justa, el ruido es igual que en nuestra red optimizada (Ecs. 8 y 11-13). Sin pérdida de generalidad, establecimos la entrada a la red $h = 0$, ya que estaría completamente determinada por el requisito de igualar la media de la respuesta con la media objetivo, μ_{tgt} , pero no afectaría el autocorrelograma del sistema, que fue el foco de nuestra investigación. Dado que la variabilidad en una red lineal no depende de la entrada (a diferencia de nuestro modelo de circuito no lineal), utilizamos una W_L diferente para igualar cada covarianza objetivo, Σ_{tgt} :

$$W_L = \frac{1}{\gamma_L} \left(I - \sqrt{\gamma_L \Sigma_{tgt}^{-1}} \right) \quad (31)$$

dónde $\gamma_{opt} = 2 e^{\frac{\mu_{tgt}}{\sigma_E^2}}$.

Experimentos numéricos después del entrenamiento

Para obtener una estimación confiable de los momentos estacionarios de las respuestas neuronales a una entrada fija (Figs. 2 y 3), se extrajeron de la red un total de 20 000 muestras independientes (tomadas con 200 ms de diferencia), sin incluir los transitorios, a medida que la actividad neuronal evolucionó de acuerdo con la ecuación 8. Las actividades neuronales en la Fig. 2a muestran 1 s de actividad de red simulada, convolucionada con una ventana deslizante de 20 ms para que coincida con los efectos del agrupamiento de picos para calcular las tasas promedio en los experimentos. Las trayectorias neuronales de la Fig. 2b corresponden a la actividad neuronal de dos células de la red con orientaciones preferentes de 42° ($\circ$) y 16° ($\circ$), durante un periodo post-transitorio de 500 ms. Para ilustrar tanto el grado de modulación de las covarianzas posteriores como la correspondencia entre las covarianzas posteriores y de red de la Fig. 3c, se calcularon las tres PC superiores de cada covarianza posterior. Posteriormente, se proyectó la actividad neuronal sobre cada PC y se calculó la cantidad de varianza en cada dirección. Los gráficos centrales de la Fig. 3c presentan estas PC posteriores escaladas por la raíz cuadrada de la varianza total en esa dirección en el GSM (en verde) o en la red (en rojo).

Los autocorrelogramas en la Fig. 4a se calcularon en 500 ventanas no superpuestas de 2 s de actividad neuronal simulada cada una (submuestreadas a 0,4 ms) tras el inicio del estímulo (excluyendo transitorios), y luego se promediaron en estas ventanas. Los autocorrelogramas se calcularon primero para los potenciales de membrana de las células individuales y luego se promediaron en todas las células. Los correlogramas cruzados y los retardos E-I en la Fig. 4b-c se calcularon a partir de una única simulación de 400 s de duración tras el inicio del estímulo, excluyendo transitorios (sin submuestreo). El retardo E-I para cada célula se determinó como la ubicación del máximo en el componente antisimétrico del correlograma cruzado entre su entrada total E e I. Los muestreadores de Langevin en la Fig. 4a-b correspondieron a redes neuronales con dinámica lineal reversible en el tiempo, que no respetan el principio de Dale, según lo definido por las Ecs. 30 y 31. Los autocorrelogramas y los correlogramas cruzados para el muestreador de Langevin se calcularon como para la red original.

Las tasas de disparo promedio en la Fig. 5a se calcularon a partir de los mismos trazos neuronales utilizados en la Fig. 2 para calcular los momentos μ (en este caso, se tomó el promedio de r en lugar de u). Para calcular los factores de Fano en la Fig. 5b, se utilizó un proceso Gamma no homogéneo con la tasa variable en el tiempo dada por (λ) para cada neurona i , y la forma de la distribución del intervalo entre picos se controló mediante un parámetro adicional, ISI (Tabla S1). Se calcularon los recuentos de picos en una ventana de 100 ms durante 500 000 ensayos independientes. Nuestros resultados fueron cualitativamente robustos a la elección de K ISI,

que determinó principalmente la magnitud general de los factores Fano (en particular, era necesario lograr factores Fano < 1 en alto contraste), pero no su modulación por estímulos. $K_{ISI} > 1$

Los espectros de potencia en la Fig. 5c se basaron en potenciales de campo locales simulados (LFP), calculados como la actividad neuronal promedio (entre células) (potenciales de membrana), siguiendo enfoques estándar⁶, utilizando las mismas muestras que los autocorrelogramas de la Fig. 4a (ver arriba). La frecuencia pico gamma se identificó como la ubicación del máximo local (dentro de la banda gamma, 20–80 Hz) del espectro de potencia. Los transitorios en la Fig. 5d se calcularon a partir de tasas de disparo promedio en células E y ensayos (= 100), promediados adicionalmente en una ventana de tiempo deslizante de 10 ms para imitar la resolución de los datos experimentales. Para dar cuenta de los retrasos de respuesta observados en los datos experimentales, utilizamos un tiempo de retraso aleatorio (gaussiano truncado, con una media de 45 ms y una desviación estándar de 5 ms) para la entrada de avance de cada par de células E–I en la red.

Para estimar las conductancias de entrada (Fig. 5e), equiparamos la corriente de entrada total (excitatoria o inhibitoria) de nuestro modelo con la corriente (excitatoria o inhibitoria) de un modelo canónico basado en conductancia⁵¹. Esto dio como resultado la siguiente expresión:

$$g_i E/I(t) \approx \frac{C_m \sum_j E/I_{wijj}(t)}{\tau_i \left[\sqrt{\frac{E/I}{- (u_i(t) + V_{\text{resto}})}} \right]} \quad (32)$$

donde C_m es la capacitancia de la membrana, V E/I denota los potenciales de inversión para las corrientes E/I , V_{rest} es un potencial basal (de reposo) añadido a los potenciales de membrana de nuestro modelo. Elegimos -80 mV y -65 mV. Las conductancias g_i y g_j en la Fig. 5e se muestran en relación con sus valores en estado estacionario durante la actividad espontánea y se promedian a lo largo de 20 ensayos para una sola neurona con orientación preferida alineada con la del estímulo.

Los autocorrelogramas y espectros de potencia de la Fig. 6c se calcularon como en las Fig. 4a y 5c, pero para las direcciones en el espacio de respuestas neuronales correspondientes a los diez primeros componentes principales (CP) de la variabilidad neuronal. Para cuantificar la oscilación en las respuestas neuronales a lo largo de alguna dirección en el espacio de estados (CP, Fig. 6d; o LFP, Datos Extendidos, Fig. 4b), calculamos la proyección correspondiente de las respuestas neuronales y, a continuación, ajustamos la siguiente función paramétrica a su autocorrelograma:

$$C_X(\Delta t) = [(1 - \chi) + \chi \cos(2\pi f \Delta t)] \cdot \left[\frac{\hat{r}}{\tau - \tau\eta} - \frac{|\Delta t|}{\hat{r}} - \frac{\hat{el}}{\tau - \tau\eta} - \frac{|\Delta t|}{\hat{el}} \right] \quad (33)$$

Donde τ y $\tau\eta$ son dos parámetros de constante de tiempo, $\chi[0,1]$ cuantifica el grado de oscilación y representa la frecuencia f de oscilación dominante. Se realizaron ajustes de la Ec. 33 a la actividad de red simulada utilizando Tensorflow. La forma de la Ec. 33 se basó en que, para $\tau = 0$, se reduce a

$$C_0(\Delta t) = e^{-\frac{\hat{r}}{\tau - \tau\eta} - \frac{|\Delta t|}{\hat{r}} - \frac{\hat{el}}{\tau - \tau\eta} - \frac{|\Delta t|}{\hat{el}}} \quad (34)$$

que es la función de autocorrelación de las fluctuaciones en una única neurona (aislada y, por lo tanto, no oscilante) con constante de tiempo de membrana τ que recibe entradas ruidosas con correlación $0(\Delta)$ (Eq. tiempo $\hat{\tau}_\eta$ (Esto se puede observar integrando las ecuaciones 18-20). De manera más general, para $\chi > 0$, do el 34) determina la envolvente de $C_0(\Delta)$ (Ecuación 33):

$$(1 - 2\chi)C_0(\Delta t) \leq C_\chi(\Delta t) \leq C_0(\Delta t) \quad (35)$$

Los sobreimpulsos en las figuras 7c y d se obtuvieron utilizando el mismo estímulo que se utilizó para entrenar la red con un contraste de 0,7, y se calcularon como el promedio máximo entre ensayos ($n_{\text{ens}} = 100$) (respuesta de cada célula E (potencial de membrana para c, tasa de disparo para d), menos su respuesta media estacionaria, promediada adicionalmente sobre 1000 configuraciones de retardo en nuestra red (como para la figura 5d, consulte más arriba). Las diferencias de estado estacionario denotan la magnitud de las respuestas medias evocadas de cada célula con respecto a su respuesta media previa al estímulo. Los resultados en el gráfico inferior de la figura 7d se calcularon promediando los estímulos presentados en la orientación preferida de cada neurona ($\pm 30^\circ$) u ortogonales a su orientación preferida ($\pm 30^\circ$).

Análisis con procesos gaussianos

Para la Fig. 6a-b, consideramos un proceso gaussiano estacionario, con momentos coincidentes (GP56) con una función de autocorrelación que estaba en la misma forma paramétrica que la ajustada a la red.

$= \tau_E = \tau_\eta = C_\chi(\Delta t)$ (Ec. 33), al establecer ambas constantes de tiempo en sus valores característicos de las respuestas, la red τ_η 20 ms. Esto generó la siguiente forma:

$$CGP(\Delta t) = [(1 - \chi) + \chi \cos(2\pi f \Delta t)] \cdot \left(1 + \frac{|\Delta t|}{\tau_E} \right)^{-1} \quad (36)$$

Nosotros usamos $\chi \in \{0, 0.2, 0.7\}$ (donde $\chi = 0$ corresponde a una única neurona aislada) en $\sigma_{GP}^2 = 40$ Hz. Fijamos la media y la varianza del GP en $\mu_{GP} = 0$ y $\sigma_{GP}^2 = 4$, respectivamente, sin pérdida de generalidad (Nota suplementaria de matemáticas).

Para las figuras 7a y 7b, y la figura 9 de datos extendidos, utilizamos GPs cuyas distribuciones estacionarias coincidían con la misma distribución objetivo (véase más abajo) antes del inicio del estímulo (tiempo < 0) y convergían a la misma nueva distribución objetivo tras el inicio del estímulo (para $t \geq 0$). Estos GPs diferían únicamente en su comportamiento transitorio. El GP que capturó con mayor fidelidad nuestra red optimizada se construyó tomando la evolución temporal de la media y la varianza de una neurona real de la red completa alrededor del inicio del estímulo, incluyendo los sobreimpulsos ("con sobreimpulsos" en la figura 7a y la figura 9a de datos extendidos, en rojo). Para ello, elegimos la neurona cuya orientación preferida coincidía con la del estímulo presentado. Además, el autocorrelograma de este GP también se configuró para que coincidiera con el autocorrelograma de esa neurona (recuadro de la figura 9a de datos extendidos, a la derecha). Se construyeron dos GPs adicionales con el mismo autocorrelograma que el primer GP, pero con diferentes cursos temporales de media y varianza. En uno, la media y la varianza convergieron exponencialmente con una constante de tiempo de E ("exponencial" en la Fig. 7a, y la Fig. 9a de Datos Extendidos, discontinua en negro). En el otro, la media y la varianza saltaron inmediatamente al inicio del estímulo a sus nuevos valores estacionarios ("instantáneo" en la Fig. 7a, y la Fig. 9a de Datos Extendidos, discontinua en negro).

gris). Si bien un proceso instantáneo de este tipo no es realizable por ningún sistema dinámico continuo, proporciona un límite inferior útil para el error de muestreo.

En la Fig. 6b y la Fig. 9b de Datos Extendidos, utilizamos la divergencia de Kullback-Leibler simetrizada promedio entre la distribución objetivo GSM, y la distribución muestreada por el GP, $\mathcal{Q}_T$ durante una ventana de tiempo finita T para medir el desempeño de estos sistemas:

$$\overline{DSKL} \left[\mathcal{Q}_T \parallel \mathcal{P} \right] = \frac{1}{4} \left[\left(\mu_{\mathcal{P}}^2(T) \sigma_{\mathcal{P}}^{-2} + \sigma_{\mathcal{Q}}^2 - 2(\mu_{\mathcal{P}}(T) \mu_{\mathcal{Q}}) \right) + \left(\mu_{\mathcal{Q}}^2(T) \sigma_{\mathcal{P}}^{-2} + \sigma_{\mathcal{Q}}^2 - 2(\mu_{\mathcal{Q}}(T) \mu_{\mathcal{P}}) \right) \right] \quad (37)$$

donde $\cdot$ denota promedio de prueba (como arriba), $\mu_{\mathcal{P}}(T) = \mu_{\mathcal{P}}(T)$, $\mu_{\mathcal{Q}}(T) = \mu_{\mathcal{Q}}(T)$, $\sigma_{\mathcal{P}}^2(T)$ y $\sigma_{\mathcal{Q}}^2(T)$ son las medias y varianzas de $\mathcal{P}$ y $\mathcal{Q}_T$, respectivamente (Nota suplementaria de matemáticas).

La figura 7 muestra únicamente el término de DSKL que depende de la media de la muestra, $\mu_{\mathcal{Q}}(T)$ (a través de $\mu_{\mathcal{Q}}(T)$):

$$\overline{DSKL} = \frac{1}{4} \left(\mu_{\mathcal{Q}}^2(T) \sigma_{\mathcal{P}}^{-2} + \sigma_{\mathcal{Q}}^2 - 2(\mu_{\mathcal{Q}}(T) \mu_{\mathcal{P}}) \right) \quad (38)$$

En la Fig. 6b, utilizamos una única distribución objetivo (que coincide con los momentos estacionarios del GP, véase más arriba) y promediamos $n = 100.000$ ensayos de muestreo del GP durante un tiempo creciente (eje x), ya que también variamos la resolución temporal en 0,5 ms. En la Fig. 7b y la Fig. 9b de Datos Extendidos, la distribución objetivo cambió instantáneamente al inicio del estímulo ($t = 0$) a partir de una distribución de respuesta correspondiente a 0.

estímulo de contraste (actividad espontánea) con el correspondiente a un estímulo de alto contraste (imagen de entrenamiento en el nivel de contraste 0,7; Fig. 7a y Datos ampliados Fig. 9b, líneas verdes).

Las distribuciones de respuesta se obtuvieron de la célula E en la red original que fue ajustada a la orientación dominante del estímulo. En cada punto temporal calculado t_x (eje), $\overline{DSKL}(\mathcal{Q}_T \parallel \mathcal{P})$ era entre la distribución objetivo momentánea y la distribución de las muestras de GP recolectadas en una ventana de tiempo deslizante de 100 ms que finaliza en t_x , con un promedio de $n = 10.000$ ensayos, para cada uno de los tres perfiles de transición (líneas). Las GP se muestrearon con una resolución temporal de 1 ms.

Análisis de datos experimentales

La Fig. 7e muestra nuevos análisis de registros experimentales de macacos despiertos V1 durante la presentación de rejillas móviles de diferentes orientaciones²³. Siguiendo el mismo procedimiento que en la Ref. 6, solo se incluyeron en el análisis las células que estaban significativamente sintonizadas (índice de sintonización de orientación mayor de 0,75) y tenían una tasa evocada promedio superior a 1 pico por segundo. Para cada célula y cada estímulo, se obtuvo primero un trazo de tasa de disparo dependiente del tiempo promediando los picos a lo largo de los ensayos en una ventana cuadrada deslizante de 50 ms. A partir de estos trazos, la diferencia en estado estacionario y el tamaño del sobreimpulso (puntos en la parte superior de la Fig. 7e) se calcularon respectivamente como la respuesta evocada promedio excluyendo transitorios (> 160 ms después del inicio del estímulo) y el máximo del trazo de respuesta durante el transitorio (< 160 ms después del inicio del estímulo), menos la respuesta basal promedio (calculada a partir de los 300 ms previos a la presentación del estímulo). Los resultados en el gráfico inferior de la Fig. 7e se calcularon de la misma manera que para las neuronas modelo (ver arriba).

Estadística


Los tamaños de muestra (número de ensayos) se seleccionaron según los siguientes criterios. En primer lugar, al estudiar las propiedades de la red, se seleccionó una muestra lo suficientemente grande (> 10.000 muestras independientes) como para que los errores estándar fueran menores que el ancho de línea en los gráficos correspondientes.

En segundo lugar, al comparar el comportamiento de la red con los resultados experimentales, se seleccionó el mismo orden de magnitud para n que en los experimentos originales.

Las regresiones lineales en la Fig. 7e (arriba) y la Fig. 9d de datos extendidos se realizaron utilizando la función 'linregress' de SciPy, que informa un valor p de dos caras utilizando una prueba de Wald con una distribución t de la estadística de prueba.

En la Fig. 7e (abajo), se comprobó la significancia del ajuste por sobreimpulso mediante una prueba t pareada bilateral con la función 'ttest_rel' de SciPy. Se asumió que la distribución de los datos era normal, pero esto no se comprobó formalmente.

Datos extendidos




Datos extendidos Fig. 1. Parámetros GSM y de red.

a, Filtros: campos proyectivos del GSM y campos receptivos de la red. Cada imagen de filtro muestra el campo proyectivo de una variable latente (columnas de A; Ec. 1), que coincidía con el campo receptivo del par de células EI correspondiente en la red (filas de W [AA] $T/15$; Ec. 14; cf. Fig. 1a y c). b, Covarianza previa en el GSM (C en Ec. 2). c, Estímulos de muestra generados por el GSM, también utilizados para probar la generalización de la red en las Fig. 3b-c. d, Parámetros de la red optimizada. d, Pesos recurrentes (arriba: pesos brutos; centro: valores absolutos normalizados) y covarianza del ruido de proceso (abajo) después del entrenamiento.

Los pesos y las covarianzas se muestran solo para una fila (de cada cuadrante) de W (Ec. 8) y $\Sigma \eta$ (Ec. 11), respectivamente, ya que son circulares. Por lo tanto, cada línea muestra los pesos que conectan, o

La covarianza entre células de diferentes tipos (véase la leyenda) en función de la diferencia en sus estímulos preferidos. Como muestra la figura, el perfil de conectividad de las células E o I en la red optimizada fue en gran medida independiente de si la célula postsináptica era excitadora o inhibidora (arriba). En general, las conexiones recurrentes E e I presentaron amplitudes de sintonización similares, siendo las conexiones E ligeramente más amplias que las I (centro).

Sin embargo, la entrada neta E a cualquier célula de la red seguía estando más estrechamente ajustada que la entrada neta I, debido a que las respuestas de las células presinápticas E estaban más ajustadas que las de las células I (no se muestra). La red optimizada también retuvo una cantidad sustancial de ruido de proceso, mayor en las células E que en las I, y mostró una alta correlación tanto entre las células E e I de un par como entre células con diferente ajuste (hasta una diferencia de ajuste de $\sim 30^\circ$; abajo). e. La no linealidad de entrada (Ec. 14), que convierte las activaciones del campo receptivo de avance ff (W células para el conjunto de entrenamiento se presenta en gris. Como muestra la figura, la transformación de entrada optimizada, que captura los efectos no lineales del preprocesamiento x) i en entradas de red h_j (negro). A modo de comparación, la distribución de las entradas en todos ascendente de los estímulos visuales, tenía un umbral que estaba justo por debajo de la distribución de las salidas del campo receptivo, lo que garantizaba que toda la información relacionada con el estímulo se transmitiera en la señal de entrada, y un exponente cercano a dos, notablemente similar al utilizado por las células de la red (cf. Ec. 9 y tabla S1).




Datos extendidos Fig. 2. Normalización divisiva y el mecanismo subyacente a las oscilaciones en la red optimizada.

ab, La normalización divisiva, o suma sublineal de respuestas neuronales, se ha propuesto como un cálculo canónico en circuitos corticales³⁸. A su vez, se ha propuesto que la red supralineal estabilizada (SSN), que formó el sustrato de nuestra red optimizada, proporciona el mecanismo dinámico subyacente a la normalización divisiva²⁷. Por lo tanto, nos preguntamos si nuestra red optimizada también la exhibía. a, De acuerdo con la normalización divisiva, la respuesta de la red a la suma de dos estímulos (morado sólido) fue menor que la suma de sus respuestas a los estímulos individuales (rojo/azul sólido), y se ubicó entre el promedio (morado punteado) y la suma (morado discontinuo). El recuadro muestra los estímulos utilizados en este ejemplo. b, Normalización divisiva genérica en la red optimizada. Ajustamos un modelo fenomenológico estándar de normalización divisiva (adaptado de la Ref. 38) a las respuestas de tasa de disparo media (entre ensayos) de las células E en la red optimizada, (r_E), como una función de la entrada de avance h a la red (es decir, sin tener en cuenta su dinámica recurrente; Ec. 14):

$$\langle r_o \rangle_i^{(\beta)} = b_2 + \left(\langle r_i \rangle^{(\beta)} + b_1 \right) \left[\left(h_i^{(\beta)} \right) + s_2 \right]^{-1}, \text{ donde } \langle r_i \rangle^{(\beta)} \text{ y } h_i^{(\beta)} \text{ eran la entrada de avance y } y_o$$


la tasa de disparo promedio de la célula i en respuesta al estímulo β , respectivamente, y b_1 , b_2 y s fueron parámetros constantes. La matriz de parámetros M fue responsable de la normalización, dividiendo la entrada h_i por una mezcla de entradas competidoras a otras neuronas. M fue parametrizada como una matriz circulante simétrica para respetar la simetría rotacional de la red entrenada (Datos Extendidos Fig. 1). En total, nuestro modelo de normalización divisiva tuvo $3 + (N \cdot E / 2) + 1 = 29$ parámetros libres. El ajuste del modelo se realizó a través de la minimización de la diferencia cuadrática promedio entre las tasas de la red y del modelo, más un regularizador de energía elástica para elementos vecinos de M . Aquí se muestra un diagrama de dispersión de las respuestas neuronales a un conjunto de 500 estímulos aleatorios (generados como el conjunto de datos de generalización, Métodos), predichos por el modelo fenomenológico vs. producidos por la red real. Cada punto corresponde a un par estímulo-neurona. El recuadro muestra tres perfiles de respuesta promedio representativos en la red (puntos) y el ajuste del modelo fenomenológico (líneas). Obsérvese la superposición casi perfecta entre la red y el modelo fenomenológico en los tres casos. El modelo de normalización divisiva también superó tanto a un modelo lineal como a un modelo de inhibición sustractiva (no mostrado). Estos resultados demuestran claramente que, de acuerdo con los datos empíricos, nuestra red entrenada realizó una normalización divisiva de sus entradas en condiciones generales. *cd*, Uso de la fijación de voltaje para estudiar los mecanismos subyacentes a las oscilaciones en la red optimizada. Para determinar si las oscilaciones en nuestra red se debían a la interacción de las células E e I , o si surgían únicamente dentro de alguna de estas poblaciones, realizamos dos experimentos simulados. En cada simulación, se fijó el voltaje de cualquiera de las dos poblaciones (E o I) a su media (temporal), calculada a partir de la red original, para cada entrada del conjunto de entrenamiento. Por lo tanto, la entrada recurrente de la población fijada se mantuvo prácticamente constante a su media normal, pero no reaccionó a los cambios en la otra población. Como se esperaba para una red en el régimen de inhibición-estabilizada, la fijación de las células I resultó en una dinámica descontrolada inestable, lo que impidió un análisis posterior de las oscilaciones (no se muestra). *c*, Ilustración del experimento de fijación de E en la red optimizada (cf. Fig. 1b). Para cada estímulo, el voltaje de cada célula E se fijó a su voltaje medio, μ_E , obtenido cuando la red se presentó con el mismo estímulo sin fijación de voltaje. *d*, Espectros de potencia LFP en la red después de la fijación de voltaje de la población E en diferentes niveles de contraste (colores como en la Fig. 2). La red permaneció estable, pero el pico en su espectro de potencia LFP característico de las oscilaciones gamma ya no estaba presente (cf. Fig. 5c, recuadro). Esto muestra que las oscilaciones gamma en la red original requerían interacciones entre las células E e I (es decir, se generaron por el llamado mecanismo “PIN



Datos extendidos Fig. 3. Redes aleatorias.

La parametrización de nuestra red fue altamente restringida (p. ej. topología de anillo con estructura de covarianza de ruido de proceso y peso circulante y simétrico, relación E:I 1:1, campos receptivos fijos). Para probar si estas restricciones por sí solas, sin ninguna optimización, fueron suficientes para generar los resultados que obtuvimos en la red optimizada, muestreamos matrices de peso aleatoriamente, extrayendo cada uno de los 8 hiperparámetros de la matriz de peso (Ec. 10) de una distribución exponencial truncada entre 0,1 y 10 veces los valores encontrados originalmente por optimización. Descartamos matrices que eran inestables o que convergían a una solución trivial (todas las tasas medias iguales a 0). Menos del 20% de las matrices generadas cumplieron estos criterios, lo que confirma aún más que la optimización no fue trivial. Se muestran los resultados para seis de tales redes aleatorias de ejemplo (columnas). a, Pesos recurrentes como una función de la diferencia en los estímulos preferidos de dos células (cf. Datos Extendidos Fig. 1d, arriba). Las diferentes líneas representan pesos que conectan células de diferentes tipos (leyenda). bc, media (b) y desviación estándar de las respuestas del potencial de membrana (c), promediadas sobre la población, en función del contraste.


(cf. Fig. 3a). Los puntos grises en el eje x indican los niveles de contraste de entrenamiento. Nótese la amplia gama de comportamientos mostrados por estas redes. Por ejemplo, la desviación estándar de las respuestas podría subir, bajar o incluso ser no monótona con el contraste, mientras que el rango de tasas medias también varió enormemente. de, Tasa media de disparo (d) y factor Fano (e) de neuronas como una función de la orientación del estímulo (relativa a su orientación preferida) durante la actividad espontánea (rojo oscuro) y evocada (naranja claro; cf. Fig. 5a-b). La tasa media pico del ejemplo 3 excedió los 50 Hz y por lo tanto se muestra como recortada en esta figura. Nótese que las curvas de ajuste de la tasa media (durante la actividad evocada) fueron muy estrechas para la mayoría de las redes (todas excepto el ejemplo 5), resultando en tasas de 0 Hz y por lo tanto factores Fano indefinidos para estímulos más alejados de la orientación preferida. f, Espectros de potencia LFP a diferentes niveles de contraste (colores como en la Fig. 2). Obsérvese la ausencia de picos gamma (cf. Fig. 5c, recuadro). g, Respuesta de frecuencia promedio alrededor del inicio del estímulo a diferentes niveles de contraste (colores como en la Fig. 2). Las barras negras muestran el periodo del estímulo. Obsérvese la ausencia de transitorios (cf. Fig. 5d). Para estimar los momentos de red en bd, se utilizaron $n = 20\,000$ muestras independientes (tomadas con 200 ms de diferencia). Se calcularon los promedios poblacionales ($n = 50$ células) para b y c. Las frecuencias de disparo promedio en el panel g se calcularon sobre $n = 100$ ensayos.



Datos extendidos Fig. 4. Comparación de redes aleatorias y optimizadas: costo logrado y características dinámicas.

Las redes se clasifican en todos los paneles en orden decreciente de coste total alcanzado (mostrado en a). Las redes aleatorias son las que se muestran en la Fig. 3 de Datos Extendidos. La red originalmente optimizada que se presenta en el texto principal se indica con *, y la red optimizada sin aplicar el principio de Dale (Fig. 8 de Datos Extendidos) se marca con †. Se estudiaron otras redes optimizadas para confirmar que las redes bien optimizadas mostraban un comportamiento similar de forma fiable. Esto fue importante porque nuestra función de coste era altamente no convexa. Por lo tanto,


cualquier mínimo encontrado por nuestro optimizador, como el correspondiente a la red optimizada originalmente, no tenía garantía de ser el mínimo global. Por lo tanto, entrenamos 10 redes más en la función de costo original (Métodos), comenzando desde condiciones iniciales aleatorias, y mostramos aquí aquellas cuyo costo final fue al menos aproximadamente tan bajo como el de la red original (9 de 10). a, Costo total (Ec. 25) calculado para cada una de las redes aleatorias y (izquierda) para redes que fueron optimizadas para el costo original (derecha). Los colores indican diferentes componentes de la función de costo (leyenda, véanse las Ecs. 26-29 para definiciones matemáticas). El recuadro muestra solo las redes optimizadas (nótese la diferente escala y). Nótese que el costo alcanzado por las redes aleatorias fue de 1 a 3 órdenes de magnitud mayor que el alcanzado por las redes optimizadas. Además, ninguna de las redes optimizadas alcanzó costos sustancialmente menores que el que presentamos en el texto principal. bc, Oscilación (b) y tamaño de sobreimpulso transitorio (c) para cada red en a. La oscilación se calculó mediante ajustes numéricos de la Ec. 33 al autocorrelograma del LFP generado por la red (Métodos). Los transitorios en las tasas de disparo promedio de la población se cuantificaron como el tamaño del sobreimpulso normalizado por el cambio en la media del estado estacionario (véase también la Fig. 7a). Cabe destacar que, en comparación con las redes optimizadas, incluida la —, presentada en el texto principal, las oscilaciones y los transitorios fueron prácticamente inexistentes en las redes aleatorias. Además, todas las redes optimizadas presentaron oscilatoriedad sustancial y sobreimpulsos transitorios (Datos Extendidos, Figs. 4b-c). Esto sugiere que los resultados obtenidos para la red originalmente optimizada fueron representativos de los mínimos alcanzables de la función de costo.



Datos extendidos Fig. 5. Redes de control sin modulación de variabilidad completa.

Las modulaciones de variabilidad son un sello distintivo de la inferencia basada en muestreo⁵. Para determinar si también fueron cruciales para nuestros resultados, optimizamos las redes con funciones de costo modificadas, ya sea estableciendo ambos valores $\mu = 0$ y $\sigma = 0$ (Ec. 25), lo que requiere que solo se emparejen las medias de respuesta (ag; véase también la Fig. 5, columna derecha), o estableciendo solo $\text{cov} = 0$, lo que requiere el emparejamiento de las medias de respuesta y las varianzas, pero no de las covarianzas (hn; véase también Métodos). ab, hi, Parámetros de red como en Datos Extendidos, Fig. 1d-e. Ambas redes desarrollaron pesos de conexión débiles (a y h, arriba), con anchos casi idénticos para las entradas E e I en ambas E.

y células I (a y h, centro), y una transformación de entrada casi lineal (b e i). c, j, Actividad de la población de muestra como en la Fig. 2a. de, kl, Momentos coincidentes entre el observador ideal y la red para estímulos de entrenamiento como en la Fig. 2c-d. El acoplamiento extremadamente débil en la primera red (a, arriba) significó una arquitectura esencialmente de alimentación hacia adelante. Por lo tanto, su covarianza de respuesta simplemente reflejó su covarianza de ruido de proceso (compare e y a, abajo). Las correlaciones de entrada altas en la segunda red (h, abajo) resultaron en un modo único y global de fluctuaciones de salida (l). fg, mn, Generalización para estímulos de prueba como en la Fig. 3a-b. Los recuadros en g muestran las medias de respuesta posterior y de red GSM para estímulos de prueba de ejemplo como en la Fig. 3c. Los momentos de respuesta en n se muestran solo para los estímulos de entrenamiento, no para los estímulos de prueba, sino distinguiendo las varianzas (azul, abajo) y las covarianzas (lavanda, abajo). Ambas redes no lograron ajustar los momentos que no se les exigía explícitamente. Por lo tanto, las curvas de ajuste de la tasa de disparo se conservaron en ambas redes, pero los factores de Fano apenas se modularon en la primera red (Datos Extendidos, Fig. 6a-b). Es crucial que ninguna de estas redes mostrara oscilaciones perceptibles ni sobreimpulsos transitorios (Datos Extendidos, Fig. 6c-e). Los momentos de respuesta en dg y kn se estimaron a partir de $n = 20\,000$ muestras independientes (tomadas con una separación de 200 ms). Los momentos medios de la población en f y m se promediaron además en $n = 50$ células E. Las correlaciones en e y l son correlaciones de Pearson.




Datos extendidos Fig. 6. Comparación de la dinámica neuronal entre la red originalmente optimizada y las redes de control.

ae, Dinámica de redes optimizadas como en la Fig. 5a-e. La red originalmente optimizada del artículo principal (izquierda) se compara con varias redes de control, de izquierda a derecha: sin

Penalización por lentitud (Fig. 10 de Datos Extendidos), sin modulación de covarianza (emparejamiento de medias y varianzas; Fig. 5h-n de Datos Extendidos), sin modulación de covarianza y varianza (emparejamiento de medias únicamente; Fig. 5a-g de Datos Extendidos), aplicando factores de Fano constantes (Fig. 7 de Datos Extendidos) y sin aplicar el principio de Dale (Fig. 8 de Datos Extendidos). Para facilitar la comparación, solo se muestran los espectros de potencia dependientes del estímulo para la red optimizada del artículo principal, sin mostrar la dependencia de la frecuencia pico gamma con el contraste (cf.

Fig. 5c, centro), ya que la mayoría de las redes de control no presentaron picos gamma perceptibles. Para más detalles sobre las redes de control, véanse los títulos de las figuras correspondientes (Datos Extendidos, Figs. 5, 7, 8 y 10). Los momentos de respuesta en a se estimaron a partir de $n = 20\,000$ muestras independientes (tomadas con una separación de 200 ms). Las tasas de disparo medias en d se calcularon a lo largo de $n = 100$ ensayos.


El panel e muestra la media $\pm$ sem ($n = 20$ ensayos).



Datos extendidos Fig. 7. Red de control: imposición de factores Fano constantes.

Los factores Fano deben ser específicamente independientes del estímulo para una clase de modelos, los códigos poblacionales probabilísticos (PPC) (lineales)¹², que proporcionan un vínculo conceptualmente muy diferente entre la variabilidad neuronal y la representación de la incertidumbre que el proporcionado por el muestreo^{5,18}, que perseguimos aquí. Por lo tanto, utilizamos nuestro enfoque basado en la optimización para comparar directamente la dinámica del circuito requerida por los PPC con la de nuestra red originalmente optimizada que implementaba el muestreo. Para ello, entrenamos una red de control adicional cuyo objetivo era igualar la modulación media de la red de control (lo que resultó en curvas de ajuste realistas), manteniendo constantes los factores Fano. Logramos esto mediante el diseño de un conjunto de covarianzas objetivo que resultarían (junto con las respuestas medias objetivo utilizadas por todas las demás redes) en factores Fano constantes, asumiendo un efecto de Poisson y una función de autocorrelación decreciente exponencialmente (utilizando los resultados analíticos en la referencia 52). El entrenamiento posterior

procedió exactamente como para las otras redes, con los mismos parámetros e en la función de costo que para la red originalmente optimizada, solo empleando los nuevos objetivos de covarianza. ab, Parámetros de red como en Datos Extendidos Fig. 1d-e. La red hizo uso de fuertes conexiones inhibitorias (a, arriba), gran ruido de proceso compartido (a, abajo) y entradas fuertemente moduladas (b). c, Actividad de población de muestra como en la Fig. 2a. de, Momentos de coincidencia entre el observador ideal y la red para estímulos de entrenamiento como en la Fig. 2c-d. fg, Generalización para estímulos de prueba como en la Fig. 3a-b. Los recuadros en g muestran las medias de respuesta posterior y de red GSM para estímulos de prueba de ejemplo como en la Fig. 3c. La red fue capaz de hacer coincidir las respuestas medias en el conjunto de entrenamiento y generalizar a estímulos nuevos (d, fg), mientras mantenía los factores Fano relativamente constantes según lo requerido (Datos Extendidos Fig. 6b). Para mantener la coherencia con los resultados previos, obtuvimos los factores Fano simulando numéricamente el mismo tipo de proceso Gamma no homogéneo que en las otras redes (Métodos), violando así los supuestos de Poisson spiking bajo los cuales calculamos las covarianzas objetivo de la red (véase más arriba); de ahí las pequeñas modulaciones restantes de los factores Fano. Esencialmente, aunque el procedimiento de entrenamiento fue idéntico al utilizado para la red original, difiriendo únicamente en la modulación de variabilidad requerida proporcionada por los objetivos (véase más arriba), esta red de control no mostró oscilaciones en la banda gamma (Datos Extendidos Fig. 6c). Surgieron transitorios dominados por inhibición, pero fueron más débiles que en la red original (Datos Extendidos Fig. 6d y e). Los momentos de respuesta en dg se estimaron a partir de $n = 20.000$ muestras independientes (tomadas con 200 ms de diferencia). Los momentos medios poblacionales en f se promediaron adicionalmente en $n = 50$ células E. Las correlaciones en e son correlaciones de Pearson.




Datos extendidos Fig. 8. Red de control: el principio de Dale no se aplica.

Para determinar en qué medida las restricciones biológicas que utilizamos para la red optimizada, y en particular la aplicación del principio de Dale, eran necesarias para lograr el rendimiento y el comportamiento dinámico de la red original, optimizamos una red con la misma función de coste que la red original (Ec. 25), pero sin aplicar el principio de Dale. Esto significó que los signos de los pesos sinápticos en cada cuadrante de la matriz de pesos (los coeficientes a XY en la Ec. 10) no estaban restringidos. Por lo demás, la optimización procedió del mismo modo que antes (Métodos). El entrenamiento de esta red resultó ser mucho más difícil y propenso a generar redes inestables, lo cual evitamos mediante una detención temprana. ab, Parámetros de red como en Datos Extendidos Fig. 1d-e. Como no se aplicó el principio de Dale, solo se pueden mostrar los tipos de células nocionales (leyenda). Sin embargo, curiosamente, la red seguía obedeciendo al principio de Dale tras la optimización (arriba): todas las sinapsis salientes de cualquier célula tenían el mismo signo. Nótese que los pesos salientes de las células cuyos momentos fueron restringidos (células E, cuya actividad se muestra y analiza en cg) fueron realmente negativos. Por lo tanto, en efecto, estas células se volvieron inhibitorias durante el entrenamiento. c, Actividad de la población de muestra como en la Fig. 2a. de, Momentos de coincidencia entre el observador ideal y la red para estímulos de entrenamiento como en la Fig. 2c-d. f, Generalización a estímulos de prueba como en la Fig. 3a. g, Momentos de coincidencia entre el observador ideal y la red para estímulos de entrenamiento como en la Fig. 3b (lavanda). Nótese que aquí, a diferencia de la Fig. 3, los momentos de respuesta se muestran solo para estímulos de entrenamiento, no para estímulos de prueba, sino distinguiendo varianzas (azul, abajo) y covarianzas (lavanda, abajo).

En general, el comportamiento de esta red fue similar al de la red optimizada originalmente (véanse las figuras 2 y 3). Por lo tanto, logró un rendimiento muy superior al de las redes aleatorias (Fig. 4a de Datos Extendidos). Sin embargo, su rendimiento fue considerablemente inferior al de las redes optimizadas con el principio de Dale aplicado (Fig. 4a de Datos Extendidos), y también fue cualitativamente diferente: prácticamente no presentó oscilaciones ni sobreimpulsos transitorios (Fig. 4b-c de Datos Extendidos, Fig. 6 de Datos Extendidos).


Los momentos de respuesta en dg se estimaron a partir de $n = 20\,000$ muestras independientes (tomadas con una separación de 200 ms). Los momentos de respuesta promedio poblacional en f se promediaron adicionalmente en $n = 50$ celdas E. Las correlaciones en e son correlaciones de Pearson.



Datos ampliados Figura 9. Análisis adicionales del papel de los transitorios en el apoyo a la inferencia continua.

ab, Análisis de transitorios en la respuesta de una sola neurona. (El panel izquierdo en a se reproduce de la Fig. 7a). a, Evolución temporal del potencial de membrana medio (u) (izquierda) y la desviación estándar del potencial de membrana (derecha) en tres respuestas neuronales diferentes (líneas gruesas) con autocorrelaciones idénticas (coincidentes con las autocorrelaciones neuronales en la red completa, recuadro, cf. Fig. 4a), pero con diferentes medias dependientes del tiempo (izquierda) y desviaciones estándar (derecha). La línea verde delgada muestra la media variable en el tiempo del objetivo (izquierda) y la desviación estándar (derecha). b, Divergencia total (Ec. 37, Métodos) entre la distribución del objetivo en un punto dado en el tiempo y la distribución representada por la actividad neuronal muestreada en los 100 ms anteriores, para cada una de las tres respuestas (colores como en a). En comparación, tenga en cuenta que la Fig. 7b solo muestra el término dependiente de la media de la divergencia (Ec. 38, Métodos). Las barras negras en ab muestran el período del estímulo. Media y divergencia calculadas como un promedio en múltiples ensayos ($n = 10,000$). c, Trayectorias de respuesta óptimas (líneas rojas) para la estimación continua de la media de una distribución del objetivo (líneas verdes delgadas). Diferentes tonos de rojo indican trayectorias óptimas correspondientes a tres niveles objetivo diferentes (5, 10 y 20 mV, emulando diferentes niveles de contraste). Optimizamos las trayectorias de respuesta neuronal (Ec. S39, Nota matemática suplementaria) de modo que la distancia entre su promedio temporal, calculado utilizando un filtro de caja prospectivo ($\tau = 10$ ms) y 0 en caso contrario, con $\tau = 20$ ms, y la señal objetivo de paso de Heaviside correspondiente se minimizara bajo una restricción de suavidad ($\text{smooth} = 1$; Ec. S37, Nota matemática suplementaria). Nótese que el sobreimpulso transitorio en la respuesta óptima se asemeja mucho a los observados en la red optimizada (Fig. 5d, Fig. 7c-d): su magnitud escala con el valor de la media objetivo y es seguida por oscilaciones amortiguadas. Se obtuvieron resultados similares (con menos oscilación después del sobreimpulso) también para un kernel "con fugas" de decaimiento exponencial (no se muestra). d, Relación entre la magnitud del sobreimpulso y la diferencia de estado estacionario: análisis de grabaciones experimentales de

macaco despierto V1 23. d, Magnitud de sobreimpulso versus diferencia de estado estable: igual que la Fig. 7e, pero restringiendo el análisis a diferencias de estado estable por debajo de 60 Hz (para excluir valores atípicos). La línea roja muestra la regresión lineal (bandas de confianza de $\pm 95\%$). La correlación entre el tamaño del sobreimpulso y la diferencia en estado estacionario sigue siendo significativa: prueba de Wald bilateral $R^2 = 0.27$ ($n = 1263$ pares célula-estímulo). e, la modificación sistemática de la diferencia máxima en estado estacionario (eje x) utilizada para restringir el análisis de la correlación entre el tamaño del sobreimpulso y la diferencia en estado estacionario (d y Fig. 7e) revela que la correlación es robusta (línea negra $\pm 95\%$ intervalos de confianza) y sigue siendo altamente significativa (línea azul, que muestra los valores p correspondientes; nótese la escala logarítmica) para todos los umbrales excepto el más pequeño (y, por lo tanto, el tamaño muestral más pequeño). Las líneas punteadas horizontales muestran una correlación = 0 (negra) y un nivel de significancia = 0,05 (azul) como referencia. A medida que aumenta la diferencia máxima en estado estacionario, el número de puntos. Las También se consideran aumentos de $n = 4$ a $n = 1279$. correlaciones en a son correlaciones de Pearson. R Los valores y los valores p correspondientes en e se obtuvieron mediante regresión lineal realizada como en d.



Datos extendidos Fig. 10. Red de control: sin penalización de lentitud explícita.

Para comprobar si la penalización explícita por lentitud en nuestra función de coste (Ec. 29) era necesaria para obtener el comportamiento dinámico mostrado por la red optimizada del texto principal, establecimos $\text{eslow} = 0$ en la Ec. 25. ab, Parámetros de red como en Datos Extendidos Fig. 1d-e. c, Actividad de la población de muestra como en la Fig. 2a. de, Momentos de coincidencia entre el observador ideal y la red para estímulos de entrenamiento como en las Fig. 2c-d. f, Generalización para estímulos de prueba como en la Fig. 3a. g, Momentos de coincidencia entre el observador ideal y la red para estímulos de entrenamiento como en la Fig. 3b (lavanda). Nótese que aquí, a diferencia de la Fig. 3, los momentos de respuesta se muestran solo para el entrenamiento.

Estímulos, no para estímulos de prueba, sino distinguiendo varianzas (azul, inferior) y covarianzas (lavanda, inferior). Cabe destacar que esta red se comportó prácticamente de forma idéntica a la red optimizada originalmente (véase también la Fig. 6 de Datos Extendidos). Esto podría atribuirse a que nuestra optimización implícitamente promovió el muestreo rápido por defecto, simplemente mediante el uso de una ventana de promediado finita para calcular los momentos promedio de las respuestas de la red, y en particular mediante la inclusión de muestras inmediatamente o poco después del inicio del estímulo (Métodos). Los momentos de respuesta en dg se estimaron a partir de $n = 20\,000$ muestras independientes (tomadas con una separación de 200 ms). Los momentos medios de la población en f se promediaron además en $n = 50$ células E. Las correlaciones en e son correlaciones de Pearson.

Material complementario

Consulte la versión web en PubMed Central para obtener material complementario.

Expresiones de gratitud

Este trabajo contó con el apoyo del Wellcome Trust (Premio a Investigador Nuevo 095621/Z/11/Z y Premio a Investigador en Ciencias 212262/Z/18/Z para ML, y Premio Semilla 202111/Z/16/Z para GH) y del Programa Científico Fronteras Humanas (Beca de Investigación RGP0044/2018 para ML). Agradecemos a A. Ecker, P. Berens, M. Bethge y A.

Agradecemos a los autores por hacer públicos sus datos, a G. Orbán, A. Bernacchia, R. Haefner e Y. Ahmadian por sus útiles debates, y a JP Stroud por sus comentarios detallados sobre el manuscrito.

Disponibilidad de datos

Todos los datos experimentales informados aquí han sido recopilados por otros y publicados previamente.

Los datos experimentales de las Fig. 5a-b reproducen los análisis de la Ref. 6 de los datos de la Ref. 23 (datos publicados en el repositorio de la Ref. 57). Los datos experimentales de las Fig. 5c-d se obtuvieron directamente de las gráficas de los artículos originales, Refs. 2-4. Los datos experimentales de la Fig. 7 constituyen un análisis novedoso de los datos de la Ref. 23, con la autorización de los autores. El código y los parámetros para generar los datos correspondientes a los experimentos numéricos del artículo se han hecho públicos (véase la declaración de disponibilidad del código más adelante).

Disponibilidad del código

El código (Python) y los parámetros para los experimentos numéricos están disponibles en bitbucket.org/RSE_1987/ssn_inference_numerical_experiments. El código (OCaml) para el procedimiento de optimización está disponible en bitbucket.org/RSE_1987/ssn_inference_optimizer.

Referencias

1. Churchland M, et al. El inicio del estímulo apaga la variabilidad neuronal: un fenómeno cortical generalizado. *Neurociencia de la Naturaleza*. 2010; 13:369. [PubMed: 20173745]
2. Haider B, Häusser M, Carandini M. La inhibición domina las respuestas sensoriales en la corteza despierta. *Naturaleza*. 2013; 493:97–100. [PubMed: 23172139]
3. Ray S, Maunsell JH. Las diferencias en las frecuencias gamma en la corteza visual restringen sus posibles usos en computación. *Neuron*. 2010; 67:885–896. [PubMed: 20826318]
4. Roberts M, et al. Coherencia gamma robusta entre V1 y V2 de macaco mediante coincidencia dinámica de frecuencias. *Neuron*. 2013; 78:523–536. [PubMed: 23664617]
5. Orbán G, Berkes P, Fiser J, Lengyel M. Variabilidad neuronal y representaciones probabilísticas basadas en muestreo en la corteza visual. *Neuron*. 2016; 92:530–543. [PubMed: 27764674]

6. Hennequin G, Ahmadian Y, Rubin D, Lengyel M, Miller K. El régimen dinámico de la corteza sensorial: la dinámica estable en torno a un único atractor ajustado al estímulo explica los patrones de variabilidad del ruido. *Neuron*. 2018; 98:846–860. [PubMed: 29772203]
7. Buzsáki G, Wang X. Mecanismos de las oscilaciones gamma. *Revista anual de neurociencia*. 2012; 35:203–225.
8. Gray C, König P, Engel A, Singer W. Las respuestas oscilatorias en la corteza visual del gato exhiben interacción Sincronización columnar que refleja las propiedades globales del estímulo. *Nature*. 1989; 338:334–337. [PubMed: 2922061]
9. Akam T, Kullmann D. Las oscilaciones y las redes de filtrado favorecen el enrutamiento flexible de la información. *Neurona*. 2010; 67:308–320. [PubMed: 20670837]
10. Masquelier T, Hugues E, Deco G, Thorpe S. Oscilaciones, codificación de fase de disparo y plasticidad dependiente del tiempo de pico: un esquema de aprendizaje eficiente. *Journal of Neuroscience*. 2009; 29:13484–13493. [PubMed: 19864561]
11. Bastos A, et al. Microcircuitos canónicos para codificación predictiva. *Neuron*. 2012; 76:695–711. [PubMed: 23177956]
12. Ma W, Beck J, Latham P, Pouget A. Inferencia bayesiana con códigos poblacionales probabilísticos. *Nature Neurociencia*. 2006; 9:1432–1438. [PubMed: 17057707]
13. Berkes P, Orbán G, Lengyel M, Fiser J. La actividad cortical espontánea revela las características de un modelo interno óptimo del entorno. *Science*. 2011; 331:83–87. [PubMed: 21212356]
14. Shadlen M, Movshon J. Sincronía sin límites: una evaluación crítica de la vinculación temporal Hipótesis. *Neuron*. 1999; 24:67–77. [PubMed: 10677027]
15. Thiele A, Stoner G. La sincronía neuronal no se correlaciona con la coherencia del movimiento en el área cortical. MT. *Nature*. 2003; 421:366–370. [PubMed: 12540900]
16. Tiesinga P, Sejnowski T. Iluminación cortical: ¿son las oscilaciones gamma atencionales impulsadas por ING? ¿O PING? *Neuron*. 2009; 63:727–732. [PubMed: 19778503]
17. Knill, D., Richards, W. La percepción como inferencia bayesiana. Cambridge University Press; 1996.
18. Fiser J, Berkes P, Orbán G, Lengyel M. Percepción y aprendizaje estadísticamente óptimos: desde Del comportamiento a las representaciones neuronales. *Tendencias en Ciencias Cognitivas*. 2010; 14:119–130. [PubMed: 20153683]
19. Deneve S, Latham P, Pouget A. Computación eficiente e integración de señales con población ruidosa Códigos. *Nature Neuroscience*. 2001; 4:826. [PubMed: 11477429]
20. Haefner R, Berkes P, Fiser J. Toma de decisiones perceptual como inferencia probabilística mediante muestreo neuronal. *Neuron*. 2016; 90:649–660. [PubMed: 27146267]
21. Bányai M, et al. La complejidad del estímulo configura las correlaciones de respuesta en la corteza visual primaria. *Actas de la Academia Nacional de Ciencias*. 2019; 116:2723–2732.
22. Sohl-Dickstein J, Mudigonda M, DeWeese M. Monte Carlo hamiltoniano sin balance detallado. *arXiv preimpresión arXiv*: 1409.5191. 2014
23. Ecker A, et al. Activación neuronal descorrelacionada en microcircuitos corticales. *Science*. 2010; 327:584–587. [PubMed: 20110506]
24. Wainwright, M, Simoncelli, E. Mezclas de escala de gaussianas y estadísticas de imágenes naturales. *Avances en sistemas de procesamiento de información neuronal*. 2000. 855–861.
25. Coen-Caglies R, Kohn A, Schwartz O. Control flexible de influencias contextuales en la visión natural. *Neurociencia de la naturaleza*. 2015
26. Schwartz O, Sejnowski T, Dayan P. Organización perceptual en la ilusión de inclinación. *Journal of Vision*. 2009; 9:19–19.
27. Ahmadian Y, Rubin D, Miller K. Análisis de la red supralineal estabilizada. *Neuronal Computación*. 2013; 25:1994–2037. [PubMed: 23663149]
28. Priebe N, Ferster D. Inhibición, umbral de pico y selectividad del estímulo en la corteza visual primaria. *Neurona*. 2008; 57:482–497. [PubMed: 18304479]
29. van Vreeswijk C, Sompolinsky H. Estado caótico equilibrado en un modelo de circuitos corticales. *Neuronal Computación*. 1998; 10:1321–1371. [PubMed: 9698348]
30. Hennequin G, Vogels T, Gerstner W. El control óptimo de la dinámica transitoria en redes balanceadas facilita la generación de movimientos complejos. *Neuron*. 2014; 82:1394–1406. [PubMed: 24945778]

31. MacKay, D. Teoría de la información, inferencia y algoritmos de aprendizaje. Cambridge University Press; 2003.
32. Murray J, et al. Una jerarquía de escalas de tiempo intrínsecas a lo largo de la corteza de primates. *Nature Neuroscience*. 2014; 17:1661. [PubMed: 25383900]
33. Grabska-Barwinska, A, Beck, J, Pouget, A, Latham, P. Desmezcla de olores: inferencia rápida en olfacción. *Avances en sistemas de procesamiento de información neuronal*. 2013. 1968–1976.
34. Buesing L, Bill J, Nessler B, Maass W. Dinámica neuronal como muestreo: un modelo para computación estocástica en redes recurrentes de neuronas en pico. *PLoS computational biology*. 2011; 7:e1002211. [PubMed: 22096452]
35. Savin, C, Deneve, S. Representaciones espacio-temporales de la incertidumbre en redes neuronales de picos. *Avances en sistemas de procesamiento de información neuronal*. 2014. 2024–2032.
36. Hennequin, G, Aitchison, L, Lengyel, M. Inferencia basada en muestreo rápido en redes neuronales equilibradas. *Avances en sistemas de procesamiento de información neuronal*. 2014. 2240–2248.
37. Okun M, Lampl I. Correlación instantánea de la excitación y la inhibición durante actividades continuas y sensoriales. *Nature Neuroscience*. 2008; 11:535. [PubMed: 18376400]
38. Carandini M, Heeger D. Normalización como cálculo neuronal canónico. *Nature Reviews Neuroscience*. 2012; 13:51.
39. Echeveste R, Hennequin G, Lengyel M. Propiedades de escala asintóticas de la media y la varianza posteriores en el modelo de mezcla de escala gaussiana. Preimpresión de arXiv: 1706.00925. 2017
40. Yamins D, et al. Modelos jerárquicos optimizados para el rendimiento predicen respuestas neuronales en la corteza visual superior. *Actas de la Academia Nacional de Ciencias*. 2014; 111:8619–8624.
41. Festa, D, Hennequin, G, Lengyel, M. Memorias analógicas en una red equilibrada basada en tasa de neuronas IE. *Avances en sistemas de procesamiento de información neuronal*. 2014. 2231–2239.
42. Song H, Yang G, Wang X. Entrenamiento de redes neuronales recurrentes excitatorio-inhibitorias para tareas cognitivas: Un marco simple y flexible. *PLoS computational biology*. 2016; 12:e1004792. [PubMed: 26928718]
43. Orhan, A, Ma W. Inferencia probabilística eficiente en redes neuronales genéricas entrenadas con retroalimentación no probabilística. *Nature Communications*. 2017; 8:138.
44. Remington E, Narain D, Hosseini E, Jazayeri M. Cálculos sensoriomotores flexibles mediante la reconfiguración rápida de la dinámica cortical. *Neuron*. 2018; 98:1005–1019. [PubMed: 29879384]
45. Mante V, Sussillo D, Shenoy K, Newsome W. Computación dependiente del contexto mediante dinámica recurrente en la corteza prefrontal. *Nature*. 2013; 503:78. [PubMed: 24201281]
46. Aitchison L, Lengyel M. El cerebro hamiltoniano: inferencia probabilística eficiente con dinámica de circuitos neuronales excitatorios-inhibitorios. *PLoS computational biology*. 2016; 12:e1005186. [PubMed: 28027294]
47. Rao R, Ballard D. Codificación predictiva en la corteza visual: una interpretación funcional de algunos efectos extraclásicos del campo receptivo. *Nature Neuroscience*. 1999; 2:79. [PubMed: 10195184]
48. Keller G, Mrsic-Flogel T. Procesamiento predictivo: un cálculo cortical canónico. *Neuron*. 2018; 100:424–435. [PubMed: 30359606]
49. Vinck M, Bosman C. Más gamma, más predicciones: la sincronización gamma como mecanismo clave para la integración eficiente de las entradas del campo receptivo clásico con las predicciones del entorno. *Fronteras en neurociencia de sistemas*. 2016; 10:35. [PubMed: 27199684]
50. Roelfsema P, Lamme V, Spekreijse H. Sincronía y covariación de las tasas de disparo en el primario Corteza visual durante la agrupación de contornos. *Nature Neuroscience*. 2004; 7:982. [PubMed: 15322549]
51. Dayan, P, Abbott, L. *Neurociencia teórica*. Vol. 806. Cambridge, MA: MIT Press; 2001.
52. Hennequin G, Lengyel M. Caracterización de la variabilidad en redes neuronales recurrentes no lineales. Preimpresión de arXiv: 1610.03110. 2016
53. Werbos P. Retropropagación a través del tiempo: qué hace y cómo hacerlo. *Actas del IEEE*. 1990; 78:1550–1560.
54. Kingma D, Ba J. Adam: Un método para la optimización estocástica. Preimpresión de arXiv arXiv: 1412.6980. 2014

55. Zhu C, Byrd R, Lu P, Nocedal J. Algoritmo 778: L-BFGS-B: Subrutinas Fortran para optimización a gran escala con restricciones de acotación. *ACM Transactions on Mathematical Software (TOMS)*. 1997; 23:550–560.
56. Williams, C, Rasmussen, C. *Procesos gaussianos para el aprendizaje automático*. Vol. 2. MIT Press; Cambridge, MA: 2006.
57. Ecker A, et al. Dependencia del estado de las correlaciones de ruido en la corteza visual primaria del macaco. *Neuron*. 2014; 82:235–248. [PubMed: 24698278]




Fig. 1. El modelo generativo estadístico y el circuito neuronal correspondiente que implementa la inferencia probabilística basada en muestreo.

a, Esquema del modelo generativo de mezcla de escala gaussiana (GSM). Un parche de imagen se construye como una combinación lineal de un conjunto fijo de características localizadas y orientadas, similares a un filtro de Gabor (campos proyectivos, que difieren únicamente en sus orientaciones, distribuidos uniformemente entre -90° y 90°), con intensidades de características específicas del estímulo (variables latentes) extraídas de una distribución gaussiana multivariante. El parche de imagen resultante se escala mediante una variable de contraste global y se corrompe por ruido (no se muestra). (El estímulo mostrado es solo ilustrativo: el

El modelo GSM empleado aquí no era lo suficientemente complejo para generar imágenes fotorrealistas.

Para ver una muestra de parches de imagen generados, consulte la Figura 3c y la Figura 1c de Datos Extendidos.) b, 2-proyección dimensional de la distribución posterior sobre variables latentes dado un estímulo visual, calculada por el observador ideal bayesiano bajo el modelo generativo. c, Una red neuronal excitatoria-inhibitoria (E-I) que recibe un parche de imagen como entrada, filtrado por campos receptivos de avance idénticos a los campos proyectivos del modelo generativo en a.

La actividad de cada célula E representa el valor de una variable latente en el modelo generativo. Como ilustración de la topología en anillo de la red, se muestran las conexiones salientes de un par de células EI (la intensidad de la conexión se indica mediante el ancho de línea y el tamaño de la sinapsis; véanse los detalles en el texto). d, Respuestas de las dos células E correspondientes a las variables latentes mostradas en b. La trayectoria de respuesta se muestra a partir de la distribución posterior correspondiente a lo largo del tiempo, dado el mismo estímulo.




Fig. 2. Inferencia y respuestas en la red optimizada.

a, Actividad poblacional de muestra de potenciales de membrana de células excitatorias (u_E (color) en cero (E) (arriba) y alto contraste (abajo). El estímulo de alto contraste tiene una orientación dominante de 0° (flecha). Las neuronas están ordenadas según su orientación preferida. b, Izquierda: Estímulos en el conjunto de entrenamiento (el sombreado del color del marco indica el nivel de contraste; la división en verde y rojo indica que se utilizaron los mismos estímulos como entrada para el observador ideal y la red neuronal). Derecha: Elipses de covarianza (2 desviaciones estándar) de las distribuciones posteriores del observador ideal (verde) y de las distribuciones de respuesta correspondientes de la red (rojo). Las trayectorias en rojo muestran secuencias de muestra de 500 ms de actividades en la red. Se muestran proyecciones para dos variables latentes/células E representativas, con campos proyectivos/receptivos en las orientaciones preferidas de 42° y 16° (recuadros al final de los ejes). c, Media (arriba) y desviación estándar (abajo) de las variables latentes bajo la distribución posterior del observador ideal (izquierda, verde) y de los potenciales de membrana de las células E bajo la distribución estacionaria de la red (derecha, rojo), ordenada por

Su orientación preferida para cada estímulo del conjunto de entrenamiento. d, Matrices de correlación de las distribuciones posteriores del observador ideal (izquierda, verde) y las distribuciones de respuesta estacionarias de la red (derecha, rojo). Los colores de las líneas en c y los colores de los marcos en d corresponden a diferentes niveles de contraste, los mismos colores que los marcos de estímulo en b. Los momentos de respuesta en c y d se estimaron a partir de $n = 20\,000$ muestras independientes (tomadas con una separación de 200 ms). Las correlaciones en d son correlaciones de Pearson.




Fig. 3. Generalización en la red optimizada.

a, Media y desviación estándar de las variables latentes (verde) y respuestas estacionarias de la red (rojo) promediadas sobre la población, en función del contraste. Los círculos y los puntos grises en el eje x indican los niveles de contraste de entrenamiento. La red se generaliza correctamente a los niveles de contraste sin entrenamiento (segmentos entre círculos). b, Media estacionaria (arriba) y covarianza (abajo) durante la actividad de la red (eje y) frente a la actividad posterior (eje x). Cada punto corresponde a la respuesta de una célula individual (arriba) o un par de células (abajo) a uno de los estímulos entrenados (lavanda) o a uno de los estímulos nuevos sin entrenamiento del conjunto de prueba (naranja). c, Ejemplos de

Generalización en la red. Cada fila corresponde a un estímulo diferente y muestra los momentos estadísticos correspondientes de las variables latentes bajo la respuesta posterior GSM (verde) y las respuestas estacionarias en la red (roja). Como referencia, la fila superior muestra uno de los estímulos de entrenamiento. Las cinco filas inferiores muestran la generalización a nuevos estímulos de prueba.

Izquierda: estímulos de ejemplo. Centro: GSM (verde) y medias de la red (roja), y los tres primeros componentes principales de la covarianza GSM, escalados por la raíz cuadrada de la varianza que explican de la respuesta posterior GSM (verde) y de la covarianza de la red (roja). Derecha: Matrices de correlación de las distribuciones posteriores del observador ideal (izquierda, cuadros verdes) y las distribuciones de respuesta de la red (derecha, cuadros rojos). Los momentos de respuesta en todos los paneles se estimaron a partir de $n = 20.000$ muestras independientes (tomadas con 200 ms de diferencia). Los momentos de la media poblacional en a se promediaron adicionalmente en $n = 50$ celdas E. Las correlaciones en c son correlaciones de Pearson.




Fig. 4. Correlaciones temporales en la red optimizada.

a, Autocorrelaciones del potencial de membrana (promedio de la población) en la red para niveles crecientes de contraste de estímulo (de rojo oscuro a pálido; mismos colores que en las figuras 2b–d). La autocorrelación de una red puramente de propagación hacia adelante (con el mismo ruido de proceso) se muestra para comparación (línea negra discontinua), junto con las del ruido de proceso (línea negra punteada) y una colección de redes que implementan el muestreo de Langevin en cada nivel de contraste (de gris oscuro a claro). b, Correlación cruzada retardada (izquierda) en el muestreador de Langevin (arriba) y en la red E–I optimizada (abajo), descompuesta en componentes temporalmente simétricos (centro) y antisimétricos (derecha). Cada línea corresponde a un par de células diferente (se muestran 3 pares representativos), el color codifica la identidad de las células participantes (E o I, tenga en cuenta que no hay separación de células E e I en las redes de Langevin). c, Retraso entre las entradas totales de E e I a cada célula E, en función de la orientación del estímulo (en relación con la orientación preferida) en diferentes niveles de contraste (colores).




Fig. 5. Dinámica de tipo cortical en la red optimizada.

Izquierda: datos experimentales; centro: red optimizada; derecha: red de control entrenada para modular sus respuestas medias, pero no su variabilidad. ab, Tasa media de activación (a) y factor de Fano (b) de las neuronas en función de la orientación del estímulo (en relación con la orientación preferida) durante la actividad espontánea (rojo oscuro) y evocada (naranja claro). Los resultados experimentales muestran la media $\pm$ sem ($n = 99$ células). c, Frecuencia gamma máxima en el espectro de potencia del potencial de campo local (LFP) en función del contraste. El recuadro de la red optimizada y el panel principal de la red de control muestran los espectros de potencia del LFP a diferentes niveles de contraste (colores como en las figuras 2 y 3).

4). Nótese que no se muestra dependencia de la frecuencia gamma para la red de control ya que no hubo picos gamma discernibles en sus espectros de potencia. Los resultados experimentales muestran media $\pm$ DE ($n = 14$ sesiones). d, Respuesta de frecuencia promedio alrededor del inicio del estímulo a diferentes niveles de contraste (colores). e, Conductancia excitatoria e inhibitoria (media $\pm$ EEM, relativa a la línea base, ver Métodos para detalles) durante una respuesta de estímulo transitoria. Los resultados experimentales muestran media $\pm$ EEM ($n = 8$ ensayos). Los resultados numéricos muestran media $\pm$ EEM ($n = 20$ ensayos). Las barras negras en d muestran el período del estímulo. Los paneles ab reproducen análisis de la Ref. 6 de datos de la Ref. 23 (macaco despierto V1). Los datos experimentales en c se reprodujeron de la Ref. 4 (macaco despierto V1), en d se reprodujeron de la Ref. 3 (macaco despierto V1) y en e se reprodujeron de la Ref. 2 (ratón despierto V1).




Fig. 6. Las oscilaciones mejoran el tiempo de mezcla.

ab, Análisis de oscilaciones en la respuesta de una sola neurona. a, Espectros de potencia de tres respuestas neuronales diferentes (líneas de color) con media y varianza idénticas, pero diferentes grados de oscilatoriedad. Recuadro: Funciones de autocorrelación. La línea punteada negra representa la autocorrelación del ruido de proceso. b, Divergencia entre la distribución estimada a partir de un tiempo de muestreo finito (eje x) y la distribución estacionaria real para los tres sistemas (colores como en a).

cd, Análisis de oscilaciones en la red completa. c, Espectros de potencia de la actividad neuronal de la red a lo largo de las direcciones de los componentes principales (CP) de su distribución de respuesta estacionaria, ordenados por rango de CP (colores). Recuadro: Autocorrelación de la actividad neuronal a lo largo de las direcciones del 1.er y el 10.º CP (colores como en el gráfico principal).

d, Oscilación del autocorrelograma a lo largo de cada componente principal (colores como en c) en función de la fracción.

De la varianza total de las respuestas que capturan. Cabe destacar que nuestra medida de oscilatoriedad se basa en las contribuciones relativas de un componente oscilatorio frente a uno no oscilatorio en un ajuste paramétrico al autocorrelograma y, por lo tanto, es invariante a la magnitud general de las fluctuaciones (que se descompone mediante la autocorrelación en lugar de la autocovarianza de las respuestas). Métodos. Las barras de error muestran la media $\pm$ sem ($n = 50$ estímulos).




Fig. 7. Los transitorios admiten la inferencia continua.

ab, Análisis de transitorios en la respuesta de una sola neurona. a, Evolución temporal del potencial de membrana medio (izquierda) y su promedio móvil (derecha), en tres respuestas neuronales diferentes (líneas gruesas) con autocorrelaciones idénticas (coincidentes con las autocorrelaciones neuronales en la red completa, Fig. 9a de Datos Extendidos; cf. Fig. 6), pero con diferentes medias dependientes del tiempo (mostradas aquí) y varianzas (Fig. 9a de Datos Extendidos). La línea verde delgada muestra la media del objetivo variable en el tiempo. b, Divergencia entre la distribución del objetivo en un momento dado y la distribución representada por la actividad neuronal muestreada en los 100 ms anteriores, para cada una de las tres respuestas (colores como en a). Aquí se muestra el término dependiente de la media de la divergencia, que depende de la diferencia entre la media del objetivo y el promedio móvil de las muestras (mostrado en a, derecha; véase la Fig. 9b de Datos Extendidos para la divergencia completa). ab Negro

Las barras muestran el período del estímulo. La media y la divergencia se calcularon como un promedio de múltiples ensayos ($n = 10.000$). c, Arriba: magnitud del sobreimpulso frente a la diferencia en el estado estacionario de los potenciales de membrana (véase a para la leyenda). Cada punto corresponde a la respuesta de una célula a un estímulo particular. Abajo: magnitud del sobreimpulso en función de la orientación del estímulo (en relación con la orientación preferida). d, Arriba: igual que c, arriba, para las tasas de disparo. Abajo: sobreimpulso de la tasa promedio en los estímulos cuya orientación está alineada con la orientación preferida de las células ($0 \pm 30^\circ$) o es casi ortogonal a ella ($90 \pm 30^\circ$). e, Análisis de registros experimentales del macaco despierto V1 23. Arriba: magnitud del sobreimpulso frente a la diferencia en el estado estacionario, como en d, arriba. La línea negra muestra la regresión lineal (bandas de confianza del $\pm 95\%$); ***: prueba de Wald bilateral $p_{\text{pag}} = 3 \times 10^{-5}$ ($= 1280$ pares célula-estímulo, $R^2 = 0,33$; véase también Datos ampliados Fig. 9d-e). Abajo: cada punto gris representa el sobreimpulso de la tasa promedio de una célula a través de los estímulos cuya orientación está alineada con la orientación preferida de las células ($0 \pm 30^\circ$), o casi ortogonal a ella ($90 \pm 30^\circ$), la media de cada grupo ($\pm \text{sem}$) se presenta en negro, como en d; ***: prueba t pareada bilateral $p = 6 \times 10^{-9}$ ($n = 80$ células, $n = 79$). (Para una mejor comparación con d, el rango y se trunca a 50 Hz, recortando 2 puntos de datos. Los análisis estadísticos utilizaron todos los datos).