



Scikit-NeuroMSI: Un marco generalizado para modelar la neurociencia multisensorial Integración

Renato Paredes^{1,2} · Juan B. Cabral^{3,4} · Peggy Seriès⁵

Aceptado: 14 de julio de
 2025 © El/Los autor(es) 2025

Abstracto

La integración multisensorial es un mecanismo neuronal fundamental, crucial para comprender la cognición. Existen múltiples modelos teóricos que explican los procesos computacionales que sustentan este mecanismo. Sin embargo, no existe un marco consolidado que facilite el examen de la integración multisensorial en diversos contextos experimentales y computacionales. Presentamos Scikit-NeuroMSI, un marco accesible de código abierto basado en Python, diseñado para optimizar la implementación y evaluación de modelos computacionales de integración multisensorial. Se demostraron las capacidades de Scikit-NeuroMSI al permitir la implementación de múltiples modelos de integración multisensorial en diferentes niveles de análisis. Además, ilustramos la utilidad del software para explorar sistemáticamente el comportamiento del modelo en tareas de inferencia causal espaciotemporal mediante barridos de parámetros en simulaciones. En particular, realizamos un análisis comparativo de modelos bayesianos y de red de integración multisensorial para identificar puntos en común que permitan conectar ambos niveles de descripción, abordando una pregunta de investigación clave en este campo. Analizamos la importancia de este enfoque para generar hipótesis basadas en datos computacionales en la investigación multisensorial. Se presentan recomendaciones para mejorar este software y orientaciones para futuras investigaciones utilizando este marco.

Palabras clave Integración multisensorial · Inferencia causal · Software científico · Neurociencia computacional · Modelos computacionales

Introducción

La integración multisensorial es el proceso neuronal mediante el cual se fusionan las señales provenientes de distintas modalidades sensoriales (como la visual, la táctil o la auditiva). Como resultado,

La respuesta multisensorial puede diferir significativamente de las respuestas provocadas por estímulos confinados a una sola modalidad sensorial (Stein y Stanford, 2008; Stein et al., 2010). Las alteraciones del procesamiento multisensorial pueden afectar diversos dominios cognitivos (Wallace et al., 2020). Por ejemplo, se observan alteraciones en la función multisensorial en diversos trastornos neuropsiquiátricos y neurológicos (p. ej., esclerosis múltiple congénita, TEA, demencia, pérdida sensorial, dislexia) (Martin et al., 2013; Haß et al., 2017; Zvyagintsev et al., 2017; Paredes et al., 2022; Cascio et al., 2012; Stevenson et al., 2014; Hahn et al., 2014; Zhou et al., 2018; Noel et al., 2022a; Wu et al., 2012; Festa et al., 2017; Ramkhalawansingh et al., 2017). Además, un importante cuerpo de investigación está explorando el potencial de los marcadores multisensoriales para predecir futuras manifestaciones clínicas o servir como puntos focales clave para intervenciones terapéuticas (Bolognini et al., 2005; Sánchez et al., 2013; Gieseler et al., 2018).

El modelado computacional es crucial para el avance del campo debido a su potencial para desarrollar teorías formales de los mecanismos neuronales de la integración multisensorial (Mei-er y Noppeney, 2020; Colonius y Diederich, 2020).

B Renato Paredes

renato.paredes@pucp.edu.pe

¹ Departamento de Psicología, Pontificia Universidad Católica de Perú, Lima, Perú

² Instituto de Investigaciones Psicológicas, Facultad de Psicología, Universidad Nacional de Córdoba, Córdoba, Argentina

³ Grupo de Innovación y Desarrollo Tecnológico, Gerencia De Vinculación Tecnológica, Centro Espacial Teófilo Tabanera, Comisión Nacional de Actividades Espaciales (CONAE), Córdoba, Argentina

⁴ Consejo Nacional de Investigaciones Científicas y Técnicas (CONICET), Buenos Aires, Argentina

⁵ Escuela de Informática, Universidad de Edimburgo, Edimburgo, Reino Unido

obliga a los científicos a analizar, especificar y formalizar sus ideas, al mismo tiempo que les permite generar predicciones cuantitativas precisas adecuadas para probar en experimentos futuros (Blohm et al., 2020; Guest y Martin, 2021). En consecuencia, el cuerpo La literatura sobre modelos computacionales de integración multisensorial ha experimentado un crecimiento sustancial en los últimos dos años. décadas (Colonius y Diederich, 2020).

Los principales enfoques de modelado son la combinación óptima de señales (Ernst y Banks, 2002; Alais y Burr, 2004; Fetsch et al., 2013; Parise y Ernst, 2016), inferencia causal bayesiana (Körding et al., 2007; Shams y Beierholm, 2010;

Rohe y Noppeney, 2015; Rohe y otros, 2019; Meijer y Noppeney, 2020), raza (Diederich, 1992, 1995; Colonius y Diederich, 2004; Colonius et al., 2017) y red (Ma y Pouget, 2008; Ma y Rahmati, 2013; Ohshiro y otros, 2011; Miller y otros, 2017; Cuppini et al., 2017; Ursino et al., 2019). A pesar de basarse en mecanismos muy generales, estos modelos suelen estar restringidos a un ámbito específico. paradigma experimental (por ejemplo, localización espacial, orientación juicios, juicios de orden temporal, detección de velocidad, ilusión de destello inducida por sonido, entre otros) y varían en su nivel de descripción (por ejemplo, cálculo, implementación o algoritmo) y sofisticación.

En general, el campo carece de un enfoque teórico unificado para Integración multisensorial que permite la prueba de modelos en diferentes paradigmas experimentales y computacionales. Existe una creciente necesidad de software científico diseñado específicamente para representan los conceptos y mecanismos distintivos que caracterizan la integración de información proveniente de diferentes sistemas sensoriales. modalidades. Hasta donde sabemos, todavía no existe ningún software que Puede proporcionar un entorno computacional unificado diseñado Para facilitar el examen de las diferencias en las predicciones de los modelos. Los modeladores de integración multisensorial actualmente dependen sobre paquetes creados para el modelado computacional de neurociencia de propósito general, como Brian Stimberg et al. (2019), HDDM (Wiecki et al., 2013), TAPAS (Frässle et al., 2021) o PyRates (Gast et al., 2019), BrainPy (Wang et al., 2023), entre otros. También existen alternativas para modelos específicos de integración multisensorial, como el modelo causal bayesiano. Inference Toolbox (Zhu et al., 2024a), pero no hay marcos que abarca más de un enfoque de modelado.

Aquí presentamos Scikit-NeuroMSI (Paredes et al., 2023), Un framework de código abierto de Python (Rossum y Drake, 2010) que simplifica la implementación de modelos neurocomputacionales de integración multisensorial. El paquete Actualmente permite ejecutar modelos computacionales seminales de integración multisensorial e implementar fácilmente nuevos modelos. definidos por los usuarios. A modo de ilustración, mostramos cómo este marco facilita el análisis de la multisensorialidad espaciotemporal. Integración en diferentes niveles de descripción utilizando el modelo bayesiano y modelos de red.

Este artículo está dirigido a un público diverso en neurociencia. y campos computacionales, incluida la neurología computacional.

científicos e investigadores en el procesamiento sensorial. También es beneficioso para desarrolladores de software e ingenieros interesados en modelos de integración multisensorial. Si bien los conocimientos básicos de neurociencia y programación son útiles, la competencia en Se necesita Python para comprender la implementación de Scikit-NeuroMSI, ya que está desarrollado en este lenguaje. El documento es accesible al cubrir fundamentos teóricos y Implementaciones prácticas, con explicaciones y ejemplos de código para facilitar la comprensión. Quienes tengan conocimientos de Python pueden profundizar. directamente en los detalles de implementación, mientras que los recién llegados Encontrará suficiente contexto para comprender los conceptos. Este enfoque destaca el desafío de estandarizar los modelos de integración multisensorial, lo que requiere una combinación de neurociencia, matemáticas e ingeniería de software.

Software

Descripción general del diseño

Los experimentos sobre integración multisensorial investigan cómo El cerebro combina información de múltiples modalidades sensoriales para crear una percepción unificada del entorno. Estas Los estudios a menudo implican manipular la confiabilidad o congruencia de señales sensoriales de diferentes modalidades, como visión y el tacto, para examinar cómo pesa y integra esta información (Colonius y Diederich, 2020). Los paradigmas experimentales incluyen tareas de localización espacial para interacciones espaciales intermodales (Ernst y Banks, 2002; Alais y Burr, 2004), juicios de orden temporal para el tiempo percepción de eventos multisensoriales (Ferri et al., 2016), o la ilusión de doble destello para la influencia auditiva en la percepción visual (Shams et al., 2002), entre otros.

Los modelos computacionales desempeñan un papel crucial en la investigación multisensorial al proporcionar marcos para predecir y Explicar las respuestas conductuales y neuronales en contextos multisensoriales (Chandrasekaran, 2017). Estos modelos ayudan a los investigadores comprender los principios subyacentes de la integración sensorial, como la ponderación de señales basada en la confiabilidad y la efectividad inversa (Stein et al., 2020). Al comparar las predicciones del modelo Con datos empíricos, los investigadores pueden probar hipótesis sobre Los mecanismos neuronales de la integración y ganancia multisensorial conocimientos sobre cómo el cerebro crea percepciones coherentes a partir de diversas entradas sensoriales (Blohm et al., 2020).

Hay disponible una amplia gama de modelos computacionales para la integración multisensorial (Colonius y Diederich, 2020), Proporcionar descripciones a nivel computacional, algorítmico y niveles de implementación dentro de la teoría del procesamiento de la información (Marr, 2010). Sin embargo, es inusual encontrar formal Evaluaciones de integración multisensorial utilizando más de un modelo en el momento de tender un puente entre los niveles de análisis (Ursino y otros, 2014).

Scikit-NeuroMSI fue diseñado para cumplir tres requisitos fundamentales en el estudio computacional de sistemas multisensoriales. integración:

1. Estandarización de modelos: los investigadores necesitan comparar diferentes enfoques teóricos (bayesiano, neuronal, Red, estimación de máxima verosimilitud, entre otros) utilizando métodos de análisis consistentes. Nuestro marco Proporciona una interfaz estandarizada para implementar y Analizando diferentes tipos de modelos.
2. Canal de procesamiento de datos: el marco maneja múltiples Procesamiento de datos tridimensionales en:
 - Dimensiones espaciales (coordenadas espaciales 1D a 3D)
 - Secuencias temporales
 - Múltiples modalidades sensoriales (por ejemplo, visual, auditiva, tocar)
3. Herramientas de análisis: Ofrecemos herramientas integradas para:
 - Barrido de parámetros en todas las configuraciones del modelo
 - Visualización y exportación de resultados
 - Análisis estadístico de los resultados del modelo

Además, el software procesa atributos fundamentales. de insumos experimentales pertinentes a la investigación multisensorial: coordenadas espaciales (por ejemplo, grados de ángulo visual y sonido) ubicación de la fuente), propiedades temporales (que abarcan el inicio del estímulo, la duración y los intervalos entre estímulos), estímulo intensidad y fiabilidad espaciotemporal (ruido aleatorio). Cada La entrada se valida para garantizar el cumplimiento de los estándares de formato, seguido de una transformación a un formato estandarizado. Representaciones internas que facilitan el procesamiento eficaz de los modelos. El software aplica sistemáticamente la verificación de tipos. y protocolos de validación de datos para garantizar la integridad de los mismos. entradas antes de continuar con el procesamiento.

En consecuencia, el software requiere una salida uniforme para Cada modelo de integración multisensorial. Este resultado incorpora los valores de actividad de todas las modalidades participantes. necesitando al menos dos modos unisensoriales junto con uno Modo multisensorial. Existe una opción para la salida. relacionadas con las respuestas de inferencia causal, según lo determinado por la usuario. Estos prerrequisitos guiaron las decisiones de diseño técnico. se detallará en la siguiente sección.

Un enfoque formal y técnico para el modelo Normalización

Describimos la base teórica y matemática de los modelos de integración multisensorial. Primero, describimos la forma propiedades y el marco matemático necesarios para comprender estos problemas computacionales teóricamente, lo que ayuda al abordar los desafíos de la ingeniería de software. Nuestro desarrollo...

El desarrollo de Scikit-NeuroMSI tuvo como objetivo articular estos problemas con diferencias conceptuales mínimas, eliminando sobrecarga de programación para centrarse en la solución de problemas multisensoriales Cuestiones de integración (Brooks y Kugler, 1987). Se discuten detalles específicos de implementación y consideraciones prácticas. en la Sección "Modelos Implementados", con ejemplos de aplicación de estos principios en el marco del software.

Formalidades del modelo computacional

Este trabajo tiene como objetivo crear un marco unificado para los modelos de integración multisensorial (Colonius y Diederich, 2020). a través de Scikit-NeuroMSI, facilitando la interoperabilidad entre herramientas de análisis, comparación y explicación, independientemente del modelo específico.

Considere dos salidas de modelo distintas r_0 y r_1 , tales como Modelos bayesianos (Körding et al., 2007; Shams y Beier-holm, 2010), redes neuronales (Cuppini et al., 2014, 2017), o estimadores de máxima verosimilitud (Ernst y Banks, 2002; Alais y Burr, 2004), con diferentes modalidades y dimensiones. Cualquier función de procesamiento f debe manejar tanto r_0 como r_1 igualmente bien.

En general, nuestro objetivo es crear modelos (m) que produzcan resultados (r) compatibles con cualquier función de procesamiento f , garantizar que los nuevos m o f sean mutuamente compatibles (véase Apéndice A para una formulación matemática). Por ejemplo, El código 1 muestra que los modelos de redes neuronales (Cuppini et al., 2017) y modelos de estimación de máxima verosimilitud (Alais y Burr, 2004) se pueden analizar con el mismo barrido de parámetros

herramientas.

Code 1

Example showing how Scikit-NeuroMSI enables the use of consistent analysis tools across different types of multisensory integration models, regardless of their underlying theoretical framework.

```
# import all the needed models and tools
>>> from skneuromsi import neural, mle, sweep

# we create two models that are totally different in nature
>>> m0 = neural.Cuppini2017()
>>> m1 = mle.AlaisBurr2004()

# the utility sweep works for any model
>>> sweep.ParameterSweep(m0, target="auditory_position")
>>> sweep.ParameterSweep(m1, target="auditory_position")
```

Otro objetivo era permitir a los usuarios elegir la modalidad sensorial que simulan, reflejando escenarios del mundo real. Por ejemplo, un investigador podría estudiar la percepción visual-auditiva. interacción de estímulos en un experimento y visual-táctil en otro. Esto permite que los modelos adapten los parámetros a Adaptar dinámicamente las modalidades seleccionadas. Como se ha demostrado En el Código 2, una configuración audiovisual revela parámetros como "posición auditiva", mientras que una configuración visual-táctil los reemplaza con parámetros como "tactile_posi ción", manteniendo intacta la estructura y la lógica del modelo central.

Code 2 Example of mode configuration in a model: The same neural network model (Cuppini2017) can be configured for different sensory modalities. Compare how the run function parameters automatically adapt between auditory-visual (top) and tactile-visual (bottom) configurations while maintaining the same underlying model architecture. Note that the outputs of `m0.run` and `m1.run` show the function signatures since they are not executed. To execute the function, the code should be `m0.run()` or `m1.run()`

```
# import all the needed models and tools
>>> from skneuromsi import neural, mle, sweep

# The same model with two different modes0 configurations
# the models can have an arbitrary number of modes
>>> m0 = neural.Cuppini2017(mode0="auditory")
>>> m1 = neural.Cuppini2017(mode0="tactile")

# check the parameters of the run function (all auditory)
>>> m0.run
<function skneuromsi.neural._cuppini2017.Cuppini2017.run(*,
    ↳ auditory_position=None, visual_position=None, auditory_sigma=32,
    ↳ visual_sigma=4, auditory_intensity=28, visual_intensity=27,
    ↳ auditory_duration=None, auditory_onset=0, auditory_stim_n=1,
    ↳ visual_duration=None, visual_onset=0, visual_stim_n=1,
    ↳ noise=False, feedforward_weight=18, cross_modal_weight=1.4,
    ↳ causes_kind='count', causes_dim='space')>

# 'auditory' change for tactile
>>> m1.run
<function skneuromsi.neural._cuppini2017.Cuppini2017.run(*,
    ↳ tactile_position=None, visual_position=None, tactile_sigma=32,
    ↳ visual_sigma=4, tactile_intensity=28, visual_intensity=27,
    ↳ tactile_duration=None, tactile_onset=0, tactile_stim_n=1,
    ↳ visual_duration=None, visual_onset=0, visual_stim_n=1,
    ↳ noise=False, feedforward_weight=18, cross_modal_weight=1.4,
    ↳ causes_kind='count', causes_dim='space')>
```

El requisito de diseño final garantiza multidimensionalidad
Análisis de datos. Cada punto de salida del modelo está asociado con un modo, tiempo y espacio específicos, con la dimensión espacial Posiblemente abarcando de una a tres dimensiones. Por consiguiente, el resultado del modelo puede comprender hasta cinco dimensiones. (5D).

Diseño orientado a objetos

Seleccionar un ecosistema para una herramienta es una decisión subjetiva. La mayoría de los proyectos de análisis de datos utilizan Python debido a su rico ecosistema científico (Pérez et al., 2010). Elegimos Python para explotar mecanismos orientados a objetos, mejorando la simplicidad y extensibilidad de herramientas. En lenguajes orientados a objetos como Python, las clases estructuran los tipos de datos agrupando atributos (estado) y métodos (comportamiento), lo que permite una organización cohesiva del código y proporciona herencia para compartir funcionalidades. sin duplicación de código (Booch, 1982).

Un mecanismo conceptual disponible en los lenguajes de programación orientados a objetos que empleamos son las clases abstractas. Estos representan tipos de datos que, aunque poseen un protocolo completo (es decir, sus funciones, los datos que reciben y los tipos de retorno están completamente definidos), tienen ciertos comportamientos que permanecen sin especificar. Por ejemplo, como se muestra en el Código 3, La clase Foo utiliza la funcionalidad ya establecida en el método method0() sin necesidad de redundancia en el código fuente. Además, esto establece una jerarquía.

Estructura cal, o herencia, entre FooABC y Foo
tipos, lo que indica que cualquier objeto creado o instanciado por Foo es una instancia del tipo FooABC. El aspecto final
Es importante tener en cuenta que FooABC se declara explícitamente como una entidad incompleta y, por lo tanto, no se puede instanciar, lo que se logra adornando método1() con @abstractmethod.

Code 3 Example of abstract vs concrete class implementation in Python: The abstract class (FooABC) defines a protocol with both concrete and abstract methods, while its concrete implementation (Foo) provides the required implementation of the abstract method. Note how creating an instance of the abstract class fails, while the concrete class is instantiated successfully.

```
# modules that expose abstract class
# functionality in Python
from abc import ABC, abstractmethod

class FooABC(ABC): # FooABC is an Abstract-Base-Class
    def method0(self):
        print("This is a concrete method")

    @abstractmethod
    def method1(self): ...

class Foo(FooABC): # Foo inherits from FooABC
    def method1(self):
        return self.method0()

# Creating objects
foo = FooABC() # This fails, method1 is not defined
foo = Foo()    # Works

# calling the methods
foo.method0() # Works
foo.method1() # Works
```

Seguimos el "Principio de Inversión de Dependencia" (DIP), un principio SOLID esencial (Martin, 2000), que establece dos reglas fundamentales:

- 1. Los módulos de alto nivel no deben depender de los de bajo nivel. Ambos deben depender de abstracciones.
- 2. Las abstracciones no deben depender de los detalles. Los detalles deben dependen de abstracciones.

Para ilustrar su importancia, comparamos dos implementaciones de herramientas de procesamiento de modelos. El código 4 está estrechamente acoplado. confiando directamente en un modelo específico, mientras que el Código 5 es más Flexible, utilizando inyección de dependencia a través de una base abstracta clase.

Code 4 Example of a tool without Dependency Injection: The tool function is tightly coupled to a specific model implementation (Model1), making it inflexible and difficult to extend to other model types.

```
# Example without Dependency Inversion
class Model1:
    def process(self, data):
        return data * 2

def tool_for_model1(data):
    # Tool is tightly coupled to Model1
    model = Model1()
    return model.process(data)
```

La principal distinción entre estas metodologías radica en que el Código 4 contiene una función de herramienta codificada específicamente para operar únicamente con el Modelo 1, lo que impide su aplicación a otros tipos de modelos a menos que la función sea modificada. Por el contrario, el Código 5 está diseñado para adaptarse cualquier modelo que herede de ModelABC, lo que facilita la integración perfecta de nuevos tipos de modelos y permite la ejecución del modelo en tiempo real. sustitución, mejorando la capacidad de prueba mediante objetos simulados y garantizando una separación más sólida de intereses. Este patrón es esencial para Scikit-NeuroMSI, ya que permite la consistencia Implementación de herramientas en varios modelos de integración multisensorial.

Code 5 Example of a tool with Dependency Injection: Depending on an abstraction (ModelABC), the tool function can work with any model that implements the required interface, allowing flexible model substitution and easier testing.

```
# Example with Dependency Inversion
from abc import ABC, abstractmethod

class ModelABC(ABC):
    @abstractmethod
    def process(self, data):
        pass

class Model1(ModelABC):
    def process(self, data):
        return data * 2

def tool(model: ModelABC, data):
    # Tool depends on abstraction (ModelABC)
    return model.process(data)
```

Proponemos un conjunto de clases para reducir la “brecha semántica” que separa las ideas de cómo una integración multisensorial El problema se expresa y cómo el código que representa estos Se escriben las ideas. Dos clases principales forman la arquitectura central. del marco:

- ModelABC: Una clase base abstracta que define el estándar Interfaz Dard para todos los modelos de integración multisensorial
- NDResult: Un objeto de resultado responsable de almacenar información de estímulo multidimensional y proporcionar análisis herramientas para la investigación

Este diseño de dos clases separa la implementación del modelo lógica de las capacidades de manejo y análisis de datos, siguiendo los principios estándar de ingeniería de software. La totalidad de Las clases, junto con sus interconexiones, se presentan en un diagrama que emplea lenguaje UML (Jacobson et al., 2000) Para representar formalmente las relaciones entre los módulos principales del proyecto (ver Fig. 1).

ParameterSweep es una herramienta para realizar análisis de parámetros. barre los modelos, ofreciendo alta flexibilidad y empleando estrategias intercambiables para procesar los resultados, permitiendo una gestión eficiente de la memoria. NDResultCollec-tion sirve como una clase auxiliar diseñada para agregar y

Comprimir los resultados en colecciones organizadas. Esto facilita Funcionalidades avanzadas, como el análisis de efectos de disparidad espacio-temporal. Además, NDResultCollection es El formato de salida estándar de ParameterSweep cuando se utiliza La estrategia de procesamiento predeterminada. Para una descripción completa de las clases implementadas, consulte el Apéndice B.

Modelos implementados

Cualquier modelo de integración multisensorial debe definir el vínculo entre respuestas a señales unisensoriales, como las visuales y auditiva y respuestas a señales intermodales como la visual-auditiva. Esta conexión varía según el espacio y características temporales, configuración experimental y nivel de descripción (por ejemplo, neuronas individuales, poblaciones neuronales, neuroimagen, comportamientos). Esto abre un amplio espectro de Enfoques para modelar las observaciones derivadas de experimentos de integración multisensorial.

Un paradigma predominante en este campo es el ventrílocuo. Efecto (Thurlow y Jack, 1973). Este fenómeno surge cuando se presentan simultáneamente estímulos visuales y auditivos incongruentes, lo que lleva al observador a percibir un singular origen tanto visual (los movimientos de la cara de una marioneta) y estímulos auditivos (del habla), atribuyéndolos al mismo Fuente (el habla de la marioneta) (véase la Fig. 2 para una ilustración). Este efecto se investiga sistemáticamente en el laboratorio. entornos a través de tareas diseñadas para evaluar la espacialidad localización de una fuente auditiva dentro de un entorno visual-auditivo combinado (Alais y Burr, 2004).

En general, estos modelos pretenden explicar “reglas empíricas” comunes derivadas de paradigmas de integración multisensorial. (ver Colonius y Diederich 2020 y Stein et al. 2020 para una revisión detallada). La “regla espacio-temporal” sugiere que Los estímulos cercanos en el espacio y el tiempo tienen más probabilidades de integrarse. La “regla de efectividad inversa” establece que la integración es Más fuerte cuando la intensidad de entrada unimodal disminuye. Además, la “regla de confiabilidad” enfatiza una mayor ponderación. de modalidades más confiables (por ejemplo, con menor ruido). Estas Se ha demostrado que las “reglas” observadas empíricamente surgen de principios computacionales comunes (Ohshiro et al., 2011) y no necesariamente requieren modelos alternativos para su explicación. En consecuencia, el desafío clave es el desarrollo de modelos capaces de dar cuenta de las observaciones empíricas de la integración multisensorial en varios niveles de descripción.

Aquí presentamos los principales modelos del Ventrílocuo. Efecto actualmente disponible en el paquete Scikit-NeuroMSI. El Apéndice C contiene una exposición matemática completa de los modelos, así como el código necesario para su ejecución. El paquete actualmente incluye modelos pertinentes a paradigmas adicionales, como el Flash inducido por sonido




Fig. 1 Diagrama de clases reducido de Scikit-NeuroMSI. Las flechas vacías representan la herencia; la flecha con punta de diamante indica que hay múltiples Los objetos NDResult se agregan en una única NDResultCollection y todas las demás relaciones tienen etiquetas explicativas

Ilusión (Cuppini et al., 2014; Zhu et al., 2024b). Estos
Los modelos no se explican en profundidad en este artículo, pero
están detalladamente delineados en la documentación del usuario.

Además, ofrecemos orientación sobre cómo optimizar la
Incorporación de nuevos modelos al paquete. Trabajamos activamente.
Fomentar la comunidad investigadora especializada en multisensorial




Fig. 2 Modelos implementados en Scikit-NeuroMSI. La ilustración representa cómo el paquete de software permite modelar el efecto Ventriloquist (es decir, la integración espacial bajo disparidades audiovisuales) utilizando tres enfoques diferentes: Integrador bimodal casi óptimo, bayesiano Red de inferencia causal y de inferencia causal espaciotemporal

Integración sory para contribuir a esta iniciativa desarrollando y compartir sus propios modelos (consulte [las Pautas de contribución](#)).

Integrador bimodal casi óptimo

Un modelo temprano propone que el proceso de combinación de señales de diferentes modalidades se asemeja a un máximo

Integrador de verosimilitud (Ernst y Banks, 2002). El Integrador Bimodal Casi Óptimo (Alais y Burr, 2004) para Las señales auditivas (A) y visuales (V) en el contexto de una tarea de localización espacial auditiva (por ejemplo, el efecto ventrílocuo) pueden ser calculado sumando las estimaciones unisensoriales (S^A y S^V) ponderados por su fiabilidad. En consecuencia, el sistema integrado La percepción está predispuesta a alinearse más estrechamente con la señal. que presenta menor variabilidad.

Inferencia causal bayesiana

En el modelo anterior, la integración de señales es esencial para estimar con precisión un estímulo intermodal. Sin embargo, si hay una diferencia significativa entre las evaluaciones subjetivas S^A y S^V a partir de un estímulo visual-auditivo, el observador puede- No se puede determinar si esta diferencia se debe a ruido aleatorio en procesamiento de señales neuronales o divergencia sistemática de señales. Originalmente diseñado para explicar el efecto ventrílocuo, el El modelo de inferencia causal bayesiana (Körding et al., 2007) distingue si S^A y S^V surgen de un único audiovisual. evento (integración) o eventos separados (segregación). Para ello, El observador considera la probabilidad de S^A y S^V dado un evento común o separado y la probabilidad previa de una fuente común. Una mayor probabilidad ocurre si los dos unisensoriales Las señales son similares, lo que a su vez aumenta la probabilidad de infiriendo que las señales tienen una causa común.

Modelo de red para la integración audiovisual y causal Inferencia

Los modelos de inferencia causal bayesianos proporcionan un alto nivel descripción (es decir, nivel computacional de análisis según a Marr (Marr, 2010)) de los cálculos realizados por el cerebro para integrar señales unisensoriales. Recientemente, se han propuesto modelos de redes neuronales como alternativa para modelar inferencia causal en paradigmas de integración multisensorial (Cup-pini et al., 2017; Fang et al., 2019; Rideaux et al., 2021), proporcionando una descripción de bajo nivel de tal mecanismo.

La red de integración audiovisual e inferencia causal (Cuppini et al., 2017) presenta dos regiones unisensoriales para procesar estímulos auditivos y visuales ruidosos, interconectadas por Sinapsis excitatorias intermodales. Aquí, neuronas con codificación de frecuencia están organizados espacialmente, con neuronas más cercanas que responden a posiciones espaciales más cercanas. Estas regiones emulan el procesamiento sensorial en la corteza unisensorial del cerebro y determinan la

Ubicación espacial de los estímulos mediante el cálculo del baricentro de actividad en las regiones auditiva y visual. Intermodal Las conexiones hacen que la localización espacial de una modalidad ser influenciado por la presentación concurrente en otro, incluso si se procesa por separado.

Red de inferencia causal espaciotemporal multisensorial

Nuestro grupo de investigación desarrolló la Red de Inferencia Causal Espacio-temporal Multisensorial para explicar la ilusión de destello inducida por el sonido (Paredes et al., 2025). Este modelo fue construido sobre modelos de red anteriores para el espacio (Cuppini et al., 2017) y temporal (Cuppini et al., 2014) multisensorial Integración para informar dos niveles de procesamiento de inferencia causal. Nuestro modelo consta de tres capas: dos codifican la información auditiva. y estímulos visuales por separado y se conectan a un sistema multisensorial. Capa mediante sinapsis de avance y retroalimentación. En las áreas unisensorias, el modelo calcula la posición espaciotemporal. de los estímulos externos. Además, en el área multisensorial El modelo calcula la inferencia causal. Esta arquitectura neuronal permite el cálculo iterativo de la causalidad espaciotemporal. inferencia a través de la red (Rohe et al., 2019).

En resumen, nuestro modelo conserva la conectividad neuronal (lateral, intermodal, de avance) y las entradas como se detalla en la red discutida anteriormente (Cuppini et al., 2017), al tiempo que integra la conectividad de retroalimentación. Además, esto El modelo introduce latencia en las entradas neuronales intermodales y de retroalimentación de avance de acuerdo con la literatura. lo que indica que las interacciones tempranas y tardías durante el procesamiento multisensorial. Además, en consonancia con Cuppini et al. (2014), se han incorporado filtros temporales para auditivos, neuronas visuales y multisensoriales para replicar el temporal progresión de la entrada neuronal y la dinámica sináptica. Estos Los filtros tienen en cuenta constantes de tiempo específicas que determinan la características temporales de cada grupo de neuronas, a saber auditivo, visual o multisensorial.

Ejemplos de aplicaciones

Modelado de inferencia causal espaciotemporal con Scikit-NeuroMSI

La inferencia causal es un cálculo muy relevante para la integración multisensorial (Körding et al., 2007; Shams y Beierholm, 2010, 2022). Inferencia causal en multisensorial La integración se examina a través de tareas implícitas o explícitas. La inferencia causal explícita implica tareas en las que los participantes están obligados a evaluar directamente la relación causal entre estímulos (juicio unitario) en un entorno multisensorial, mientras que La inferencia causal implícita implica tareas en las que los participantes Se requieren para estimar la ubicación espaciotemporal de la estímulos. Una investigación en profundidad de cómo los mecanismos causales

El mismo opera en ambos tipos de tareas y se encuentra actualmente en curso. (Acerbi et al., 2018) y se ha descubierto que es distinto en poblaciones neurodiversas (por ejemplo, Noel et al. (2022b)).

En general, los modelos de inferencia causal multisensorial se basan principalmente en la inferencia bayesiana (Körding et al., 2007), ofreciendo una descripción de alto nivel (como se describe en el nivel computacional de Marr (Marr, 2010)) de cómo el cerebro integra la información sensorial señales (French y DeAngelis, 2020). Recientemente, los modelos de redes neuronales han surgido como una alternativa para modelar inferencia causal en contextos multisensoriales (Cuppini et al., 2017; Fang et al., 2019; Rideaux et al., 2021), que proporciona una implementación tentativa del mecanismo. Sin embargo, estos modelos No se han probado rigurosamente en múltiples marcos o dimensiones experimentales (es decir, espacio y tiempo), ni tampoco Se han comparado con otros modelos. A continuación, Preguntas: 1) ¿Son comparables los modelos probabilísticos y de red? ¿En su desempeño al ajustar datos? 2) ¿Estos modelos consideran con precisión tanto las causales implícitas como las explícitas? respuestas de inferencia? 3) ¿Estos modelos muestran rendimiento? ¿Diferencias al trabajar con disparidades espaciales o temporales?

Configuración de modelado

Utilizamos los modelos actualmente implementados en Scikit-NeuroMSI para reproducir respuestas humanas en el ámbito audiovisual

tareas de inferencia causal (ver Experimentos 2, 3 y 4 en Noel et al. (2022b) para más detalles sobre la configuración experimental) y comparamos cualitativamente su desempeño. Para cada tarea, ajustamos Los modelos implementados para las respuestas conductuales de los pacientes sanos participantes de control utilizando el algoritmo de evolución diferencial (Storn y Price, 1997) disponible en la biblioteca SciPy para el lenguaje de programación Python (Virtanen et al., 2020). Detalles sobre el procedimiento de ajuste y lectura del modelo para Cada tarea se puede encontrar en el Apéndice D.

En primer lugar, modelamos una tarea de localización espacial auditiva con señales visuales dispares (Experimento 2 en Noel et al. (2022b)) para examinar el desempeño de la inferencia causal implícita de la modelos. Nuestro enfoque principal es la modulación de la percepción espacial auditiva por estímulos visuales, un fenómeno conocido como Sesgo auditivo. Presentamos cada modelo con un estímulo auditivo en una posición fija (45°) y estímulos visuales en diferentes posiciones relativas a la señal auditiva: ± 3 , ± 6 , ± 12 y $\pm 24^\circ$ (véase la Fig. 3, izquierda). Para simplificar, presentamos cada posible combinación de estímulos audiovisuales solo una vez, y todos Con este enfoque se eliminan las fuentes de ruido. Siguiendo Körding et al. (2007) y Cuppini et al. (2017), calculamos el sesgo auditivo como la disparidad espacial entre la Posición del estímulo auditivo y la posición detectada por cada modelo, dividido por la distancia entre los estímulos auditivos y visuales. Ajustamos las respuestas de sesgo auditivo. del modelo para que se corresponda con las respuestas humanas bajo la




Figura 3. Tareas de inferencia causal. La figura muestra la inferencia causal. tareas reportadas en Noel et al. (2022b) que fueron simuladas en este estudio. Panel izquierdo: Tarea de disparidad audiovisual espacial. Los participantes vieron un disco visual y escuché un tono auditivo en diferentes lugares y con Diferentes pequeñas disparidades (arriba = sin disparidad, abajo = pequeña disparidad). Presentamos cada modelo con un estímulo auditivo en una posición fija (45°) y estímulos visuales en diferentes posiciones relativas a la señal auditiva: ± 3 , ± 6 , ± 12 y $\pm 24^\circ$. Los modelos debían determinar la posición de la

Estímulos auditivos e informe el número de causas (1 o 2). Panel derecho: Tarea de disparidad audiovisual temporal. Los participantes vieron un disco visual. y escuché un estímulo auditivo con diferentes inicios en relación con el visual. señal. Presentamos a cada modelo un estímulo visual con un inicio fijo (160 ms) y estímulos auditivos en diferentes inicios en relación con la señal visual: 0, ± 20 , ± 80 , ± 150 y $+250$ ms. Los modelos debían determinar la número de causas de los estímulos (1 o 2)

condición de alta confiabilidad de la señal visual (ver Noel et al. 2022b)

(para más detalles).

A continuación, modelamos una tarea de informe de causa común audiovisual. bajo disparidades espaciales (Experimento 3 en Noel et al. (2022b))

para examinar el desempeño de la inferencia causal explícita del modelos. Se entregan estímulos audiovisuales a cada modelo en

las mismas posiciones que en la simulación anterior. Aquí, nuestro El enfoque es la modulación de los juicios de unidad (comunes) informes de causa) de los modelos por la disparidad espacial de la estímulos. Para el modelo bayesiano, determinamos la proporción de informes que indican una causa común calculando la probabilidad posterior de una causa común (véase la ecuación C7).

Por el contrario, para los modelos de red, esta proporción se identifica a través de la activación neuronal máxima (consulte la ecuación C9), observado dentro de las neuronas multisensoriales.

Finalmente, modelamos un informe audiovisual de causa común. tarea bajo disparidades temporales (Experimento 4 en Noel et al. (2022b)) para examinar la inferencia causal temporal explícita Rendimiento de los modelos. Aquí nos centramos en cómo las disparidades temporales en los estímulos afectan los juicios de unidad de los modelos. Presentamos cada modelo con un estímulo visual en un inicio fijo (160 ms) y estímulos auditivos en diferentes inicios relativo a la señal visual: 0, ± 20 , ± 80 , ± 150 y ± 250 ms (ver Fig. 3, derecha). Cada posible combinación de audiovisuales El estímulo se presenta solo una vez y se eliminan todas las fuentes de ruido con este enfoque. Calculamos las proporciones de Informes de causa común de los modelos como en la simulación anterior.

Resultados de la simulación

Comparamos el rendimiento de los modelos implementados en las tareas de inferencia causal mencionadas. Auditivo

Las respuestas de sesgo se muestran en la figura 4a. Observamos que ambos Los modelos bayesianos (Körding et al., 2007) y de red (Cup-pini et al., 2017) proporcionan una buena aproximación al comportamiento. datos, mientras que el modelo de estimación de máxima verosimilitud (MLE) (Alais y Burr, 2004) no logra reproducir disparidades audiovisuales más allá de $\pm 6^\circ$.

Además, se muestran respuestas de inferencia causal espacial. en la Fig. 4b. Observamos que todos los modelos evaluados proporcionan una aproximación justa a las respuestas conductuales, con los modelos de redes neuronales (Cuppini et al., 2017) superando a los Modelo de inferencia causal bayesiana (Körding et al., 2007) en disparidades audiovisuales inferiores a $\pm 6^\circ$.

Las respuestas de inferencia causal temporal se muestran en la figura 4c. Observamos que tanto el modelo de inferencia causal bayesiano (Körding et al., 2007) y el modelo espaciotemporal multisensorial La red de inferencia causal (Paredes et al., 2025) proporciona una buena aproximación a las respuestas conductuales, mientras que la modelo de red para la integración audiovisual (Cuppini et al., 2017) no logra reproducir disparidades temporales más allá de ± 100 EM.

Los hallazgos de la serie actual de simulaciones indican que la inferencia causal bayesiana y la correlación espaciotemporal Los modelos de redes de inferencia causal ofrecen la representación más precisa de los datos de los participantes. Sin embargo, la eficacia de




Figura 4. Modelos de tareas de inferencia causal audiovisual. La figura muestra respuestas óptimas de los modelos implementados en multisensorial Inferencia causal en las tareas de disparidad audiovisual reportadas en Noel et al. (2022b). (a) Rendimiento de los modelos en localización espacial dentro una tarea de inferencia causal implícita. Este gráfico revela que los modelos bayesianos y Los modelos de red proporcionan un rendimiento óptimo, mientras que el modelo MLE No reproduce disparidades audiovisuales más allá de $\pm 6^\circ$. (b) Rendimiento de los modelos en informes de fuentes comunes bajo disparidades espaciales dentro de una tarea de inferencia causal explícita. Estas simulaciones muestran que

Los modelos de red superan al modelo de inferencia causal bayesiano en disparidades espaciales audiovisuales inferiores a $\pm 6^\circ$. (c) Rendimiento de la modelos en informes de fuentes comunes bajo disparidades temporales dentro de un Tarea de inferencia causal explícita. Este gráfico muestra que tanto la Red de Inferencia Causal Espaciotemporal Multisensorial como la Bayesiana Los modelos de inferencia causal proporcionan aproximaciones justas al desempeño humano, mientras que el modelo de red para la integración audiovisual no logra reproducir disparidades más allá de ± 100 ms

Ambos modelos disminuyen cuando se abordan las disparidades temporales, lo que subraya la necesidad de nuevos modelos que evalúen eficazmente Incorporar la inferencia causal dentro del dominio temporal.

Comparación de modelos de red y bayesianos de Inferencia causal espaciotemporal con Scikit-NeuroMSI

Hasta donde sabemos, esta es la primera vez que se da una interpretación implícita y La inferencia causal espaciotemporal explícita es computacionalmente Modelado utilizando una red neuronal y bayesiana combinada enfoque (Ursino et al., 2014; Acerbi et al., 2018). Este La metodología facilita la evaluación concurrente de la influencia de cada parámetro del modelo y la identificación de similitudes entre ellos. Ahora estamos equipados para realizar barridos exhaustivos de parámetros dentro de cada modelo y evaluar sus efectos sobre las respuestas del modelo para discernir puntos en común que puedan permitirnos unir ambos niveles de descripción. Este proceso permite la exploración de la variabilidad interindividual combinando diferentes enfoques de modelado, ofreciendo Nuevas formas de estudiar las diferencias observadas en la integración multisensorial en condiciones psiquiátricas o neurológicas (Martin et al., 2013; Haß et al., 2017; Zvyagintsev y otros, 2017; Paredes et al., 2022; Cascio et al., 2012; Stevenson y otros, 2014; Hahn y otros, 2014; Zhou y otros, 2018; Noel y otros, 2022a; Wu et al., 2012; fiesta et al., 2017; Ramkhalawansingh et al., 2017). A continuación, nos preguntamos: 1) ¿Cuáles serían los correlatos de los componentes? ¿Los modelos bayesianos pueden implementarse de forma más neuronal? 2) ¿Los parámetros de cada modelo tienen el mismo impacto? sobre respuestas de inferencia causal implícitas y explícitas? 3) ¿Son Los efectos de los parámetros del modelo son los mismos para las tareas que involucran ¿Disparidades espaciales o temporales?

Configuración de modelado

Para el modelo de inferencia causal bayesiana, exploramos los siguientes impacto de variar la probabilidad previa de una causa común (pcommon) y la precisión de las estimaciones unisensoriales (α o α). Para la red de inferencia causal espaciotemporal modelo, exploramos el impacto de manipular los pesos de intermodal ($W_{av,va}$), avance (W_{mc}), retroalimentación (W_{cm}) y lateral excitatoria (Lc_{0ex}) sinapsis. Estos parámetros Se seleccionaron debido a su relevancia para explicar los casos individuales. Diferencias en la integración multisensorial encontradas en condiciones psiquiátricas, como lo demuestra una investigación computacional reciente (Karvelis et al., 2018; Noel et al., 2022a, b; Paredes et al., 2022; Chrysaitis y Serisès, 2023; Noel y Angelaki, 2023). En primer lugar, exploramos el impacto de manipular estos parámetros sobre las respuestas de sesgo auditivo de los seleccionados modelos en la tarea de inferencia causal implícita (Experimento 2 en Noel et al. (2022b)). Para simplificar, calculamos la auditiva sesgo en el punto de disparidad de -6° para cada valor del explorado parámetros. A continuación, examinamos los efectos del barrido

parámetros sobre la proporción de informes sincrónicos en disparidades espaciales y temporales (Experimentos 3 y 4 en Noel et al. (2022b)). Siguiendo a Noel et al. (2022b), estas diferencias se cuantificaron sistemáticamente mediante el ajuste gaussiano. funciones a la proporción de respuestas de fuentes comunes como una función de las disparidades audiovisuales (). Los ajustes gaussianos Proporcionar tres parámetros que caracterizan las respuestas de Los modelos computacionales: (1) amplitud, que denota la proporción máxima de informes de fuentes comunes por parte del modelo; (2) media, indicando la proporción en la que la proporción de común Los informes de origen fueron máximos; y (3) ancho (desviación estándar), que refleja el alcance dentro del cual se encontraba el modelo. propenso a informar una fuente común.

Resultados de la simulación

Las respuestas de sesgo auditivo simuladas se muestran en la figura 5a. Encontramos que tanto pcommon como α dentro del modelo bayesiano El marco está inversamente relacionado con Lc y $W_{av,va}$ dentro $0ex$ el nivel de red. En línea con el modelado de red previo. de integración audiovisual (Ursino et al., 2017, 2019), nuestra Los resultados sugieren una posible correlación neuronal de la probabilidad previa de coocurrencia de estímulos audiovisuales en el sinapsis intermodales, con tal mecanismo neuronal que impacta también la precisión unisensorial. Además, las respuestas de fuente común simuladas en el La tarea de inferencia causal espacial se muestra en la figura 5b. Encontramos que α dentro del modelo bayesiano muestra un impacto opuesto en la amplitud y anchura de los informes de fuentes comunes en comparación con $W_{av,va}$ a nivel de red. Esto destaca El impacto de la conectividad intermodal en la causalidad explícita juicios de inferencia, lo que sugiere que su asociación observada Con estimaciones de precisión sensorial, potencialmente se pueden ampliar hacia áreas corticales de orden superior responsables de la inferencia causal cálculos (Rohe y Noppeney, 2015; Rohe et al., 2019). Las respuestas de fuente común simuladas en la tarea de inferencia causal temporal se muestran en la figura 5c. En contraste con Observaciones en el dominio espacial, encontramos que el pcommon dentro del modelo bayesiano muestra un impacto similar en el Amplitud y ancho de los informes de fuentes comunes comparados a W_{mc} a nivel de red. Esta discrepancia plantea preguntas sobre posibles diferencias en los mecanismos que impulsan inferencia causal temporal y espacial, o al menos, en Los supuestos fundamentales bajo los cuales se desarrollaron estos modelos formulado inicialmente. Cabe destacar que la mayoría de los esfuerzos de modelado Se han llevado a cabo en tareas de integración multisensorial espacial (estática), mientras que los modelos de inferencia causal en el ámbito temporal Recientemente se han comenzado a analizar los dominios en diferentes niveles de descripción. acumular (Cuppini et al., 2014; Pesnet Lerousseau et al., 2022; Zhu y otros, 2024b). En general, el parámetro bayesiano pcommon representa Las creencias previas sobre causas comunes podrían relacionarse con las neuro-parámetros reales como Lc_{0ex} , $W_{av,va}$ y W_{mc} representando




Figura 5 Impacto de los parámetros del modelo en las respuestas de inferencia causal en Modelos bayesianos y de red. (a) Barridos de parámetros en el implícito Tarea de inferencia causal. Las simulaciones indican que la probabilidad previa de una causa común (p_{common}) y la precisión de la estimación visual (σ_v) reducir el sesgo auditivo en el modelo bayesiano, mientras que la excitación lateral (L_{0ex}^{ξ}) y pesos intermodales ($W_{0va}^{av,va}$) mejorarlo en nuestra red modelo. (b) Barridos de parámetros en la inferencia causal espacial explícita Tarea. La proporción de respuestas de fuentes comunes en relación con el espacio.

Disparidades ajustadas a una función gaussiana para su análisis. Las simulaciones Demuestre que en el modelo de inferencia causal bayesiano el parámetro σ_v muestra un impacto opuesto en la amplitud y el ancho del común Informes fuente comparados con $W_{0va}^{av,va}$ en el modelo. (c) Barridos de parámetros en la tarea de inferencia causal temporal explícita. Las simulaciones muestran que en el modelo bayesiano p_{common} muestra un impacto similar en el Amplitud y ancho de los informes de fuentes comunes en comparación con W_{0mc}^{mc} en el modelo de red

Fuerzas sinápticas inter e intraáreas, aunque no hay datos exactos Se podrían encontrar paralelismos entre dominios (espaciales o temporales) o métricas (sesgo, amplitud y ancho). De manera similar, σ_v/a , que representa la incertidumbre en la información sensorial, podría ser inversamente proporcional. asignado a $W_{0va}^{av,va}$, lo que refleja la fuerza del transporte intermodal conectividad a nivel de red, debido a su impacto opuesto en la amplitud y anchura de los informes de fuentes comunes Durante las tareas explícitas. Las discrepancias observadas, incluyendo

Analizando los diferentes efectos de los modelos bayesianos y de red en Las tareas de inferencia causal implícita versus explícita indican la presencia de complejidades neuronales adicionales que pueden no ser completamente encapsulado por el modelado bayesiano o, por el contrario, por Enfoques de red. La comprensión adquirida de las similitudes de estos modelos abre la posibilidad de ampliar Las teorías actuales sobre la integración multisensorial (Colonius y Diederich, 2020).

Discusión

Hemos abordado el objetivo de desarrollar software científico diseñado específicamente para el modelado computacional de integración multisensorial, atendiendo una necesidad clave en la campo (Colonius y Diederich, 2020; Shams y Beierholm, 2022). Demostramos las capacidades de Scikit-NeuroMSI para facilitar la implementación de modelos de integración multisensorial e investigar sistemáticamente su comportamiento barriendo parámetros a través de simulaciones (ver Código 1 y Fig. 4). También hemos demostrado la utilidad del software mediante el modelado de la inferencia causal espaciotemporal en diferentes niveles de análisis utilizando el método bayesiano (Körding et al., 2007) y modelos de red de integración multisensorial (véase la figura 5). Abordar una pregunta fundamental necesaria para avanzar el campo (Ursino et al., 2014; French y DeAngelis, 2020; Shams y Beierholm, 2022).

Con herramientas de software como Scikit-NeuroMSI estamos Ahora es capaz de aproximarse a la integración multisensorial en diferentes niveles de análisis (Marr, 2010) (por ejemplo, computacional, algorítmico y neuronal) simultáneamente y ampliar nuestras posibilidades de generar hipótesis informadas computacionalmente. Esto permite la formulación de predicciones más precisas que pueden ser evaluados con medidas neurobiológicas y comportamentales, un factor crucial para la consolidación de las emergentes teorías de la integración multisensorial en neurociencia (Colonius y Diederich, 2020; Shams y Beierholm, 2022).

Una aplicación inmediata de nuestro nuevo marco de modelado es el estudio de las diferencias de integración multisensorial en trastornos psiquiátricos y neurológicos (Martin et al., 2013; Haßel et al., 2017; Zvyagintsev y otros, 2017; Paredes et al., 2022; Cascio et al., 2012; Stevenson y otros, 2014; Hahn y otros, 2014; Zhou y otros, 2018; Noel y otros, 2022a; Wu et al., 2012; Festa et al., 2017; Ramkhalawansingh et al., 2017). Por ejemplo, una nueva teoría cuantitativa sobre el TEA (Noel y Angelaki, 2023) sugiere que el TEA podría interpretarse como un trastorno de inferencia causal multisensorial (computacional nivel), donde este proceso puede verse facilitado por divisiones normalización (nivel algorítmico) y potencialmente interrumpida por desequilibrios excitatorios/inhibitorios (implementación neuronal nivel). Sin embargo, todavía no existe una evaluación formal de los datos experimentales de este trastorno utilizando más de un multisensorial. modelo de integración a la hora de tender puentes entre los niveles de análisis.

Reconocemos que nuestro esfuerzo de modelado representa un primer paso. Un paso hacia la consecución de una solución general para la multisensorialidad. Formalización de la integración. Hemos demostrado las capacidades de nuestro software en la simulación de múltiples modelos en un grupo de tres tareas similares (Noel et al., 2022b). Sin embargo, nuestro marco de software requiere la incorporación de Métricas de comparación y validación de modelos para facilitar la evaluación crítica de cada implementación del modelo (Wilson y Collins, 2019; Blohm et al., 2020). En general, proponemos una

entorno de software como una primera aproximación a un enfoque generalizado marco para la integración multisensorial, necesario para el avance teórico del campo.

Disponibilidad y direcciones futuras

Todo el código fuente está bajo una licencia BSD de 3 cláusulas y disponible en un repositorio público: <https://github.com/renatoparedes/scikit-neuromsi>. Scikit-NeuroMSI está disponible para Instalación en el índice de paquetes de Python (PyPI)¹. La documentación del usuario se genera automáticamente desde Scikit-NeuroMSI. cadenas de documentación y se publican en el servicio Leer la documentación².

En español hay una frase “Con el diario del Lunes”. (literalmente, “Con el periódico del lunes”), que comparte la mismo significado que la expresión inglesa “Monday-morning quarterback” - indicando que algo se vuelve obvio solo después de que haya sucedido. Si bien Scikit-NeuroMSI ha logrado con éxito su objetivo técnico de estandarizar modelos de integración multisensorial existentes, nuestra experiencia ha reveló oportunidades para mejorar el modelado computacional.

En concreto, la arquitectura podría mejorarse descomponiendo los modelos en dos entidades distintas:

- Un componente de procesamiento de estímulos que maneja estímulos individuales entradas sensoriales
- Un componente de integración que consolida los resultados en una modalidad unificada

O matemáticamente hablando:

$$E: S \times I \rightarrow R \quad (1)$$

Dónde:

- S representa la(s) fuente(s) de estímulo de una o varias modalidades
- I es el integrador que combina los estímulos de S

Visualizamos una implementación de Python similar a lo que Se presenta en el Código 6. Al disociar el procesamiento/generación de estímulos de los mecanismos de integración, se genera una nueva integración. Los modelos se pueden implementar y probar fácilmente sin modificar el código de estímulo subyacente. La arquitectura flexible... Simplifica la implementación de integraciones sofisticadas estrategias y permite una extensión sencilla para manejar modalidades adicionales o tipos de estímulos, lo que hace que el marco sea particularmente valioso para la investigación emergente en áreas como las interfaces cerebro-computadora y la robótica. Desde una Desde la perspectiva del software, este nuevo diseño promovería el código

¹ <https://pypi.org/project/scikit-neuromsi/>

² <https://scikit-neuromsi.readthedocs.io/>

reutilización y hacer que la base de código sea más fácil de mantener, permitiendo que la comunidad científica contribuya con nuevos modelos y extensiones al framework más fácilmente.

Code 6 Proposed implementation using composition-based design: The same integration component (`integrators.SomeIntegrator`) can process both cross-modal (audio-visual) and unimodal (audio-audio) combinations through a flexible stimulus composition interface. This design separates stimulus handling from integration logic, enabling more modular and extensible implementations.

```
from skneuromsi import stimulus, integrators

# one sound and one visual stimulus
m0 = Model(
    stimulus.Auditory(...), stimulus.Visual(...),
    integrators.SomeIntegrator(...),
)

# two sounds
m1 = Model(
    stimulus.Auditory(...), stimulus.Auditory(...),
    integrators.SomeIntegrator(...),
)
```

Declaración de intercambio de información

El código y los datos utilizados para generar las simulaciones presentadas en este artículo están disponibles en: <https://github.com/renatoparedes/Red NeuroMSI>.

Apéndice A Estandarización del modelo formal

Formalmente, nuestro objetivo es definir un marco con los siguientes propiedad:

$E : M \rightarrow R$ (A1)

Dónde:

- E es la ejecución de un modelo m.
- M es el conjunto de todos los modelos existentes.
- R es el espacio de todos los resultados posibles de M.

Entonces, para un modelo específico $m \in M$

$r = E(m)$

donde $r \in R_m \subseteq R$.

Luego definimos $f : F \rightarrow Y$ donde F representa todos los resultados pro-herramientas de procesamiento y definimos una función de procesamiento:

$f : R \rightarrow Y$

donde Y es el espacio de salida de la herramienta; y con esto tenemos definir la propiedad universal

$\forall r \in R, \forall Y : y = f(r), \forall f \in F$ (A2)

Apéndice B Clases y objetos

La clase abstracta ModelABC define las funcionalidades Responsable de configurar los nombres de los modos y establecer un Protocolo común para todos los modelos definidos en el paquete. En términos definidos en las ecuaciones anteriores, cualquier modelo que herede de ModelABC pertenece al conjunto M de la Ec. A1.

La clase NDResult es la implementación de cualquier resultado de modelos heredados de ModelABC y de un matemático

Desde el punto de vista matemático, son la realización del código de la Establezca R a partir de la ecuación A1. Como estructura de datos, NDResult (Resultado N-Dimensional) es una capa delgada que añade multisensorialidad.

Capacidades de análisis de integración sobre DataArray estructura de la biblioteca XArray (Hoyer y Hamman, 2017). XArray fue diseñado originalmente para trabajar con datos de alta dimensión del formato NetCDF (Rew y Davis, 1990), comúnmente utilizado en el procesamiento de datos satelitales.

Además, dado que XArray proporciona funciones de persistencia, un archivo .ndr Se definió un formato de persistencia que comprime un NetCDF archivo junto con sus metadatos en un contenedor ZIP (PKWARE Inc., 2022). Además, NDResult también admite la compresión, ya que los resultados del modelo suelen consumir una cantidad significativa de memoria. recursos.

La clase ParameterSweep es la herramienta principal diseñada para realizar barridos de parámetros sobre un modelo, automáticamente ejecutar el modelo varias veces mientras se varía sistemáticamente el valor de un parámetro objetivo dentro de un rango especificado. El La clase permite configurar el número de repeticiones para Cada valor de parámetro admite la ejecución paralela mediante arquitecturas multinúcleo e implementa la gestión de memoria para Prevenir condiciones de desbordamiento. En particular, ParameterSweep es independiente del modelo y puede funcionar con cualquier modelo que herede de ModelABC, lo que lo hace altamente flexible y reutilizable. Este es el primer uso de DIP.

El segundo caso de uso implementa el Patrón de Estrategia (Gamma et al., 1995), lo que permite algoritmos intercambiables para procesar los resultados de cada ejecución del modelo. Por defecto, ParameterSweep() emplea una estrategia llamada NDCollectionProcessingStrategy, que actúa como una canalización de procesamiento que primero comprime cada resultado individual y luego los agrega en datos coherentes Estructura denominada NDResultCollection, que facilita el análisis posterior. Esta decisión arquitectónica fue impulsada por la huella de memoria de los resultados, que normalmente ocupan cientos de megabytes, lo que hace que el almacenamiento simultáneo de múltiples resultados sea computacionalmente costoso. El diseño permite la implementación de estrategias personalizadas que puedan selectivamente almacenar puntos de datos específicos de cada resultado, optimizando así utilización de la memoria.

ParameterSweep admite cualquier modelo que cree instancias de una clase que hereda de ModelABC y sabe cómo procesa los objetos NDResult que genera delegando

Asignarlos a la estrategia elegida. En otras palabras, es la implementación en código de la propiedad definida en la ecuación A2.

NDRestCollection es la última pieza del rompecabezas que compone Scikit-NeuroMSI. Es una clase auxiliar que permite agrupar numerosos resultados comprimidos del mismo modelo en una sola colección y los amplía con funcionalidades clásicas de área, como el sesgo intermodal y el análisis causal (Körding et al., 2007). Además, es el tipo de dato predeterminado que devuelve la herramienta ParameterSweep() cuando se utiliza con la estrategia predeterminada. Al igual que NDRest, ofrece la posibilidad de exportar cada punto de datos a formato NetCDF en un archivo comprimido ZIP con sus metadatos en un formato llamado *.ndc.

Apéndice C Modelos implementados

C.1 Integrador bimodal casi óptimo

El Integrador Bimodal Casi Óptimo (Alais y Burr, 2004) para señales auditivas (A) y visuales (V) en el contexto de una tarea de localización espacial auditiva se puede calcular como:

$$S^{\wedge}AV = wAS^{\wedge}A + wVS^{\wedge}V \tag{C3}$$

donde S^A y S^V son estimaciones auditivas y visuales unimodales compañeros, respectivamente, y S^AV es la estimación multimodal.

Además, wA y wV son los pesos relativos para cada modalidad, definida como:

$$wA = \frac{\sigma_V}{\sigma_A + \sigma_V} \tag{C4}$$

$$wV = \frac{\sigma_A}{\sigma_V + \sigma_A} \tag{C5}$$

donde σA y σV son las varianzas de cada estímulo unimodal, respectivamente.

Estas ecuaciones muestran que la estimación multisensorial óptima suma las estimaciones unisensoriales ponderadas por sus varianzas recíprocas normalizadas.

El modelo Integrador Bimodal Casi Óptimo se puede llamar usando el Código 7.

Code 7 Example of Near-optimal Bimodal Integrator instantiation and default execution parameterisation within the Scikit-NeuroMSI package.

```
# import the model
>>> from skneuromsi.mle import AlaisBurr2004

# create the model object
>>> model = AlaisBurr2004(position_range=(0, 90), position_res=1)

# explore the model run default parameterisation
>>> model.run
<function skneuromsi.mle._alais_burr2004.AlaisBurr2004.run(*,
    auditory_position=-5, visual_position=5, auditory_sigma=3.0,
    visual_sigma=3.0, noise=None)>
```

C.2 Inferencia causal bayesiana

El modelo de inferencia causal bayesiana (Körding et al., 2007) utiliza la siguiente formulación:

$$p(x_1, x_2) = p(x_1, x_2) \frac{p(x_1, x_2 | C) p(C) p(C | C)}{p(x_1, x_2 | C = 1) p(C = 1) + p(x_1, x_2 | C = 2) (1 - p(C = 1))} \tag{C6}$$

donde x1 y x2 son dos señales unimodales y C es una variable binaria que representa el número de causas en el entorno.

La probabilidad posterior de que las señales tengan una única causa en el entorno se define de la siguiente manera:

$$p(C = 1 | x_1, x_2) = \frac{p(x_1, x_2 | C = 1) p(C = 1) p}{(x_1, x_2 | C = 1) p(C = 1) + p(x_1, x_2 | C = 2) (1 - p(C = 1))} \tag{C7}$$

y la probabilidad se calcula como:

$$p(x_1, x_2 | C = 1) = p(x_1, x_2 | X) p(X) dX \tag{C8}$$

Aquí, p(C = 1) es la probabilidad previa de una causa común (por defecto, 0.5). X representa los atributos de los estímulos (p. ej., la distancia), que se representan en el sistema nervioso como x1 y x2.

Estas ecuaciones muestran que la inferencia de una causa común de dos señales unisensoriales se calcula combinando la probabilidad y la probabilidad previa de que las señales tengan una causa común.

Existe una mayor probabilidad si las dos señales unisensoriales son similares, lo que a su vez aumenta la probabilidad de inferir que las señales tienen una causa común.

El modelo de inferencia causal bayesiana se puede llamar usando Código 8.

Code 8 Example of Bayesian Causal Inference model instantiation and default execution parameterisation within the Scikit-NeuroMSI package.

```
# import the model
>>> from skneuromsi.bayesian import Kording2007

# create the model object
>>> model = Kording2007(position_range=(0, 90), position_res=1)

# explore the model run default parameterisation
>>> model.run
<function skneuromsi.bayesian._kording2007.Kording2007.run(*,
    auditory_position=-15, visual_position=15, auditory_sigma=2.0,
    visual_sigma=10.0, p_common=0.5, prior_sigma=20.0, prior_mu=0,
    strategy='averaging', noise=True, causes_kind='count',
    dimension='space')>
```

C.3 Integración audiovisual y red de inferencia causal

La red de integración audiovisual e inferencia causal (Cuppini et al., 2017) consta de tres capas: dos codifican

estímulos auditivos y visuales, por separado, y se conectan a una capa multisensorial donde se calcula la inferencia causal. Cada uno de Estas capas constan de 180 neuronas dispuestas topológicamente. para codificar un espacio de 180°. De esta manera, cada neurona codifica 1° de El espacio y las neuronas cercanas entre sí codifican información espacial cercana. posiciones.

Cada neurona se indicará con un superíndice c que indica un área cortical específica (a , v o m para el área auditiva, visual). o área multisensorial, respectivamente). De manera similar, cada neurona tendrá un subíndice j que hace referencia a su posición espacial dentro un área determinada. Las neuronas en cada capa tienen una activación sigmoidea Función y dinámica de primer orden:

$$\tau \frac{dy_c(t)}{dt} = -y_c(t) + F(u_c(t), j) \quad c = a, v, m \quad (C9)$$

Aquí, $u(t)$ e $y(t)$ se utilizan para representar la entrada neta y salida de una neurona dada en el tiempo t . τ denota el tiempo constante de neuronas pertenecientes a un área dada c . $F(u)$ representa la relación sigmoidea:

$$F(u) = \frac{1}{1 + \exp(-s(u - \theta))} \quad (C10)$$

Aquí, s y θ denotan la pendiente y la posición central. de la relación sigmoidea, respectivamente. Neuronas en todas Las regiones difieren solo en sus constantes de tiempo, elegidas para imitar Procesamiento sensorial más rápido para estímulos en la región auditiva en comparación con los estímulos visuales.

Estas neuronas están conectadas recurrentemente en un "mexicano". patrón de "sombbrero" dentro de cada capa. Dicho patrón de conectividad consiste en definir un área excitatoria central rodeada por un anillo inhibitorio para cada neurona, de modo que toda la capa genera excitación para estímulos espacialmente cercanos e inhibición para estímulos distantes:

$$L_{sjk} = L_{ex} \cdot \exp\left(-\frac{(D_{jk})^2}{2(\sigma_{ex})^2}\right) - L_{in} \cdot \exp\left(-\frac{(D_{jk})^2}{2(\sigma_{in})^2}\right), \quad D_{jk} = 0 \quad (C11)$$

Aquí, L_c denota el peso de la sinapsis de la Neurona presináptica jk en la posición k a neurona postsináptica en posición j . D_{jk} indica la distancia entre la zona presináptica neurona y las neuronas postsinápticas dentro de un área determinada:

$$D_{jk} = \begin{cases} |j - k|, & |j - k| \leq N/2 \\ N - |j - k|, & |j - k| > N/2 \end{cases} \quad (C12)$$

Esto define una estructura circular donde cada neurona recibe el mismo número de conexiones laterales.

Por otra parte, las neuronas en cada capa unisensorial (por ejemplo, auditivo) están conectados recíprocamente con las neuronas en el

Capa opuesta (p. ej., visual). Estas conexiones son excitatorias y modifican la percepción espacial de estímulos unisensoriales. Estos pesos sinápticos están definidos simétricamente ($W_{av} = W_{va}$ y $\sigma_{av} = \sigma_{va}$) por la función gaussiana:

$$W_{cd} = W_0 \cdot \exp\left(-\frac{D_{jk}^2}{2\sigma_{cd}^2}\right), \quad cd = av \text{ o } va \quad (C13)$$

W_0 denota el nivel más alto de eficacia sináptica y D_{jk} es la distancia entre la neurona en la posición j en la región unisensorial postsináptica y la neurona en la posición k en la región unisensorial presináptica. σ_{cd} define el ancho de Las sinapsis intermodales.

Además, las neuronas de las capas unisensoriales tienen conexiones excitatorias con la capa multisensorial. Estas sinapsis Se utilizan para codificar información sobre la coincidencia espacial mutua de estímulos intermodales y la probabilidad de que dos Los estímulos fueron generados por una fuente común (es decir, se resuelven). El problema de la inferencia causal). Los pesos de estas sinapsis de propagación hacia adelante se definen simétricamente como:

$$W_{mc} = W_0 \cdot \exp\left(-\frac{D_{jk}^2}{2\sigma_{mc}^2}\right), \quad c = a, v \quad (C14)$$

Aquí W_{mc} denota el valor más alto de eficacia sináptica, D_{jk} la distancia entre la neurona multisensorial en la posición j y la neurona unisensorial en la posición k , y σ_{mc} el ancho de las sinapsis de avance. La distancia se define como:

$$D_{jk} = \begin{cases} |j - k|, & |j - k| \leq N/2 \\ N - |j - k|, & |j - k| > N/2 \end{cases} \quad (C15)$$

Aquí, t_{feed} representa la latencia de las entradas de avance. entre las regiones unisensorial y multisensorial. W_{mv} y W_{vm} son las sinapsis que conectan la neurona presináptica en Posición jk en un área unisensorial dada y la zona postsináptica neurona en la posición j en el área multisensorial.

Finalmente, los estímulos visuales y auditivos utilizados como entrada para La red se define con una función gaussiana para imitar

Los estímulos externos localizados espacialmente filtrados por los campos receptivos de las neuronas. El estímulo del exterior

El mundo se simula como una función gaussiana 1-D para representar La incertidumbre en la detección de estímulos externos:

$$E_c(t) = E_0 \cdot \exp\left(-\frac{D_{jk}^2}{2(\sigma_c)^2}\right) \quad (C16)$$

Aquí, E_0 denota la fuerza del estímulo, D_{jk} el distancia entre la neurona en la posición j y el estímulo en

posición pc, y α el grado de incertidumbre en la sensibilidad de detección. La distancia dc se define como:

$$\frac{1}{N} = \frac{|j - pc|, |j - pc| N/2}{N - |j - pc|, |j - pc| > N/2}$$

(C17)

El punto central de la función gaussiana corresponde hasta el punto de aplicación del estímulo en el exterior mundo, mientras que la desviación estándar de la función gaussiana refleja el ancho de los campos receptivos de las neuronas y La fiabilidad de la entrada externa. Este parámetro se utiliza para representar las diferentes agudezas espaciales del oído y modalidades sensoriales visuales.

La entrada neta de una neurona es la suma de una parte interna (es decir, componente dentro de la región) (I_j^{do}) y un exterior (es decir, un área extra) componente (oc j(t)):

$$u_{jj}^{c_j}(t) = I_j^{do}(t) + oc_j(t)$$

(C18)

El componente dentro de la región I_j^{do} se define como:

$$I_j^{do}(t) = \sum_k L_{jk} c_{jk} y_c(t)$$

(C19)

Aquí L_{jk} representa la fuerza de la sinapsis lateral de una neurona presináptica en la posición k a una postsináptica neurona en la posición j en la región c. $y_{c_{jaja}}$ es la actividad de la neurona presináptica en la posición k.

Es importante destacar que la entrada de área adicional se define de manera diferente para Áreas unisensoriales y multisensoriales. La entrada extra-área para Las áreas unisensoriales incluyen un estímulo del exterior. mundo (ec j(t)), un componente intermodal que proviene de la otra área unisensorial (cc j(t)) y un componente de ruido (nc j). Además, la entrada intermodal se define como:

$$c_{ccj}(t) = \sum_{k=1}^{n_{ccj}} Onda_{jk} \cdot y_{ccj}$$
$$c_{cv}(t) = \sum_{k=1}^{n_{cv}} Wva_{jk} \cdot s_{cv}^i$$

(C20)

El componente de ruido nc se extrae de una distribución uni- jform estándar en el intervalo [nmax + nmax]. Aquí, nmax se define como el 40% de la fuerza del estímulo externo para cada modalidad.

El modelo de Red de Integración Audiovisual puede ser llamado usando el Código 9:

Code 9 Example of the Audio-visual Integration Network model instantiation and default execution parameterisation within in the Scikit-NeuroMSI package.

```
# import the model
>>> from skneuromsi.neural import Cuppini2017

# create the model object
>>> model = Cuppini2017(neurons=90, position_range=(0, 90),
-> position_res=1)

# explore the model run default parameterisation
>>> model.run
<function skneuromsi.neural._cuppini2017.Cuppini2017.run(*,
-> auditory_position=None, visual_position=None, auditory_sigma=32,
-> visual_sigma=4, auditory_intensity=28, visual_intensity=27,
-> auditory_duration=None, auditory_onset=0, auditory_stim_n=1,
-> visual_duration=None, visual_onset=0, visual_stim_n=1,
-> auditory_soa=None, visual_soa=None, noise=False, noise_level=0.4,
-> feedforward_weight=18, cross_modal_weight=1.4,
-> causes_kind='count', causes_dim='space',
-> causes_peak_threshold=0.15, causes_peak_distance=None)>
```

C.4 Inferencia causal spatiotemporal multisensorial Red

El modelo consta de tres capas: dos codifican la auditiva y estímulos visuales por separado y se conectan a una capa multisensorial a través de sinapsis de avance y retroalimentación. En el unisensorial áreas, el modelo calcula la posición spatiotemporal de los estímulos externos. Además, en el área multisensorial, El modelo calcula la inferencia causal.

Este modelo mantiene la conectividad neuronal (lateral, crossmodal, feedforward) y las entradas descritas en la red presentada en la sección anterior (Cuppini et al., 2017). Nuestro modelo ahora incluye conectividad de retroalimentación ($B_{jam} = B_{vm} \eta_j$ y $\alpha_{am} = \alpha_{vm}$), definida por la siguiente ecuación:

$$B_{cm_{jk02}(\alpha_{cm})} = B_{cm} \cdot \exp - \frac{D_{jk}^2}{2}, \quad cm = am \text{ o } vm \text{ (C21)}$$

B_{cm} denota el nivel más alto de eficacia sináptica y D_{jk} es la distancia entre la neurona en la posición j en la región unisensorial postsináptica y la neurona en la posición k en la región multisensorial presináptica. α_d define el ancho de las sinapsis de retroalimentación.

En general, la entrada de retroalimentación se define como:

$$c_{ccj}(t) = \sum_{k=1}^{n_{ccj}} B_{cm_{jaja}} \cdot y_{ccj} \text{ alimentación } t - t$$

(C22)

Aquí t_f feed representa la latencia de las entradas de retroalimentación. entre las regiones multisensoriales y unisensoriales. Los pesos sinápticos de retroalimentación también son simétricos ($B_{am} = B_{vm}$ y $\alpha_{am} = \alpha_{vm}$) definidas:

Todas estas fuentes externas se filtran mediante un segundo orden. ecuación diferencial para imitar la dinámica temporal de la

estímulos en una corteza:

$$\frac{d}{dt} \delta c_{jj}(t) = \frac{Gc}{c \tau} \cdot ce(t) + cc(t) + bc(t) + nc - \frac{2 \cdot \delta c_{jj}(t)}{c \tau} - \frac{oc_{jj}(t)}{(\tau \cdot c)^2}, c = a, v \tag{C23}$$

Aquí, Gc representa la ganancia y τ las constantes de tiempo de la la dinámica.

Estas fuentes externas también se filtran mediante un segundo orden. ecuación diferencial:

$$\frac{d}{dt} \delta m_{jj}(t) = \frac{om}{m \tau} \cdot i_{yo}(t) - \frac{j(t)}{m \tau} - \frac{om}{(\tau \cdot m)^2} \tag{C24}$$

Aquí, Gm representa la ganancia y la las constantes de tiempo de la dinámica τ en las neuronas multisensoriales.

Además, la entrada intermodal se define como:

$$\begin{aligned} \text{Cauda}(t) &= j_{k=1}^{nosta} \text{Onda} \cdot y_k(t - tcr_{oss}) \\ CV(t) &= j_{k=1}^{nosta} \text{Wva} \cdot s_k(t - tcr_{oss}) \end{aligned} \tag{C25}$$

Aquí, tcr_{oss} representa la latencia de las entradas intermodales entre dos regiones unisensoriales.

El modelo de red de inferencia causal espaciotemporal multisensorial se puede llamar utilizando el código 10.

Code 10 Example of the Multisensory Spatiotemporal Causal Inference Network model instantiation and default execution parameterisation within in the Scikit-NeuroMSI package.

```
# import the model
>>> from skneuromsi.neural import Paredes2025

# create the model object
>>> model = Paredes2025(neurons=90,
                        position_range=(0, 90),
                        position_res=1,
                        time_range=(0, 150),
                        time_res = 1)

# explore the model run default parameterisation
>>> model.run
<function skneuromsi.neural._paredes2025.Paredes2025.run(*,
    auditory_soa=50, visual_soa=None, auditory_onset=16,
    visual_onset=16, auditory_duration=7, visual_duration=12,
    auditory_position=None, visual_position=None,
    auditory_intensity=2.4, visual_intensity=1.4, auditory_sigma=32,
    visual_sigma=4, noise=False, noise_level=0.4,
    temporal_noise=False, temporal_noise_scale=5,
    lateral_excitation=2, lateral_inhibition=1.8,
    cross_modal_weight=0.075, cross_modal_latency=16, feed_latency=95,
    feedback_weight=0.1, feedforward_weight=1.4, auditory_gain=None,
    visual_gain=None, multisensory_gain=None, auditory_stim_n=2,
    visual_stim_n=1, feedforward_pruning_threshold=0,
    cross_modal_pruning_threshold=0, causes_kind='count',
    causes_dim='space', causes_peak_threshold=0.8,
    causes_peak_distance=None)>
```

Apéndice D Ajuste del modelo

D.1 Lecturas del modelo

D.1.1 Tarea de inferencia causal implícita

La tarea de localización espacial audiovisual (Noel et al., 2022b) implica que los participantes determinen si un estímulo auditivo se percibe a la derecha o a la izquierda de una posición central, Se indica pulsando un botón. Posteriormente, se realiza un análisis psicométrico. Las funciones se construyen trazando la proporción de Respuestas dirigidas hacia la derecha en función de la posición del estímulo. Estos datos se modelan utilizando un modelo acumulativo. Función gaussiana. La función psicométrica proporciona dos parámetros que delinear el rendimiento de localización del Participantes: sesgo y umbral. El sesgo se define como el valor del estímulo en el que las respuestas se dividen equitativamente entre hacia la derecha y hacia la izquierda. Un sesgo que se aproxima a 0° denota Localización de alta precisión. El umbral está representado por la desviación estándar de la función gaussiana acumulada ajustada ción. Un umbral más bajo indica una mayor precisión en el espacio. localización.

Con el fin de agilizar el proceso y reconocer la

En ausencia de ruido en nuestras simulaciones, optamos por no hacerlo directamente. simular las respuestas izquierda-derecha de los participantes. En cambio, se concentró en modelar la estimación de la posición auditiva para Cada modelo. La estimación de la posición auditiva para la red. El modelo se determinó al localizar la neurona que mostraba el nivel de actividad más alto durante la simulación, con cada neurona correspondiente a un segmento espacial discreto.

D.1.2 Tareas de inferencia causal explícita

Las tareas de inferencia causal explícita requieren que los participantes determinar si los estímulos auditivos y visuales se originan en La misma fuente. En el contexto de los modelos de redes neuronales, esto La proporción se deriva en función de la activación neuronal máxima. manifestado dentro de las neuronas multisensoriales, dependiendo de la condición de que dicha activación supere el umbral de 0.15. En la tarea espacial, la evaluación de la actividad multisensorial se realiza dentro del dominio espacial al final. punto temporal, mientras que en la tarea temporal, la evaluación ocurre dentro del dominio temporal en el punto de máxima actividad. En los casos en que se identifican múltiples valores pico, producto promedio de todas las combinaciones potenciales de estos picos Se calculan los valores para estimar la proporción atribuible a la presencia de múltiples fuentes. Posteriormente, la proporción complementaria, que representa la percepción de múltiples estímulos, se calcula para determinar la proporción atribuible a informes de fuentes comunes.

D.2 Procedimiento de ajuste

La proporción de informes de sesgo auditivo o de causa común
Los datos reportados por cada modelo se ajustaron a los datos experimentales.
(Noel et al., 2022b) con la función de costo definida por la ecuación D26.

$$\text{Costo} = \sum_{i=1}^N \frac{P_{\text{data}} - P_{\text{modelo}}}{P_{\text{data}}}^2 \quad (\text{D26})$$

Aquí, P_{data} y P_{modelo} denota la proporción medida en la i -ésima disparidad de estímulos audiovisuales. N representa el número de disparidades medidas (es decir, 8 en el estudio empírico para las tareas espaciales). Esta función de coste se minimizó mediante la Implementación del algoritmo de evolución diferencial (Storn y Price, 1997) disponible en la biblioteca SciPy para Python lenguaje de programación (Virtanen et al., 2020).

Para el integrador bimodal casi óptimo (Alais y Burr, 2004), los parámetros α y σ se ajustaron bajo la restricción que el parámetro α excede el parámetro σ , mejorando así Precisión en la modalidad visual. El algoritmo se proporcionó con límites establecidos en (0,1, 48) para ambos parámetros.

Para el modelo de inferencia causal bayesiano (Körding et al., 2007), los parámetros α , σ , μ y σ también se ajustaron bajo la restricción de que el parámetro α excede el parámetro σ . Para En las tareas espaciales, el algoritmo se dotó de límites establecidos en (0,1, 48) para todos los parámetros, excepto μ que se estableció en (21, 69). Para la tarea temporal, se proporcionó el algoritmo con límites establecidos en (1, 500) para todos los parámetros.

Para las tareas espaciales, el integrador audiovisual y causal red de inferencia (Cuppini et al., 2017), parámetros α , σ , E_a y E_v , que representan la incertidumbre y la intensidad del estímulo, respectivamente, se ajustaron bajo la restricción de que auditiva La incertidumbre es mayor que la visual. El algoritmo fue proporcionado con límites establecidos en (0,1, 48) para incertidumbres y (0,1, 30) Para las intensidades. Para la tarea temporal, los parámetros τ_a , τ_v , τ_m , W_{mc} y W_{av} se ajustaron con límites establecidos en (0,1, 55), (0,1, 55), (0,1, 75), (0,01, 150) y (0,01, 24), respectivamente. En el curso de estas simulaciones, los parámetros α , σ , E_a y E_v se mantuvieron consistentemente en valores de 32, 4, 50 y 49, respectivamente, siendo la duración de los estímulos fijado en 6 ms.

Para las tareas espaciales, el Modelo Espacio-temporal Multisensorial Parámetros de la red de inferencia causal α , σ , E_a y E_v con los mismos límites y restricciones que el anterior modelo. Para la tarea temporal, los parámetros τ_a , τ_v , τ_m , W_{mc} y W_{av} se establecieron límites en (0,1, 50), (0,1, 50), (0,1, 50), (0,005, 50), (0, 7,5), (0, 0,15), (0, 0,005) respectivamente. Durante estas simulaciones, los parámetros α , σ , E_a y E_v se mantuvieron consistentemente en valores de 32, 4, 2,55 y 2,5, respectivamente, con una duración de los estímulos fijada en 6 ms. Se asume que los parámetros τ_{cr} y τ_{feed} fueron mantienen constantes en 16 ms y 24 ms, respectivamente.

Reconocemos que emplear un ajuste estandarizado

Rutina basada en un algoritmo genético para un modelo libre de ruido
Las simulaciones pueden no constituir la opción óptima en todos los casos.
modelos. Este enfoque puede ser particularmente subóptimo para
El modelo de inferencia causal bayesiano, que fue originalmente
implementado utilizando un estimador máximo a posteriori
con el supuesto de ruido de motor aleatorio durante 10.000 simulaciones
(Körding et al., 2007).

Agradecimientos Los autores agradecen sinceramente a Jean-Paul Noel por proporcionar los datos de comportamiento modelados en este estudio y proporcionar Comentarios perspicaces sobre la preparación de este manuscrito. Los autores También expresar agradecimiento a Francisco Morote por contribuir con las ilustraciones incluidas en el manuscrito.

Contribuciones de los autores RP: Conceptualización, Metodología, Software, Visualización, Análisis Formal, Redacción - borrador original. JBC: Conceptualización, Metodología, Software, Visualización, Redacción - borrador original. borrador. PD: Supervisión, Redacción - revisión y edición.

Financiación Financiación de acceso abierto proporcionada por la Pontificia Universidad Católica del Perú. No se recibió financiamiento para realizar este estudio.

Disponibilidad de datos El código y los datos utilizados para generar las simulaciones presentadas en este artículo están disponibles en: https://github.com/renatoparedes/Red_NeuroMSI

Declaraciones

Aprobación ética No aplica.

Intereses en conflicto Los autores declaran no tener intereses en conflicto.

Acceso abierto Este artículo está bajo una licencia Creative Commons
Licencia Internacional Atribución 4.0, que permite el uso, intercambio, adaptación, distribución y reproducción en cualquier medio o formato, tal y como se describe en el presente documento. siempre que le dé el crédito apropiado al autor(es) original(es) y al
Fuente, proporcionar un enlace a la licencia Creative Commons e indicar si se realizaron cambios. Las imágenes u otro material de terceros...
en este artículo están incluidos en la licencia Creative Commons del artículo, a menos que se indique lo contrario en una línea de crédito del material. Si el material no está incluido en la licencia Creative Commons del artículo y su
El uso previsto no está permitido por la normativa legal o excede los límites establecidos. Para uso permitido, deberá obtener la autorización directa del titular de los derechos de autor. Para ver una copia de esta licencia, visite <http://creativecommons.org/licencias/por/4.0/>.

Referencias

- Acerbi, L., Dokka, K., Angelaki, DE y Ma, WJ (2018). bayesiano comparación de estrategias de inferencia causal explícitas e implícitas en la percepción multisensorial del rumbo. *PLoS Computational Biology*, 14(7), Artículo e1006110. <https://doi.org/10.1371/journal.pcbi.1006110>
- Alais, D., y Burr, D. (2004). El efecto ventrilocuo resulta de Integración bimodal casi óptima. *Current Biology*, 14(3), 257–262. <https://doi.org/10.1016/j.cub.2004.01.029>
- Blohm, G., Kording, KP y Schrater, PR (2020). Un modelo de cómo hacerlo Guía para la neurociencia. *eNeuro*, 7(1), 1–12. <https://doi.org/10.1523/ENEURO.0352-19.2019>

- Bolognini, N., Rasi, F., Coccia, M., Ládavas, E. (2005). Mejora de la búsqueda visual en pacientes hemianópicos tras estimulación audiovisual. *Cerebro: una revista de neurología*, 128 (parte 12), 2830–2842. <https://doi.org/10.1093/brain/awh656>
- Booch, G. (1982). Diseño orientado a objetos. *ACM SIGAda Ada Letters*, 1(3), 64–76. <https://doi.org/10.1145/989791.989795>
- Brooks, F., y Kugler, H. (1987). No hay una solución milagrosa. Abril.
- Cascio, C.J., Foss-Feig, J.H., Burnette, C.P., Heacock, J.L., Cosby, A.A. (2012). La ilusión de la mano de goma en niños con trastornos del espectro autista: influencia retardada de la información táctil y visual combinada en la propiocepción. *Autismo: Revista Internacional de Investigación y Práctica*, 16(4), 406–419. <https://doi.org/10.1177/1362361311430404>
- Chandrasekaran, C. (2017). Principios computacionales y modelos de integración multisensorial. *Current Opinion in Neurobiology*, 43, 25–34. <https://doi.org/10.1016/j.conb.2016.11.002>
- Chrysaitis, N.A., y Seriès, P. (2023). 10 años de teorías bayesianas del autismo: una revisión exhaustiva. *Neuroscience & Biobehavioral Reviews*, 145, Artículo 105022. <https://doi.org/10.1016/j.neubiorev.2022.105022>
- Colonius, H., y Diederich, A. (2004). Interacción multisensorial en el tiempo de reacción sacádica: un modelo de ventana temporal de integración. *Revista de Neurociencia Cognitiva*, 16(6), 1000–1009. <https://doi.org/10.1162/0898929041502733>
- Colonius, H. y Diederich, A. (2020). Modelos formales y medidas cuantitativas de la integración multisensorial: una revisión selectiva. *Revista Europea de Neurociencia*, 51(5), 1161–1178. <https://doi.org/10.1111/ejn.13813>
- Colonius, H., Wolff, F.H., y Diederich, A. (2017). Desigualdades del modelo racial trimodal en la integración multisensorial: I. *Fundamentos*. *Frontiers in Psychology*, 8, 1141. <https://doi.org/10.3389/fpsyg.2017.01141>
- Cuppini, C., Magosso, E., Bolognini, N., Vallar, G. y Ursino, M. (2014). Análisis neurocomputacional de la ilusión de destello inducida por sonido. *NeuroImage*, 92, 248–266. <https://doi.org/10.1016/j.neuroimage.2014.02.001>
- Cuppini, C., Shams, L., Magosso, E. y Ursino, M. (2017). Un modelo neurocomputacional de inspiración biológica para la integración audiovisual y la inferencia causal. *Revista Europea de Neurociencia*, 46(9), 2481–2498. <https://doi.org/10.1111/ejn.13725>
- Diederich, A. (1992). Facilitación intersensorial: modelos de raza, superposición y difusión para el tiempo de reacción a múltiples estímulos (vol. 369). Fráncfort del Meno; Nueva York: Peter Lang.
- Diederich, A. (1995). Facilitación intersensorial del tiempo de reacción: Evaluación de modelos de coactivación por contra y difusión. *Journal of Mathematical Psychology*, 39(2), 197–215. <https://doi.org/10.1006/jmps.1995.1020>
- Ernst, M.O., y Banks, M.S. (2002). Los humanos integran la información visual y háptica de forma estadísticamente óptima. *Nature*, 415(6870), 429–433. <https://doi.org/10.1038/415429a>
- Fang, Y., Yu, Z., Liu, J. K. y Chen, F. (2019). Un circuito neuronal unificado de inferencia causal e integración multisensorial. *Neurocomputing*, 358, 355–368. <https://doi.org/10.1016/j.neucom.2019.05.067>
- Ferri, F., Ambrosini, E. y Costantini, M. (2016). Procesamiento espaciotemporal de estímulos somatosensoriales en la esquizotipia. *Scientific Reports*, 6(1), 38735. <https://doi.org/10.1038/srep38735>
- Festa, E.K., Katz, A.P., Ott, B.R., Tremont, G. y Heindel, W. C. (2017). Efectos disociables del envejecimiento y el deterioro cognitivo leve en la integración audiovisual ascendente. *Revista de la enfermedad de Alzheimer: JAD*, 59(1), 155–167. <https://doi.org/10.3233/JAD-161062>
- Fetsch, C.R., DeAngelis, G.C. y Angelaki, D.E. (2013). Reduciendo la brecha entre las teorías de la integración de señales sensoriales y la fisiología de las neuronas multisensoriales. *Nature Reviews Neuroscience*, 14(6), 429–442. <https://doi.org/10.1038/nrn3503>
- French, R.L. y DeAngelis, G.C. (2020). Procesamiento neuronal multisensorial: de la integración de señales a la inferencia causal. *Current Opinion in Physiology*, 16, 8–13. <https://doi.org/10.1016/j.cophys.2020.04.004>
- Frässle, S., Aponte, E.A., Bollmann, S., Brodersen, K.H., Do, C.T., Harrison, O.K. y Stephan, K.E. (2021). TAPAS: Un paquete de software de código abierto para neuromodelado traslacional y psiquiatría computacional. *Frontiers in Psychiatry*, 12, artículo 680811. <https://doi.org/10.3389/fpsyg.2021.680811>
- Gamma, E., Helm, R., Johnson, R., Vlissides, J., Patterns, D. (1995). Patrones de diseño: Elementos de software orientado a objetos reutilizable. Addison-Wesley.
- Gast, R., Rose, D., Salomon, C., Möller, H.E., Weiskopf, N. y Knösche, T.R. (2019). PyRates: Un marco de Python para simulaciones neuronales basadas en tasas. *PLOS ONE*, 14(12), Artículo e0225900. <https://doi.org/10.1371/journal.pone.0225900>
- Gieseler, A., Tahden, M.A.S., Thiel, C.M. y Colonius, H. (2018). ¿Afecta el uso de audífonos a la integración audiovisual en la discapacidad auditiva leve? *Experimental Brain Research*, 236(4), 1161–1179. <https://doi.org/10.1007/s00221-018-5206-6>
- Guest, O., y Martin, A.E. (2021). Cómo el modelado computacional puede impulsar la construcción de teorías en la ciencia psicológica. *Perspectivas sobre la ciencia psicológica: Revista de la Asociación para la Ciencia Psicológica*, 16(4), 789–802. <https://doi.org/10.1177/1745691620970585>
- Haß, K., Sinke, C., Reese, T., Roy, M., Wiswede, D., Dillo, W. y Szycik, G.R. (2017). Ventana de integración temporal ampliada en la esquizofrenia, indicada por la ilusión del doble destello. *Neuropsychiatría cognitiva*, 22(2), 145–158. <https://doi.org/10.1080/13546805.2017.1287693>
- Hahn, N., Foxe, J.J., y Molholm, S. (2014). Deficiencias en la integración multisensorial y el aprendizaje intersensorial como vías hacia la dislexia. *Neuroscience and Biobehavioral Reviews*, 47, 384–392. <https://doi.org/10.1016/j.neubiorev.2014.09.007>
- Hoyer, S. y Hamman, J. (2017). xarray: Arreglos y conjuntos de datos etiquetados con Nd en Python. *Journal of Open Research Software*, 5(1), 10–10. <https://doi.org/10.5334/jors.148>
- Jacobson, I., Booch, G., Rumbaugh, J. (2000). Uml: El proceso unificado de desarrollo de software. Addison-Wesley.
- Karvelis, P., Seitz, A.R., Lawrie, S.M. y Seriès, P. (2018). Los rasgos autistas, pero no la esquizotipia, predicen una mayor ponderación de la información sensorial en la integración visual bayesiana. *ELife*, 7, Artículo e34115. <https://doi.org/10.7554/eLife.34115>
- Körding, K.P., Beierholm, U., Ma, W.J., Quartz, S., Tenenbaum, J.B. y Shams, L. (2007). Inferencia causal en la percepción multisensorial. *PLoS ONE*, 2(9), Artículo e943. <https://doi.org/10.1371/journal.pone.0000943>
- Ma, W.J. y Pouget, A. (2008). Vinculación de las neuronas con el comportamiento en la percepción multisensorial: Una revisión computacional. *Brain Research*, 1242, 4–12. <https://doi.org/10.1016/j.brainres.2008.04.082>
- Ma, W.J. y Rahmati, M. (2013). Hacia una implementación neuronal de la inferencia causal en la combinación de señales. *Investigación Multisensorial*, 26(1–2), 159–176. <https://doi.org/10.1163/22134808-00002407>
- Marr, D. (2010). Visión: Una investigación computacional sobre la representación y el procesamiento humano de la información visual. Cambridge, Massachusetts: MIT Press.
- Martin, B., Giersch, A., Huron, C. y van Wassenhove, V. (2013). Estructura temporal y cronología de eventos en la esquizofrenia: Enlace preservado en un "ahora" más prolongado. *Neuropsychologia*, 51(2), 358–371. <https://doi.org/10.1016/j.neuropsychologia.2012.07.002>
- Martin, R.C. (2000). Principios y patrones de diseño. Objeto. Mentor, 1(34), 597.
- Meijer, D. y Noppeney, U. (2020). Modelos computacionales de integración multisensorial. *Percepción multisensorial* (págs. 113–133). Elsevier.
- Miller, R.L., Stein, B.E. y Rowland, B.A. (2017). La integración multisensorial utiliza una transformación unisensorial-multisensorial en tiempo real.

- Revista de Neurociencia: Revista Oficial de la Sociedad de Neurociencia, 37(20), 5183–5194. <https://doi.org/10.1523/JNEUROSCI.2767-16.2017>
- Noel, JP y Angelaki, DE (2023). Una teoría del autismo que conecta distintos niveles de descripción. *Tendencias en Ciencias Cognitivas*, 27(7), 631–641. <https://doi.org/10.1016/j.tics.2023.04.010>
- Noel, JP, Paredes, R., Terrebbonne, E., Feldman, JI, Woynaroski, T., Cascio, CJ y Wallace, MT (2022a). Actualización inflexible de la división entre el yo y el otro en un contexto social en el autismo: evidencia psicofísica, electrofisiológica y de modelado de redes neuronales. *Psiquiatría Biológica: Neurociencia Cognitiva y Neuroimagen*, 7(8), 756–764. <https://doi.org/10.1016/j.bpsc.13/03/2021>
- Noel, JP, Shivkumar, S., Dokka, K., Haefner, RM, Angelaki, DE (2022b). Inferencia causal aberrante y presencia de un mecanismo compensatorio en el trastorno del espectro autista. *eLife*, 11, e71866. <https://doi.org/10.7554/eLife.71866>
- Ohshiro, T., Angelaki, DE, y DeAngelis, GC (2011). Un modelo de normalización de la integración multisensorial. *Nature Neuroscience*, 14(6), 775–782. <https://doi.org/10.1038/nn.2815>
- Paredes, R., Ferri, F., Romei, V. y Serisè, P. (2025). El aumento de la excitación potencia la ilusión de destello inducida por el sonido al afectar la inferencia causal multisensorial en el espectro de la esquizofrenia. *Schizophrenia Research*, 283, 1–10. <https://doi.org/10.1016/j.schres.2025.06.007>
- Paredes, R., Ferri, F. y Serisè, P. (2022). Influencia del equilibrio E/I y la poda en las diferencias del espacio peripersonal en la esquizofrenia: Un enfoque computacional. *Schizophrenia Research*, 248, 368–377. <https://doi.org/10.1016/j.schres.2021.06.026>
- Paredes, R., Serisè, P. y Cabral, J. (2023). Scikit-NeuroMS: un marco Python para el modelado de integración multisensorial. IX Congreso de Matemática Aplicada, Computacional e Industrial, 9, 545–548.
- Parise, CV, y Ernst, MO (2016). Detección de correlación como mecanismo general para la integración multisensorial. *Nature Communications*, 7, 11543. <https://doi.org/10.1038/ncomms11543>
- Pérez, F., Granger, BE, y Hunter, JD (2010). Python: un ecosistema para la computación científica. *Computing in Science & Engineering*, 13(2), 13–21. <https://doi.org/10.1109/MCSE.2010.119>
- Pesnot Lerousseau, J., Parise, CV, Ernst, MO y Van Wassenhove, V. (2022). Cálculos de correlación multisensorial en el cerebro humano identificados mediante un modelo de codificación con resolución temporal. *Nature Communications*, 13(1), 2489. <https://doi.org/10.1038/s41467-022-29687-6>
- PKWARE Inc. (2022). Especificación del formato de archivo .ZIP (Especificación técnica n.º APPNOTE.TXT). 201 E. Pittsburgh Avenue, Suite 400, Milwaukee, WI 53204: PKWARE Inc. <http://www.pkware.com/appnote> . (Estado: FINAL - reemplaza la versión 6.3.9)
- Ramkhalawansingh, R., Keshavarz, B., Haycock, B., Shahab, S. y Campos, J.L. (2017). Análisis del efecto de la edad en la percepción visovestibular del movimiento propio mediante un paradigma de conducción. *Perception*, 46(5), 566–585. <https://doi.org/10.1177/0301006616675883>
- Rew, R. y Davis, G. (1990). NetCDF: una interfaz para el acceso a datos científicos. *IEEE Computer Graphics and Applications*, 10(4), 76–82. <https://doi.org/10.1109/38.56302>
- Rideaux, R., Storrs, KR, Maiello, G. y Welchman, AE (2021). Cómo las neuronas multisensoriales resuelven la inferencia causal. *Actas de la Academia Nacional de Ciencias*, 118(32), Artículo e2106235118. <https://doi.org/10.1073/pnas.2106235118>
- Rohe, T., Ehls, AC, y Noppeney, U. (2019). Dinámica neuronal de la inferencia causal bayesiana jerárquica en la percepción multisensorial. *Nature Communications*, 10(1), 1907. <https://doi.org/10.1038/s41467-019-09664-2>
- Rohe, T., y Noppeney, U. (2015). Las jerarquías corticales realizan inferencia causal bayesiana en la percepción multisensorial. *PLoS*
- Biología, 13(2), Artículo e1002073. <https://doi.org/10.1371/journal.pbio.1002073>
- Rossum, Gv, y Drake, FL (2010). Referencia del lenguaje Python (Versión 3.0.1 [Repr.] ed.) (N.º Pt. 2). Hampton, NH: Fundación del Software Python.
- Shams, L. y Beierholm, U. (2022). Inferencia causal bayesiana: Una teoría unificadora de la neurociencia. *Neuroscience & Biobehavioral Reviews*, 137, Artículo 104619. <https://doi.org/10.1016/j.neubiorev.2022.104619>
- Shams, L. y Beierholm, UR (2010). Inferencia causal en la percepción. *Tendencias en Ciencias Cognitivas*, 14(9), 425–432. <https://doi.org/10.1016/j.tics.2010.07.001>
- Shams, L., Kamitani, Y. y Shimojo, S. (2002). Ilusión visual inducida por el sonido. *Cognitive Brain Research*, 14(1), 147–152. [https://doi.org/10.1016/S0926-6410\(02\)00069-1](https://doi.org/10.1016/S0926-6410(02)00069-1)
- Sánchez, A., Millán-Calenti, JC, Lorenzo-López, L., & Maseda, A. (2013). Estimulación multisensorial para personas con demencia: Una revisión de la literatura. *Revista Americana de la Enfermedad de Alzheimer y Otras Demencias*, 28(1), 7–14. <https://doi.org/10.1177/1533317512466693>
- Stein, BE, Burr, D., Constantinidis, C., Laurienti, PJ, Meredith, M. A., Perrault, TJ, y Lewkowicz, DJ (2010). Confusión semántica en el desarrollo de la integración multisensorial: una solución práctica. *The European Journal of Neuroscience*, 31(10), 1713–1720. <https://doi.org/10.1111/j.1460-9568.2010.07206.x>
- Stein, BE, y Stanford, TR (2008). Integración multisensorial: cuestiones actuales desde la perspectiva de la neurona individual. *Nature Reviews Neuroscience*, 9(4), 255–266. <https://doi.org/10.1038/nrn2331>
- Stein, BE, Stanford, TR, y Rowland, BA (2020). Integración multisensorial y la sociedad para la neurociencia: entonces y ahora. *Revista de Neurociencia*, 40(1), 3–11. <https://doi.org/10.1523/JNEUROSCI.0737-19.2019>
- Stevenson, RA, Siemann, JK, Woynaroski, TG, Schneider, BC, Eberly, HE, Camarata, SM y Wallace, MT (2014). Evidencia de una integración multisensorial disminuida en los trastornos del espectro autista. *Revista de Autismo y Trastornos del Desarrollo*, 44(12), 3161–3167. <https://doi.org/10.1007/s10803-014-2179-6>
- Stimberg, M., Brette, R., Goodman, DF (2019). Brian 2, un simulador neuronal intuitivo y eficiente. *eLife*, 8, e47314. <https://doi.org/10.7554/eLife.47314>
- Storn, R., y Price, K. (1997). Evolución diferencial: una heurística simple y eficiente para la optimización global en espacios continuos. *Revista de optimización global*, 11, 341–359. <https://doi.org/10.1023/A:1008202821328>
- Thurlow, WR y Jack, CE (1973). Ciertos determinantes del efecto ventriloquia. *Perceptual and Motor Skills*, 36(3), 1171–1184. <https://doi.org/10.2466/pms.1973.36.3c.1171>
- Ursino, M., Crisafulli, A., di Pellegrino, G., Magosso, E. y Cuppini, C. (2017). Desarrollo de un estimador bayesiano para la integración audiovisual: Un estudio neurocomputacional. *Frontiers in Computational Neuroscience*, 11, 89. <https://doi.org/10.3389/fncom.2017.00089>
- Ursino, M., Cuppini, C. y Magosso, E. (2014). Enfoques neurocomputacionales para modelar la integración multisensorial en el cerebro: Una revisión. *Redes Neuronales*, 60, 141–165. <https://doi.org/10.1016/j.neunet.2014.08.003>
- Ursino, M., Cuppini, C., Magosso, E., Beierholm, U. y Shams, L. (2019). Explicación del efecto de la manipulación de la verosimilitud y la priorización mediante una red neuronal de la percepción audiovisual del espacio. *Investigación Multisensorial*, 32(2), 111–144. <https://doi.org/10.1163/22134808-20191324>
- Virtanen, P., Gommers, R., Oliphant, TE, Haberland, M., Reddy, T., Cournapeau, D. y otros (2020). Scipy 1.0: algoritmos fundamentales para computación científica en Python. *Nature Methods*, 17(3), 261–272. <https://doi.org/10.1038/s41592-019-0686-2>

- Wallace, MT, Woynarowski, TG y Stevenson, RA (2020). Integración multisensorial como ventana hacia la cognición ordenada y alterada. y Comunicación. *Revista Anual de Psicología*, 71(1), 193–219. <https://doi.org/10.1146/annurev-psych-010419-051112>
- Wang, C., Zhang, T., Chen, X., He, S., Li, S., Wu, S. (2023). Brainpy, un marco flexible, integrador, eficiente y extensible para Programación de dinámica cerebral de propósito general. *eLife*, 12, e86365. <https://doi.org/10.7554/eLife.86365>
- Wiecki, TV, Sofer, I., y Frank, MJ (2013). HDDM: Jerárquico Estimación bayesiana del modelo de deriva-difusión en Python. *Frontiers in Neuroinformatics*, 7. <https://doi.org/10.3389/fninf.2013.00014>
- Wilson, RC y Collins, AG (2019). Diez reglas simples para el modelado computacional de datos de comportamiento. *eLife*, 8, e49547. <https://doi.org/10.1016/j.1016.org/10.7554/eLife.49547>
- Wu, J., Yang, J., Yu, Y., Li, Q., Nakamura, N., Shen, Y. y Abe, K. (2012). Integración audiovisual retardada de pacientes con deterioro cognitivo leve y enfermedad de Alzheimer en comparación con pacientes normales. Controles de edad avanzada. *Revista de la enfermedad de Alzheimer: JAD*, 32(2), 317–328. <https://doi.org/10.3233/JAD-2012-111070>
- Zhou, Hy, Cai, XL, Weigl, M., Bang, P., Cheung, EF, Chan, RC (2018). Ventana de unión temporal multisensorial en los trastornos del espectro autista y los trastornos del espectro esquizofrénico: un estudio sistemático. Revisión y metaanálisis. *Revisiones de neurociencia y bioconducta*. 86, 66–76. <https://doi.org/10.1016/j.neubiorev.2017.12.013>
- Zhu, H., Beierholm, U., y Shams, L. (2024). Caja de herramientas BCI: un paquete de Python de código abierto para el modelo de inferencia causal bayesiana. *PLoS Computational Biology*, 20(7), Artículo e1011791. <https://doi.org/10.1371/journal.pcbi.1011791>
- Zhu, H., Beierholm, U., y Shams, L. (2024). El papel olvidado de Precisión unisensorial en la investigación multisensorial. *Current Biology*, 34(6), R229–R231. <https://doi.org/10.1016/j.cub.2024.01.057>
- Zvyagintsev, M., Parisi, C. y Mathiak, K. (2017). Procesamiento temporal El déficit conduce a un deterioro de la comunicación multisensorial en la esquizofrenia. *Neuropsiquiatría Cognitiva*, 22(5), 361–372. <https://doi.org/10.1080/13546805.2017.1331160>

Nota del editor: Springer Nature permanece neutral con respecto a los reclamos jurisdiccionales en mapas publicados y afiliaciones institucionales.