


Implementación de un modelo neuronal de integración multisensorial


Inferencia probabilística con dinámicas corticales realistas

Franco Molina

Directores: Renato Paredes Venero · Juan Bautista Cabral
FaMAF — Universidad Nacional de Córdoba




UNC




El cerebro

Cómo combina información
de múltiples sentidos



Los modelos

Simulaciones computacionales
que imitan circuitos neuronales





El software


Implementación en Python
en Scikit-NeuroMSI

Del corazón al cerebro

"El cerebro es solo un radiador" — Aristóteles (parafraseado)




Thomas Willis (1664)
Primeras ilustraciones
detalladas del cerebro



Ramón y Cajal (1906)
Doctrina de la neurona
Premio Nobel

La neurona



Soma

Cuerpo celular, núcleo

Dendritas

Reciben señales

Axón


Transmite señales

Sinapsis

Libera neurotransmisores

Potencial de reposo: -70 mV

Canales iónicos y potencial de acción



Hodgkin-Huxley (Nobel 1963)

Modelo matemático del potencial de acción en el axón gigante del calamar.
Primera descripción cuantitativa de la excitabilidad neuronal.

Principio “todo o nada”

$\text{Na}^+ \rightarrow$ despolarización

Los canales de sodio se abren rápidamente. La membrana se despolariza: el voltaje sube de -70 mV hasta +40 mV.

$\text{K}^+ \rightarrow$ repolarización

Los canales de potasio se abren con retardo. La membrana vuelve al potencial de reposo. La intensidad se codifica en frecuencia, no en amplitud.

Modelos de neuronas: del detalle a la abstraccion


Hodgkin-Huxley

Integra y Dispara (LIF)


Echeveste (SSN)

Modelos de tasa

Hodgkin-Huxley



Integra y Dispara



El sistema visual

1

Retina

Fotorreceptores → células ganglionares

2


LGN (tálamo)

Relevo y modulación cortical

3

V1 (corteza)

Selectividad a orientación



Hubel & Wiesel — Nobel 1981

V1: La hipercolumna

Hipercolumna ($\sim 1 \text{ mm}^2$)

Unidad funcional de la corteza visual primaria

Contiene columnas para TODAS las orientaciones posibles

(-90 a 90 grados)

Representa ambos ojos (columnas de dominancia ocular)

Cada neurona responde selectivamente a bordes en su orientacion preferida

El modelo de Echeveste simula exactamente una hipercolumna

Selectividad de orientacion

Hubel & Wiesel (Nobel 1981) descubrieron que las neuronas de V1 se activan preferentemente ante bordes en angulos especificos. Esta es la base de la percepcion de formas.


Anillo de orientaciones

Las orientaciones se organizan de forma continua. Las neuronas con orientaciones similares estan conectadas mas fuertemente: conectividad dependiente de delta-theta.

Por que importa

Esta arquitectura permite representar la orientacion de cualquier borde visual con poblaciones de neuronas que reaccionan a su orientacion preferida.

Filtros de Gabor en V1



¿Qué son los filtros de Gabor?

Los campos receptivos de V1 se parecen a filtros de Gabor. Detectan bordes y patrones locales de forma muy precisa.

De LGN a V1

Las neuronas del Lateral Geniculate Nucleus detectan luz y oscuridad. Sus señales se combinan en V1 para que las neuronas respondan a bordes y orientaciones.

Por qué importa


Estos filtros explican cómo V1 reconoce formas básicas. Son la base de muchos modelos de visión y visión por computadora.

Más allá de la visión

La integración multisensorial

Integracion multisensorial

El cerebro combina informacion de multiples sentidos. ¿Como decide cuales integrar?



El efecto ventrilocu

La vision captura la localizacion del sonido. El cerebro fusiona las dos señales porque estima que provienen de la misma fuente.

Inferencia causal

Cuando la disparidad espaciotemporal es grande, el cerebro separa las fuentes: vision y sonido se perciben como independientes.

Su cerebro hace inferencia bayesiana en tiempo real

La percepcion como inferencia bayesiana

$$P(y|x)$$

Posterior

¿Que hay ahí?

$\propto$

$$P(x|y)$$

Verosimilitud

¿Que veo?

$\times$

$$P(y)$$

Prior

¿Que esperaba?

La percepcion es inferencia

El cerebro no observa el mundo directamente. Construye la mejor estimacion posible combinando lo que espera (prior) con lo que sensa (verosimilitud).

La incertidumbre importa

En situaciones ambiguas, la distribucion posterior es ancha. En situaciones claras, es estrecha. La variabilidad neuronal refleja esta incertidumbre.

Hipótesis del muestreo neuronal

La actividad neuronal fluctuante genera muestras de la distribución posterior

La variabilidad NO es ruido

Codifica incertidumbre. Cuando el estímulo es ambiguo, la variabilidad aumenta. Cuando es claro, disminuye.

Implicación computacional


No necesitamos calcular explícitamente la posterior. La red neuronal la implementa implícitamente a través de su dinámica.

Lo que buscamos reproducir

El modelo de Echeveste muestra que una red E-I biológicamente realista puede realizar este muestreo de manera emergente.


Promedio temporal de la actividad $\approx$ Media de la distribución posterior bayesiana

Redes neuronales: conexiones y arquitecturas




Feed-forward

Transformaciones
jerárquicas



Feed-back

Modulación
top-down



Recurrente


Dinámicas complejas
Oscilaciones

Las conexiones recurrentes superan en número a feedforward y feedback — clave para dinámicas corticales

Los modelos

Cuppini — Echeveste — La brecha

Modelo de Cuppini: integración audiovisual



Fortalezas

- Efecto ventrilocuo
- Inferencia causal
- Arquitectura biológica

Limitaciones

- Determinista (sin ruido)
- Abstracción del "Spiking"
- Sin variabilidad trial-a-trial

"Como una foto del cerebro en blanco y negro: falta la dinámica"

Neuronas excitatorias e inhibitorias

Principio de Dale: cada neurona es o excitatoria o inhibitoria

Excitatoria (E)

Despolariza la membrana postsinaptica
Aumenta probabilidad de disparo

En el modelo: 50 neuronas E

Inhibitoria (I)


Hiperpolariza la membrana postsinaptica
Reduce probabilidad de disparo

En el modelo: 50 neuronas I


El balance E-I es clave para las oscilaciones gamma y la estabilidad de la red

Modelo de Echeveste: arquitectura SSN

generative model



E-I network



Arquitectura SSN

100 neuronas (50E + 50I)
organizadas en una hipercolumna de V1

Orientaciones preferidas distribuidas uniformemente en
[-90° , 90°]

Conectividad gaussiana circular: 8 parámetros
reemplazan 10.000 pesos

Ruido correlacionado temporalmente
→ variabilidad = muestras de la posterior

Función de transferencia supralineal
→ estabilización por inhibición recurrente

Stochastic Stabilized Supralinear Network

Propiedades emergentes del modelo

No impuestas — emergen de la dinamica de la red

Oscilaciones gamma (30-80 Hz)

La red oscila espontaneamente en la banda gamma sin que se programe explicitamente. Surge del balance E-I.

Transitorios inhibitorios

Picos al inicio de la respuesta que aceleran la convergencia hacia la región de alta probabilidad (reducen el burn-in), evitando difusión lenta desde el estado inicial, consistentes con registros electrofisiologicos.


Variabilidad modulada por contraste

Alta variabilidad con estímulos débiles, baja con estímulos fuertes. Codifica incertidumbre de manera automática.

Convergencia rápida al muestreo

En pocos ciclos, la distribución de actividad converge a la posterior bayesiana del modelo generativo.

El modelo generativo GSM



Gaussian Scale Mixture

Modelo estadístico de parches de imagen natural. Captura las correlaciones de segundo orden que existen en escenas naturales.

$$\mathbf{x} = \mathbf{z} \cdot \mathbf{A} \cdot \mathbf{y} + \epsilon$$

$\mathbf{x}$: parche de imagen | $\mathbf{z}$: contraste local

$\mathbf{A}$: filtros de Gabor (campos proyectivos)

$\mathbf{y}$: variables latentes (coeficientes) | ϵ : ruido sensorial

Por que este modelo

El GSM define el problema de inferencia que la SSN debe resolver

La posterior $P(\mathbf{y}|\mathbf{x}, \mathbf{z})$ es gaussiana con media y covarianza calculables
Exactamente

Esto permite entrenar la red comparando sus momentos contra el observador ideal bayesiano.

Entrenamiento del modelo

Fase 1: ADAM

250 iteraciones
Gradiente estocastico
50 trials por estimulo
Exploracion amplia del espacio



Fase 2: L-BFGS-B

Gradiente deterministico
Assumed Density Filtering (ADF)
Convergencia fina sobre los parámetros
Quasi-Newton

15 parametros libres: 8 de conectividad + 4 de ruido + 3 de entrada

Objetivo del entrenamiento

Ajustar los 15 parametros para que los momentos estadisticos de la red (media, varianza, covarianza, autocorrelacion) coincidan con los del modelo generativo GSM.

La brecha

Cuppini

Multisensorial
Determinista



Echeveste

Unimodal
Estocástico

**Cuppini
(multisensorial)**

+

**Echeveste
(dinámicas)**

=

**Modelo
futuro**

Scikit-NeuroMSI y la implementación

El camino de OCaml a Python/JAX

Scikit-NeuroMSI

Framework de código abierto para modelado de integración multisensorial

¿Qué es?

Es una herramienta diseñada específicamente para modelos de integración multisensorial, desarrollada por el Doc. Paredes y el Doc. Cabral.

Modelos incluidos

- Integrador bimodal óptimo (MLE)
- Inferencia causal bayesiana (Körding et al.)
- Red neuronal de Cuppini (audiovisual)
- + Echeveste ([este trabajo](#))

¿Para qué sirve?

- Implementar y comparar modelos multisensoriales con interfaz estandarizada
- Garantizar reproducibilidad computacional
- Barridos de parámetros y análisis de resultados integrados


Tecnología


JAX • XArray • NetCDF • soporte GPU

Licencia BSD 3-Clause • GitHub + ReadTheDocs

`pip install scikit-neuromsi`

Arquitectura del software





¿Qué implementamos?

Reimplementación completa: Python/OCaml → Python/JAX

1

Modelo generativo GSM

Filtros de Gabor, estímulos, momentos objetivo

2

Integrador SSN

Dinámica neuronal, activación supralineal

3

Conectividad en anillo

Parametrización circulante, principio de Dale

4

Pipeline de entrenamiento

ADAM + L-BFGS-B, función de costo 4 términos

5

Visualización y análisis

Potenciales, espectros, transitorios

6

Cargador de datos

Parámetros pre-entrenados del paper original

Resultados

Eq numerica – Entrenamiento - Comportamiento

3 niveles de validación

De componentes individuales a propiedades emergentes del sistema completo

1

Pruebas unitarias

Verifican componentes aislados contra código original de Echeveste:

- Inicialización con parámetros por defecto y personalizados
- Generación de matriz W: principio de Dale, anillo, bloques E/I
- Activación supralineal $k \cdot [u]^2$
- Entrenamiento ADAM + L-BFGS-B
- Covarianza de ruido $\Sigma\eta$

2

Entrenamiento robusto

Entrenamientos partiendo de las mismas bases:

- Zona de confianza del 10%
- Simulaciones con los parámetros obtenidos
- Carga y utilización de los parámetros

3

Simulaciones comparativas

Replican figuras del artículo original:

- Raster plot y actividad poblacional
- Convergencia de momentos estadísticos
- Oscilaciones gamma emergentes
- Variabilidad modulada por contraste
- Transitorios inhibitorios al inicio

Equivalencia numérica

$\sim 10^{-15}$

Error máximo
25 funciones · 10.000 muestras

Distribución Normal

✓ 0.00

Activación Neuronal

✓ 0.00

Momentos ν, γ

✓ 0.00

Evolución Temporal

✓ 0.00

Conectividad

✓ 0.00

Ruido O-U

✓ 0.00

GSM Posterior

✓ 0.00





Funciones Auxiliares

✓ 0.00

"Las dos implementaciones dan exactamente el mismo resultado"



Entrenamiento robusto: 100 corridas

Noise Covariance Parameters (100 runs)







FALLAS




FALLAS




FALLAS








FALLAS




FALLAS





Actividad poblacional



Raster plot



Convergencia de momentos



Conclusiones

- ▶ Reimplementación completa

Python/OCaml → Python/JAX

- ▶ Equivalencia numérica ($\sim 10^{-15}$)
- ▶ 10.000 corridas confirman robustez
- ▶ Propiedades emergentes reproducidas

Trabajo futuro

Fusionar Cuppini + Echeveste

Redes de control

Datos electrofisiológicos

¡Gracias!

Franco Molina · FaMAF · Universidad Nacional de Córdoba

Directores: Renato Paredes Venero · Juan Bautista Cabral