

Capítulo 6

Resultados

La validación de una implementación computacional constituye un proceso esencial que va más allá de la simple verificación de que el código ejecuta sin errores. En el contexto de modelos neuronales complejos como el de Echeveste et al. (2020), la correctitud de la implementación debe evaluarse en múltiples niveles, desde la precisión numérica de funciones individuales hasta la emergencia de propiedades dinámicas globales que definen el comportamiento del sistema.

Este capítulo presenta los resultados de un proceso de validación estructurado en cuatro niveles complementarios. En primer lugar, se describe la infraestructura de **pruebas automatizadas** desarrollada para verificar componentes individuales del modelo. En segundo lugar, se presenta una **validación función por función** que compara directamente nuestra implementación con el código original de Echeveste, demostrando equivalencia numérica a nivel de precisión de punto flotante. En tercer lugar, se analizan los resultados del **procedimiento de entrenamiento**, comparando los parámetros optimizados con los valores de referencia. Finalmente, se presentan **simulaciones comparativas** que replican las figuras centrales del artículo original, demostrando que la red implementada exhibe las propiedades de inferencia probabilística características del modelo.

6.1. Infraestructura de validación

La validación de una reimplementación completa (desde OCaml hacia Python/JAX) requiere verificar no solo que los componentes individuales funcionen correctamente de manera aislada, sino también que su comportamiento numérico sea idéntico al del código de referencia. Esta sección describe la infraestructura de pruebas automatizadas desarrollada para garantizar la fidelidad de la implementación, organizada en pruebas unitarias que verifican la lógica interna y pruebas de integración que evalúan la equivalencia con el código original.

6.1.1. Pruebas unitarias de la clase principal

El archivo `test_echeveste2020.py` implementa once clases de pruebas que cubren los aspectos fundamentales del modelo. Estas verificaciones aseguran la correcta inicialización con parámetros por defecto y personalizados, permitiendo

que el modelo se instancie con diferentes tamaños de red y constantes de tiempo sin generar errores.

Un aspecto crítico es la verificación de la **matriz de conectividad**. Las pruebas comprueban que la matriz $\mathbf{W}$ tenga la forma correcta, que respete el principio de Dale, y que exhiba la topología de anillo esperada según la Ecuación 3.12. Específicamente, se verifica que los bloques $\mathbf{W}_{EE}$ y $\mathbf{W}_{IE}$ contengan únicamente valores positivos, que los bloques $\mathbf{W}_{EI}$ y $\mathbf{W}_{II}$ contengan únicamente valores negativos, y que cada bloque exhiba estructura circulante donde W_{ij} depende únicamente de $|\theta_i - \theta_j|$.

La **función de activación supralineal** (Ecuación 3.11) se prueba exhaustivamente para garantizar el comportamiento correcto:

$$r = k \cdot [u]_+^n = 0,3 \cdot [\text{máx}(0, u)]^2$$

Las pruebas verifican el comportamiento para potenciales negativos (tasa cero), potenciales positivos (respuesta cuadrática), y casos límite. Esta verificación resulta fundamental dado que cualquier error en la función de transferencia se propagaría a través de toda la dinámica de la red.

6.1.2. Pruebas unitarias del módulo de entrenamiento

A su vez, el archivo `test_echeveste2020_training.py` también implementa pruebas específicas para el procedimiento de optimización en dos etapas descrito en la Sección 5.5. Estas pruebas son particularmente delicadas dado que el entrenamiento involucra diferenciación automática a través de ecuaciones diferenciales estocásticas.

Las pruebas verifican que los 8 parámetros de conectividad (a_{EE} , a_{EI} , a_{IE} , a_{II} , d_{EE} , d_{EI} , d_{IE} , d_{II}) se actualizan correctamente durante la optimización, que las restricciones de bounds se respetan (amplitudes ≥ 0 , anchos $\in [0, \sqrt{2}]$), y que la función de costo decrece monótonamente a lo largo de las iteraciones. A su vez, se verifica la construcción correcta de la matriz de covarianza de ruido Σ_η , incluyendo su dimensión, simetría, positividad semi-definida, y estructura de bloques consistente con las Ecuaciones 3.14 y 3.15.

Las pruebas end-to-end verifican que el método `train()` complete ambas etapas sin errores y que la red entrenada pueda ejecutar simulaciones estables sin divergir numéricamente.

6.1.3. Validación función por función contra código original

Más allá de las pruebas unitarias que verifican la lógica interna, se realizó una validación exhaustiva comparando cada función de nuestra implementación con su equivalente en el código original de Echeveste et al.. Este proceso constituye la verificación más rigurosa de equivalencia numérica, ya que evalúa directamente si ambas implementaciones producen resultados idénticos para los mismos inputs.

La metodología consistió en generar $N = 10,000$ muestras aleatorias para cada función, ejecutar tanto la implementación original como la nuestra con inputs idénticos, y calcular el error máximo absoluto entre los resultados. Las funciones se organizaron en ocho categorías que cubren todos los componentes matemáticos del modelo, desde funciones auxiliares básicas hasta el cálculo completo de la posterior del GSM.

6.1. INFRAESTRUCTURA DE VALIDACIÓN

La Tabla 6.1 presenta el resumen de esta validación por categoría. Los resultados demuestran que todas las 25 funciones evaluadas producen resultados numéricamente equivalentes, con errores máximos del orden de la precisión de punto flotante de doble precisión ($\sim 10^{-15}$ a 10^{-16}).

Tabla 6.1: Resumen de validación función por función contra código original de Echeveste ($N = 10\,000$ muestras por función).

#	Categoría	Error máximo	Estado
1	Distribución Normal (<code>f1</code> , <code>f2_exact</code>)	0,00	✓
2	Activación Neuronal (<code>get_r</code> , <code>get_r_prime</code>)	0,00	✓
3	Momentos ν , γ (<code>nu_recursive</code> , <code>get_gamma</code>)	$7,11 \times 10^{-15}$	✓
4	Evolución Temporal (<code>new_u</code> , <code>mu_dot</code> , <code>u_dot_det</code>)	0,00	✓
5	Conectividad Paramétrica (kernel Eq. 3.12, <code>get_J</code>)	0,00	✓
6	Ruido O-U (<code>eps_1</code> , <code>eps_2</code> , update step)	$1,11 \times 10^{-16}$	✓
7	GSM Posterior (Σ_z , μ_z , <code>get_x</code> , P_z)	0,00	✓
8	Funciones Auxiliares (<code>sqr_norm</code> , <code>rel_error</code> , etc.)	0,00	✓

Los errores no nulos observados en las categorías 3 y 6 corresponden exactamente a la precisión de punto flotante IEEE 754 de doble precisión, donde el ϵ de máquina es $\epsilon \approx 2,22 \times 10^{-16}$. Estos errores surgen de diferencias en el orden de operaciones aritméticas entre implementaciones y no representan discrepancias algorítmicas.

La Figura A.5 en el Apéndice A presenta el detalle completo de las 25 funciones validadas, incluyendo las referencias a las líneas de código específicas tanto en el repositorio original como en nuestra implementación. Esta trazabilidad permite verificar independientemente la correspondencia entre ambas bases de código.

Estos resultados proporcionan confianza de que cualquier diferencia observada en el comportamiento de alto nivel del modelo (dinámicas, propiedades de muestreo) no puede atribuirse a errores en la implementación de funciones individuales.

6.1.4. Consistencia en la generación de estímulos

Un requisito fundamental para las siguientes validaciones, es asegurar que el modelo generativo GSM implementado en *Scikit-NeuroMSI* genere estímulos idénticos a los del código original bajo las mismas configuraciones. Para ello, se verificó la consistencia del vector de entrada $\mathbf{h}$ a través de cuatro variantes del pipeline de generación, comparando los resultados con los datos precomputados de referencia.

Como se observa en la Figura 6.1, se evaluaron los siguientes flujos de datos:

- **$\mathbf{h_true}$ (precomputed):** Valores de $\mathbf{h}$ extraídos directamente de los archivos `.mat` originales, son los datos reales utilizados por Echeveste et al. en la simulación representando el objetivo numérico a replicar.
- **GSM loaded stimulus:** El vector $\mathbf{h}$ generado por nuestra implementación utilizando el estímulo sensorial $\mathbf{x}$ cargado de los archivos originales ($\mathbf{x}_{\text{loaded}} \rightarrow \mathbf{h}$).

6.2. VALIDACIÓN DEL PROCEDIMIENTO DE ENTRENAMIENTO

- **GSM from y_{latent} :** Un paso antes, recuperando solo el vector latente y se resuelve el sistema lineal $x = zAy$ a partir de los datos originales, y luego se regenera x y h desde dicho y .
- **GSM bump:** Generación sintética completa mediante nuestra función `generate_bump_stimulus(A,  $\sigma$ )`, utilizando una amplitud de 6.0 y un factor de ancho de 0.15, sin recurrir a datos externos.




Figura 6.1: Comparación de la entrada h generada por el GSM frente a los datos de referencia de Echeveste. Los paneles muestran cuatro niveles de contraste (z). La coincidencia entre las curvas ($\text{MSE} < 10^{-13}$) confirma que el pipeline de generación y la transformación no lineal son idénticos a la implementación de referencia.

Los resultados muestran diferencias del orden de 10^{-13} a 10^{-15} , garantizando que cualquier discrepancia posterior en la dinámica de la red no se deba a errores en la generación del estímulo de entrada.

6.2. Validación del procedimiento de entrenamiento

Una vez verificada la equivalencia numérica de los componentes individuales, el siguiente nivel de validación consiste en confirmar que el procedimiento de entrenamiento converge hacia parámetros comparables a los reportados por Echeveste et al. (2020). Esta validación resulta particularmente significativa

6.2. VALIDACIÓN DEL PROCEDIMIENTO DE ENTRENAMIENTO

dato que nuestra implementación en JAX¹ constituye una reimplementación completa del código original en OCaml², como se describió en la Sección 5.5.4.

6.2.1. Diseño del experimento

Para evaluar la robustez del procedimiento de entrenamiento, se ejecutaron múltiples corridas independientes partiendo de condiciones iniciales aleatorias. Cada corrida siguió el protocolo de dos etapas descrito en la Sección 5.5: Stage 1 con 250 iteraciones de ADAM ($\eta = 0,002$, $N_{\text{trial}} = 50$), seguido de Stage 2 con optimización L-BFGS-B utilizando el método ADF para gradientes determinísticos.

Los valores de referencia corresponden a los parámetros optimizados reportados en la Tabla Suplementaria S1 del artículo original, reproducidos en la Tabla 5.3 del Capítulo 5.

6.2.2. Convergencia de parámetros de conectividad

La Figura 6.2 presenta los resultados de la optimización para los parámetros de conectividad. En cada panel, los puntos representan los valores obtenidos en corridas individuales, la línea punteada roja indica el valor de referencia de Echeveste, y la banda sombreada corresponde a una tolerancia de $\pm 10\%$.




Figura 6.2: Parámetros de conectividad optimizados en 100 corridas independientes.

Los resultados muestran que las amplitudes de conectividad convergen consistentemente hacia valores cercanos a los de referencia, como se detalla en la Tabla 6.2. Las amplitudes exhiben baja variabilidad entre corridas (coeficientes de variación $< 10\%$), indicando que el paisaje de optimización tiene una estructura bien definida para estos parámetros.

¹<https://docs.jax.dev/>

²<https://ocaml.org/>

6.2. VALIDACIÓN DEL PROCEDIMIENTO DE ENTRENAMIENTO

Tabla 6.2: Convergencia de amplitudes y anchos de conectividad ($N = 100$ corridas independientes).

Parámetro	Referencia	Obtenido	CV	Tolerancia
a_{EE}	0.331	$0,34 \pm 0,02$	5.9 %	98 %
a_{EI}	0.081	$0,08 \pm 0,01$	12.5 %	97 %
a_{IE}	0.363	$0,37 \pm 0,02$	5.4 %	96 %
a_{II}	0.074	$0,08 \pm 0,02$	25.0 %	89 %
d_{EE}	0.803	$0,81 \pm 0,05$	6.2 %	91 %
d_{EI}	0.569	$0,57 \pm 0,04$	7.0 %	94 %
d_{IE}	0.860	$0,87 \pm 0,05$	5.7 %	88 %
d_{II}	0.630	$0,67 \pm 0,06$	9.0 %	82 %

CV: Coeficiente de variación ($\text{std}/\text{media} \times 100 \%$).

Un análisis complementario revela que las corridas que se desvían de la tolerancia en un parámetro tienden a compensar con desviaciones en otros parámetros, manteniendo el costo final comparable. Esto sugiere la existencia de una variedad de soluciones aproximadamente equivalentes en el espacio de parámetros, fenómeno común en problemas de optimización con funciones de costo no convexas.

6.2.3. Convergencia de parámetros de ruido

Los parámetros de la covarianza de ruido Σ_η resultan críticos para las propiedades de muestreo de la red. La Figura 6.3 presenta los resultados de la optimización. Es importante aclarar que las escalas del eje vertical se eligieron para facilitar la comparación: d_η y ρ utilizan escala $[0, 1]$ por ser fracciones normalizadas y coeficientes de correlación respectivamente, mientras que σ_E y σ_I comparten escala $[0, 10]$ mV para permitir comparación directa entre las magnitudes de ruido excitatorio e inhibitorio.

6.2. VALIDACIÓN DEL PROCEDIMIENTO DE ENTRENAMIENTO




Figura 6.3: Parámetros de covarianza de ruido optimizados en 100 corridas independientes. Las líneas punteadas rojas indican los valores de referencia de la Tabla S1 de Echeveste et al. (2020), y las bandas sombreadas representan tolerancias de $\pm 10\%$.

Los resultados revelan un fenómeno interesante: mientras que d_σ y ρ convergen de manera robusta, las desviaciones estándar σ_E y σ_I exhiben mayor variabilidad entre corridas. Sin embargo, la *proporción* σ_E/σ_I se mantiene aproximadamente constante, recordándonos de nuevo la existencia de una familia de soluciones equivalentes. Esta observación es consistente con la teoría que el ruido de proceso es independiente del estímulo, la red puede compensar cambios en la magnitud del ruido ajustando la escala de la conectividad recurrente.

6.2.4. Convergencia de parámetros de entrada

Los tres parámetros de la transformación de entrada feedforward (α_h , β_h , γ_h) definen la no linealidad que convierte el estímulo visual en la corriente de entrada a cada neurona. La Tabla 6.3 presenta la comparación con los valores de referencia.

Tabla 6.3: Comparación de parámetros de transformación de entrada.

Parámetro	Referencia	Obtenido	Error relativo
α_h (escala)	1.9555	$1,94 \pm 0,05$	$< 1\%$
β_h (línea base)	0.1032	$0,10 \pm 0,01$	$< 5\%$
γ_h (exponente)	2.0343	$2,01 \pm 0,03$	$< 2\%$

El exponente $\gamma_h \approx 2$ resulta particularmente notable: su proximidad al exponente supralineal $n = 2$ de la función de transferencia neuronal sugiere una consistencia en el procesamiento no lineal a través de las etapas del modelo. Esta coincidencia no es impuesta *a priori* sino que emerge de la optimización.

6.3. Reproducción de resultados experimentales

El nivel más exigente de validación consiste en verificar que la red implementada reproduce las propiedades de inferencia probabilística y las dinámicas corticales reportadas en el artículo original. Para esto, hicimos énfasis en replicar los experimentos correspondientes a la Figura 2 de Echeveste et al. (2020), que constituye la demostración central de que la red entrenada implementa correctamente muestreo de la distribución posterior del modelo generativo GSM.

6.3.1. Protocolo de simulación

Las simulaciones utilizaron los parámetros pre-entrenados cargados mediante el método `load_parameters()` descrito en la Sección 5.1.2. Se ejecutaron simulaciones de 1000 ms para cada uno de los cinco niveles de contraste del conjunto de entrenamiento ($z \in \{0, 0,125, 0,25, 0,5, 1,0\}$), con los parámetros detallados en la Tabla 6.4.

Tabla 6.4: Parámetros de simulación para reproducción de figuras.

Parámetro	Descripción	Valor
N_E, N_I	Neuronas E e I	50, 50
T_{sim}	Tiempo de simulación	1000 ms
$T_{\text{burn-in}}$	Período de estabilización	200 ms
dt	Paso de integración	0.2 ms
Orientación estímulo	Centro de la gaussiana	0

6.3.2. Actividad poblacional dependiente del contraste

La Figura 6.4 basada en el panel (a) de la Figura 2 del artículo original, mostrando los potenciales de membrana excitatorios u_E en función del tiempo y la orientación para diferentes niveles de contraste.

Los resultados muestran las propiedades esperadas del modelo. En ausencia de estímulo (contraste cero), la actividad fluctúa alrededor de valores bajos con distribución espacial aproximadamente uniforme, reflejando el ruido de proceso $\eta(t)$ filtrado por la dinámica recurrente. Con contraste máximo, la presencia de un estímulo con orientación dominante en 0 induce un incremento de actividad centrado en las neuronas con orientación preferida cercana a esta dirección, con magnitud consistente con la diferencia entre estado espontáneo y estimulado observada en registros de V1.

6.3. REPRODUCCIÓN DE RESULTADOS EXPERIMENTALES




Figura 6.4: Actividad poblacional de potenciales de membrana excitatorios. Panel izquierdo: contraste $z = 0$ (actividad espontánea). Panel central: contraste $z = 1$ (estimulación máxima). Panel derecho: entrada feedforward $\mathbf{h}$ correspondiente al contraste máximo. El eje vertical representa la orientación preferida de cada neurona (-90 a 90), el eje horizontal representa el tiempo.

6.3.3. Correspondencia de momentos con el observador ideal

La validación central del modelo consiste en verificar que los momentos de la distribución de respuestas de la red coinciden con los momentos de la posterior del GSM. Sin embargo, esta comparación requiere una consideración importante: los momentos del GSM corresponden a variables latentes $\mathbf{y}$, mientras que

6.3. REPRODUCCIÓN DE RESULTADOS EXPERIMENTALES

la red produce potenciales de membrana u_E que pasan por una no linealidad (Ecuación 3.11). Para una comparación válida, los momentos del posterior deben transformarse a través de esta no linealidad.

Específicamente, si $y_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$ representa la distribución posterior marginal para la neurona i , los momentos transformados se calculan como:

$$\mathbb{E}[f(y_i)] = \int f(y) p(y_i) dy \quad (6.1)$$

$$\text{Var}[f(y_i)] = \int (f(y) - \mathbb{E}[f(y_i)])^2 p(y_i) dy \quad (6.2)$$

donde $f(u) = k \cdot [\text{máx}(u + u_0, 0)]^n$ es la función de transferencia del SSN. Esta transformación tiene una consecuencia importante: aunque la desviación estándar del posterior GSM es constante para todas las orientaciones (dado un contraste fijo), la desviación estándar después de la no linealidad varía espacialmente, produciendo el característico perfil en forma de U observado en la Figura 6.5.




Figura 6.5: Comparación de momentos de primer y segundo orden. Paneles superiores: media de potenciales de membrana vs. orientación para diferentes contrastes. Paneles inferiores: desviación estándar vs. orientación. Columna izquierda: observador ideal (GSM). Columna derecha: red neuronal (SSN).

Varias observaciones emergen de esta comparación. Las curvas de media poblacional exhiben perfiles gaussianos centrados en la orientación del estímulo, con amplitud creciente con el contraste, y la red neuronal reproduce fielmente tanto la forma como la escala de estas curvas. Un resultado particularmente significativo es la reducción de la variabilidad con el contraste, fenómeno co-

nocido como quenching³ y observado experimentalmente en corteza visual de primates (Echeveste et al., 2020). En el modelo, este comportamiento emerge naturalmente de las propiedades del GSM: mayor contraste implica mayor relación señal-ruido, lo que reduce la incertidumbre posterior y, consecuentemente, la variabilidad de las muestras neuronales.

6.3.4. Estructura de correlaciones poblacionales

El análisis más completo de las propiedades de muestreo requiere examinar la matriz completa de correlaciones entre todas las neuronas. La Figura 6.6 presenta esta comparación, mostrando que las matrices exhiben la estructura característica de la topología de anillo.

La diagonal principal muestra máxima correlación, y a medida que nos alejamos de la diagonal, la correlación decae gradualmente, reflejando que neuronas con orientaciones preferidas más distantes están menos correlacionadas. La estructura de correlaciones se modifica con el contraste de manera consistente entre el observador ideal y la red: para contraste cero, las correlaciones están determinadas principalmente por el prior del GSM, mientras que con el aumento del contraste, la estructura refleja progresivamente más la información del estímulo. Calculando la correlación de Pearson elemento por elemento entre ambas matrices, se obtienen valores superiores a 0.95 para todos los niveles de contraste.

6.4. Propiedades dinámicas emergentes

Más allá de reproducir los momentos estadísticos correctos, el modelo de Echeveste se distingue por exhibir propiedades dinámicas que emergen como consecuencia del objetivo de muestreo sin ser explícitamente impuestas durante el entrenamiento. Esta sección presenta evidencia preliminar de que nuestra implementación preserva estas características, junto con las direcciones de trabajo futuro necesarias para una validación completa.

6.4.1. Variabilidad modulada por estímulo

El fenómeno de quenching de variabilidad puede cuantificarse mediante el factor de Fano⁴, definido como $F = \text{Var}[r]/\mathbb{E}[r]$. Para un proceso de Poisson, $F = 1$; valores menores indican variabilidad sub-poissoniana, característica de respuestas corticales bajo estimulación.

El análisis cuantitativo del factor de Fano a partir de los datos de simulación muestra una reducción sistemática con el aumento del contraste: para contraste $z = 0$, el factor de Fano promedio se encuentra en el rango $1,0 - 1,2$, mientras que para $z = 1$ decrece hacia valores en el rango $0,6 - 0,8$. Esta reducción es particularmente pronunciada para las neuronas cuya orientación preferida

³El término *quenching* (literalmente “apagado” o “supresión”) refiere a la observación experimental de que la variabilidad trial-to-trial de las respuestas neuronales disminuye abruptamente tras la presentación de un estímulo, comparada con la alta variabilidad durante actividad espontánea.

⁴El factor de Fano es una medida adimensional de dispersión relativa, análoga al coeficiente de variación pero apropiada para procesos de conteo.

6.4. PROPIEDADES DINÁMICAS EMERGENTES




Figura 6.6: Matrices de correlación de Pearson entre potenciales de membrana excitatorios. Fila superior: observador ideal (GSM). Fila inferior: red neuronal (SSN). Cada columna corresponde a un nivel de contraste diferente.

coincide con la del estímulo, consistente con observaciones experimentales en V1 de primates (Echeveste et al., 2020).

6.4.2. Análisis de oscilaciones gamma

Una propiedad emergente notable del modelo de Echeveste et al. (2020) es la presencia de oscilaciones en el rango gamma (30-80 Hz), cuya frecuencia pico aumenta con el contraste del estímulo. Esta característica no es impuesta durante el entrenamiento, sino que surge como consecuencia de optimizar la red para realizar muestreo de la distribución posterior del GSM. La relevancia de este hallazgo radica en que las oscilaciones gamma se observan consistentemente en registros electrofisiológicos de la corteza visual primaria (V1) de primates, sugiriendo que podrían ser un subproducto funcional del cómputo probabilístico más que un epifenómeno.

Para verificar esta propiedad en nuestra implementación, se analizó el potencial de campo local Local Field Potential (LFP), calculado como el promedio de los potenciales de membrana excitatorios:

$$\text{LFP}(t) = \frac{1}{N_E} \sum_{i=1}^{N_E} u_E^{(i)}(t) \quad (6.3)$$

Esta señal representa la actividad poblacional de la red, análoga a lo que se mide experimentalmente mediante electrodos extracelulares. Posteriormente, se calculó el espectro de potencia del LFP mediante el método de Welch, que permite estimar la densidad espectral de potencia promediando sobre múltiples ventanas temporales.

La Figura 6.7 presenta los resultados de este análisis para los cinco niveles de contraste del conjunto de entrenamiento. Los paneles individuales muestran el espectro de potencia en escala logarítmica, donde la banda sombreada indica el rango gamma (30-80 Hz) y las líneas punteadas marcan la frecuencia pico detectada dentro de este rango. El panel inferior derecho sintetiza el resultado principal: la frecuencia pico gamma en función del contraste.






Figura 6.7: Análisis espectral del potencial de campo local (LFP). Los cinco primeros paneles muestran el espectro de potencia para cada nivel de contraste, con la banda gamma (30-80 Hz) sombreada en rojo y la frecuencia pico indicada con línea punteada. El panel inferior derecho muestra la dependencia de la frecuencia pico con el contraste, confirmando el incremento predicho por el modelo: de aproximadamente 32 Hz (contraste bajo) a 56 Hz (contraste máximo).

Los resultados confirman que la red implementada reproduce la fenomenología reportada en el artículo original. Para contraste nulo o bajo ($z \leq 0,25$), la frecuencia pico se mantiene alrededor de 32 Hz, correspondiente al extremo inferior del rango gamma. A medida que el contraste aumenta, la frecuencia pico se desplaza progresivamente hacia valores más altos, alcanzando aproximadamente 56 Hz para contraste máximo ($z = 1,0$). Este comportamiento es cualitativamente consistente con observaciones experimentales en V1, donde se ha reportado que la frecuencia de oscilaciones gamma aumenta con el contraste del estímulo visual (Echeveste et al., 2020).

Desde una perspectiva computacional, este fenómeno puede interpretarse en términos de la dinámica de muestreo: mayor contraste implica mayor certeza sobre el estímulo (menor varianza posterior), lo que permite a la red explorar el espacio de estados más rápidamente, manifestándose como oscilaciones de mayor frecuencia. Esta interpretación conecta las propiedades espectrales observadas con la función de inferencia probabilística que la red implementa.

6.5. Resumen del capítulo

Este capítulo presentó los resultados de la validación de nuestra implementación del modelo de Echeveste et al. (2020) en múltiples niveles. La validación función por función demostró equivalencia numérica exacta con errores del orden de la precisión de punto flotante ($\sim 10^{-15}$). Las pruebas unitarias verificaron la correctitud de componentes individuales. El procedimiento de entrenamiento de-

mostró convergencia robusta hacia parámetros comparables a los de referencia. Las simulaciones replicaron las figuras centrales del artículo original, confirmando que la red implementa correctamente muestreo de la distribución posterior del modelo generativo GSM.

Estos resultados establecen que la implementación está lista para su uso en investigaciones que requieran un modelo de dinámicas corticales biológicamente realistas para inferencia probabilística unimodal. Las validaciones pendientes identificadas, particularmente respecto a generalización, análisis espectral y redes de control, definen direcciones claras para trabajo futuro.

Capítulo 7

Conclusiones y trabajo a futuro

Completar: CONCLUSIONES

Apéndice A

Material complementario

Este apéndice contiene diagramas técnicos y tablas de mayor detalle que complementan las explicaciones de los capítulos anteriores. Estas figuras proporcionan una visión más exhaustiva de la arquitectura de software, los flujos de ejecución y los resultados de validación, lo que resulta útil para lectores interesados en comprender o extender la implementación.

A.1. Diagramas de arquitectura




Figura A.1: Estructura modular del paquete `scikit-neuromsi`. Se detalla la organización del código en submódulos especializados: el núcleo (**core/**) con la clase base abstracta y el contenedor de resultados, el módulo neuronal (**neural/**) con las clases de simulación y las funciones de entrenamiento en JAX, el módulo generativo (**generative/**) con el modelo GSM, y el sistema de gestión de datos (**data/**) con los cargadores especializados.

A.1. DIAGRAMAS DE ARQUITECTURA




Figura A.2: Diagrama de clases UML detallado de la implementación Echeveste2020. Se observa la herencia desde la clase base abstracta **SKNMSIMethodABC**, la composición del integrador **SSNIntegrator** como dataclass, las dependencias con el modelo generativo **GSM** y los cargadores de datos (**EchevesteDataLoader**, **GSMDataLoader**) para la configuración de la red. Los parámetros de los modelos están simplificados indicándolo con “...”.

A.2. Diagramas de secuencia




Figura A.3: Diagrama de secuencia del flujo de ejecución (parte 1 de 2). Muestra la Fase 1 de inicialización del modelo con sus parámetros, seguida de la Alternativa A que ilustra el proceso de carga de parámetros pre-entrenados mediante el **DataLoader**, incluyendo la obtención de la matriz de conectividad $\mathbf{W}$ y la matriz de covarianza de ruido Σ_{η} .

A.2. DIAGRAMAS DE SECUENCIA




Figura A.4: Diagrama de secuencia del flujo de ejecución (parte 2 de 2). Muestra la Alternativa B correspondiente al entrenamiento completo y la integración de la dinámica SSN para producir el `NDRResult`.

A.3. Validación de la implementación

Validation Summary: Implementation vs Original Code
(N = 10,000 random samples per function)

Category	Function	Original	Implementation	Max Error
1. Distribucion Normal	f1 (PDF)	methods.py:13	_gsm.py	0.00
1. Distribucion Normal	f2_exact (CDF)	methods.py:16	_gsm.py	0.00
2. Activacion Neuronal	get_r (activacion)	methods.py:43	_echeveste2020.py:63	0.00
2. Activacion Neuronal	get_r_prime (derivada)	methods.py:51	_echeveste2020.py	0.00
3. Momentos (nu, gamma)	nu_recursive (n=2)	methods.py:98	_echeveste2020.py	7.11e-15
3. Momentos (nu, gamma)	get_gamma	methods.py:146	_echeveste2020.py	0.00
3. Momentos (nu, gamma)	nu_recursive (n=0)	methods.py:99	direct	0.00
3. Momentos (nu, gamma)	nu_recursive (n=1)	methods.py:101	direct	0.00
4. Evolucion Temporal	new_u (Euler step)	methods.py:289	_echeveste2020.py	0.00
4. Evolucion Temporal	mu_dot (mean deriv)	methods.py:322	_echeveste2020.py	0.00
4. Evolucion Temporal	u_dot_det (deterministic)	methods.py:292	_echeveste2020.py	0.00
5. Conectividad Parametrica	parametric_kernel (Eq.10)	Eq.10 paper	_echeveste2020.py:1404	0.00
5. Conectividad Parametrica	get_J (Jacobian)	methods.py:128	_echeveste2020.py	0.00
6. Ruido (O-U Process)	eps_1 (O-U decay)	methods.py:390	_echeveste2020.py	1.11e-16
6. Ruido (O-U Process)	eps_2 (O-U noise)	methods.py:391	_echeveste2020.py	1.11e-16
6. Ruido (O-U Process)	O-U update step	methods.py:396	_echeveste2020.py	0.00
7. GSM (Posterior)	get_sigma_z (post cov)	GSM.py:111	_gsm.py:789	0.00
7. GSM (Posterior)	get_mu_z (post mean)	GSM.py:107	_gsm.py:789	0.00
7. GSM (Posterior)	get_x (stimulus)	GSM.py:95	_gsm.py:303	0.00
7. GSM (Posterior)	P_z (gamma dist)	GSM.py:204	_gsm.py	0.00
8. Funciones Auxiliares	sqr_norm	methods.py:20	direct	0.00
8. Funciones Auxiliares	rel_error	methods.py:1116	direct	0.00
8. Funciones Auxiliares	rescale	methods.py:24	direct	0.00
8. Funciones Auxiliares	rel_dist	methods.py:27	direct	0.00
8. Funciones Auxiliares	Mat_from_Chol	methods.py:269	direct	0.00

All 25 functions passed validation. Maximum errors are within floating-point precision ($\sim 10^{-15}$).

Figura A.5: Resumen completo de validación función por función. La tabla muestra las 25 funciones validadas, organizadas por categoría, con referencias a las líneas de código específicas tanto en el repositorio original (`methods.py`, `GSM.py`) como en nuestra implementación (`_echeveste2020.py`, `_gsm.py`). Todos los errores máximos están en el orden de la precisión de punto flotante ($\sim 10^{-15}$), confirmando equivalencia numérica exacta.

Apéndice B

Figuras originales del modelo de Echeveste

Las siguientes figuras, reproducidas de Echeveste et al. (2020), ilustran el comportamiento del modelo neuronal optimizado y su correspondencia con el observador ideal bayesiano. Estas figuras sirven como referencia para comprender los resultados que nuestra implementación busca replicar.




Figura B.1: Actividad de población en la red neuronal optimizada, extraída de Echeveste et al. (2020). Se muestra la evolución temporal de los potenciales de membrana u_E de las células excitatorias (codificados por color), ordenadas según su orientación preferida. Panel superior: respuesta a un estímulo de contraste cero, donde la actividad fluctúa de manera relativamente uniforme entre orientaciones. Panel inferior: respuesta a un estímulo de alto contraste con orientación dominante en 0 (indicada por la flecha), donde se observa actividad elevada sostenida en neuronas con orientaciones preferidas cercanas al estímulo. La barra de escala indica 200 ms.




Figura B.2: Comparación entre las distribuciones del observador ideal y las respuestas de la red, extraído de Echeveste et al. (2020). Izquierda: conjunto de estímulos de entrenamiento, donde el color del marco indica el nivel de contraste. Derecha: elipses de covarianza (2 desviaciones estándar) de las distribuciones posteriores del observador ideal (verde) y de las distribuciones de respuesta correspondientes de la red neuronal (rojo). Las trayectorias rojas muestran secuencias de 500 ms de actividad en la red. Las proyecciones corresponden a dos variables latentes representativas con campos receptivos de orientaciones preferidas 42 y 16 (indicados en los recuadros de los ejes).




Figura B.3: Momentos estadísticos de las distribuciones posteriores y de respuesta, extraídos de Echeveste et al. (2020). Fila superior: media de las variables latentes bajo la distribución posterior del observador ideal (izquierda, verde) y de los potenciales de membrana u_E bajo la distribución estacionaria de la red (derecha, tonos cálidos). Fila inferior: desviación estándar correspondiente. Las neuronas están ordenadas por orientación preferida. Los colores de las líneas corresponden a los diferentes niveles de contraste mostrados en la Figura B.2. Los momentos fueron estimados a partir de $n = 20\,000$ muestras independientes tomadas con 200 ms de separación.




Figura B.4: Matrices de correlación de las distribuciones posteriores y de respuesta, extraídas de Echeveste et al. (2020). Columna izquierda (marcos verdes): correlaciones de Pearson de la distribución posterior del observador ideal. Columna derecha (marcos rojos/naranjas): correlaciones de la distribución estacionaria de respuestas de la red neuronal. Cada fila corresponde a un nivel de contraste diferente, con los colores de los marcos coincidiendo con los estímulos de la Figura B.2. La estructura diagonal indica correlaciones positivas fuertes entre neuronas con orientaciones preferidas similares, mientras que las correlaciones negativas (azul) aparecen entre neuronas con orientaciones ortogonales.

Bibliografía

- Alais, D. and Burr, D. (2004). The ventriloquist effect results from near-optimal bimodal integration. *Current biology*, 14(3):257–262.
- Bishop, C. M. and Nasrabadi, N. M. (2006). *Pattern recognition and machine learning*, volume 4. Springer.
- Blanco, C. (2014). *Historia de la neurociencia*. Biblioteca nueva Madrid.
- Cuppini, C., Shams, L., Magosso, E., and Ursino, M. (2017). A biologically inspired neurocomputational model for audiovisual integration and causal inference. *European Journal of Neuroscience*, 46(9):2481–2498.
- Dale, H. (1935). Pharmacology and nerve-endings.
- Dayan, P. and Abbott, L. F. (2005). *Theoretical neuroscience: computational and mathematical modeling of neural systems*. MIT press.
- Echeveste, R., Aitchison, L., Hennequin, G., and Lengyel, M. (2020). Cortical-like dynamics in recurrent circuits optimized for sampling-based probabilistic inference. *Nature neuroscience*, 23(9):1138–1149.
- Eliasmith, C. and Anderson, C. H. (2003). *Neural engineering: Computation, representation, and dynamics in neurobiological systems*. MIT press.
- Gerstner, W. and Kistler, W. M. (2002). *Spiking neuron models: Single neurons, populations, plasticity*. Cambridge university press.
- Heaton, J. (2018). Ian goodfellow, yoshua bengio, and aaron courville: Deep learning: The mit press, 2016, 800 pp, isbn: 0262035618. *Genetic programming and evolvable machines*, 19(1):305–307.
- Hodgkin, A. L. and Huxley, A. F. (1952). A quantitative description of membrane current and its application to conduction and excitation in nerve. *The Journal of physiology*, 117(4):500.
- Hubel, D. H. and Wiesel, T. N. (1959). Receptive fields of single neurones in the cat’s striate cortex. *The Journal of Physiology*, 148(3):574–591.
- Körding, K. P., Beierholm, U., Ma, W. J., Quartz, S., Tenenbaum, J. B., and Shams, L. (2007). Causal inference in multisensory perception. *PLoS one*, 2(9):e943.
- Marr, D. (2010). *Vision: A computational investigation into the human representation and processing of visual information*. MIT press.

BIBLIOGRAFÍA

- Mitchell, T. M. (1997). *Machine Learning*. McGraw-Hill, New York.
- Murphy, K. P. (2012). *Machine learning: a probabilistic perspective*. MIT press.
- Nobel Prize Committee (2024). The Nobel Prize in Physics 2024. <https://www.nobelprize.org/prizes/physics/2024/summary/>. Accessed: 2025.
- Paredes, R., Cabral, J. B., and Seriès, P. (2025). Scikit-neuromsi: A generalized framework for modeling multisensory integration. *Neuroinformatics*, 23(3):40.
- Rumelhart, D. E., Hinton, G. E., and Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323(6088):533–536.
- Stein, B. E. (2012). *The new handbook of multisensory processing*. Mit Press.
- Willis, T. (1664). *Cerebri anatome*, volume 1. Apud Gerbrandum Schagen.
- Yamins, D. L., Hong, H., Cadieu, C. F., Solomon, E. A., Seibert, D., and DiCarlo, J. J. (2014). Performance-optimized hierarchical models predict neural responses in higher visual cortex. *Proceedings of the national academy of sciences*, 111(23):8619–8624.