



Universidad
Nacional
de Córdoba



Facultad de Matemática,
Astronomía, Física y
Computación

Implementación de un modelo neuronal de integración multisensorial de inferencia probabilística con dinámicas corticales realistas

por

Franco Molina

Presentado ante la **FACULTAD DE MATEMÁTICA, ASTRONOMÍA,
FÍSICA Y COMPUTACIÓN** como parte de los requerimientos para la ob-
tención del grado de Licenciado en ciencias de la computación de la

UNIVERSIDAD NACIONAL DE CÓRDOBA

Enero, 2026

Directores: Dr. Renato Paredes Venero
Dr. Juan Bautista Cabral



Implementación de un modelo neuronal de integración multisensorial de
inferencia probabilística con dinámicas corticales realistas © 2026 by Franco
Molina is licensed under Creative Commons Attribution-ShareAlike 4.0
International

Certifico que el trabajo incluido en este documento es el resultado de tareas de investigación originales y que no ha sido presentado para optar a un título en ninguna otra Universidad o Institución.

Agradecimientos

Gracias a juan, renato y messi.

Glosario

ADAM Adaptive Moment Estimation	XLVI
ADF Assumed density filtering	XLVI
ANN Redes neuronales artificiales	XXXIII
BMA Bayesian Model Averaging	LI
CNN Redes neuronales convolucionales	XXXIII
CS Colículo superior	XX
DIP Dependency Inversion Principle	XLIX
GRU Gated Recurrent Units	XXXIV
GSM Gaussian scale mixture	XIX, XL, XLI, XLIV, XLVI
L-BFGS-B Largescale bound-constrained optimization	XLVI
LGN Núcleo geniculado lateral	XVIII
LIF Leaky Integrate-and-Fire	XXIII
LSTM Long Short-Term Memory	XXXIV
MLP Perceptrón multicapa	XXXIII
NetCDF Network Common Data Form	LI
PCA Análisis de componentes principales	XXXII
RNN Redes neuronales recurrentes	XXXIV
SSN Stabilized Supralinear Network	XXVII, XLII

Índice general

Agradecimientos	I
Glosario	II
Índice de figuras	VII
1. Introducción	X
1.1. Organización del trabajo	XI
2. Antecedentes	XIII
2.1. Contexto histórico de la neurociencia	XIII
2.2. Fundamentos biológicos	XV
2.2.1. La neurona como unidad funcional	XV
2.2.2. El sistema visual: de la retina a la corteza	XVII
2.2.3. Filtros de Gabor como modelo de campos receptivos	XIX
2.2.4. Vías visuales: procesamiento paralelo	XIX
2.2.5. El colículo superior y la integración multisensorial	XX
2.2.6. De la biología a la computación	XXI
2.3. Neurociencia computacional	XXI
2.3.1. Los tres niveles	XXI
2.3.2. Codificación y decodificación neuronal	XXII
2.3.3. Modelos de neuronas	XXII
2.3.4. Conexiones neuronales	XXIV
2.3.5. Redes neuronales recurrentes y dinámicas corticales	XXVI
2.4. Integración multisensorial	XXVII
2.4.1. La percepción como inferencia probabilística	XXVII
2.4.2. Combinación óptima de señales	XXVIII
2.4.3. El problema de la inferencia causal	XXVIII
2.4.4. El efecto ventrílocuo como paradigma experimental	XXIX
2.5. Modelos biológicamente inspirados	XXIX
2.5.1. El paradigma de la ingeniería neuronal	XXX
2.5.2. Ruido y variabilidad neuronal	XXXI
2.5.3. Redes excitatorias-inhedorias	XXXI
2.6. Machine learning aplicado a la neurociencia	XXXII
2.6.1. Paradigmas de aprendizaje	XXXII
2.6.2. Redes neuronales artificiales	XXXIII
2.6.3. Arquitecturas profundas y convolucionales	XXXIII
2.6.4. Redes recurrentes	XXXIV

2.6.5.	Estadística bayesiana y aprendizaje	XXXV
2.6.6.	Redes neuronales para inferencia probabilística	XXXV
2.7.	Hacia la integración computacional	XXXVI
2.7.1.	Antecedentes directos	XXXVI
3.	Modelos Estudiados	XXXVII
3.1.	El modelo de Cuppini para integración audiovisual e inferencia causal	XXXVII
3.1.1.	Arquitectura del modelo	XXXVII
3.1.2.	Mecanismos de integración e inferencia	XXXVIII
3.1.3.	Capacidades y limitaciones	XXXIX
3.2.	El modelo de Echeveste para inferencia probabilística con dinámicas corticales	XXXIX
3.2.1.	Marco teórico: muestreo como inferencia	XXXIX
3.2.2.	Arquitectura de red	XL
3.2.3.	El modelo generativo (GSM)	XL
3.2.4.	Dinámica neuronal	XLII
3.2.5.	Entrenamiento para muestreo	XLIV
3.2.6.	Propiedades emergentes	XLVI
3.2.7.	Roles funcionales de las dinámicas	XLVI
3.2.8.	Limitaciones y extensiones	XLVII
4.	Scikit-NeuroMSI: Un Framework para Modelado de Integración Multisensorial	XLVIII
4.1.	Motivación y objetivos del framework	XLVIII
4.2.	Arquitectura de software	XLIX
4.2.1.	Principios de diseño	XLIX
4.2.2.	Sistema de aliasing de parámetros	XLIX
4.2.3.	Clases principales	XLIX
4.2.4.	Backend de datos	LI
4.3.	Modelos implementados	LI
4.4.	Implementación técnica	LII
4.4.1.	Gestión de dependencias	LII
4.4.2.	Ejecución paralela	LII
4.4.3.	Gestión de memoria	LIII
4.5.	Aplicaciones	LIII
4.5.1.	Paradigma del efecto ventrílocuo	LIII
4.5.2.	Ilusión del flash inducido por sonido	LIV
4.5.3.	Aplicaciones clínicas	LIV
4.6.	Contexto en el ecosistema de herramientas	LIV
4.7.	Direcciones futuras y contribuciones de la comunidad	LV
4.7.1.	Mejoras arquitectónicas	LV
4.7.2.	Nuevos modelos	LV
4.7.3.	Información del proyecto	LV
4.8.	Relevancia para el presente trabajo	LV
5.	Implementación	LVII
6.	Resultados	LVIII

ÍNDICE GENERAL

7. Conclusiones y trabajo a futuro	LIX
Bibliografía	LXI

Índice de figuras

2.1. El cerebro de Willis. Del libro <i>Cerebri Anatome</i> (Willis, 1664). Este grabado representa las arterias cerebrales.	XIII
2.2. Dibujo de Ramón y Cajal de las células del cerebelo de un pollo, mostrado en “Estructura de los centros nerviosos de las aves”, Madrid, 1905.	XIV
2.3. Estructura anatómica de una neurona, mostrando sus componentes principales.	XV
2.4. Representación esquemática de la membrana neuronal mostrando canales iónicos selectivos.	XVI
2.5. Vía Visual Primaria. Esquema anatómico que muestra el sistema de transmisión de señales visuales.	XVII
2.6. Evolución temporal del potencial de membrana V de una neurona <i>íntegra-y-dispara</i> impulsada por una corriente constante. Para mayor claridad, el potencial se presenta normalizado respecto al umbral de disparo ($V_{th} = 1,0$) y el reposo ($V_{reset} = 0$).	XXIV
2.7. Modelo computacional de red neuronal feed-forward de una sola capa oculta.	XXV
2.8. Arquitectura de red neuronal con conexiones feedforward e incluyendo conexiones top-down resaltadas en azul.	XXV
2.9. Arquitectura de red recurrente. Las conexiones horizontales entre neuronas de la misma capa y las conexiones bidireccionales entre capas permiten que la actividad de cada neurona influya sobre sus vecinas, generando dinámicas temporales complejas.	XXVI
2.10. Ventriloquia espacial: la ubicación aparente de un sonido objetivo auditivo puede ser desplazada por la percepción de un estímulo visual (un destello).	XXIX
2.11. Representación de una red neuronal profunda. Se ilustra la organización en múltiples capas ocultas que permite la extracción jerárquica de características, desde rasgos simples a representaciones abstractas.	XXXIV
2.12. Red neuronal recurrente totalmente conectada con 4 neuronas.	XXXV
3.1. Estructura de la red de Cuppini et al.. Las regiones visual y auditiva procesan los estímulos sensoriales externos. Estas regiones están interconectadas mediante sinapsis excitatorias directas y envían proyecciones feedforward de largo alcance dirigidas al área de inferencia causal.	XXXVIII

ÍNDICE DE FIGURAS

- 3.2. El modelo generativo estadístico y el circuito neuronal correspondiente que implementa la inferencia probabilística basada en muestreo. XL
- 3.3. Conjunto de entrenamiento del modelo de Echeveste. Los cinco estímulos comparten el mismo contenido $\bar{\mathbf{y}}$ (gaussiana de 27° centrada en 0°) pero difieren en su nivel de contraste $z^{(\alpha)} \in \{0, 0,125, 0,25, 0,5, 1,0\}$ XLV
- 4.1. Diagrama de clases reducido de Scikit-NeuroMSI. Las flechas vacías representan la herencia, la flecha con punta de diamante indica que varios objetos NDResult se agregan en una única NDResultCollection, y todas las demás relaciones tienen etiquetas explicativas. L

Capítulo 1

Introducción

La integración multisensorial es un proceso neuronal fundamental mediante el cual el cerebro combina información proveniente de distintas modalidades sensoriales para generar representaciones más robustas y confiables del entorno. Cuando vemos a alguien hablar, integramos automáticamente las señales visuales de los movimientos labiales con las señales auditivas de la voz, percibiendo un evento unificado más claro que cualquiera de sus componentes por separado. Este fenómeno, documentado extensamente desde los estudios pioneros en el colículo superior (Stein, 2012), constituye una de las capacidades más notables del sistema nervioso.

Diversos enfoques computacionales han buscado capturar los mecanismos subyacentes a esta integración. Los modelos de máxima verosimilitud proponen que el cerebro selecciona la estimación perceptual que maximiza la probabilidad de las observaciones, mientras que los modelos bayesianos incorporan conocimiento previo para obtener distribuciones posteriores sobre las variables de interés. Más recientemente, arquitecturas neuronales inspiradas en la estructura cerebral han intentado implementar estas inferencias de manera biológicamente plausible.

Entre estos desarrollos, dos trabajos resultan particularmente relevantes por representar enfoques complementarios al problema. Por un lado, el modelo de Cuppini et al. (2017) aborda la integración audiovisual mediante una arquitectura de tres capas jerárquicas que reproduce exitosamente fenómenos experimentales como el efecto ventrilocuo, la ilusión perceptual donde un sonido parece provenir de la ubicación de un estímulo visual simultáneo. Sin embargo, al utilizar modelos de tasa deterministas, este enfoque no captura la variabilidad y las dinámicas oscilatorias características de la actividad cortical real.

Por otro lado, el modelo de Echeveste et al. (2020) demuestra que redes neuronales con restricciones biológicas pueden implementar inferencia probabilística mediante muestreo estocástico, exhibiendo propiedades emergentes como oscilaciones gamma, transitorios inhibitorios y variabilidad trial-a-trial consistentes con registros electrofisiológicos. No obstante, este modelo está restringido al procesamiento de una única modalidad sensorial, sin abordar la integración multisensorial ni el problema de la inferencia causal.

Esta situación revela una brecha significativa: los modelos que capturan la arquitectura funcional de la integración multisensorial carecen de dinámicas corticales realistas, mientras que aquellos con dinámicas biológicamente plau-

sibles están limitados al procesamiento unimodal. Además, cada modelo ha sido implementado independientemente, en distintos lenguajes y con estructuras incompatibles, dificultando su comparación sistemática y cualquier intento de integración.

La visión a largo plazo que motiva este trabajo es el desarrollo de modelos que combinen la arquitectura multimodal del enfoque de Cuppini con las dinámicas corticales del modelo de Echeveste. Un modelo así permitiría estudiar cómo fenómenos como el efecto ventrílocuo emergen de circuitos neuronales que no solo integran información de múltiples modalidades, sino que lo hacen mediante mecanismos de muestreo estocástico biológicamente plausibles. Sin embargo, alcanzar esta visión requiere primero sentar bases técnicas sólidas.

El presente trabajo representa el primer paso en esta dirección mediante la implementación del modelo de Echeveste dentro del framework Scikit-NeuroMSI (Paredes et al., 2025), una plataforma de código abierto en Python¹ diseñada específicamente para la modelización neurocomputacional de la integración multisensorial. Esta implementación incluye la arquitectura de red con poblaciones excitatorias e inhibitorias, el modelo generativo que define el problema de inferencia, y el procedimiento de entrenamiento para muestreo.

Junto con el modelo, el trabajo desarrolla herramientas de análisis para estudiar modelos con dinámicas temporales relevantes, incluyendo visualización de la evolución de potenciales de membrana, análisis espectral para identificar oscilaciones, y comparación de estadísticas de respuesta con valores objetivo. La validación verifica que la implementación reproduce las propiedades reportadas originalmente: convergencia de momentos, variabilidad modulada por contraste, y presencia de dinámicas temporales características.

Es importante delimitar claramente el alcance de esta contribución. La fusión del modelo de Echeveste con el modelo de Cuppini, la implementación de inferencia causal multisensorial, y la validación contra datos experimentales de integración audiovisual quedan como direcciones de investigación futura. El presente trabajo se enfoca exclusivamente en establecer las bases técnicas que harán posibles estas extensiones, reconociendo que una implementación correcta y validada del modelo unimodal de Echeveste es condición necesaria para cualquier desarrollo posterior hacia el procesamiento multisensorial con dinámicas corticales realistas.

1.1. Organización del trabajo

Los capítulos de este trabajo se organizan de la siguiente manera:

El Capítulo 2 presenta los fundamentos necesarios para comprender el trabajo. Se introduce el contexto histórico de la neurociencia, los mecanismos biológicos de señalización neuronal desde el nivel molecular hasta la organización cortical, los principios de integración multisensorial y la inferencia causal, y las técnicas de aprendizaje automático relevantes para la optimización de redes recurrentes.

El Capítulo 3 describe en detalle los dos modelos computacionales centrales: el modelo de Cuppini para integración audiovisual e inferencia causal, que representa el objetivo a largo plazo hacia el cual apuntan las extensiones futuras;

¹<https://www.python.org/>

y el modelo de Echeveste para inferencia probabilística con dinámicas corticales, cuya implementación constituye el objeto central del presente trabajo.

El Capítulo 4 presenta Scikit-NeuroMSI, el framework de código abierto que proporciona la infraestructura técnica sobre la cual se desarrolla la implementación. Se describen su arquitectura de software, los modelos previamente implementados, y su relevancia para el presente trabajo.

El Capítulo 5 documenta el desarrollo de la implementación del modelo de Echeveste, detallando las decisiones de diseño, la integración con el framework, y las herramientas de análisis desarrolladas.

En el Capítulo 6 se presentan los resultados de validación, verificando que la implementación reproduce las propiedades reportadas en el trabajo original.

Finalmente, las conclusiones generales son presentadas en el Capítulo 7, donde se discuten las contribuciones realizadas, las limitaciones del trabajo, y las direcciones futuras de investigación hacia la integración multisensorial con dinámicas corticales realistas.

Capítulo 2

Antecedentes

2.1. Contexto histórico de la neurociencia

La neurociencia, entendida como el estudio sistemático del sistema nervioso y sus funciones, constituye uno de los campos de estudio científico más fascinantes y complejos de la historia humana. Comprender cómo el cerebro se relaciona con la mente, cómo las redes de neuronas dan lugar a la percepción, el pensamiento y la conciencia, ha cautivado a filósofos y científicos desde la antigüedad. Sin embargo, el camino hacia una ciencia madura del cerebro ha sido largo, marcado por revoluciones conceptuales que han transformado radicalmente nuestra comprensión (Blanco, 2014).




Figura 2.1: El cerebro de Willis. Del libro *Cerebri Anatome* (Willis, 1664). Este grabado representa las arterias cerebrales.

Esta ciencia ha experimentado transformaciones conceptuales profundas desde sus orígenes. Partiendo del debate entre visiones cardiocéntricas y encefalocéntricas, donde Aristóteles defendía una visión que situaba tanto el alma como las facultades cognitivas en el corazón, y por su parte, Hipócrates y, posteriormente Galeno, argumentaron que el cerebro era la base de la inteligencia y las emociones. Este debate, iniciado en la Grecia clásica encontró su resolución gradual a través de siglos de investigación anatómica y fisiológica (Blanco, 2014).

2.1. CONTEXTO HISTÓRICO DE LA NEUROCIENCIA

Este conflicto entre visiones cardiocéntricas y encefalocentristas se mantuvo durante siglos. Galeno de Pérgamo (129-216 d.C.), a través de sus estudios anatómicos en animales, estableció una doctrina que dominaría el pensamiento médico durante más de un milenio: la teoría ventricular. Según esta concepción, los ventrículos cerebrales, las cavidades llenas de líquido en el interior del cerebro, eran los repositorios de las facultades mentales, organizadas jerárquicamente desde la sensación hasta la memoria y el razonamiento (Blanco, 2014).

El siglo XVIII trajo consigo el descubrimiento de la naturaleza eléctrica de la actividad nerviosa, punto que analizaremos y trabajaremos mas adelante, un hallazgo que transformaría para siempre nuestra comprensión del sistema nervioso. Luigi Galvani (1737-1798) demostró en 1791 que la estimulación eléctrica podía provocar contracciones musculares gracias a sus experimentos en ranas, estableciendo que la “electricidad animal” era el medio de comunicación nerviosa (Blanco, 2014). Este descubrimiento abrió la puerta a una comprensión del sistema nervioso basada en principios físicos mensurables.

Continuando con el siglo XIX el cual consolidó dos pilares fundamentales de la neurociencia moderna. Por un lado, Santiago Ramón y Cajal estableció la doctrina de la neurona, demostrando que el sistema nervioso está compuesto por células individuales discretas que se comunican a través de contactos especializados, posteriormente denominados sinapsis por Charles Sherrington. Por otro lado, los estudios sobre localización cortical de Paul Broca y Carl Wernicke establecieron que diferentes regiones cerebrales median funciones cognitivas específicas (Blanco, 2014).

El siglo XX presencié avances decisivos para el presente trabajo. Alan Hodgkin y Andrew Huxley desarrollaron en la década de 1950 el primer modelo cuantitativo completo de la excitabilidad neuronal, describiendo los mecanismos iónicos del potencial de acción en el axón gigante del calamar (Hodgkin and Huxley, 1952). Este modelo, que les valió el Premio Nobel de Medicina en 1963, sigue siendo una referencia en la neurociencia computacional y será detallado en la Sección 2.3.3.




Figura 2.2: Dibujo de Ramón y Cajal de las células del cerebelo de un pollo, mostrado en “Estructura de los centros nerviosos de las aves”, Madrid, 1905.

Complementariamente, los estudios de Henry Dale, Otto Loewi y Bernard Katz establecieron los principios de la transmisión sináptica química, revelando cómo los neurotransmisores median la comunicación entre neuronas (Blanco, 2014). Y finalmente, David Hubel y Torsten Wiesel revolucionaron nuestra comprensión del procesamiento visual cortical en las décadas de 1950 y 1960. Mediante registros electrofisiológicos en la corteza visual de gatos, descubrieron

que las neuronas corticales responden selectivamente a características específicas del estímulo, como la orientación de barras luminosas (Hubel and Wiesel, 1959). Describieron la organización jerárquica del sistema visual, desde células simples que responden a bordes orientados en posiciones específicas, hasta células complejas con mayor invariancia espacial. Su trabajo, reconocido con el Premio Nobel de Medicina en 1981, estableció los principios de selectividad neuronal que fundamentan los modelos computacionales de corteza visual, incluyendo el modelo de Echeveste et al. (2020) que implementaremos en este trabajo.

Estos desarrollos históricos convergieron con el nacimiento de las ciencias de la computación para dar lugar a la neurociencia computacional, disciplina que proporciona el marco teórico y metodológico del presente trabajo.

2.2. Fundamentos biológicos

Los modelos computacionales de procesamiento neuronal deben fundamentarse en las propiedades biológicas de las neuronas y los circuitos que las interconectan. En esta sección vamos a presentar los principios biológicos esenciales que subyacen a los modelos estudiados en este trabajo, desde los mecanismos iónicos de la señalización neuronal hasta la organización funcional de las áreas corticales involucradas en la percepción visual y multisensorial.




Figura 2.3: Estructura anatómica de una neurona, mostrando sus componentes principales.

2.2.1. La neurona como unidad funcional

La neurona es la unidad fundamental de procesamiento del sistema nervioso. Estructuralmente, cada neurona comprende un cuerpo celular o soma que contiene el núcleo y la maquinaria metabólica, dendritas que reciben señales de otras neuronas, un axón que transmite señales hacia células postsinápticas, y terminales sinápticos especializados para la liberación de neurotransmisores (Dayan and Abbott, 2005).

Toda esta estructura está delimitada por una membrana celular cuyas propiedades eléctricas son fundamentales para la comunicación entre neuronas, que

depende de cambios rápidos en el potencial eléctrico. En reposo, esta membrana mantiene una diferencia de potencial de aproximadamente -70 mV, con el interior de la célula negativo respecto al exterior. Este potencial de reposo se establece mediante canales iónicos selectivos, principalmente permeables a iones de potasio (K^+), junto con la acción de bombas iónicas que mantienen los gradientes de concentración (Dayan and Abbott, 2005).

Canales iónicos y potencial de acción

Los canales iónicos son proteínas integrales que atraviesan la membrana celular y permiten el paso selectivo de iones específicos. La particularidad de los canales iónicos neuronales es su alta conductancia, del orden de 10^7 cargas por segundo, lo que permite los cambios rápidos en el potencial de membrana necesarios para generar potenciales de acción (Dayan and Abbott, 2005).

El potencial de acción, descubierto y caracterizado cuantitativamente por Hodgkin and Huxley (1952), constituye la señal eléctrica fundamental mediante la cual las neuronas transmiten información a distancia. Su generación depende de dos poblaciones de canales iónicos dependientes de voltaje: los canales de sodio (Na^+), cuya apertura produce la despolarización rápida de la membrana, y los canales de potasio (K^+), cuya apertura más lenta permite la repolarización. El potencial de acción procede según un patrón de “todo o nada”, donde todos los impulsos exhiben la misma amplitud, y la intensidad del estímulo se codifica mediante la frecuencia de disparo (Dayan and Abbott, 2005).

El modelo de Hodgkin-Huxley, que será presentado en detalle en la Sección 2.3.3, formaliza matemáticamente estos mecanismos mediante un sistema de ecuaciones diferenciales que describe la dinámica del potencial de membrana en función de las conductancias iónicas dependientes de voltaje.




Figura 2.4: Representación esquemática de la membrana neuronal mostrando canales iónicos selectivos.

Transmisión sináptica

La comunicación entre neuronas ocurre predominantemente mediante sinapsis químicas, donde la llegada de un potencial de acción al terminal presináptico desencadena la liberación de neurotransmisores hacia la hendidura sináptica. Estos neurotransmisores se unen a receptores en la membrana de la neurona postsináptica, alterando su conductancia iónica y modificando su potencial

2.2. FUNDAMENTOS BIOLÓGICOS

eléctrico junto con la probabilidad de que esta genere su propio impulso (Dayan and Abbott, 2005).

Este mecanismo se modela como una transferencia de señales con efectos contrapuestos. Dependiendo del tipo de interacción, la neurona receptora puede sufrir una despolarización (excitación), que aumenta su probabilidad de disparo, o una hiperpolarización (inhibición), que la reduce. Esta distinción funcional permite organizar los modelos de redes neuronales, un tema que explicaremos más adelante en la Sección 2.3.3.

2.2.2. El sistema visual: de la retina a la corteza

El sistema visual procesa la información luminosa a través de una serie de estaciones organizadas jerárquicamente: retina, núcleo geniculado lateral del tálamo (LGN), corteza visual primaria (V1), y áreas corticales extraestriadas. En cada nivel aumenta la complejidad de las características extraídas del estímulo visual (Dayan and Abbott, 2005).




Figura 2.5: Vía Visual Primaria. Esquema anatómico que muestra el sistema de transmisión de señales visuales.

Retina y células ganglionares

La retina transforma la energía luminosa en señales eléctricas mediante los fotorreceptores: los conos, responsables de la visión en color y de alta resolución en condiciones de buena iluminación, y los bastones, más sensibles pero acromáticos, que permiten la visión en condiciones de baja luminosidad. Esta señal es procesada por circuitos locales antes de llegar a las células ganglionares

cuyos axones forman el nervio óptico y constituyen la salida de la retina hacia el cerebro.

Dichas células ganglionares son un tipo de neuronas de axón mielinizado localizadas en la superficie interna de la retina. Se clasifican en dos tipos principales según su tamaño y propiedades funcionales: las células magnocelulares (M), grandes y sensibles al movimiento y contraste, y las células parvocelulares (P), más pequeñas y sensibles al color y detalle fino. Estas neuronas responden a estímulos lumínicos únicamente dentro de una región concreta del espacio visual denominada campo receptivo, y sus respuestas dependen del contraste entre regiones iluminadas y oscuras (Dayan and Abbott, 2005). Los campos receptivos de las células ganglionares presentan una organización centro-periferia antagonista: las células centro-ON se excitan con luz en el centro de su campo receptivo y se inhiben con luz en la periferia, mientras que las células centro-OFF presentan el patrón inverso. Esta distinción nos será útil en los siguientes párrafos.

Núcleo geniculado lateral

El Núcleo geniculado lateral (LGN) actúa como estación de relevo entre la retina y la corteza visual. Éste se encarga de preservar la organización retinotópica, donde neuronas vecinas procesan regiones adyacentes del campo visual. Además de transmitir información feedforward desde la retina, el LGN recibe conexiones feedback desde la corteza que modulan su actividad, sugiriendo un papel activo en el procesamiento visual más allá del simple relevo (Dayan and Abbott, 2005).

Corteza visual primaria (V1)

La corteza visual primaria, también conocida como área V1 o corteza estriada, constituye la primera estación de procesamiento cortical de la información visual. Como toda la corteza cerebral, V1 se organiza en seis capas horizontales numeradas del 1 al 6 desde la superficie hacia el interior. Cada capa tiene una composición celular y patrones de conectividad característicos: la capa 4 recibe las entradas principales desde el LGN, mientras que otras capas procesan esta información y la transmiten a otras regiones corticales.

Hubel and Wiesel (1959) descubrieron que las neuronas de V1 responden selectivamente a características específicas de los estímulos, particularmente a bordes y barras con orientaciones determinadas, una propiedad ausente en las células ganglionares y del LGN. A su vez, identificaron dos tipos principales de neuronas en V1. Las *células simples*, ubicadas principalmente en la capa 4, presentan campos receptivos con regiones ON y OFF separadas espacialmente, respondiendo a bordes orientados en posiciones específicas del campo visual. Cada célula simple está afinada para detectar estímulos con orientaciones en un rango de aproximadamente diez grados (Blanco, 2014). Y las *células complejas*, localizadas en las capas 2, 3, 5 y 6, responden también a bordes orientados pero con mayor invariancia a la posición exacta del estímulo dentro de su campo receptivo, que es más amplio que el de las células simples. El modelo de Hubel y Wiesel propone que la selectividad a orientación de las células simples surge de la convergencia de entradas desde células del LGN con campos receptivos alineados (Dayan and Abbott, 2005).

En V1, las neuronas con propiedades de respuesta similares se organizan en columnas verticales que atraviesan las diferentes capas corticales. Las columnas de orientación, de entre 30 y 100 micrómetros de grosor, agrupan neuronas que responden a la misma orientación preferida. Estas columnas se disponen sistemáticamente de modo que un recorrido tangencial a través de la corteza encuentra secuencialmente todas las orientaciones posibles. Las columnas de dominancia ocular alternan el predominio de respuesta al ojo izquierdo y derecho. El conjunto de columnas que representa un ciclo completo de orientaciones para ambos ojos, junto con las estructuras denominadas “blobs” que procesan información de color, constituye una *hipercolumna* de aproximadamente un milímetro cuadrado (Blanco, 2014; Dayan and Abbott, 2005). Esta organización modular se repite a lo largo de toda la superficie de V1.

Esta arquitectura columnar es directamente relevante para el modelo de Echeveste, que simula precisamente una hipercolumna de V1 como unidad funcional para la inferencia probabilística sobre orientaciones visuales, como se detallará en el Capítulo 3.

2.2.3. Filtros de Gabor como modelo de campos receptivos

Los campos receptivos de las células simples de V1, con sus regiones ON y OFF, pueden aproximarse matemáticamente. Una función de Gabor es el producto de una función gaussiana, que define la extensión espacial del campo receptivo, y una función sinusoidal, que captura la estructura de bandas claras y oscuras (Dayan and Abbott, 2005):

$$D_s(x, y) = \frac{1}{2\pi\sigma_x\sigma_y} \exp\left(-\frac{x^2}{2\sigma_x^2} - \frac{y^2}{2\sigma_y^2}\right) \cos(kx - \phi) \quad (2.1)$$

Los parámetros de esta función determinan las propiedades del campo receptivo: σ_x y σ_y controlan la extensión espacial en las direcciones horizontal y vertical respectivamente, k es la frecuencia espacial preferida que determina el espaciado entre bandas claras y oscuras, y ϕ es la fase espacial preferida que determina dónde caen los límites entre regiones ON y OFF dentro del campo receptivo. Estudios experimentales han demostrado que las funciones de Gabor proporcionan excelentes aproximaciones a los campos receptivos medidos en células simples de la corteza visual de gatos y primates (Dayan and Abbott, 2005).

La orientación preferida de un filtro de Gabor se obtiene rotando el sistema de coordenadas. Y finalmente una neurona con orientación preferida θ , responde máximamente a bordes orientados en dicha dirección. Estos filtros juegan un papel central en el Gaussian scale mixture (GSM) utilizado por Echeveste et al. (2020) el cual se explicará en el Capítulo 3.

2.2.4. Vías visuales: procesamiento paralelo

Después del procesamiento inicial en V1, la información visual se distribuye a través de múltiples áreas corticales extraestriadas organizadas en dos corrientes principales de procesamiento paralelo (Dayan and Abbott, 2005):

La vía ventral (“qué”) se proyecta desde V1 hacia V2, V4 y la corteza inferotemporal. Esta vía se especializa en el reconocimiento de objetos, procesando

información sobre forma, color e identidad. Lesiones en esta vía producen agnosias visuales, dificultades para reconocer objetos a pesar de una visión básica preservada.

La vía dorsal (“dónde/cómo”) se proyecta desde V1 hacia V2, el área MT (V5) y la corteza parietal posterior. Esta vía procesa información sobre movimiento, localización espacial y guía de acciones motoras. Lesiones en esta vía producen déficits en la localización de objetos y en la coordinación visomotora.

Esta división funcional tiene implicaciones directas para los modelos que estudiaremos. El modelo de Echeveste, que representa características visuales como la orientación en una hipercolumna de V1, está más relacionado con el procesamiento de la vía ventral. En contraste, el modelo de Cuppini, que representa la localización espacial de estímulos audiovisuales, está más relacionado con el procesamiento de la vía dorsal. Como se discutirá en el Capítulo 3, la eventual integración de ambos enfoques requerirá considerar cómo interactúan estos diferentes tipos de representaciones corticales.

2.2.5. El colículo superior y la integración multisensorial

El Colículo superior (CS) es una estructura del mesencéfalo que desempeña un papel fundamental en la orientación de la atención y los movimientos oculares hacia estímulos relevantes del entorno. A diferencia de las áreas corticales discutidas anteriormente, el CS recibe información de múltiples modalidades sensoriales, visual, auditiva y somatosensorial, organizándolas en mapas topográficos superpuestos (Stein, 2012).

El CS se organiza en capas funcionalmente diferenciadas: las capas superficiales procesan predominantemente información visual y mantienen una representación retinotópica del campo visual, mientras que las capas profundas son multimodales y contienen neuronas que responden a estímulos de diferentes modalidades cuando estos provienen de ubicaciones espaciales coincidentes. Esta convergencia anatómica de información multisensorial hace del CS un punto ideal para estudiar los mecanismos de integración sensorial.

Estudios electrofisiológicos en el CS han revelado principios fundamentales de la integración multisensorial que los modelos computacionales deben capturar (Stein, 2012; Paredes et al., 2025). La *regla espacial* establece que estímulos de diferentes modalidades cercanos en el espacio producen respuestas potenciadas (superaditivas) comparadas con las respuestas unimodales, mientras que estímulos distantes producen respuestas deprimidas. La *regla temporal* indica que la integración es máxima cuando los estímulos de diferentes modalidades son cercanos en el tiempo. Y la *regla de efectividad inversa* establece que la potenciación multisensorial es mayor cuando los estímulos unimodales individuales son débiles o ambiguos (Cuppini et al., 2017).

El modelo de Cuppini, que será presentado en el Capítulo 3, captura estos principios mediante una arquitectura de tres capas donde las regiones unisensoriales están organizadas topográficamente y conectadas a una capa de inferencia causal que determina si estímulos audiovisuales provienen de una fuente común o de fuentes independientes.

2.2.6. De la biología a la computación

Los fundamentos biológicos presentados en esta sección establecen las restricciones y fenómenos que los modelos computacionales de procesamiento neuronal deben capturar. La organización jerárquica del sistema visual, desde los campos receptivos en la retina hasta la selectividad a orientación en V1, proporciona el sustrato para el modelo de Echeveste. A su vez, la integración multisensorial en estructuras como el colículo superior, con sus principios de coincidencia espacial y temporal, fundamenta el modelo de Cuppini.

Ya desarrolladas las restricciones biológicas fundamentales. La siguiente sección presenta el marco formal de la neurociencia computacional que permite formalizar estas restricciones y evaluar las capacidades de los modelos resultantes.

2.3. Neurociencia computacional

La neurociencia computacional representa una síntesis moderna de neurobiología, matemáticas y ciencias de la computación, orientada a comprender cómo el sistema nervioso procesa información y genera comportamiento. Esta disciplina no se limita a simular fenómenos neuronales, sino que también busca identificar los principios computacionales fundamentales que subyacen a las funciones cerebrales y estudiar como estos métodos matemáticos, físicos e informáticos pueden proporcionar información importante sobre el funcionamiento del sistema nervioso. (Dayan and Abbott, 2005).

2.3.1. Los tres niveles

Un marco conceptual fundamental para la neurociencia computacional fue propuesto por Marr (2010) en su influyente obra *Vision*. Donde argumentó que cualquier sistema de procesamiento de información puede ser analizado en tres niveles distintos, pero complementarios (Marr, 2010):

El **nivel computacional** aborda la pregunta de *qué* computa el sistema y *por qué*. En este nivel, se especifica el problema computacional que el sistema debe resolver y la lógica de la estrategia mediante la cual puede resolverse. Por ejemplo, para la corteza visual, el problema computacional podría ser inferir las características más probables de un estímulo (como su orientación o contraste) a partir de información sensorial ruidosa, representando no solo una estimación puntual, sino la incertidumbre asociada a dicha estimación.

El **nivel algorítmico** pregunta *cómo* se implementa el cómputo. ¿Qué representaciones utiliza el sistema? ¿Qué algoritmos transforman estas representaciones? Este nivel especifica los procedimientos concretos mediante los cuales se resuelve el problema computacional.

Finalmente, el **nivel de implementación** se ocupa de cómo los circuitos neuronales implementan el algoritmo. ¿Qué circuitos neuronales realizan el cómputo? ¿Cómo se codifica la información en patrones de actividad neuronal? Por ejemplo, en el caso de la inferencia probabilística, esto implica especificar cómo redes recurrentes de neuronas, pueden implementar el muestreo de distribuciones posteriores.

Esta jerarquía de niveles proporciona una estructura para organizar nuestro conocimiento del cerebro y, específicamente, para conectar descripciones funcio-

nales con mecanismos neuronales. En este trabajo, donde buscamos implementar un modelo de inferencia causal multisensorial con dinámicas corticales realistas, se opera precisamente en la interfaz entre estos niveles: partimos de una especificación computacional (inferencia bayesiana) y buscamos su implementación en circuitos neuronales biológicamente plausibles.

2.3.2. Codificación y decodificación neuronal

Una cuestión central en neurociencia computacional es cómo las neuronas representan información sobre el mundo externo y los estados internos del organismo. La investigación en este ámbito se ha centrado en dos problemas complementarios: la *codificación neuronal* (cómo los estímulos se traducen en patrones de actividad neuronal) y la *decodificación neuronal* (cómo la información puede extraerse de estos patrones) (Dayan and Abbott, 2005).

El patrón neuronal más estudiado tradicionalmente es la **tasa de disparo**: la frecuencia promedio de potenciales de acción generados por una neurona en un intervalo de tiempo dado. Estudios clásicos de Adrian en la década de 1920 demostraron que la intensidad de un estímulo se correlaciona con la tasa de disparo de las neuronas sensoriales (Blanco, 2014). Sin embargo, trabajos recientes han propuesto que el **potencial de membrana** en sí mismo puede servir como variable representacional. En este enfoque, no solo el valor medio del potencial sino también su variabilidad codifica información relevante sobre el estímulo y la incertidumbre asociada a su estimación. La tasa de disparo se deriva entonces como una transformación no lineal del potencial de membrana.

Esta relación entre potencial de membrana y tasa de disparo tiene implicaciones importantes para la codificación poblacional. Cuando múltiples neuronas representan conjuntamente un estímulo, la distribución de sus potenciales de membrana puede codificar no solo una estimación puntual de las características del estímulo, sino toda una distribución de probabilidad que refleja la incertidumbre perceptual. Por todo esto, la elección de cómo modelar la dinámica neuronal determina qué tipo de información puede ser codificada y posteriormente decodificada del patrón de actividad poblacional. En la Sección 3.2 exploraremos en detalle cómo esta idea se formaliza matemáticamente en el contexto de la inferencia probabilística.

2.3.3. Modelos de neuronas

La neurociencia computacional ha desarrollado una variedad de modelos de neuronas con diferentes niveles de detalle biofísico, desde descripciones detalladas que involucran miles de ecuaciones diferenciales acopladas hasta simplificaciones útiles para estudiar grandes redes interconectadas. La elección del modelo apropiado depende de las preguntas que se desean abordar y del compromiso entre realismo biológico y tratabilidad computacional (Dayan and Abbott, 2005).

El modelo de Hodgkin-Huxley

El modelo Hodgkin-Huxley constituye una de las bases del modelado biofísico de neuronas (Hodgkin and Huxley, 1952). Desarrollado a partir de experimentos en el axón gigante del calamar, este modelo describe cómo los potenciales de acción surgen de la apertura y cierre de canales iónicos dependientes de voltaje.

El modelo integra propiedades eléctricas fundamentales de la membrana neuronal: la capacitancia de membrana C_m , las conductancias de los canales de sodio, potasio y fuga ($\bar{g}_{Na}$, $\bar{g}_K$ y g_L), y la actividad de las puertas iónicas descrita por las variables m , h y n , que se abren y cierran con tasas dependientes del voltaje. Estas propiedades se relacionan mediante un sistema de cuatro ecuaciones diferenciales acopladas, cuya ecuación principal describe la dinámica del potencial de membrana V :

$$C_m \frac{dV}{dt} = -\bar{g}_{Na} m^3 h (V - E_{Na}) - \bar{g}_K n^4 (V - E_K) - g_L (V - E_L) + I_{ext} \quad (2.2)$$

El modelo captura cuantitativamente la generación del potencial de acción, incluyendo su forma característica y el período refractario (Dayan and Abbott, 2005). Sin embargo, su complejidad computacional lo hace impráctico para simulaciones de redes grandes.

El modelo integra-y-dispara

Para simulaciones a mayor escala, se emplean modelos simplificados que capturan las características esenciales de la dinámica neuronal. El modelo integra y dispara (Leaky Integrate-and-Fire (LIF)) es quizás el más ampliamente utilizado. Según Eliasmith and Anderson (2003), este modelo representa un balance conveniente entre realismo neuronal y tratabilidad computacional ya que introduce la no linealidad más prominente de los sistemas neuronales, el potencial de acción, mientras mantiene una formulación matemática simple:

$$\tau_m \frac{dV}{dt} = -(V - V_{rest}) + R_m I(t) \quad (2.3)$$

donde V es el potencial de membrana, τ_m es la constante de tiempo de membrana, V_{rest} es el potencial de reposo, R_m es la resistencia de membrana, e $I(t)$ es la corriente de entrada. Cuando V alcanza un umbral V_{th} , se registra un potencial de acción y el potencial se reinicia a un valor V_{reset} .

A pesar de su simplicidad, el modelo LIF reproduce muchas propiedades cualitativas de neuronas reales, incluyendo la variabilidad en los tiempos de disparo y la sensibilidad a fluctuaciones en la entrada (Dayan and Abbott, 2005).

Modelos de tasa

En un nivel aún más abstracto, los **modelos de tasa** (*rate models*) describen la actividad neuronal en términos de la tasa de disparo promedio de poblaciones de neuronas, ignorando los tiempos precisos de los potenciales de acción individuales (Dayan and Abbott, 2005). Una formulación común es:

$$\tau \frac{dr}{dt} = -r + f \left(\sum_j w_{ij} r_j + h_i \right) \quad (2.4)$$

donde r es la tasa de disparo, $f(\cdot)$ es una función de transferencia no lineal (típicamente sigmoide o rectificadora), w_{ij} son los pesos sinápticos, y h_i es la entrada externa.

Los modelos de tasa son computacionalmente eficientes y han sido ampliamente utilizados para estudiar fenómenos como la memoria de trabajo, la toma




Figura 2.6: Evolución temporal del potencial de membrana V de una neurona *integra-y-dispara* impulsada por una corriente constante. Para mayor claridad, el potencial se presenta normalizado respecto al umbral de disparo ($V_{th} = 1,0$) y el reposo ($V_{reset} = 0$).

de decisiones, y la integración sensorial. Sin embargo, al promediar la actividad neuronal, no capturan la variabilidad temporal que caracteriza la actividad cortical real (Gerstner and Kistler, 2002).

Neuronas estocásticas con dinámica de membrana

El modelo neuronal propuesto por Echeveste et al. (2020), el cual es el objeto de estudio de este trabajo, ocupa un lugar intermedio en la jerarquía de complejidad presentada. A diferencia de los modelos de tasa puros, este enfoque mantiene el potencial de membrana como variable dinámica principal, permitiendo que su variabilidad temporal codifique información. A diferencia del modelo LIF, no implementa un mecanismo de disparo explícito con umbral y reinicio, sino que deriva la tasa de disparo como una transformación continua y supralineal del potencial de membrana.

Crucialmente, este tipo de modelo incorpora dos características biológicas fundamentales: ruido estocástico que genera variabilidad en las respuestas, y la distinción explícita entre poblaciones excitatorias e inhibitorias, respetando el principio de Dale (cada neurona libera el mismo tipo de neurotransmisor en todas sus sinapsis, siendo exclusivamente excitatoria o inhibitoria). Estas características resultan esenciales para implementar inferencia probabilística mediante muestreo, como se desarrollará en profundidad en la Sección 3.2.

En síntesis, los modelos presentados representan diferentes compromisos entre fidelidad biofísica y tratabilidad computacional. Sin embargo, las propiedades computacionales de estos modelos dependen no solo de la dinámica de neuronas individuales, sino fundamentalmente de cómo estas se conectan formando redes. En la siguiente sección exploraremos cómo la arquitectura de conexiones recurrentes entre poblaciones excitatorias e inhibitorias da lugar a dinámicas corticales complejas.

2.3.4. Conexiones neuronales

Los modelos de neuronas individuales descritos anteriormente constituyen los bloques fundamentales del procesamiento neuronal. Sin embargo, las fun-

ciones cognitivas emergen de la interacción coordinada de miles o millones de neuronas conectadas en redes. La arquitectura de red, forma en que estas neuronas se conectan, determina en gran medida las capacidades computacionales del circuito. Según Dayan and Abbott (2005), existen tres clases principales de interconexiones en los circuitos neuronales.

Las **conexiones feedforward** traen información desde una región ubicada en una etapa anterior de procesamiento hacia una etapa posterior. Computacionalmente, las redes feedforward llamadas así por implementar solo este tipo de conexiones, implementan transformaciones jerárquicas donde cada capa extrae características progresivamente más abstractas de la entrada. Esta arquitectura es eficiente para tareas de clasificación y reconocimiento de patrones, y ha inspirado modelos exitosos como las redes convolucionales en aprendizaje profundo (Heaton, 2018). Sin embargo, las redes puramente feedforward tienen limitaciones importantes: no pueden mantener información en ausencia de entrada, ni generar dinámicas temporales complejas.




Figura 2.7: Modelo computacional de red neuronal feed-forward de una sola capa oculta.

Las **conexiones top-down** llevan señales de regreso desde etapas posteriores del procesamiento hacia etapas anteriores. El número de fibras feedforward y top-down entre regiones conectadas es típicamente comparable (Dayan and Abbott, 2005). Computacionalmente, estas conexiones permiten que información contextual y expectativas de niveles superiores modulen el procesamiento en niveles inferiores, implementando mecanismos como atención selectiva y codificación predictiva.




Figura 2.8: Arquitectura de red neuronal con conexiones feedforward e incluyendo conexiones top-down resaltadas en azul.

Las **conexiones recurrentes** interconectan neuronas dentro de una misma etapa de procesamiento. Una observación fundamental es que las sinapsis recurrentes típicamente superan en número a las conexiones feedforward o top-down (Dayan and Abbott, 2005). Esta preponderancia tiene profundas implicaciones computacionales: mientras que las redes feedforward transforman la informa-

ción de manera estática, las redes con conectividad recurrente pueden generar dinámicas temporales complejas. Entre las capacidades únicas de las redes recurrentes se encuentran: **actividad sostenida** en ausencia de entrada externa, **amplificación selectiva** de señales débiles, **fenómenos oscilatorios** en diversas bandas de frecuencia, y formación de **estados atractores** que pueden servir como memorias asociativas (Dayan and Abbott, 2005).

Dada la importancia de la conectividad recurrente para las funciones computacionales que nos interesan en este trabajo, en la siguiente sección exploraremos en detalle las propiedades de las redes recurrentes y las dinámicas que emergen de ellas.




Figura 2.9: Arquitectura de red recurrente. Las conexiones horizontales entre neuronas de la misma capa y las conexiones bidireccionales entre capas permiten que la actividad de cada neurona influya sobre sus vecinas, generando dinámicas temporales complejas.

2.3.5. Redes neuronales recurrentes y dinámicas corticales

Los circuitos corticales se caracterizan por conexiones recurrentes abundantes que pueden clasificarse según su efecto sobre la neurona postsináptica: las **conexiones excitatorias** aumentan el potencial de membrana, incrementando la probabilidad de disparo, mientras que las **conexiones inhibitorias** lo disminuyen, reduciendo dicha probabilidad. En el contexto del modelado computacional, esta distinción suele formalizarse mediante el **principio de Dale**, que asume que cada neurona libera el mismo tipo de neurotransmisor en todas sus sinapsis, clasificándose como excitatoria o inhibitoria. Si bien la evidencia actual muestra que las neuronas biológicas pueden co-liberar múltiples neurotransmisores, esta simplificación resulta útil para construir modelos tratables computacionalmente (Dale, 1935).

La interacción entre poblaciones excitatorias e inhibitorias da lugar a dinámicas complejas que van más allá de la simple transmisión de información feed-forward (Dayan and Abbott, 2005). Como se mencionó anteriormente, si las conexiones recurrentes son suficientemente fuertes, el patrón de actividad poblacional puede volverse parcialmente independiente de la estructura de la entrada, permitiendo que la red mantenga estados de actividad que proveen memoria de entradas previas.

Un fenómeno particularmente importante que emerge de las redes recurrentes son las **oscilaciones neuronales**. Las interacciones entre poblaciones excitatorias e inhibitorias pueden generar actividad oscilatoria en diversas bandas

de frecuencia, incluyendo oscilaciones gamma (30-80 Hz) que han sido asociadas con el procesamiento sensorial y la atención (Echeveste et al., 2020). Estas oscilaciones no son simples fenómenos sino que pueden cumplir roles funcionales específicos en el procesamiento de información.

Un modelo particularmente influyente que captura estas propiedades es la **red supralineal estabilizada** (SSN, *Stabilized Supralinear Network*), que incorpora propiedades esenciales de los circuitos corticales. Este modelo incluye poblaciones separadas de neuronas excitatorias e inhibitorias, funciones de transferencia supralineales (expansivas) consistentes con observaciones experimentales en neuronas corticales, y conectividad recurrente que estabiliza la actividad del circuito (Echeveste et al., 2020).

El SSN reproduce fenómenos corticales importantes como la normalización divisiva (un cómputo canónico de circuitos corticales), las respuestas transitorias al inicio de estímulos, y las oscilaciones gamma cuya frecuencia aumenta con el contraste del estímulo. Crucialmente, este modelo constituye la base arquitectónica del trabajo de Echeveste et al. (2020), quienes demostraron cómo extenderlo para implementar inferencia probabilística basada en muestreo. Los detalles matemáticos completos de esta extensión, incluyendo la dinámica neuronal, la función de transferencia supralineal, el rol del ruido estocástico, y cómo estas propiedades emergen del objetivo de muestreo, se presentan en la Sección 3.2.

2.4. Integración multisensorial

La percepción de los estímulos que nos rodean rara vez depende de una única modalidad sensorial. Cuando conversamos con alguien, integramos información visual de los movimientos de sus labios con las señales auditivas de su voz. Esta integración de información proveniente de múltiples sentidos, conocida como **integración multisensorial**, es un proceso neuronal fundamental que mejora nuestra capacidad para percibir y actuar en el mundo (Stein, 2012).

2.4.1. La percepción como inferencia probabilística

La inferencia probabilística proporciona una solución al problema de formar percepciones al mezclar información parcial y ruidosa de múltiples fuentes, incluyendo diferentes señales sensoriales, modalidades y formas de memoria (Echeveste et al., 2020). Formalmente, esta fusión resulta en una **distribución posterior** que expresa la probabilidad de que características relevantes del entorno sean interpretadas de diferentes formas, dada la información disponible a través de los sentidos.

Dado que, por ejemplo, el sistema visual solo tiene acceso a los fotones absorbidos en la retina, la interpretación de los objetos requiere ir más allá de la información directamente disponible. El cerebro debe entonces *inferir* las propiedades del mundo externo a partir de esta información sensorial comúnmente incompleta y ruidosa. El teorema de Bayes nos proporciona el marco formal para esta inferencia:

$$P(\mathbf{y}|\mathbf{x}) = \frac{P(\mathbf{x}|\mathbf{y})P(\mathbf{y})}{P(\mathbf{x})} \quad (2.5)$$

donde $\mathbf{y}$ representa las variables del mundo que se desean inferir, $\mathbf{x}$ son las observaciones sensoriales, $P(\mathbf{x}|\mathbf{y})$ es la verosimilitud (la probabilidad de observar los datos sensoriales $\mathbf{x}$ dado un estado específico del mundo $\mathbf{y}$), $P(\mathbf{y})$ es el conocimiento previo sobre el mundo llamado probabilidad a priori, y $P(\mathbf{y}|\mathbf{x})$ es la distribución posterior que representa la creencia actualizada tras observar los datos sensoriales.

Evidencia en diversos campos sugiere que el cerebro representa distribuciones posteriores al menos de manera aproximada (Echeveste et al., 2020). Esta perspectiva tiene implicaciones profundas: la variabilidad en las respuestas sensoriales no sería simplemente “ruido” a eliminar, sino que podría reflejar la incertidumbre inherente a la inferencia sobre el estado del mundo.

2.4.2. Combinación óptima de señales

Cuando múltiples modalidades sensoriales proporcionan información sobre una misma propiedad del entorno, surge la pregunta de cómo combinarlas de manera óptima. Un modelo influyente propone que el proceso de combinación de señales se asemeja a un **integrador de máxima verosimilitud** (Alais and Burr, 2004).

En el contexto de la localización espacial audiovisual, si $\hat{S}_A$ y $\hat{S}_V$ representan las estimaciones unimodales auditiva y visual respectivamente, la estimación integrada óptima se obtiene como un promedio ponderado:

$$\hat{S}_{AV} = w_A \hat{S}_A + w_V \hat{S}_V \quad (2.6)$$

donde los pesos w_A y w_V son proporcionales a la **confiabilidad** (inversa de la varianza) de cada modalidad:

$$w_A = \frac{\sigma_V^2}{\sigma_A^2 + \sigma_V^2}, \quad w_V = \frac{\sigma_A^2}{\sigma_A^2 + \sigma_V^2} \quad (2.7)$$

Esta formulación captura una intuición fundamental: las señales más confiables (con menor varianza) reciben mayor peso en la estimación final. La visión, típicamente más precisa espacialmente que la audición, domina la percepción de localización cuando ambas modalidades están disponibles (Paredes et al., 2025).

2.4.3. El problema de la inferencia causal

Dicho modelo asume implícitamente que todas las señales provienen de una misma fuente. Sin embargo, en el mundo real, señales de diferentes modalidades pueden originarse de eventos independientes. Cuando existe una diferencia significativa entre las estimaciones $\hat{S}_A$ y $\hat{S}_V$, el observador enfrenta un cuestionamiento natural: ¿esta diferencia se debe a ruido en el procesamiento neural, o indica que las señales provienen de fuentes separadas? (Paredes et al., 2025).

El modelo de **inferencia causal bayesiana** (Körding et al., 2007) extiende el marco probabilístico para abordar este problema. El observador debe inferir no solo la localización de los estímulos, sino también la *estructura causal* subyacente: si las señales auditiva y visual provienen de una causa común ($C = 1$) o de causas separadas ($C = 2$).

La probabilidad posterior de una causa común dado las observaciones se calcula mediante:

$$P(C = 1|\mathbf{x}_A, \mathbf{x}_V) = \frac{P(\mathbf{x}_A, \mathbf{x}_V|C = 1)P(C = 1)}{P(\mathbf{x}_A, \mathbf{x}_V|C = 1)P(C = 1) + P(\mathbf{x}_A, \mathbf{x}_V|C = 2)P(C = 2)}$$

Finalmente la verosimilitud de una causa común es mayor cuando las señales unisensoriales son similares, aumentando así la probabilidad de inferir que comparten un origen (Paredes et al., 2025).

Para evaluar experimentalmente estas predicciones, los investigadores han desarrollado diversos paradigmas que permiten manipular sistemáticamente la congruencia entre modalidades sensoriales.

2.4.4. El efecto ventrilocuo como paradigma experimental

El **efecto ventrilocuo**, donde un estímulo auditivo es percibido como proveniente de la ubicación de un estímulo visual simultáneo, constituye un paradigma experimental estándar para estudiar la integración multisensorial y la inferencia causal (Alais and Burr, 2004). Este fenómeno ilustra cómo la visión, típicamente más precisa espacialmente, puede “capturar” la localización percibida de un sonido. Cuando la disparidad espacial excede cierto umbral, los observadores perciben dos eventos separados, consistente con el modelo de inferencia causal (Körding et al., 2007).

Este fenómeno constituyó parte de la motivación inicial del presente trabajo. Sin embargo, como se detalló en el Capítulo 1, el alcance final se reorientó hacia objetivos más fundamentales, estableciendo las bases computacionales necesarias para futuras extensiones hacia la integración multisensorial. Modelar computacionalmente estos fenómenos requiere circuitos neuronales capaces de implementar inferencia probabilística mientras exhiben dinámicas biológicamente plausibles. En las siguientes secciones exploraremos los principios que guían el desarrollo de tales modelos.




Figura 2.10: Ventriloquia espacial: la ubicación aparente de un sonido objetivo auditivo puede ser desplazada por la percepción de un estímulo visual (un destello).

2.5. Modelos biológicamente inspirados

La búsqueda de modelos computacionales que capturen los mecanismos neuronales de la cognición ha dado lugar a diversas aproximaciones, que varían en

su nivel de abstracción y realismo biológico. En esta sección, vamos a revisar los principios fundamentales que guían el desarrollo de modelos biológicamente inspirados, con especial énfasis en aquellos que buscan implementar funciones computacionales mediante dinámicas neurológicamente plausibles.

2.5.1. El paradigma de la ingeniería neuronal

El libro seminal *Neural Engineering: Computation, Representation, and Dynamics in Neurobiological Systems* de Eliasmith and Anderson (2003), establece un marco sistemático para construir modelos que conectan la representación neuronal con la computación. Este paradigma, conocido como **ingeniería neuronal**, propone tres principios fundamentales:

Principio 1: Representación. Establece que las poblaciones de neuronas representan información mediante patrones de actividad distribuidos. Formalmente, si $\mathbf{x}$ es una variable que el sistema nervioso necesita representar, cada neurona i en una población contribuye con una actividad:

$$a_i = G_i[\alpha_i \mathbf{e}_i \cdot \mathbf{x} + J_i^{bias}] \quad (2.8)$$

donde $G_i[\cdot]$ es la función de transferencia de la neurona (típicamente un modelo LIF), α_i es un factor de ganancia, $\mathbf{e}_i$ es el “vector de codificación” preferido de la neurona, y J_i^{bias} es una corriente de fondo (Eliasmith and Anderson, 2003). Este principio puede extenderse para representar no solo valores puntuales sino distribuciones de probabilidad completas.

Principio 2: Transformación. Especifica cómo las conexiones sinápticas entre poblaciones neuronales pueden implementar transformaciones matemáticas de las variables representadas. Dado que queremos computar una función, los pesos sinápticos óptimos pueden derivarse mediante métodos de optimización (Eliasmith and Anderson, 2003).

Principio 3: Dinámica. Describe cómo las propiedades temporales de las redes recurrentes permiten implementar sistemas dinámicos. La dinámica de una representación neuronal puede describirse mediante:

$$\frac{d\mathbf{x}}{dt} = f(\mathbf{x}, \mathbf{u}) \quad (2.9)$$

donde $\mathbf{u}$ representa entradas externas y f es la función que controla la evolución del sistema (Eliasmith and Anderson, 2003). Este principio es particularmente relevante cuando las dinámicas temporales, como transitorios y oscilaciones, no son meros epifenómenos sino que cumplen roles funcionales específicos en el procesamiento de información.

Estos principios proporcionan una metodología rigurosa para pasar de especificaciones funcionales a implementaciones neuronales. Sin embargo, enfoques más recientes han demostrado que es posible invertir esta lógica: partir de restricciones biológicas conocidas sobre la arquitectura de circuitos corticales, como la separación de poblaciones excitatorias e inhibitorias, funciones de transferencia supralineales, y ruido de proceso, y optimizar los parámetros para lograr una función computacional deseada, permitiendo que las dinámicas específicas emerjan como consecuencia de la optimización (Echeveste et al., 2020).

Independientemente del enfoque adoptado, una decisión fundamental es el nivel de detalle con que se modela la actividad neuronal. Los principios presentados pueden implementarse tanto con modelos de tasa como con modelos que

capturan explícitamente los potenciales de acción individuales, cada uno con sus propias ventajas y limitaciones.

2.5.2. Ruido y variabilidad neuronal

Una característica ubicua de la actividad neuronal es su **variabilidad**. Incluso bajo estimulación constante, las neuronas muestran fluctuaciones considerables en sus tiempos de disparo de trial a trial. Esta variabilidad, lejos de ser simplemente “ruido” que debe ignorarse, puede tener importantes funciones computacionales (Gerstner and Kistler, 2002).

Las fuentes de variabilidad neuronal incluyen:

- **Ruido de canal:** fluctuaciones estocásticas en la apertura y cierre de canales iónicos
- **Ruido sináptico:** variabilidad en la liberación de vesículas y en la respuesta postsináptica
- **Ruido de red:** actividad de fondo de otras neuronas en el circuito

En modelos computacionales, el ruido se incorpora típicamente como un término estocástico aditivo en las ecuaciones dinámicas. Un aspecto crítico es si este ruido es dependiente o independiente del estímulo. Como veremos en la Sección 3.2, el modelo de Echeveste et al. incorpora específicamente **ruido de proceso independiente del estímulo**, una restricción biológica que resulta fundamental para las propiedades emergentes del circuito.

Crucialmente, la variabilidad neuronal puede tener un rol funcional en la inferencia probabilística. La hipótesis del **muestreo neuronal** propone que el cerebro representa distribuciones de probabilidad mediante muestras estocásticas de la actividad neuronal (Echeveste et al., 2020). En este marco, la variabilidad trial-a-trial no es ruido a eliminar sino una característica funcional que permite explorar el espacio de posibles interpretaciones de los estímulos sensoriales.

2.5.3. Redes excitatorias-inhedoras

Partiendo de las bases del ya mencionado principio de Dale, al modelar los circuitos corticales con poblaciones separadas de neuronas excitatorias (E) e inhibitorias (I) también nos permite estudiar dinámicas que emergen de su interacción. En el régimen de **balance excitación-inhibición**, las corrientes excitatorias e inhibitorias a cada neurona se cancelan aproximadamente en promedio, manteniendo el potencial de membrana medio por debajo del umbral de disparo. En este régimen, los potenciales de acción ocurren solo cuando fluctuaciones en la entrada son suficientemente fuertes para alcanzar el umbral, generando patrones de disparo irregulares con alta variabilidad (Dayan and Abbott, 2005).

El **estado balanceado** tiene propiedades computacionalmente interesantes: genera actividad irregular similar a la observada en corteza, permite respuestas rápidas a cambios en la entrada, y puede implementar dinámicas de muestreo para inferencia probabilística (Echeveste et al., 2020). Estas propiedades hacen que las redes E-I balanceadas sean un punto fuerte para modelos de procesamiento cortical.

Los principios y restricciones biológicas presentados en esta sección definen el espacio de arquitecturas biológicamente plausibles. Sin embargo, especificar la arquitectura no determina los valores de los parámetros (pesos sinápticos, constantes de tiempo) que permiten a la red realizar una función computacional específica. Para encontrar estos parámetros, los enfoques modernos recurren a técnicas desarrolladas en el campo del aprendizaje automático, que revisaremos en la siguiente sección.

2.6. Machine learning aplicado a la neurociencia

El aprendizaje automático (*machine learning*) es el campo de estudio en el cual un programa de computadora aprende de una experiencia E respecto a una clase de tareas T y una medida de rendimiento P , si su rendimiento en las tareas de T , medida por P , mejora con la experiencia E (Mitchell, 1997). Esta disciplina y la neurociencia han mantenido una relación simbiótica desde sus orígenes: por un lado, el cerebro ha inspirado muchos de los algoritmos de aprendizaje más exitosos, y por otro, las técnicas de machine learning proporcionan herramientas poderosas para analizar datos neuronales y desarrollar modelos computacionales del cerebro (Heaton, 2018). En esta sección, revisamos los conceptos fundamentales de machine learning relevantes para el modelado neurocientífico.

2.6.1. Paradigmas de aprendizaje

El aprendizaje automático puede clasificarse en tres paradigmas principales según la naturaleza de la señal de entrenamiento disponible (Bishop and Nasrabadi, 2006; Murphy, 2012).

El **aprendizaje supervisado** opera cuando se dispone de pares entrada-salida etiquetados $\{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^N$. El objetivo es aprender una función f que mapee entradas a salidas correctamente, típicamente minimizando una función de pérdida:

$$\mathcal{L} = \sum_{i=1}^N L(f(\mathbf{x}_i; \boldsymbol{\theta}), \mathbf{y}_i) \quad (2.10)$$

donde $\boldsymbol{\theta}$ son los parámetros del modelo y L mide la discrepancia entre predicciones y etiquetas. En el contexto neurocientífico, el aprendizaje supervisado se utiliza para entrenar redes neuronales que reproduzcan aspectos específicos de la actividad cortical o del comportamiento.

El **aprendizaje no supervisado** busca descubrir estructura en datos sin etiquetas. Esto incluye tareas como el agrupamiento (*clustering*), la reducción de dimensionalidad, y la estimación de densidad. El Análisis de componentes principales (PCA) es un ejemplo clásico, utilizado frecuentemente para identificar patrones de covariación en poblaciones neuronales (Bishop and Nasrabadi, 2006).

El **aprendizaje por refuerzo** considera un agente que interactúa con un ambiente y recibe señales de recompensa, aprendiendo una política que maximice la recompensa acumulada a largo plazo (Bishop and Nasrabadi, 2006).

En el contexto del presente trabajo, el paradigma relevante es el aprendizaje supervisado, aunque con una particularidad importante: en lugar de entrenar

una red para producir una salida puntual correcta, el objetivo es que la *distribución* de respuestas de la red coincida con una distribución objetivo. Esto requiere definir funciones de pérdida que comparen estadísticas de las respuestas (como media y covarianza) con los valores objetivo derivados de un modelo generativo. Este enfoque, desarrollado por Echeveste et al. (2020), será detallado en la Sección 3.2.

2.6.2. Redes neuronales artificiales

Las Redes neuronales artificiales (ANNs) son modelos computacionales inspirados en la estructura del cerebro, compuestos por unidades de procesamiento interconectadas organizadas en capas (Heaton, 2018). Aunque difieren significativamente de las redes biológicas en muchos detalles, capturan principios importantes de procesamiento distribuido y aprendizaje mediante ajuste de conexiones.

El Perceptrón multicapa (MLP) es la arquitectura más básica. Cada capa l computa:

$$\mathbf{h}^{(l)} = \sigma(\mathbf{W}^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}) \quad (2.11)$$

donde $\mathbf{h}^{(l)}$ son las activaciones de la capa l , $\mathbf{W}^{(l)}$ es la matriz de pesos, $\mathbf{b}^{(l)}$ es el vector de sesgos, y $\sigma(\cdot)$ es una función de activación no lineal (Heaton, 2018).

Un avance fundamental para el entrenamiento de estas redes fue el algoritmo de **retropropagación** (*backpropagation*), popularizado por Rumelhart et al. (1986). Este algoritmo permite ajustar los pesos de todas las capas simultáneamente, propagando los gradientes del error desde la salida hacia la entrada mediante la regla de la cadena:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{(l)}} = \frac{\partial \mathcal{L}}{\partial \mathbf{h}^{(l)}} \frac{\partial \mathbf{h}^{(l)}}{\partial \mathbf{W}^{(l)}} \quad (2.12)$$

La importancia de este algoritmo para el campo fue reconocida con el Premio Turing 2018, otorgado a Geoffrey Hinton, Yoshua Bengio y Yann LeCun por sus contribuciones al aprendizaje profundo, y más recientemente con el Premio Nobel de Física 2024 a Hinton y John Hopfield por los fundamentos del aprendizaje automático con redes neuronales artificiales (Nobel Prize Committee, 2024). En el contexto del presente trabajo, la retropropagación a través del tiempo (*backpropagation through time*) constituye la base para optimizar los parámetros de redes recurrentes como la de Echeveste et al. (2020), donde se combina con optimizadores modernos como ADAM y L-BFGS-B.

2.6.3. Arquitecturas profundas y convolucionales

El **aprendizaje profundo** (*deep learning*) se refiere al entrenamiento de redes neuronales con múltiples capas ocultas. La profundidad permite aprender representaciones jerárquicas donde las capas inferiores extraen características simples y las superiores combinan estas en representaciones más abstractas (Heaton, 2018).

Las Redes neuronales convolucionales (CNNs) son particularmente relevantes para el procesamiento visual. Inspiradas en la organización jerárquica del

sistema visual, las CNNs aplican filtros convolucionales que son equivariantes a traslaciones:

$$(h * w)[i, j] = \sum_m \sum_n h[m, n] \cdot w[i - m, j - n] \quad (2.13)$$

Notablemente, CNNs entrenadas para clasificación de imágenes desarrollan representaciones en sus capas ocultas que correlacionan fuertemente con la actividad neuronal a lo largo de la jerarquía visual, desde V1 hasta corteza inferotemporal (Yamins et al., 2014).




Figura 2.11: Representación de una red neuronal profunda. Se ilustra la organización en múltiples capas ocultas que permite la extracción jerárquica de características, desde rasgos simples a representaciones abstractas.

2.6.4. Redes recurrentes

Las Redes neuronales recurrentes (RNNs) extienden las redes feedforward al incluir conexiones que forman ciclos, permitiendo que la actividad pasada influya en el procesamiento presente (Heaton, 2018). La dinámica de una RNN simple está dada por:

Como se discutió en la Sección 2.3.5, los circuitos corticales se caracterizan por conexiones recurrentes abundantes que permiten generar dinámicas temporales complejas. Las Redes neuronales recurrentes (RNNs) constituyen el análogo computacional de estos circuitos biológicos, extendiendo las redes feedforward al incluir conexiones que forman ciclos, permitiendo que la actividad pasada influya en el procesamiento presente (Heaton, 2018). La dinámica de una RNN simple está dada por:

$$\mathbf{h}_t = \sigma(\mathbf{W}_{hh}\mathbf{h}_{t-1} + \mathbf{W}_{xh}\mathbf{x}_t + \mathbf{b}) \quad (2.14)$$

donde $\mathbf{h}_t$ es el estado oculto en el tiempo t y $\mathbf{x}_t$ es la entrada.

Las RNNs son el análogo computacional de los circuitos corticales recurrentes. Arquitecturas como Long Short-Term Memory (LSTM) y Gated Recurrent Units (GRU) incorporan mecanismos de compuerta que permiten mantener información relevante a lo largo de secuencias largas (Heaton, 2018).

En el contexto de este trabajo, las RNNs con restricciones biológicas dadas por poblaciones E-I separadas, funciones de activación plausibles y ruido de pro-

ceso, proporcionan un marco para estudiar cómo las dinámicas corticales pueden implementar funciones computacionales como la inferencia probabilística.




Figura 2.12: Red neuronal recurrente totalmente conectada con 4 neuronas.

2.6.5. Estadística bayesiana y aprendizaje

El marco **bayesiano** proporciona una interpretación probabilística del aprendizaje donde los parámetros del modelo son tratados como variables aleatorias con distribuciones de probabilidad (Bishop and Nasrabadi, 2006). Dada una verosimilitud $P(\mathcal{D}|\theta)$ para los datos y un prior $P(\theta)$ sobre los parámetros, el teorema de Bayes proporciona la distribución posterior:

$$P(\theta|\mathcal{D}) = \frac{P(\mathcal{D}|\theta)P(\theta)}{P(\mathcal{D})} \quad (2.15)$$

Esta perspectiva es particularmente relevante para la neurociencia computacional. Diversos autores han propuesto que el cerebro opera según principios bayesianos, manteniendo y actualizando distribuciones de probabilidad sobre estados del mundo (Dayan and Abbott, 2005; Eliasmith and Anderson, 2003).

La **inferencia aproximada** es necesaria cuando la distribución posterior no puede calcularse analíticamente. Métodos como Markov Chain Monte Carlo (MCMC) y la inferencia variacional proporcionan aproximaciones tractables (Heaton, 2018). Como veremos, estos métodos tienen análogos propuestos en dinámicas neuronales.

2.6.6. Redes neuronales para inferencia probabilística

Un aspecto fundamental para este trabajo es comprender cómo redes neuronales pueden implementar inferencia probabilística. La hipótesis del **muestreo neuronal** propone que las fluctuaciones en la actividad neuronal representan muestras de distribuciones de probabilidad, de modo que la actividad promediada en el tiempo corresponde a esperanzas bajo distribuciones posteriores (Echeveste et al., 2020).

Formalmente, si un circuito neuronal implementa muestreo de una distribución $P(\mathbf{x}|\mathbf{s})$ donde $\mathbf{s}$ es un estímulo, entonces la actividad instantánea $\mathbf{x}(t)$ representa una muestra, y:

$$\langle \mathbf{x}(t) \rangle_t \approx \mathbb{E}_{P(\mathbf{x}|\mathbf{s})}[\mathbf{x}] \quad (2.16)$$

Esta perspectiva tiene implicaciones profundas para interpretar la variabilidad neuronal, sugiriendo que no es simplemente ruido sino que codifica incertidumbre sobre el estado del mundo.

Recientemente, se ha demostrado que redes neuronales recurrentes con restricciones biológicas pueden ser entrenadas para implementar muestreo de distribuciones posteriores complejas, mostrando simultáneamente propiedades dinámicas similares a las observadas en corteza (Echeveste et al., 2020). Este resultado establece un puente crucial entre la función computacional (inferencia probabilística) y los mecanismos neuronales (dinámicas corticales), y constituye un antecedente directo del presente trabajo.

2.7. Hacia la integración computacional

Los fundamentos presentados en este capítulo, desde los mecanismos biológicos de la señalización neuronal hasta las técnicas de aprendizaje automático para optimizar redes recurrentes, proporcionan el marco conceptual y metodológico para abordar el problema central de este trabajo. En esta sección final presentamos brevemente los antecedentes específicos que, desarrollados en detalle en sus respectivos capítulos, constituyen la motivación y el punto de partida de nuestra contribución.

2.7.1. Antecedentes directos

Entre los desarrollos que buscan implementar los principios de inferencia probabilística en arquitecturas biológicamente plausibles, dos modelos resultan particularmente relevantes para este trabajo.

El modelo de Cuppini et al. (2017) aborda la integración audiovisual y el efecto ventrílocuo mediante una arquitectura de tres capas que reproduce exitosamente fenómenos experimentales como el juicio de unidad. Sin embargo, al utilizar modelos de tasa deterministas, no captura las dinámicas corticales realistas observadas experimentalmente.

En contraste, el modelo de Echeveste et al. (2020) demuestra que redes neuronales con restricciones biológicas pueden implementar inferencia probabilística mediante muestreo, exhibiendo propiedades emergentes como oscilaciones gamma y transitorios inhibitorios. Sin embargo, está limitado al procesamiento unimodal.

Los detalles de ambos modelos están desarrollados en el Capítulo 3.

Más allá de sus diferencias conceptuales, ambos modelos comparten una limitación práctica ya que han sido implementados de manera independiente, en distintos lenguajes y con estructuras incompatibles, dificultando su comparación o integración. Para abordar este tipo de fragmentación en el campo, Paredes et al. (2025) desarrollaron Scikit-NeuroMSI, un framework de código abierto en Python que proporciona infraestructura común para la implementación, comparación y validación de modelos de integración multisensorial. Presentando todas sus características técnicas en el Capítulo 4.

Capítulo 3

Modelos Estudiados

Este capítulo presenta en detalle los dos modelos computacionales que constituyen los pilares conceptuales del presente trabajo. El modelo de Cuppini et al. aborda la integración audiovisual y la inferencia causal mediante una arquitectura neuronal biológicamente inspirada, representando el objetivo a largo plazo hacia el cual apuntan las extensiones futuras de este trabajo. Y en la otra mano el modelo de Echeveste et al. demuestra cómo circuitos corticales con restricciones biológicas pueden implementar inferencia probabilística mediante muestreo, exhibiendo dinámicas realistas como oscilaciones gamma y transitorios inhibitorios. Este segundo modelo constituye el objeto central de implementación del presente trabajo.

3.1. El modelo de Cuppini para integración audiovisual e inferencia causal

El problema de la inferencia causal multisensorial descrito en la Sección 2.4.3 ha motivado el desarrollo de diversos modelos computacionales. Entre ellos, el modelo desarrollado por Cuppini et al. (2017) representa un avance significativo al abordar específicamente la integración audiovisual y el efecto ventrílocuo mediante una arquitectura neuronal biológicamente inspirada.

3.1.1. Arquitectura del modelo

El modelo se estructura en tres capas jerárquicas interconectadas, cada una compuesta por neuronas organizadas topográficamente según la posición espacial de su campo receptivo.

La **capa auditiva** procesa información sobre la localización espacial de estímulos sonoros. Cada unidad en esta capa responde preferentemente a sonidos provenientes de una posición específica del espacio, aunque con campos receptivos relativamente amplios que reflejan la menor precisión espacial de la audición comparada con la visión.

La **capa visual** procesa información sobre la localización de estímulos visuales. Las unidades en esta capa tienen campos receptivos más estrechos que sus contrapartes auditivas, capturando la mayor resolución espacial del sistema visual.

3.1. EL MODELO DE CUPPINI PARA INTEGRACIÓN AUDIOVISUAL E INFERENCIA CAUSAL

La **capa multisensorial** (o de inferencia causal) recibe proyecciones feed-forward de ambas capas unisensoriales y computa la integración de señales y la decisión sobre la estructura causal subyacente.

Las capas se interconectan mediante tres tipos de sinapsis: conexiones *laterales intra-área* organizadas en un perfil de “sombrero mexicano” que implementa competencia local, conexiones *cross-modales* excitatorias recíprocas entre las capas auditiva y visual, y proyecciones *feedforward* hacia la capa multisensorial.




Figura 3.1: Estructura de la red de Cuppini et al.. Las regiones visual y auditiva procesan los estímulos sensoriales externos. Estas regiones están interconectadas mediante sinapsis excitatorias directas y envían proyecciones feedforward de largo alcance dirigidas al área de inferencia causal.

3.1.2. Mecanismos de integración e inferencia

El modelo implementa dos mecanismos computacionales distintos pero interrelacionados:

El primer mecanismo, mediado por las **sinapsis cross-modales** entre las capas unisensoriales, produce la integración clásica multisensorial. Cuando estímulos visual y auditivo se presentan en posiciones espaciales cercanas, las conexiones cross-modales excitatorias refuerzan mutuamente las actividades en ambas regiones, atrayendo las representaciones espaciales hacia una posición común. Este mecanismo da lugar al efecto ventrilocuo: el sesgo de la localización auditiva percibida hacia la posición del estímulo visual.

El segundo mecanismo, mediado por la **capa multisensorial**, computa la inferencia causal propiamente dicha. La actividad en esta capa integra información de ambas modalidades y determina si los estímulos se perciben como provenientes de una causa común o de fuentes independientes. La presencia de uno o dos picos de actividad por encima de un umbral de detección indica, respectivamente, la inferencia de una causa única o de causas separadas.

3.1.3. Capacidades y limitaciones

El modelo reproduce exitosamente varios fenómenos experimentales: **el efecto ventrilocuo** emerge naturalmente de la dinámica, con magnitud dependiente de la confiabilidad relativa de las señales; **el juicio de unidad** exhibe el patrón correcto donde la probabilidad de percibir una causa común disminuye con la disparidad espacial; y el **sesgo auditivo** es modulado por la decisión causal, siendo mayor cuando se infiere una causa común (Cuppini et al., 2017).

Sin embargo, el modelo presenta limitaciones significativas desde la perspectiva de la neurociencia computacional moderna. Al utilizar modelos de tasa deterministas, no captura la variabilidad trial-a-trial característica de las respuestas corticales, las oscilaciones gamma observadas durante la integración multisensorial, los transitorios inhibitorios al inicio de estímulos, ni la naturaleza estocástica de la inferencia perceptual.

Estas limitaciones motivaron inicialmente el presente trabajo, con el objetivo a largo plazo de desarrollar modelos de integración multisensorial que exhiban dinámicas corticales biológicamente plausibles. El modelo de Echeveste et al., descrito en la siguiente sección, demuestra que tales dinámicas pueden emerger de redes neuronales optimizadas para inferencia probabilística.

3.2. El modelo de Echeveste para inferencia probabilística con dinámicas corticales

En contraste con el modelo anterior, el trabajo de Echeveste et al. (2020) aborda el problema desde la dirección opuesta: partiendo de restricciones biológicas sobre la dinámica de circuitos corticales, demuestran que redes neuronales recurrentes pueden ser optimizadas para implementar inferencia probabilística basada en muestreo. Este modelo constituye un antecedente fundamental para el presente trabajo, por lo que a continuación se presenta una descripción detallada de sus componentes.

3.2.1. Marco teórico: muestreo como inferencia

La percepción puede entenderse como inferencia bayesiana sobre las causas latentes de las observaciones sensoriales. Dado un estímulo sensorial $\mathbf{x}$, el cerebro busca inferir las variables latentes $\mathbf{y}$ que lo generaron, caracterizadas por la distribución posterior enunciada en la Ecuación 2.5.

La hipótesis del **muestreo neuronal** propone que, en lugar de representar esta distribución analíticamente, el cerebro la representa mediante muestras temporales. La actividad neuronal fluctuante proporciona muestras de la posterior, de modo que la distribución empírica de actividades a lo largo del tiempo aproxima $P(\mathbf{y}|\mathbf{x})$. Formalmente, si $\mathbf{y}(t)$ representa la actividad instantánea:

$$\langle \mathbf{y}(t) \rangle_t \approx \mathbb{E}_{P(\mathbf{y}|\mathbf{x})}[\mathbf{y}] \quad (3.1)$$

Esta perspectiva transforma la variabilidad neuronal de un fenómeno a ignorar en una característica funcional que codifica incertidumbre perceptual.

3.2. EL MODELO DE ECHEVESTE PARA INFERENCIA PROBABILÍSTICA CON DINÁMICAS CORTICALES

3.2.2. Arquitectura de red

La red modela una **hipercolumna** de la corteza visual primaria (V1): una unidad funcional que contiene neuronas sensibles a todas las orientaciones posibles de bordes visuales en una misma ubicación del campo visual. Las neuronas se organizan conceptualmente en un **anillo**, donde la posición de cada una corresponde a su orientación preferida, distribuida uniformemente entre -90° y 90° (ver Figura 3.2).

La red contiene dos poblaciones: **excitatorias** (E) e **inhibitorias** (I), organizadas en pares E-I que comparten la misma orientación preferida. Cada neurona excitatoria representa una variable latente del modelo generativo GSM es decir, la intensidad de una característica visual orientada, mientras que las neuronas inhibitorias actúan como unidades auxiliares que estabilizan la dinámica del circuito.

La conectividad entre neuronas depende de la **diferencia de orientación** entre ellas: neuronas con orientaciones similares tienen conexiones más fuertes que neuronas con orientaciones diferentes. Esta estructura “circulante” refleja la organización columnar observada en V1 y reduce drásticamente el número de parámetros libres de N^2 a solo 8 parámetros que definen el perfil de conectividad.




Figura 3.2: El modelo generativo estadístico y el circuito neuronal correspondiente que implementa la inferencia probabilística basada en muestreo.

3.2.3. El modelo generativo (GSM)

Para especificar el problema computacional objetivo, los autores adoptan el **modelo de mezcla de escala gaussiana** (Gaussian scale mixture (GSM)), un modelo generativo bien establecido que captura las estadísticas de parches de imágenes naturales (Echeveste et al., 2020). En este modelo, un parche de imagen $\mathbf{x} \in \mathbb{R}^{N_x}$ se genera como:

$$\mathbf{x}|\mathbf{y}, z \sim \mathcal{N}(z\mathbf{A}\mathbf{y}, \sigma_x^2\mathbf{I}) \quad (3.2)$$

3.2. EL MODELO DE ECHEVESTE PARA INFERENCIA PROBABILÍSTICA CON DINÁMICAS CORTICALES

donde $\mathbf{y} \in \mathbb{R}^{N_y}$ son las variables latentes que representan intensidades de características visuales, $\mathbf{A} \in \mathbb{R}^{N_x \times N_y}$ es la matriz de *campos proyectivos* (cuyas columnas son filtros tipo Gabor orientados, como se describió en la Sección 2.2.3), $z \in \mathbb{R}$ es una variable de contraste global, y σ_x^2 es la varianza del ruido sensorial.

Las variables latentes siguen un prior gaussiano multivariado:

$$\mathbf{y} \sim \mathcal{N}(\mathbf{0}, \mathbf{C}) \quad (3.3)$$

donde $\mathbf{C}$ es la matriz de covarianza del prior, parametrizada como matriz circulante cuyos elementos varían suavemente en función de la diferencia angular entre las orientaciones preferidas de los campos proyectivos correspondientes.

Para modelar inferencia en una hipercolumna de V1, los campos proyectivos (columnas de $\mathbf{A}$) se eligen como filtros de Gabor orientados que difieren únicamente en su orientación, distribuidos uniformemente entre -90° y 90° , formando así una topología de anillo.

$$\mathbf{x} = z \cdot \mathbf{A}\mathbf{y} + \epsilon \quad (3.4)$$

donde $\mathbf{y}$ son variables latentes (intensidades de características visuales como filtros de Gabor), $\mathbf{A}$ es la matriz de campos proyectivos, z es una variable de contraste global, y ϵ es ruido sensorial.

Distribución posterior del observador ideal

Bajo el GSM, la distribución posterior sobre las variables latentes dado un parche de imagen y un contraste conocido tiene forma gaussiana:

$$P_{\text{GSM}}(\mathbf{y}|\mathbf{x}, z) = \mathcal{N}(\mathbf{y}; \boldsymbol{\mu}_{\text{GSM}}, \boldsymbol{\Sigma}_{\text{GSM}}) \quad (3.5)$$

con media y covarianza posteriores dadas por:

$$\boldsymbol{\mu}_{\text{GSM}} = \frac{z}{\sigma_x^2} \boldsymbol{\Sigma}_{\text{GSM}} \mathbf{A}^\top \mathbf{x} \quad (3.6)$$

$$\boldsymbol{\Sigma}_{\text{GSM}} = \left(\mathbf{C}^{-1} + \frac{z^2}{\sigma_x^2} \mathbf{A}^\top \mathbf{A} \right)^{-1} \quad (3.7)$$

Nótese que la covarianza posterior decrece con z^2 : a mayor contraste, menor incertidumbre en la estimación. Por su parte, la media posterior depende del contraste de manera que para contrastes altos converge hacia el valor verdadero de las variables latentes, mientras que para contrastes bajos se acerca a la media del prior (cero). Estas propiedades, mayor precisión y mejores estimaciones con mayor contraste, son características que la red neuronal deberá reproducir.

En el modelo, el contraste z se aproxima con su valor verdadero z^* , dado que es un único escalar cuya inferencia integra información de todos los píxeles:

$$P_{\text{GSM}}(\mathbf{y}|\mathbf{x}) \approx P_{\text{GSM}}(\mathbf{y}|\mathbf{x}, z^*) \quad (3.8)$$

3.2. EL MODELO DE ECHEVESTE PARA INFERENCIA PROBABILÍSTICA CON DINÁMICAS CORTICALES

Transformación de variables latentes a potenciales de membrana

Siguiendo trabajos previos, los potenciales de membrana u_i se toman como una transformación débilmente no lineal de las activaciones de características visuales y_i :

$$u_i(y_i) = [\alpha_{nl}y_i + \beta_{nl}]_+^{\gamma_{nl}} \quad (3.9)$$

donde $[\cdot]_+$ denota la función de rectificación (threshold-linear), y α_{nl} , β_{nl} , γ_{nl} son respectivamente la escala, línea base y exponente de la transformación. Esta transformación permite que los potenciales de membrana representen las intensidades de características mientras respetan restricciones biológicas como la no-negatividad.

3.2.4. Dinámica neuronal

El modelo implementa una **red supralineal estabilizada** Stabilized Supralinear Network (SSN), una arquitectura que captura propiedades esenciales de los circuitos corticales. La red consiste en N_E neuronas excitatorias y N_I neuronas inhibitorias. La dinámica de cada neurona i está controlada por:

$$\tau_i \frac{du_i}{dt} = -u_i(t) + h_i(t) + \sum_j W_{ij}r_j(t) + \eta_i(t) \quad (3.10)$$

donde u_i es el potencial de membrana, h_i es la entrada feedforward dependiente del estímulo, W_{ij} son los pesos sinápticos recurrentes, r_j es la tasa de disparo de la neurona j , y $\eta_i(t)$ es ruido de proceso correlacionado temporalmente.

Función de transferencia supralineal

Las tasas de disparo se derivan de los potenciales de membrana mediante una función de transferencia supralineal:

$$r_i(t) = k [u_i(t)]_+^n \quad (3.11)$$

donde $[\cdot]_+$ denota rectificación ($[x]_+ = \max(0, x)$), k es un factor de escala, y $n > 1$ es el exponente supralineal (ambos parámetros fijos). Esta no linealidad es consistente con observaciones experimentales en neuronas corticales y resulta fundamental para las propiedades de estabilización del circuito. El término “supralineal” indica que la función es convexa para potenciales positivos, lo que produce respuestas que crecen más rápido que linealmente con la entrada.

Parametrización de la conectividad (topología de anillo)

Dado que la red debe exhibir la misma simetría circular que el GSM estructurado en anillo, la conectividad recurrente se parametriza de forma rotacionalmente simétrica. Las neuronas se organizan en pares E-I alrededor de un “anillo” según sus orientaciones preferidas, y la conectividad es una función gaussiana circular de la diferencia de orientación entre células.

Específicamente, cada cuadrante de la matriz de pesos ($E \rightarrow E$, $E \rightarrow I$, $I \rightarrow E$, $I \rightarrow I$) se define como:

3.2. EL MODELO DE ECHEVESTE PARA INFERENCIA PROBABILÍSTICA CON DINÁMICAS CORTICALES

$$W_{XY}(\theta_i, \theta_j) = a_{XY} \exp \left(\frac{\cos(2(\theta_i - \theta_j)) - 1}{d_{XY}^2} \right) \quad (3.12)$$

donde $X, Y \in \{E, I\}$, $\theta_i = \pi i / N_{E/I}$ es la orientación preferida de la i -ésima neurona E/I, a_{XY} controla la amplitud de las conexiones, y d_{XY} controla su ancho espacial.

Para respetar el **principio de Dale**, se imponen las siguientes restricciones sobre las amplitudes:

- $a_{XE} > 0$ para $X \in \{E, I\}$ (conexiones desde neuronas excitatorias son positivas)
- $a_{XI} < 0$ para $X \in \{E, I\}$ (conexiones desde neuronas inhibitorias son negativas)

Esta parametrización circulante reduce drásticamente el número de parámetros libres: en lugar de optimizar todos los elementos de la matriz de pesos, para esta sección solo se optimizan 8 parámetros (a_{XY} y d_{XY} para cada cuadrante).

Ruido de proceso

El ruido de proceso $\eta_i(t)$ modela la variabilidad intrínseca y extrínseca de la actividad neuronal (entradas de otras áreas cerebrales, fluctuaciones de canal, etc.). Crucialmente, este ruido es **independiente del estímulo**, lo que implica que la red debe usar sus dinámicas recurrentes para moldear la variabilidad de manera apropiada para cada entrada.

El ruido es gaussiano con media cero y correlaciones espaciales y temporales:

$$\langle \eta_i(t) \rangle = 0, \quad \langle \eta_i(t) \eta_j(t+s)^\top \rangle = \Sigma_{ij}^\eta \exp(-|s|/\tau_\eta) \quad (3.13)$$

donde τ_η es la escala temporal del ruido y Σ^η es la matriz de covarianza espacial instantánea.

La covarianza espacial del ruido también se parametriza de forma circulante:

$$\Sigma_{EE/II}^\eta(\theta_i, \theta_j) = \sigma_{E/I}^2 \exp \left(\frac{\cos(2(\theta_i - \theta_j)) - 1}{d_\sigma^2} \right) \quad (3.14)$$

$$\Sigma_{EI}^\eta(\theta_i, \theta_j) = \rho \sigma_E \sigma_I \exp \left(\frac{\cos(2(\theta_i - \theta_j)) - 1}{d_\sigma^2} \right) \quad (3.15)$$

donde $\sigma_E, \sigma_I > 0$ son las desviaciones estándar del ruido para poblaciones E e I, ρ es el coeficiente de correlación entre ruido E e I, y d_σ controla el ancho espacial de las correlaciones de ruido. Esto introduce 4 parámetros adicionales para el entrenamiento.

Entrada feedforward

La entrada dependiente del estímulo a cada neurona se obtiene aplicando un filtro lineal al estímulo seguido de una no linealidad estática:

$$h_i(t) = \left[\alpha_h \left(\beta_h + \sum_j W_{ij}^{ff} x_j(t) \right) \right]_+^{\gamma_h} \quad (3.16)$$

3.2. EL MODELO DE ECHEVESTE PARA INFERENCIA PROBABILÍSTICA CON DINÁMICAS CORTICALES

donde $\mathbf{x}(t)$ es el estímulo (parche de imagen), $\mathbf{W}^{ff}$ es la matriz de campos receptivos feedforward, y $\alpha_h, \beta_h, \gamma_h$ son respectivamente la escala, línea base y exponente de la no linealidad de entrada, así agregando estos últimos 3 parámetros.

Los campos receptivos feedforward se fijan idénticos a los campos proyectivos del GSM:

$$\mathbf{W}^{ff} = \frac{1}{15} [\mathbf{A} \ \mathbf{A}]^\top \quad (3.17)$$

donde $[\mathbf{A} \ \mathbf{A}]$ denota la concatenación de $\mathbf{A}$ consigo misma (para proporcionar la misma entrada a cada par E-I).

Correspondencia entre red y modelo generativo

Existe una correspondencia uno-a-uno entre las variables latentes del GSM y las neuronas excitatorias de la red: el potencial de membrana de cada célula E representa la intensidad de una característica visual diferente. Las neuronas inhibitorias se tratan como unidades auxiliares no explícitamente restringidas por el objetivo computacional, pero esenciales para la estabilidad y las dinámicas del circuito.

En resumen, la red tiene **15 parámetros libres**:

- 8 para la matriz de pesos (a_{XY}, d_{XY} para cada cuadrante)
- 4 para la covarianza del ruido ($\sigma_E, \sigma_I, \rho, d_\sigma$)
- 3 para la no linealidad de entrada ($\alpha_h, \beta_h, \gamma_h$)

3.2.5. Entrenamiento para muestreo

El aspecto técnicamente más novedoso del trabajo de Echeveste et al. es el procedimiento de optimización. A diferencia de enfoques tradicionales que entrenan redes para producir respuestas promedio correctas, aquí el objetivo es que la *distribución* de respuestas de la red coincida con la distribución posterior del modelo generativo.

Momentos objetivo

Para cada estímulo de entrenamiento $\mathbf{x}^{(\alpha)}$, se computan los momentos objetivo de la posterior bajo el GSM. Estos “momentos objetivo” se definen transformando los momentos de la posterior sobre $\mathbf{y}$ al espacio de potenciales de membrana $\mathbf{u}$ mediante la ecuación 3.9:

$$\boldsymbol{\mu}_{\text{tgt}}^{(\alpha)} = \int \mathbf{u}(\mathbf{y}) P_{\text{GSM}}(\mathbf{y}|\mathbf{x}^{(\alpha)}) d\mathbf{y} \quad (3.18)$$

$$\boldsymbol{\Sigma}_{\text{tgt}}^{(\alpha)} = \int \mathbf{u}(\mathbf{y}) \mathbf{u}^\top(\mathbf{y}) P_{\text{GSM}}(\mathbf{y}|\mathbf{x}^{(\alpha)}) d\mathbf{y} - \boldsymbol{\mu}_{\text{tgt}}^{(\alpha)} (\boldsymbol{\mu}_{\text{tgt}}^{(\alpha)})^\top \quad (3.19)$$

3.2. EL MODELO DE ECHEVESTE PARA INFERENCIA PROBABILÍSTICA CON DINÁMICAS CORTICALES

Conjunto de entrenamiento

El conjunto de entrenamiento consiste en solo cinco parches de imagen con el mismo contenido pero diferentes niveles de contraste:

$$\mathbf{x}^{(\alpha)} = z^{(\alpha)} \mathbf{A} \bar{\mathbf{y}} \quad (3.20)$$

con $\alpha = 1, \dots, 5$ y $z^{(\alpha)} \in \{0, 0,125, 0,25, 0,5, 1,0\}$. El contenido $\bar{\mathbf{y}}$ es una función gaussiana de 27 de ancho centrada en 0 (una única orientación dominante). Gracias a la parametrización rotacionalmente invariante, entrenar en un estímulo equivale a entrenar en todas sus posibles rotaciones.




Figura 3.3: Conjunto de entrenamiento del modelo de Echeveste. Los cinco estímulos comparten el mismo contenido $\bar{\mathbf{y}}$ (gaussiana de 27° centrada en 0°) pero difieren en su nivel de contraste $z^{(\alpha)} \in \{0, 0,125, 0,25, 0,5, 1,0\}$.

Función de costo

El entrenamiento de la red consiste en ajustar parámetros de modo que la distribución de actividad neuronal reproduzca las estadísticas deseadas. Formalmente, esto se logra minimizando una función de costo $\mathcal{F}$ que cuantifica la discrepancia entre el comportamiento actual de la red y el objetivo:

$$\mathcal{F} = \sum_{\alpha} \left(\epsilon_{\text{mean}} \phi_{\text{mean}}^{(\alpha)} + \epsilon_{\text{var}} \phi_{\text{var}}^{(\alpha)} + \epsilon_{\text{cov}} \phi_{\text{cov}}^{(\alpha)} + \epsilon_{\text{slow}} \phi_{\text{slow}}^{(\alpha)} \right) \quad (3.21)$$

donde los coeficientes ϵ controlan la importancia relativa de cada término.

Los primeros tres términos penalizan diferencias entre los momentos de la distribución de respuestas de la red (promediados sobre una ventana temporal) y los momentos objetivo correspondientes:

$$\phi_{\text{mean}}^{(\alpha)} = \int_{T_{\text{mín}}}^{T_{\text{máx}}} \left\| \boldsymbol{\mu}^{(\alpha)}(t) - \boldsymbol{\mu}_{\text{tgt}}^{(\alpha)} \right\|_F^2 dt \quad (3.22)$$

$$\phi_{\text{var}}^{(\alpha)} = \int_{T_{\text{mín}}}^{T_{\text{máx}}} \left\| \boldsymbol{\sigma}^{(\alpha)}(t) - \boldsymbol{\sigma}_{\text{tgt}}^{(\alpha)} \right\|_F^2 dt \quad (3.23)$$

$$\phi_{\text{cov}}^{(\alpha)} = \int_{T_{\text{mín}}}^{T_{\text{máx}}} \left\| \boldsymbol{\Sigma}^{(\alpha)}(t, 0) - \boldsymbol{\Sigma}_{\text{tgt}}^{(\alpha)} \right\|_F^2 dt \quad (3.24)$$

donde $\boldsymbol{\mu}^{(\alpha)}(t) = \langle \mathbf{u}(t) \rangle$ es la media across-trial de los potenciales de membrana, $\boldsymbol{\sigma}^{(\alpha)}(t) = \text{diag}(\boldsymbol{\Sigma}^{(\alpha)}(t, 0))$ es el vector de varianzas, $\boldsymbol{\Sigma}^{(\alpha)}(t, 0)$ es la matriz de covarianza instantánea, y $\|\cdot\|_F$ denota la norma de Frobenius.

El cuarto término es un costo de “lentitud” que penaliza la autocorrelación temporal de las respuestas, incentivando que muestras consecutivas sean estadísticamente independientes:

3.2. EL MODELO DE ECHEVESTE PARA INFERENCIA PROBABILÍSTICA CON DINÁMICAS CORTICALES

$$\phi_{\text{slow}}^{(\alpha)} = \int_0^{\tau_{\text{máx}}} \left\| \text{diag}(\mathbf{C}^{(\alpha)}(\tau)) \right\|_F^2 d\tau \quad (3.25)$$

donde $\mathbf{C}^{(\alpha)}(\tau) = \text{corr}(\mathbf{u}(t), \mathbf{u}(t + \tau))$ es la matriz de autocorrelación temporal.

Procedimiento de optimización

Fase 1 (estocástica): Se emplea un método de gradiente estocástico usando $N_{\text{trial}} = 50$ trials por estímulo para estimar los momentos de las respuestas. Se realizan 250 iteraciones del optimizador ADAM. Durante esta fase, el inicio de la ventana de promediado $T_{\text{mín}}$ se “recuece” (annealing) sistemáticamente desde $T_{\text{mín}} = 0$ ms hasta $T_{\text{máx}} - 50$ ms, incentivando dinámicas de muestreo rápidas desde el inicio del estímulo.

Fase 2 (determinística): Se continúa la optimización usando el optimizador L-BFGS-B con el método de Assumed density filtering (ADF) para calcular determinísticamente los momentos de la distribución de respuestas. Este método asume que la distribución conjunta espacio-temporal de potenciales de membrana es gaussiana, permitiendo obtener los momentos en forma cerrada.

La función de costo es no convexa, por lo que Echeveste et al. verificaron la robustez de los resultados realizando 10 optimizaciones adicionales desde condiciones iniciales aleatorias, encontrando que todas las soluciones con costos comparables exhibían cualitativamente las mismas propiedades dinámicas.

3.2.6. Propiedades emergentes

Notablemente, la red optimizada exhibe un conjunto de propiedades dinámicas que emergen como consecuencia del objetivo de muestreo, sin ser explícitamente impuestas durante el entrenamiento:

Variabilidad modulada por el estímulo: La varianza de las respuestas neuronales decrece con el contraste del estímulo, reproduciendo observaciones experimentales en corteza visual. Este comportamiento refleja directamente las propiedades de la posterior del GSM, donde mayor contraste implica menor incertidumbre.

Transitorios inhibitorios: Al inicio de un estímulo, la inhibición domina transitoriamente sobre la excitación, generando sobrepicos (*overshoots*) en las tasas de disparo poblacionales seguidos de adaptación hacia un estado estacionario. La magnitud de estos transitorios escala con el contraste del estímulo.

Oscilaciones gamma: La actividad de la red exhibe oscilaciones en el rango gamma (30-80 Hz), detectables tanto en autocorrelogramas de neuronas individuales como en el potencial de campo local (LFP) simulado. Crucialmente, la frecuencia pico de las oscilaciones gamma aumenta con el contraste del estímulo, replicando hallazgos experimentales robustos en V1 de primates.

3.2.7. Roles funcionales de las dinámicas

Echeveste et al. demostraron que estas propiedades dinámicas no son meros epifenómenos sino que cumplen roles funcionales específicos en la inferencia probabilística:

3.2. EL MODELO DE ECHEVESTE PARA INFERENCIA PROBABILÍSTICA CON DINÁMICAS CORTICALES

Rol de las oscilaciones: mejora del tiempo de mezcla

Las oscilaciones gamma implementan una forma de muestreo fuera del equilibrio que acelera la exploración del espacio de estados. En algoritmos de muestreo clásicos como Langevin, la dinámica es reversible temporalmente, lo que limita la velocidad con la que muestras consecutivas se vuelven estadísticamente independientes (“tiempo de mezcla”). Las trayectorias oscilatorias de la red optimizada permiten que muestras consecutivas cubran una región más amplia del espacio, reduciendo la correlación temporal y efectivamente aumentando el número de muestras independientes por unidad de tiempo.

Finalmente, la red optimizada alcanza convergencia a la distribución objetivo un orden de magnitud más rápido que un muestreador de Langevin equivalente, un método estándar de muestreo estocástico donde las muestras se generan mediante difusión gradual hacia la distribución objetivo, pero cuya dinámica reversible limita la velocidad de exploración del espacio de estados.

Rol de los transitorios: reducción del tiempo de burn-in

Los transitorios aceleran la convergencia de las muestras hacia la distribución estacionaria correcta al inicio de la estimulación (reducción del “burn-in”). En lugar de difundir lentamente desde un estado inicial arbitrario, las respuestas transitorias rápidamente “saltan” hacia la región de alta probabilidad del espacio posterior.

El análisis teórico muestra que, para un estimador que promedia muestras en una ventana temporal finita, la trayectoria óptima que minimiza el error de estimación debe exhibir sobrepicos (overshoots) cuya magnitud escala con el valor objetivo. Los transitorios observados en la red optimizada reproducen cualitativamente esta predicción teórica.

Notablemente, Echeveste et al. validaron esta predicción analizando datos experimentales publicados de V1 en mono despierto, encontrando una correlación positiva entre la magnitud del sobrepico transitorio y el cambio en la tasa de disparo estacionaria, consistente con las predicciones del modelo.

3.2.8. Limitaciones y extensiones

La principal limitación del modelo de Echeveste para los propósitos de este trabajo es su restricción a **procesamiento unimodal**. El modelo fue diseñado para representar inferencia sobre características visuales de un único parche de imagen, sin considerar la integración de información de múltiples modalidades sensoriales ni el problema de la inferencia causal.

Otras limitaciones incluyen: la arquitectura simplificada de hipercolumna (topología de anillo) que limita la generalización a estímulos más complejos, la ausencia de mecanismos de plasticidad sináptica o aprendizaje continuo y la aproximación del contraste con su valor verdadero que evita el problema de inferencia jerárquica completa.

Sin embargo, el marco teórico y las técnicas de optimización desarrolladas son, en principio, generalizables a arquitecturas más complejas. La metodología de entrenar redes con restricciones biológicas para que sus distribuciones de respuesta coincidan con posteriores objetivo podría extenderse a modelos generativos multimodales que incluyan estructura causal. Esta extensión constituye la dirección que motivó inicialmente el presente trabajo.

Capítulo 4

Scikit-NeuroMSI: Un Framework para Modelado de Integración Multisensorial

El desarrollo de modelos computacionales de integración multisensorial ha sido tradicionalmente fragmentado, con diferentes grupos de investigación implementando sus propios modelos en diversos lenguajes y frameworks, dificultando la comparación sistemática y la reproducibilidad. Este capítulo presenta Scikit-NeuroMSI, el framework de código abierto en Python¹ desarrollado por Paredes et al., que proporciona la infraestructura técnica sobre la cual se desarrolla el presente trabajo.

4.1. Motivación y objetivos del framework

La integración multisensorial es un proceso neuronal fundamental que ha sido estudiado desde múltiples niveles de análisis, generando una diversidad de modelos teóricos. Sin embargo, hasta el desarrollo de Scikit-NeuroMSI, no existía un marco consolidado que facilitara la implementación, comparación y validación de estos modelos en contextos experimentales diversos (Paredes et al., 2025).

Los objetivos principales del framework son:

- Proporcionar una **infraestructura común** para implementar modelos de integración multisensorial a diferentes niveles de descripción, desde modelos probabilísticos de alto nivel hasta redes neuronales biológicamente inspiradas.
- Facilitar la **comparación sistemática** entre modelos mediante interfaces estandarizadas para simulación y evaluación.

¹<https://www.python.org/>

- Promover la **reproducibilidad** de resultados computacionales en la comunidad de investigación en neurociencia computacional.
- Servir como **plataforma educativa** para la enseñanza de conceptos de integración multisensorial y modelado neurocomputacional.

4.2. Arquitectura de software

Scikit-NeuroMSI está diseñado siguiendo principios de ingeniería de software que facilitan la extensibilidad y comparación entre modelos. La arquitectura se fundamenta en patrones de diseño establecidos que permiten agregar nuevos modelos sin modificar el código existente.

4.2.1. Principios de diseño

El framework implementa el **Principio de Inversión de Dependencias** (Dependency Inversion Principle (DIP)), donde los módulos de alto nivel no dependen de módulos de bajo nivel, sino que ambos dependen de abstracciones. Esto se logra mediante la definición de interfaces abstractas que especifican qué operaciones debe soportar cualquier modelo, independientemente de su implementación interna.

Adicionalmente, el framework utiliza el **Patrón Estrategia** (*Strategy Pattern*), que permite encapsular diferentes algoritmos de integración sensorial como objetos intercambiables. Un usuario puede, por ejemplo, comparar las predicciones de un modelo bayesiano con las de una red neuronal simplemente intercambiando el objeto modelo, sin modificar el código de simulación o análisis.

4.2.2. Sistema de aliasing de parámetros

Una característica distintiva del framework es el sistema de **aliasing de parámetros**, implementado mediante la clase `ParameterAliasTemplate`. Este sistema permite que los modelos definan nombres genéricos internos para sus parámetros (como `mode0_position`, `mode1_position`), mientras que los usuarios pueden interactuar con nombres más intuitivos y específicos del dominio (como `auditory_position`, `visual_position`).

El aliasing se configura en tiempo de instanciación del modelo. Por ejemplo, al crear un modelo con `mode0=".auditory"` y `mode1="visual"`, el sistema automáticamente genera los alias correspondientes, permitiendo que el método `run()` acepte parámetros como `auditory_position` en lugar del genérico `mode0_position`. Esta abstracción facilita la legibilidad del código de usuario sin sacrificar la generalidad interna del framework.

4.2.3. Clases principales

La arquitectura central se compone de varias clases principales que definen la estructura del framework:

SKNMSIMethodABC (*Scikit-NeuroMSI Method Abstract Base Class*) es una clase base abstracta que define la interfaz estándar para todos los modelos de

4.2. ARQUITECTURA DE SOFTWARE

integración sensorial. Cualquier modelo que herede de esta clase puede ser procesado uniformemente por las herramientas del framework, independientemente de si es un modelo bayesiano, una red neuronal, o un estimador de máxima verosimilitud. Los métodos abstractos que todo modelo debe implementar incluyen la inicialización con parámetros específicos, la ejecución de una simulación dado un conjunto de estímulos, configuración de aliasing, y la extracción de resultados en formato estandarizado.

NDResult (*N-Dimensional Result*) es el objeto responsable de almacenar la información multidimensional de los estímulos y las respuestas del modelo. Esta estructura maneja datos con exactamente cuatro dimensiones predefinidas: **modes** (modalidades sensoriales como visual, auditiva, multisensorial), **times** (evolución temporal de las respuestas), **positions** (posiciones espaciales de los estímulos), y **positions_coordinates** (coordenadas múltiples para cada posición, útil en espacios multidimensionales). NDResult proporciona además herramientas integradas para el análisis de resultados mediante *accessors* al estilo de pandas: **result.plot** para visualización y **result.stats** para estadísticas descriptivas. Incluyendo exportación a formatos estándar mediante el método **to.ndr()**.

NDResultCollection permite agregar múltiples objetos NDResult, facilitando el análisis de barridos de parámetros o comparaciones entre modelos. Esta clase implementa operaciones de filtrado, agrupamiento y reducción sobre colecciones de resultados, y extiende las funcionalidades con análisis específicos del área como sesgo cross-modal e inferencia causal. Similar a NDResult, ofrece la capacidad de exportar los datos a formato NetCDF comprimido con metadatos en un formato denominado **.ndc**.

ParameterSweep es una herramienta para realizar barridos sistemáticos de parámetros sobre cualquier modelo. Dado un modelo y un conjunto de rangos para sus parámetros, ParameterSweep ejecuta automáticamente simulaciones para todas las combinaciones especificadas, almacenando los resultados en una NDResultCollection para análisis posterior.




Figura 4.1: Diagrama de clases reducido de Scikit-NeuroMSI. Las flechas vacías representan la herencia, la flecha con punta de diamante indica que varios objetos NDResult se agregan en una única NDResultCollection, y todas las demás relaciones tienen etiquetas explicativas.

4.2.4. Backend de datos

El almacenamiento y manipulación de datos multidimensionales se implementa mediante **XArray**², una biblioteca de Python diseñada específicamente para trabajar con arreglos etiquetados de N dimensiones. Esta extiende las capacidades de NumPy agregando nombres y coordenadas a cada dimensión, lo que facilita la selección, agregación y visualización de datos complejos.

Para la persistencia de datos, el framework utiliza un formato basado en archivos ZIP que combina Network Common Data Form (NetCDF) para los datos multidimensionales con JSON para los metadatos. Los resultados de simulaciones se guardan en archivos con extensión **.ndr** (*NDResult*) o **.ndc** (*NDResultCollection*). Internamente, cada archivo ZIP contiene: **metadata.json** con información del modelo, parámetros de ejecución, versión del framework, plataforma y timestamp; y **ndata.nc** con los datos xarray en formato NetCDF. Esta estructura permite que los resultados sean cargados y analizados posteriormente, compartidos entre investigadores, o procesados con herramientas externas compatibles con NetCDF.

4.3. Modelos implementados

El framework incluye implementaciones de referencia de varios modelos establecidos en la literatura de integración multisensorial. Estas implementaciones sirven tanto como herramientas de investigación como ejemplos para desarrolladores que deseen agregar nuevos modelos.

El **integrador bimodal óptimo** implementa la combinación de señales mediante máxima verosimilitud según la Ecuación 2.6. Este modelo asume que ambas señales sensoriales provienen de la misma fuente y las combina ponderando por sus confiabilidades relativas (inversas de las varianzas).

La implementación permite especificar las varianzas de las señales visual y auditiva, ya sea como valores fijos o como funciones de la posición espacial (capturando, por ejemplo, la menor precisión auditiva en la periferia). El modelo proporciona una línea base teórica contra la cual comparar modelos más complejos.

El modelo de **inferencia causal bayesiana** implementa el marco de Körding et al. (2007) para inferir la estructura causal subyacente a las señales multisensoriales. A diferencia del integrador MLE, este modelo no asume automáticamente que las señales provienen de la misma fuente, sino que computa la probabilidad posterior de causa común versus causas separadas.

La implementación incluye el cálculo de la probabilidad de causa común, el promediado bayesiano sobre estructuras causales Bayesian Model Averaging (BMA), y la generación de respuestas de sesgo de localización y juicio de unidad. Los parámetros ajustables incluyen la probabilidad prior de causa común y las varianzas sensoriales.

El **modelo de red de Cuppini** proporciona una implementación completa de la arquitectura de tres capas descrita en la Sección 3.1. Esta implementación permite simular la dinámica temporal del modelo, variando parámetros como

²<https://docs.xarray.dev/en/stable/>

4.4. IMPLEMENTACIÓN TÉCNICA

los pesos de conexiones cross-modales, la amplitud de las conexiones laterales tipo sombrero mexicano, y las constantes de tiempo de las diferentes capas.

La implementación soporta la presentación de estímulos audiovisuales con disparidades espaciales y temporales configurables, y extrae predicciones sobre el efecto ventrílocuo (sesgo de localización auditiva) y la inferencia causal (número de picos en la capa multisensorial).

El modelo de **red de inferencia causal espacio-temporal** extiende la red de Cuppini para incorporar disparidades temporales además de espaciales. Permite estudiar la ventana de integración temporal, es decir, el rango de asincronías audiovisuales dentro del cual los estímulos se perciben como provenientes de una fuente común.

La implementación incluye filtros temporales diferenciados para las modalidades visual y auditiva, capturando las diferentes latencias de procesamiento. Esto permite simular fenómenos como la ilusión del flash inducido por sonido (*sound-induced flash illusion*), donde un único flash acompañado de múltiples sonidos se percibe como múltiples flashes.

4.4. Implementación técnica

Esta sección describe aspectos técnicos de la implementación relevantes para desarrolladores que deseen extender el framework o comprender su funcionamiento interno.

4.4.1. Gestión de dependencias

Scikit-NeuroMSI está implementado en Python 3 y depende de bibliotecas estándar del ecosistema científico: NumPy para operaciones numéricas, SciPy para algoritmos científicos, XArray para datos multidimensionales, Matplotlib y Seaborn para visualización, pandas para manipulación de datos tabulares, joblib para paralelización, y tqdm para barras de progreso. Para los modelos neuronales con dinámica temporal, el framework utiliza **BrainPy**³ como backend de integración numérica, que opcionalmente soporta aceleración mediante JAX⁴ para cómputo en GPU.

El framework se distribuye a través de PyPI (*Python Package Index*), permitiendo instalación mediante `pip install scikit-neuromsi`. Las dependencias se gestionan automáticamente durante la instalación.

4.4.2. Ejecución paralela

Para barridos de parámetros extensos, el framework soporta ejecución paralela mediante el módulo `multiprocessing` de Python. El usuario puede especificar el número de procesos a utilizar, y el framework distribuye automáticamente las simulaciones entre ellos.

Para modelos implementados con JAX, la paralelización puede extenderse a GPUs mediante `jax.pmap`, permitiendo ejecutar múltiples simulaciones simultáneamente en dispositivos de alto rendimiento.

³<https://brainpy.readthedocs.io/>

⁴<https://docs.jax.dev/>

4.4.3. Gestión de memoria

Los modelos de redes neuronales con dinámica temporal pueden generar grandes volúmenes de datos (actividad de cientos de neuronas durante miles de pasos temporales en múltiples trials). El framework implementa estrategias para manejar estos casos: almacenamiento incremental a disco durante simulaciones largas, compresión de datos mediante algoritmos estándar de NetCDF, y opciones para almacenar solo estadísticas resumidas en lugar de trayectorias completas.

4.5. Aplicaciones

En el artículo que presenta el framework, Paredes et al. (2025) demuestran su utilidad mediante varios análisis representativos.

4.5.1. Paradigma del efecto ventrílocuo

El efecto ventrílocuo, introducido en la Sección 2.4.4, constituye el paradigma principal para validar modelos de integración audiovisual. El framework permite simular experimentos típicos donde estímulos visual y auditivo se presentan con diferentes disparidades espaciales, midiendo el sesgo resultante en la localización auditiva percibida.

Un ejemplo típico de uso del framework para simular el efecto ventrílocuo es:

```
>>> from skneuromsi.neural import Cuppini2017
>>> from skneuromsi import ParameterSweep
>>> import numpy as np

# Crear modelo con modalidades específicas
>>> model = Cuppini2017(mode0="auditory", mode1="visual")

# Configurar barrido de disparidades
>>> disparities = np.arange(-24, 25, 6)
>>> sweep = ParameterSweep(
    model=model,
    target="visual_position",
    range=45 + disparities
)

# Ejecutar simulaciones
>>> results = sweep.run(auditory_position=45)

# Visualizar resultados
>>> results.cplot.unity_report()
```

Ejemplo del uso de Scikit-NeuroMSI para simular el efecto ventrílocuo. Se crea un modelo Cuppini2017 con modalidades auditiva y visual, se configura un barrido de disparidades espaciales, y se visualizan los resultados mediante el accessor de colección.

Los autores comparan las predicciones de modelos bayesianos y de redes neuronales, encontrando que ambos reproducen cualitativamente el patrón experimental de sesgo decreciente con la disparidad, pero con diferencias cuantitativas que podrían distinguirse experimentalmente.

4.5.2. Ilusión del flash inducido por sonido

Esta ilusión, donde un único flash visual acompañado de múltiples sonidos se percibe como múltiples flashes, demuestra que la integración multisensorial puede alterar la percepción incluso de modalidades típicamente dominantes como la visión. El modelo de red de inferencia causal espacio-temporal, desarrollado por el grupo de investigación de los autores del framework, fue construido específicamente para dar cuenta de este fenómeno (Paredes et al., 2025).

4.5.3. Aplicaciones clínicas

Los autores señalan que una aplicación prometedora del framework es el estudio de diferencias en integración multisensorial asociadas a condiciones psiquiátricas y neurológicas. Estudios han documentado alteraciones en la integración audiovisual en trastornos del espectro autista (TEA), esquizofrenia, y demencias. El framework permitiría formalizar hipótesis sobre qué parámetros de los modelos podrían estar alterados en estas condiciones, y generar predicciones cuantitativas testables experimentalmente.

4.6. Contexto en el ecosistema de herramientas

Scikit-NeuroMSI ocupa un nicho específico en el ecosistema de herramientas para neurociencia computacional. A diferencia de simuladores de redes neuronales de propósito general como **Brian**⁵ o **NEST**⁶, que se enfocan en la simulación detallada de neuronas de disparo, Scikit-NeuroMSI está diseñado específicamente para modelos de integración multisensorial, proporcionando abstracciones y herramientas optimizadas para este dominio.

Comparado con frameworks de modelado cognitivo como **HDDM**⁷ (para modelos de difusión de decisiones) o **TAPAS**⁸ (para modelos computacionales en psiquiatría), Scikit-NeuroMSI se especializa en la dimensión sensorial del procesamiento, permitiendo una descripción más detallada de cómo señales de múltiples modalidades se combinan antes de informar decisiones.

Frameworks de redes neuronales recurrentes como **PyRates**⁹ o **BrainPy**¹⁰ comparten el enfoque en dinámicas de poblaciones neuronales, pero no incluyen las abstracciones específicas para estímulos multisensoriales, inferencia causal, o métricas de integración que Scikit-NeuroMSI proporciona.

⁵<https://briansimulator.org/>

⁶<https://ebrains.eu/data-tools-services/tools/nest>

⁷<https://hddm.readthedocs.io/>

⁸<https://www.translationalneuromodeling.org/tapas>

⁹<https://pyrates.readthedocs.io/>

¹⁰<https://brainpy.readthedocs.io/>

4.7. Direcciones futuras y contribuciones de la comunidad

El desarrollo de Scikit-NeuroMSI continúa activamente, con varias direcciones planificadas para versiones futuras.

4.7.1. Mejoras arquitectónicas

Una mejora planificada es la separación más clara entre la representación de estímulos y los integradores que los procesan. Actualmente, algunos modelos asumen formatos específicos de estímulo, lo que limita la flexibilidad. Una arquitectura de “estímulo-integrador” más modular permitiría combinar diferentes tipos de estímulos con diferentes modelos de manera más flexible.

Otra dirección es el soporte mejorado para modelos jerárquicos, donde la salida de un modelo alimenta la entrada de otro. Esto permitiría construir arquitecturas complejas combinando componentes más simples.

4.7.2. Nuevos modelos

El framework está diseñado para que la comunidad contribuya nuevas implementaciones de modelos. Dando lugar al presente trabajo que contribuye en esta dirección mediante la implementación del modelo de Echeveste, que introduce al framework el primer modelo con dinámicas corticales realistas basadas en muestreo estocástico. Esta implementación establece patrones para que futuros contribuidores puedan seguir para agregando modelos similares.

4.7.3. Información del proyecto

Scikit-NeuroMSI se distribuye bajo licencia BSD 3-Clause, permitiendo uso libre tanto académico como comercial. El código fuente está disponible en GitHub¹¹, donde se aceptan contribuciones mediante pull requests. La documentación completa, incluyendo tutoriales y referencia de API, está disponible en Read the Docs¹².

4.8. Relevancia para el presente trabajo

Scikit-NeuroMSI proporciona la infraestructura técnica fundamental sobre la cual se desarrolla la implementación del modelo de Echeveste presentada en esta tesis. Específicamente:

La implementación existente del modelo de Cuppini sirve como **punto de referencia** para entender cómo modelos de redes neuronales se integran en el framework, y como objetivo eventual para futuras extensiones que combinen ambos enfoques.

La arquitectura modular del framework permite **integrar** el modelo de Echeveste de manera que pueda ser comparado directamente con modelos existentes usando las mismas herramientas de análisis.

¹¹<https://github.com/renatoparedes/scikit-neuromsi>

¹²<https://scikit-neuromsi.readthedocs.io>

Las abstracciones de NDResult y XArray proporcionan una **estructura natural** para almacenar las trayectorias temporales de potenciales de membrana que el modelo de Echeveste genera, con soporte para múltiples trials, condiciones de estímulo, y poblaciones neuronales.

Las herramientas de visualización y análisis existentes pueden **extenderse** para las necesidades específicas del modelo de Echeveste, como análisis espectral para detectar oscilaciones gamma o comparación de momentos de respuesta con momentos objetivo.

Finalmente, al contribuir la implementación del modelo de Echeveste al framework, este trabajo la hace **disponible para la comunidad científica**, maximizando su impacto y reproducibilidad, y estableciendo las bases para que otros investigadores construyan sobre este trabajo hacia modelos de integración multisensorial con dinámicas corticales realistas.

Capítulo 5

Implementación

Completar: IMPLEMENTACION

Capítulo 6

Resultados

Completar: RESULTADOS

Capítulo 7

Conclusiones y trabajo a futuro

Completar: CONCLUSIONES

Bibliografía

- Alais, D. and Burr, D. (2004). The ventriloquist effect results from near-optimal bimodal integration. *Current biology*, 14(3):257–262.
- Bishop, C. M. and Nasrabadi, N. M. (2006). *Pattern recognition and machine learning*, volume 4. Springer.
- Blanco, C. (2014). *Historia de la neurociencia*. Biblioteca nueva Madrid.
- Cuppini, C., Shams, L., Magosso, E., and Ursino, M. (2017). A biologically inspired neurocomputational model for audiovisual integration and causal inference. *European Journal of Neuroscience*, 46(9):2481–2498.
- Dale, H. (1935). Pharmacology and nerve-endings.
- Dayan, P. and Abbott, L. F. (2005). *Theoretical neuroscience: computational and mathematical modeling of neural systems*. MIT press.
- Echeveste, R., Aitchison, L., Hennequin, G., and Lengyel, M. (2020). Cortical-like dynamics in recurrent circuits optimized for sampling-based probabilistic inference. *Nature neuroscience*, 23(9):1138–1149.
- Eliasmith, C. and Anderson, C. H. (2003). *Neural engineering: Computation, representation, and dynamics in neurobiological systems*. MIT press.
- Gerstner, W. and Kistler, W. M. (2002). *Spiking neuron models: Single neurons, populations, plasticity*. Cambridge university press.
- Heaton, J. (2018). Ian goodfellow, yoshua bengio, and aaron courville: Deep learning: The mit press, 2016, 800 pp, isbn: 0262035618. *Genetic programming and evolvable machines*, 19(1):305–307.
- Hodgkin, A. L. and Huxley, A. F. (1952). A quantitative description of membrane current and its application to conduction and excitation in nerve. *The Journal of physiology*, 117(4):500.
- Hubel, D. H. and Wiesel, T. N. (1959). Receptive fields of single neurones in the cat’s striate cortex. *The Journal of Physiology*, 148(3):574–591.
- Körding, K. P., Beierholm, U., Ma, W. J., Quartz, S., Tenenbaum, J. B., and Shams, L. (2007). Causal inference in multisensory perception. *PLoS one*, 2(9):e943.
- Marr, D. (2010). *Vision: A computational investigation into the human representation and processing of visual information*. MIT press.

BIBLIOGRAFÍA

- Mitchell, T. M. (1997). *Machine Learning*. McGraw-Hill, New York.
- Murphy, K. P. (2012). *Machine learning: a probabilistic perspective*. MIT press.
- Nobel Prize Committee (2024). The Nobel Prize in Physics 2024. <https://www.nobelprize.org/prizes/physics/2024/summary/>. Accessed: 2025.
- Paredes, R., Cabral, J. B., and Seriès, P. (2025). Scikit-neuromsi: A generalized framework for modeling multisensory integration. *Neuroinformatics*, 23(3):40.
- Rumelhart, D. E., Hinton, G. E., and Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323(6088):533–536.
- Stein, B. E. (2012). *The new handbook of multisensory processing*. Mit Press.
- Willis, T. (1664). *Cerebri anatome*, volume 1. Apud Gerbrandum Schagen.
- Yamins, D. L., Hong, H., Cadieu, C. F., Solomon, E. A., Seibert, D., and DiCarlo, J. J. (2014). Performance-optimized hierarchical models predict neural responses in higher visual cortex. *Proceedings of the national academy of sciences*, 111(23):8619–8624.